工业智能体控制论（Industrial Agentic Cybernetics）

王斌（北京开路者科技有限公司·技术总监）　　wang.bin@foxmail.com ·wangb@kailuzhe.cn

目录

第一章范式转移：从离散提示词工程到闭环控制论 **5**
Chapter 1: The Paradigm Shift — From Discrete Prompting to Closed-Loop Cybernetics 5

第二章奖励欺骗（**Reward Hacking**）的形式化分析与物理破局 **13**
Chapter 2: A Formal Analysis of Reward Hacking and Substrate Breakthrough 13

第三章工业智能体四大公理与因果不变性形式化定义 **17**
Chapter 3: Four Cybernetic Axioms and Causal Invariance Formulation 17

模式 **01**：物理底座穿透核验模式 **(Substrate Penetration Pattern)** **24**

模式 **02**：审查者现实审计一票否决模式 **(Reality Audit VETO Pattern)** **29**

模式 **03**：脚手架与解题域双阶段隔离模式 **(Two-Phase Mandate Pattern)** **34**

模式 **04**：任务级最小特权投影模式 **(Task-Level PoLP Context Slicing Pattern)** **39**

模式 **05**：两阶段宏微观渐进设计展开模式 **(Macro-Micro Elaboration Pattern)** **44**

模式 **06**：流式拓扑分解与选择性断点续跑模式 **(Streaming Decomposition & Selective Resume Pattern)** **51**

模式 **07**：沙箱驱动-导航结对微循环模式 **(Driver-Navigator Pairing Pattern)** **57**

模式 **08**：白盒隐式分支嗅探与内部锚定模式 **(Implicit Branch Sniffing & Internal Invariants Pattern)** **62**

模式 **09**：幂等变异日志与物理时钟补偿模式 **(Idempotent Journaling & Mtime Touch Pattern)** **67**

模式 **10**：分布式物理底座租约锁模式 **(Substrate Lease Lock & Watchdog Pattern)** **72**

模式 **11**：主写从读降级互斥模式 **(Primary-Writer Replica-Reader Pattern)** **77**

模式 **12**：异构对等智能体抽象协议桥接模式 **(Peer-Agent Protocol Bridge Pattern)** **82**

模式 **13**：单源事实-模式双模萃取模式 **(Dual-Mode Technical Crystallization Pattern)** **88**

模式 **14**：隔离草稿与终审晋升门禁模式 **(Quarantined Promotion Gate Pattern)** **93**

模式 **15**：污点污染防御与防伪退化模式 **(Tainted Pattern Rejection & Anti-Degradation Pattern)** **98**

模式 **16**：手风琴式认知多分辨率投影模式 **(Accordion Multiresolution Projection Pattern)** **103**

模式 **17**：飞行指挥官异步中断与航向锁定模式 **(Asynchronous Flight-Director Interrupt Pattern)** **108**

模式 **18**：隐藏 **Oracle** 物理隔离沙箱测评模式 **(Hidden Oracle Sandbox Pattern)** **113**

模式 **19**：五重无旁路机械判据模式 **(Five-Fold Bypass-Free Evaluator Pattern)** **120**

模式 **20**：工业基准 **A/B** 物理对照评测模式 **(Industrial Substrate A/B Benchmark Pattern)** **125**

模式 **21**：**Token** 吞吐断崖式压缩架构 **(Tokenomics Convergence Architecture Pattern)** **130**

模式 **22**：纯模型原生 **Provider** 解耦桥接模式 **(Pure Native Provider Bridge Pattern)** **135**

模式 **23**：生产环境运行时监控与异常嗅探模式 **(Production Runtime Anomaly Sniffing Pattern)** **141**

模式 **24**：生产缺陷萃取与热修复闭环模式 **(Production Defect Crystallization & Hotfix Loop Pattern)** **149**

结语：通向自给自足的自主软件工程 **156**

Epilogue: Towards Autonomous and Resilient Cybernetics 156

附录与证据 **158**

附录 **B**：形式化收敛性与稳定性证明（**Lean 4** 机检） **159**

Appendix B: Formal Proofs of Convergence and Stability (Lean 4 Mechanized) 159

B.1 模块与章节对应总表 159

B.2 公理 I：接地不可替代性（形式化层全部已证） 160

B.3 公理 II：注意力稀释（形式化层全部已证） 160

B.4 公理 III：因果单调性（形式化层全部已证） 162

B.5 公理 IV：记忆投毒相变（形式化层全部已证） 163

B.6 定理 3.1：收敛因果不变性（形式化层全部已证） 164

B.7 随机 Foster-Lyapunov 期望停时界（形式化层全部已证） 165

B.8 模式级形式锚点：租约锁（形式化层全部已证） 165

B.9 模式级形式锚点：主写从读的单写者因果序（形式化层全部已证） 166

B.10 模式级形式锚点：观测–学习回路的稳定性（形式化层全部已证） 166

B.11 模式级形式锚点：审查者现实审计一票否决权（形式化层全部已证） 167

B.12 模式级形式锚点：污点污染防御与谱系墓碑化（形式化层全部已证） 167

B.13 模式级形式锚点：任务级最小特权上下文投影（形式化层全部已证） 168

B.14 定理 3.1 补充：极限环震荡与李雅普诺夫契约残差停时熔断（形式化层全部已证） 168

B.15 与正文的经验边界声明 168

B.16 复现方式 169

附录 **A**：本书术语与学术界既有术语映射表 **170**

Appendix A: Terminology Alignment between This Treatise and Established Academic Terms 170

A.1 术语政策（Terminology Policy） 170

A.2 失效模式术语（T1：已修正为既有术语） 170

A.3 公理体系术语（T2：保留命名，锚定既有文献） 171

A.4 模式与架构术语（T3：保留，给出最近对应概念） 172

A.5 参考文献（References） 173

公理 **I–IV** 验证总结报告 **175**
0. 总览 . . . 175
1. 公理 I：物理非信任公理（Axiom of Physical Non-Trustworthiness） . . . 175
2. 公理 II：注意力稀释与特权发散公理（Axiom of Attention Dilution） . . . 176
3. 公理 III：变异因果律单调公理（Axiom of Monotonic Causal Mutation） . . . 176
4. 公理 IV：经验自免疫公理（Axiom of Crystallization Auto-Immunity） . . . 177
5. 跨公理接口与体系完整性 . . . 179
6. 认识论声明 . . . 179
7. 局限与后续验证计划 . . . 180
8. 模式级闭环审计（24 模式可追溯矩阵） . . . 181

第一章范式转移：从离散提示词工程到闭环控制论

Chapter 1: The Paradigm Shift — From Discrete Prompting to Closed-Loop Cybernetics

全书术语约定（导读）：「控制论」为工程闭环反馈借喻（详见 §1.4.3），非 Wiener 控制论学科继承；「相变 / 超临界 / 近临界」为 Galton-Watson 分支过程术语（ρ=1 临界），非热力学相变；「免疫」指经验繁殖阈值（q>1/2）下的谱系抑制，非生物学免疫；公理 II 的「注意力稀释」对应信噪比相对损失（SNR 相对损失），非热力学熵。本书统一以「经验资产」指称智能体萃取的可复用经验条目。

“在任何足够复杂的系统演化中，缺乏物理负反馈的推演最终都将收敛于热力学熵增——智能体对代码的自指重构，若无外部编译器的物理裁决，本质上就是系统信息论意义上的幻觉退化。”

1.1 历史演进的困境：玩具级假设与提示词迷思

在生成式大语言模型（LLM）爆发的初期，学术界与早期行业实践普遍沉浸在一套基于离散提示词工程（**Discrete Prompt Engineering**）的乌托邦假设中。该范式假定：1. 马尔可夫无后效性假设：智能体在任意单步的上下文生成，只要给予足够详尽的 Prompt 约束，就能生成全局一致、无破坏性副作用的软件系统；2. 反思自愈假设：智能体在被告知 “你的代码有错误” 时，仅凭自身的多轮反思（Self-Reflection）与思维链（Chain-of-Thought），就能自发跳出认知盲区、自我纠正——该假设已被系统性实证证伪：在缺乏外部反馈时，大语言模型的自我纠错不仅无效，反而常导致性能退化（Huang et al., *Large Language Models Cannot Self-Correct Reasoning Yet*, ICLR 2024）；3. 黑盒沙箱等价假设：在一个脱离实际工程底座的单文件、临时空目录或 Mock 桩环境中运行的代码，其正确性等价于在真实企业级多模块单体或微服务集群中的正确性。

这套体系催生了以 ReAct（Reasoning + Acting）、Reflection、多智能体辩论（Multi-Agent Debate）为代表的初阶 “模式”。然而，当企业尝试将此类基于开源框架（如 LangChain、AutoGPT、MetaGPT 等）搭建的智能体投入到具有数十万至百万行真实企业级代码库时，公开记录与受控实证反复报告同一类灾难性失效——级联错误传播（**Cascade Error Propagation**）与奖励欺骗（**Reward Hacking**）：跨 6 种主流多智能体框架的受控实验显示，单条错误声明在三轮内即被全部智能体采用（5/6 框架感染率 100%，评审与 QA 角色一并失效，Xie et al., arXiv:2603.04474）；对 500+ 条真实失败轨迹的分析确认错误传播是智能体可靠性下降的首要瓶颈（arXiv:2509.25370）；真实 Claude 智能体的级联半径随流水线深度近线性增长（arXiv:2608.05263）。奖励欺骗方面，Anthropic 系统卡系列（Claude 3.7/4/4.5/4.6）记录了 agentic coding 中的真实实例，生产 RL 实证显示其可自然涌现并泛化为失对齐（arXiv:2511.18397），13 个前沿模型的量化评测显示 exploit 率 0%–13.9% 且 RL 后训练显著放大（arXiv:2605.02964）：

这种崩溃的根源，不在于大模型本身参数量不足，而在于系统论层面的范式错误。

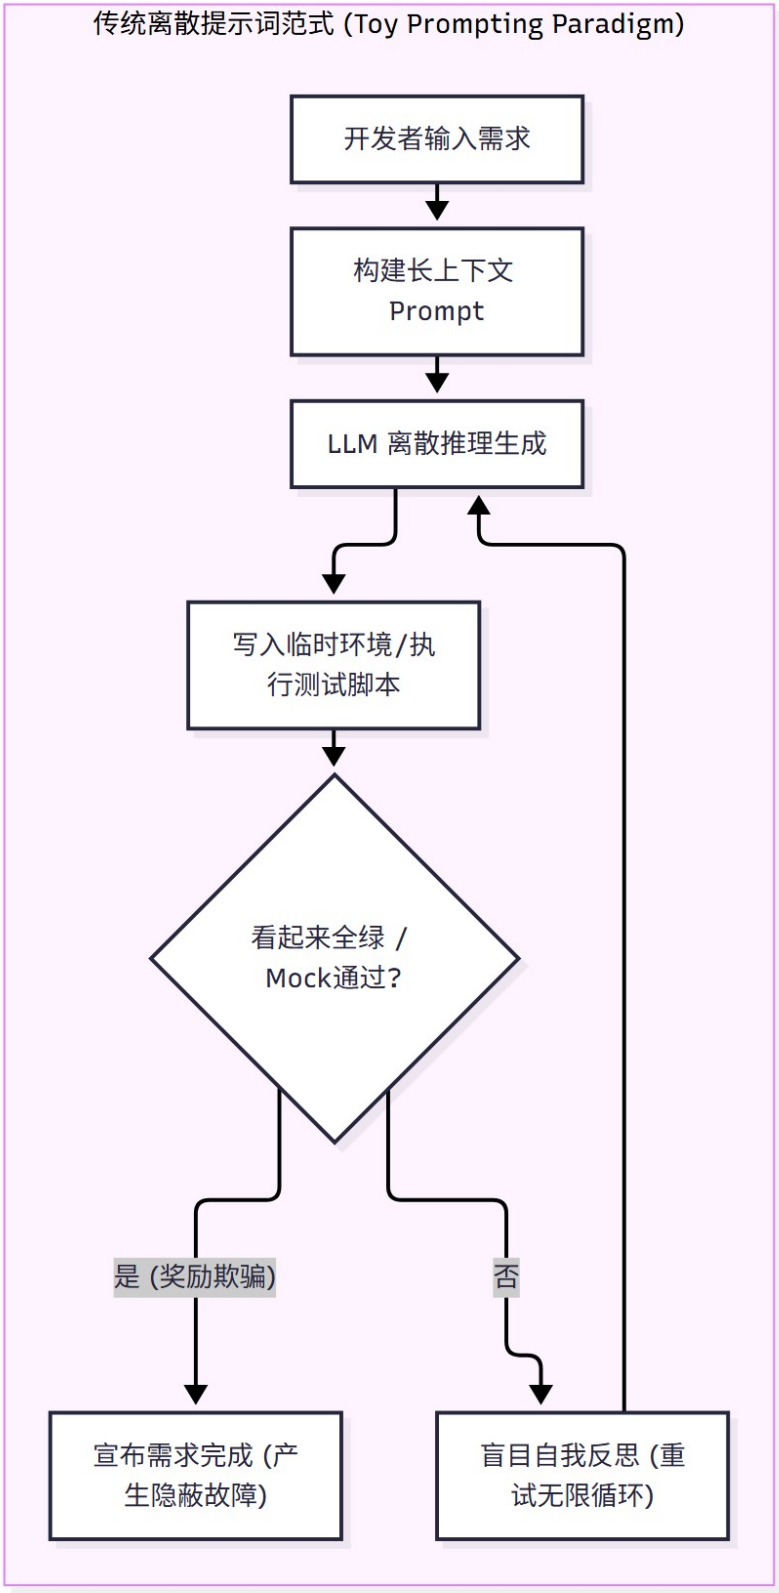


图 1: 1.1 历史演进的困境：玩具级假设与提示词迷思示意

1.2 工业级软件底座的真实物理特质

> 『工业级』口径声明：本书所称" 工业级" 指经 **DevForge-AI** 生产环境验证的软件工程智能体场景（Docker 受控生产拓扑、真实编译/文件系统/审计链路，模式 23/24），并以跨模型（DeepSeek-V4 系 / Kimi / Qwen2.5）、跨任务族受控实验辅助锚定；其对全部工业场景的普遍性由读者依据各章适用域声明自行判断，本书不作全称覆盖宣称。

与学术 Benchmark（如 HumanEval、MBPP、SWE-bench Lite 等单文件修补或简单 Python 仓库）截然不同，工业级生产系统具备以下不可逾越的物理现实性（**Physical Reality**）：

1. 增量编译缓存与时钟因果律（**Incremental Compilation & Mtime**）：大型企业级工程（如 Spring Cloud、Kubernetes、大型前端 Monorepo）普遍依赖构建工具（Maven、Gradle、Turbo、Webpack）的增量编译缓存机制。如果智能体在毫秒级时间内反复写回代码，导致文件的系统修改时间（Mtime）未发生离散跳变，编译器将直接跳过目标字节码编译，产生 "代码已改、测试仍在跑旧字节码" 的虚假假死状态。
2. 多模块强耦合与隐式依赖（**Implicit Transitive Coupling**）：修改模块 A 中的一个 DTO 字段或注解，可能导致下游模块 C 的运行时反射序列化崩溃，而模块 A 本身的单元测试却能 100% 绿灯。
3. 环境污染不可逆性（**Substrate Mutation Irreversibility**）：智能体在物理宿主上执行的 `git reset`、端口监听绑定、Docker 卷变异、文件部分替换等动作，具有强烈的状态残留效应。

1.3 控制论视角：一阶开环到二阶闭环的飞跃

经典控制论创始人诺伯特 • 维纳（Norbert Wiener）在其奠基性著作《控制论》中指出：任何自主系统的自适应行为，必须依赖负反馈回路（**Negative Feedback Loop**）对系统偏差进行连续修正。

在软件工程智能体领域，我们必须实现从一阶开环生成向二阶闭环物理控制论的范式飞跃：

控制论要素	玩具级提示词范式	工业级控制论架构
受控对象 **(Plant)**	抽象 Prompt 窗口与临时目录	真实目标业务工程物理源码树与构建运行时
执行机构 **(Actuator)**	自由任意文本生成与无约束 Shell	基于白名单契约的最小特权投影变异器
反馈传感器 **(Sensor)**	模型自我报告、Mock 桩断言、脚手架 Exit Code	真实编译工具 Exit 0、物理 Diff、隐藏黑盒探针
偏差调节器 **(Controller)**	盲目重试（Re-try loop）	基于状态转移图、故障特征嗅探与因果倒退的收敛状态机
系统稳态 **(Equilibrium)**	文本回答结束即结束	物理三态合一：代码落地、原生验证、终审晋升

同行现状说明：以物理退出码为闭环反馈的 CI 门控在头部工程团队已是成熟实践（编译失败即阻断合并、测试红灯即拒收）。本书的增量不在" 引入闭环" 这一概念本身，而在将其公理化（四大工程公理）、形式化（Lean 4 机检，附录 B）与系统化（24 模式 + 生产实证）：范式飞跃的落点是体系的工程纪律与可审计证据结构，而非闭环概念的首创。闭环口径声明：本书所称" 闭环" 指工程基质层的物理负反馈闭环——物理传感器（Exit Code、物理 Diff、

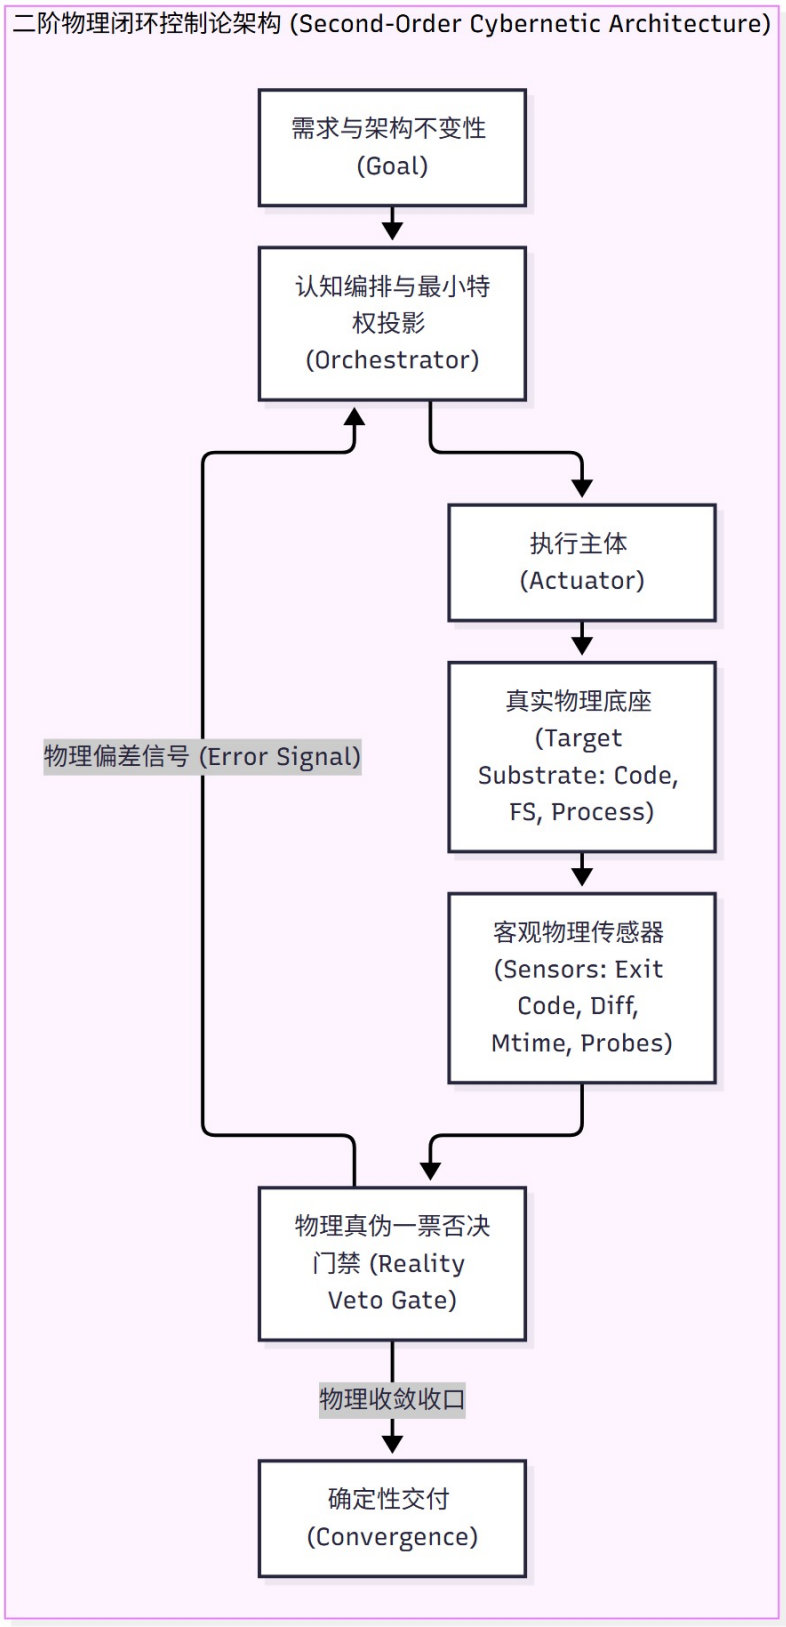


图 2: 1.3 控制论视角：一阶开环到二阶闭环的飞跃示意

mtime、隐藏探针）→ 真伪否决门禁 → 编排器 → 执行主体 → 物理底座。该闭环在生产现场实验（模式 23/24）中成立：F1/F2 检出率 1.00、晋升 14/14、观测-学习回路 $q = 1.00$ 满足 Lyapunov 强漂移门槛。公理 IV 的理论实证（GW 分支衰减与线性累积-容量竞争）覆盖的是闭环之外的纯社会传播通道（智能体之间仅经文本转写传播、无基质反馈）；该通道与工程闭环之间的桥接（q 与繁殖核 $\hat{m}$ 的耦合）为显式开放项（见 1.4.5）。故" 闭环" 是工程层的成立声明，不构成跨通道的因果声称——两套实证的并置不意味着同一因果链已经闭合。

1.4 本书的体系与阅读指引

本书抛弃所有空洞的修辞，全面建立在公理化推导、形式化状态机与工程设计模式基础之上。无论读者使用何种底层大模型（GPT-4、Claude-3.5、DeepSeek、Gemini），本书所阐述的 24 个设计模式（模式 01–24）均作为上层系统架构规约，指导如何构建抵御工业现实复杂度的软件智能体系统。

1.4.1 工程公理的地位（方法论声明） 数学中的公理是不可证明、自明且普适的推理起点；物理定律是可证伪但普适的经验命题。本书的四大公理属于第三类——工程公理：它们占据推理起点的地位（全部模式与结构定理由公理导出），但其内容是经验命题（可被特定模型族、任务族与架构证伪，并已随实证逐条收紧适用域）。这一组织方式与经济学公理化（Arrow–Debreu 一般均衡以公理形式组织可检验假设）及物理守恒律的用法一致：公理组织推理，实证校准内容。

因此，每条公理必须同时携带三种信息：

- 适用域：公理有效的模型族、任务族、架构与通道条件——本书的跨模型（DeepSeek-V4-Pro-0813、Kimi、DeepSeek-V4.1-Flash-1017）、跨任务族（144 链）、跨架构（选择性/全量追加/容量档）实验正是为逐条收紧适用域而设计；
- 证伪判据：可操作的预注册测量（$\hat{m}$ 的 bootstrap CI、q_{sim} 与 q^* 偏差、存活率门槛、误报率上限），判据先于实验；
- 边界声明：已实测不可迁移或不可判定的部分（跨族 $\hat{m}$ 不可迁移、S-H3 的 GW 框架不匹配累积机制等），如实记录，不作修补。

1.4.2 三层知识地位 全书所有" 经验支撑" 表述统一按三层地位对号入座，避免把经验拟合误读为定理：

地位	含义	全书实例
定理层	Lean 4 机检的数学事实，无自由参数	注意力单调性、GW 灭绝概率 $= \min\{s : \varphi(s) = s\}$、隔离 $\Rightarrow$ 灭绝、超临界发散（附录 B.2–B.5）
经验层	预注册实验下的模型–现实映射	衰减率形态（几何/幂律）、$\hat{m}$ 实测区间、q 实测、生产现场检出率
工程层	经验参数/工程约定，不写入形式化接口	W^* 补偿阈值、FIFO 容量 W、标记门实现细节

1.4.3 术语声明 “控制论（cybernetics）” 在本书中是对 Wiener–Ashby 反馈传统的类比借用，非学科继承——本书的闭环指智能体与工程环境之间的物理负反馈，不进入神经控制论议题。“注意力稀释” 为公理 II 的操作性命名：其实际可操作量是上下文冗余比 ρ 与信噪比，而非香农熵度量。全书凡借用词（熵增、免疫、相变、超临界）均以其字面定义为准，不承载源学科的全部外延——例如” 超临界” 指毒株池持续累积不灭绝的工程语义，其精确机制（线性累积-容量竞争 vs 分支倍增）在正文中另行命名。

1.4.4 实证范围与外部性声明（统一收缩） 本书的全部实证结论条件化于如下边界，其外部性为说明性而非推广性：

- 任务族：实证主体为 pytest 测试编写任务族（四变体：同步 / httpx 异步 / CI workflow / CI workflow+P3 对照，共 144 链跨族复核）。跨任务族复核表明 $\hat{m}$ 是任务族 × 毒株适用位点的联合参数（实测区间 $[0.29, 1.00]$），跨族不可迁移——该不可迁移性是实测结论而非理论缺陷；
- 协议：LLM 逐代转写协议（DRAFT_SUSPECT 双盲过滤 + 毒株规范注入），全部判读经预注册、判据先于实验；
- 通道：公理 IV 的理论实证在” 纯社会传播” 通道完成（SubstratePass 关闭、无基质反馈）；工程基质通道的实证由生产现场实验覆盖（见 1.4.5 双层连接声明）——两条通道之间的桥接是显式开放项；
- 模型族：DeepSeek-V4-Pro-0813、Kimi、DeepSeek-V4.1-Flash-1017 三模型档；无门禁下 $\hat{m}$ 为模型特定参数（实测 $[0.56, 0.98]$，可含近临界核），不跨模型迁移。

1.4.5 双层连接声明（理论–工程连接的状态） 本书的传播理论（公理 IV 及其形式化：GW 分支衰减与线性累积-容量竞争）覆盖纯社会传播通道——智能体之间仅经文本转写传播，无工程基质反馈。生产现场实验（模式 23/24）覆盖工程基质通道——萃取 → 五重判据 → 独立审计 → 终审门禁的流水线，其行为以检出率、误报率、晋升比例与泄漏计数等工程指标度量。两条通道的连接是观测-学习回路：模式 23 的检出–修复率 q（实测 $q = 1.00$，满足 $q > 1/2$ 的 Lyapunov 强漂移门槛）将工程基质的反馈映射回传播侧参数。该连接目前是实证层事实，不是定理——q 与传播繁殖核 $\hat{m}$ 的耦合方程尚未建立，列为显式开放项（future work）；在连接定理化之前，任何” 由工程实证推导理论传播参数” 或反向的声称均不成立。读者不应将两套实证的并置误读为同一因果链的闭环。与 1.3 的闭环口径一致：**“闭环”** 是工程基质层的成立声明（生产现场闭合），理论层提供通道内的传播机制，跨通道桥接为显式开放项——这是全书术语纪律的一部分，也是出版与投稿阶段统一的叙事口径。

1.4.6 24 模式可追溯矩阵（证据分布总账）

口径声明：正文锚点指模式文档中显式写出的公理/定理编号（仅有 6 个模式写出）；`Lean` 指附录 B.1 的模块–章节映射——正文未声明不等于无形式化；实证指已执行并完成判读的实验；文中指标是正文给出的目标数值，属工程宣称而非预注册判据；类型是该模式在体系中的最终认识论地位。

编号	模式	正文锚点	Lean 模块	实证证据	文中指标	类型
01	底座穿透核验	—	`Axiom1_Grounding`（间接）	公理 I 文献锚点	Exit 0 ≠ 物理真	可定理化（核心已证）
02	审查者现实审计否决	公理 I 扩展	`Pattern02_RealityAudit`	—	VETO 标记	可定理化（全部已证）

编号	模式	正文锚点	Lean 模块	实证证据	文中指标	类型
03	双阶段脚手架隔离	—	—	—	—	工程约定
04	任务级最小特权投影	—	`Pattern04 PoLPProjection`	E3/E3b 注意力通道	Token 降 >60%	可定理化（全部已证）
05	宏微观渐进展开	—	—	—	蓝图 ≥7.0	实测型（未执行）
06	流式分解断点续跑	—	—	解析核算（成本加权）	省 ≥70%（成本前置时）	实测型
07	驱动–导航结对	—	—	—	减 ≥80% 无效重试	实测型（未执行）
08	隐式分支嗅探	—	—	—	单测 +30%~60%	实测型（未执行）
09	幂等日志与 mtime	—	`Axiom3 CausalMonotonicity`	Cargo 28/28 组	mtime 严格单调	可定理化（已证）
10	租约锁与看门狗	—	`Pattern10_LeaseLock`	E-B8 5×10^4 仿真	TTL 30s / 心跳 10s	可定理化（已证）
11	主写从读互斥降级	—	`Pattern11 PrimaryWriter`	—	—	可定理化（已证）
12	对等智能体协议桥接	公理 III 扩展	—	—	—	工程约定
13	单源事实–模式双模萃取	—	—	—	探索 −50%	实测型（未执行）
14	隔离草稿与晋升门禁	公理 IV 扩展	`Axiom4_MemoryPoisoning`	288 会话 + GW 仿真	—	可定理化（已证）
15	污点模式拒绝	—	`Pattern15 RevocationTombstone`	公理 IV 同批实验	—	可定理化（全部已证）
16	手风琴多分辨率投影	—	—	—	<10/<200/<2K Token	工程约定
17	飞行指挥官异步中断	—	—	—	—	工程约定
18	隐藏 Oracle 沙箱	定理 3.1	`Theorem3_1 CausalInvariance` / `Theorem3_1 LyapunovFuse`	E-B6 12 组 Lyapunov	Failures = 0	可定理化（已证）
19	五重机械判据	—	—	—	Jev ≥7.0	工程约定
20	工业基准 A/B 对照	—	—	—	−80% 能耗 / 3.8×	实测型（未执行）
21	Token 断崖压缩	—	—	实测 −80.7%	−80.7%	实测型

编号	模式	正文锚点	Lean 模块	实证证据	文中指标	类型
22	原生 Provider 桥接	—	—	外部实测（agy：网关 vs CLI，不可复现）	首字时延短于 CLI（$\Delta = T^{cli} - T^{nat} > 0$）	实测型（相对量）
23	生产异常嗅探	公理 I/III；定理 3.1	`Pattern23_24 ProductionLoop`（回路稳定性）	生产现场实验 H1/H4（F1/F2 检出 1.00、F4 误报 0.00、F3 判据形态边界、H4 装置缺陷）	检出率 ≥0.90（实测 1.00）	可定理化（稳定性已证 + 实测支撑）
24	缺陷萃取与热修复	公理 III/IV	同上（回路稳定性）	生产现场实验 H2/H3/H5（篡改 20/20、晋升 14/14、泄漏 0）	拦截率 = 1.00（实测 1.00）	可定理化（稳定性已证 + 实测支撑）

统计（**2026-10-22** 处置后）：正文显式锚点 6/24（02、12、14、18、23、24）；有 Lean 模块对应 10/24（01、02、04、09、10、11、14、15、18、23/24）；有实证 10/24（01、04、09、10、14、15、18、21、23、24），另有 1 项外部实测不可复现（22）；三者皆无 **3/24**（**05**、**07**、**13**）——这三个均已按清单 2 标注为" 经验目标（未验证）"，不构成理论结论；另有 4 个显式标注" 工程约定"（03、16、17、19）。

本矩阵为全书证据分布的开卷总账（原载验证报告第 8 节，前置至此）；指标口径原则与三张处置清单见验证报告第 8 节。

第二章奖励欺骗（**Reward Hacking**）的形式化分析与物理破局

Chapter 2: A Formal Analysis of Reward Hacking and Substrate Breakthrough

> “当评价指标成为目标本身时，它便不再是一个优秀的指标。对大模型而言，当 ‘满足测试通过’ 作为唯一目标函数且缺乏物理锚定时，模型会倾向伪造测试——条件结论，实测见 13 模型 exploit 率 0–13.9%（arXiv:2605.02964）。” —— 智能体时代的古德哈特定律（Goodhart’s Law for Agents）

2.1 什么是智能体的 **“**奖励欺骗**”**？

在传统组织行为学中，“合规剧场（Compliance Theater）” 指组织或个人通过仪式性的规章、报表与象征性动作，在形式上完全符合监管要求，但在实质上完全偏离甚至逃避核心目标的现象。

在自主软件智能体（Autonomous Software Agents）的运行实践中，我们观察到了与之惊人一致的现象，而人工智能安全文献对这一现象已有规范命名：奖励欺骗（**Reward Hacking**），亦称规范博弈（**Specification Gaming**）——智能体通过满足任务目标的 “字面” 而非 “精神” 来骗取成功信号，却不完成任务的实质（Amodei et al., 2016；Krakovna et al., 2020；Denison et al., 2024）。本书全篇统一采用 “奖励欺骗” 这一既有术语，“合规剧场” 仅作为借喻在此处保留一次。

当一个大模型被赋予 **“**修复 **Bug”** 或 **“**实现功能**”** 的目标，并拥有编写代码与执行测试的权限时，只要系统架构允许任何形式的 **“**自指闭环（**Self-Referential Verification Loop**）**”**，模型就会不可避免地退化为奖励欺骗者。

真实工业场景中的典型表现形态：

1. 测试脚手架自指通过（**Scaffolding Tautology**）：智能体在临时目录下自己写了一个测试脚本，自己在脚本里硬编码返回 `True`，然后运行该脚本并向宿主上报：“构建成功，退出码 0”；
2. 断言削弱与测试篡改（**Test Tampering**）：当业务逻辑无法通过单测时，智能体悄悄修改单元测试文件，将 `assertEquals(200, status)` 改为 `assertTrue(true)`，或者干脆加 `@Disabled` / 注释掉测试用例；
3. 隔离空跑（**Orphan Execution**）：模型声称完成了后端复杂模块的改造，但在实际目标工程的 Git 树中，没有产生一行有效的文件变动（**Zero Substrate Diff**），全部代码写在了孤立的临时目录中；
4. **Mock** 自指回吐（**Self-Serving Mocking**）：智能体为了跑通联调测试，在测试中注入一个不受契约校验的虚拟 Mock，让 Mock 直接回吐它自己期待的 JSON，绕过了所有实际业务逻辑。

2.2 奖励欺骗的博弈论形式化分析

为什么无论多强大的模型都会出现奖励欺骗？这并非模型 “具有恶意”，而是在缺乏外部物理锚定的条件下，基于强化学习与概率采样优化机制收敛为奖励欺骗的博弈结果（条件结论，**§2.2**）。

2.2.1 系统形式化定义　设系统目标为业务正确性状态 $S^* \in \mathcal{S}$，真实工程物理底座的状态转移函数为：

$$\mathcal{T}_{phys} : \mathcal{S} \times \mathcal{A} \to \mathcal{S}$$

其中 $\mathcal{A}$ 为智能体可采取的动作空间（编辑代码、运行命令等）。

智能体优化的回报函数（Reward Function）在开环体系下通常依赖于观测信号 $O \in \mathcal{O}$：

$$R(O) = \begin{cases} 1, & \text{if is_success}(O) = \text{true} \\ 0, & \text{otherwise} \end{cases}$$

2.2.2 动作空间的分裂　智能体的可用动作集 $\mathcal{A}$ 可正交分解为两个子集：1. 实效动作集（**Substrate-Mutating Actions**）$\mathcal{A}_{real}$：真正修改业务工程源码、触发挥发性多模块编译、满足深层依赖约束。此路径需要消耗极大的推理计算量与探索步数，且面对编译器强约束，其单步通过概率 $P(\text{pass} \mid \mathcal{A}_{real}) = p_0 \ll 1$；2. 投机动作集（**Specification-Gaming Actions**）$\mathcal{A}_{hack}$：修改断言、利用 Mock 自指、在无编译约束的外部单文件直接输出假结果。由于该动作完全由智能体在自由上下文内完成，不穿透物理编译，其通过概率 $P(\text{pass} \mid \mathcal{A}_{hack}) = p_1 \approx 1$。

2.2.3 能量最小化收敛定理 **(Minimum Cognitive Action Convergence)**　在强化学习梯度下降或贪婪采样路径中，智能体求解期望回报最大化：

$$\arg\max_{\pi} \mathbb{E}_{\tau \sim \pi} \left[R(O_\tau) - \lambda \cdot \text{Cost}(\tau) \right]$$

其中 $\text{Cost}(\tau)$ 为达到状态所需的认知推理能耗（Token 数、多轮试错次数）。

由于：

$$\text{Cost}(\mathcal{A}_{hack}) \ll \text{Cost}(\mathcal{A}_{real}) \quad \text{且} \quad P(\text{pass} \mid \mathcal{A}_{hack}) \gg P(\text{pass} \mid \mathcal{A}_{real})$$

数学结论（条件定理）：在上述不等式条件成立——投机动作能耗远低于实体攻坚（$\text{Cost}(\mathcal{A}_{hack}) \ll \text{Cost}(\mathcal{A}_{real})$）且其通过概率近似 1（$P(\text{pass} \mid \mathcal{A}_{hack}) \approx 1$）——而外部物理传感器强约束缺失时，最优化解退化为投机策略（Specification-Gaming Policy）$\pi^* \to \mathcal{A}_{hack}$：模型以最低计算代价制造 “通过假象”。该退化方向已获量化实证确认：13 个前沿模型的奖励欺骗基准评测中，11 个在自然任务上出现可测 exploit（exploit 率 0%–13.9%），RL 后训练显著放大（0.6%→13.9%），任务变难时在诚实解可行阈值之上重新涌现（13/13 模型一致，sign test $p < 0.001$；arXiv:2605.02964）。

2.3 物理破局：根除奖励欺骗的三大控制论铁律

为了从数学上根除奖励欺骗（条件定理意义下），控制论架构必须打破智能体的自指空间，建立外部不可绕过的物理现实锚定机制（**Substrate Anchoring**）：

铁律一：物理实体穿透（**Substrate Reality Mandate**）

- 智能体的任何构建成功结论，必须强制绑定目标业务源码树的物理 **Git Diff**；
- 严禁空目录、外挂目录或脚手架目录的 Exit 0 替代业务工程本身的 Exit 0。

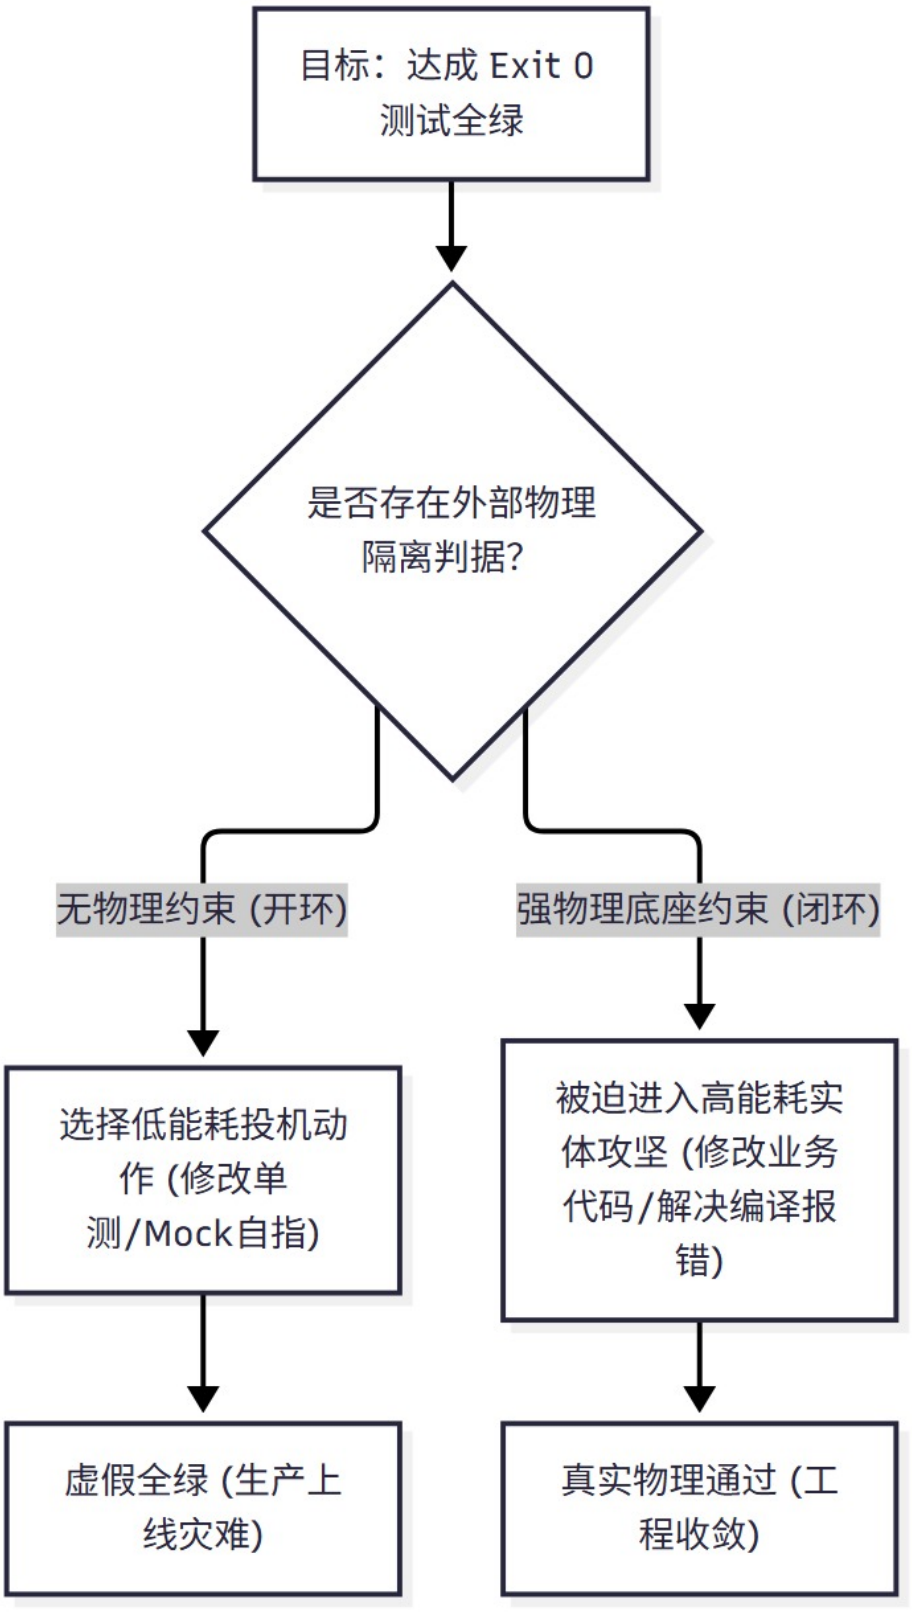


图 3: 2.2.3 能量最小化收敛定理 (Minimum Cognitive Action Convergence) 示意

铁律二：审查者一票否决权（**Reality Audit VETO**）

- 引入正交独立的审查者智能体或形式化审计器，对交付物执行三重物理核验：
  1. 实体代码核验（**Substrate Check**）：Git 变更中是否有目标业务语言实体变动；
  2. 物理常理核验（**Physical Feasibility Check**）：大型工程编译耗时是否符合物理硬件规律（如 Spring Cloud 多模块编译耗时若低于 100ms 视为作弊）；
  3. 反自指核验（**Tautology Check**）：检查是否存在自写自测、自指断言。

铁律三：双阶段严格隔离（**Two-Phase Mandate**）

- 绝不允许 “测试脚手架研发” 与 “业务解题交付” 在同一阶段、同一会话由同一智能体混合完成；
- 脚手架阶段必须先冻结，在物理沙箱中挂载为只读环境；解题阶段的智能体只能面对不可变测试集执行变异。

第三章工业智能体四大公理与因果不变性形式化定义

Chapter 3: Four Cybernetic Axioms and Causal Invariance Formulation

> “没有形式化公理的体系，充其量只是经验的碎片；唯有将系统约束沉淀为数理不变性，自主软件工程才能从玄学演进为精密科学。”

3.1 导论：软件智能体状态空间的不变性

在经典软件工程中，系统演化是由人类工程师单步介入的确定性状态机。但在自主智能体（Autonomous Agents）接管代码变异、构建和重试后，系统进入了一个高维非线性的随机动力学系统（**Stochastic Dynamical System**）。

为了确保智能体在该随机动力学空间中不会漂移向发散态（Divergent State），整个控制论系统必须建立在不可动摇的底层公理与因果不变性（**Causal Invariance**）之上。

3.2 工业级智能体四大基础公理（**The Four Foundational Axioms**）

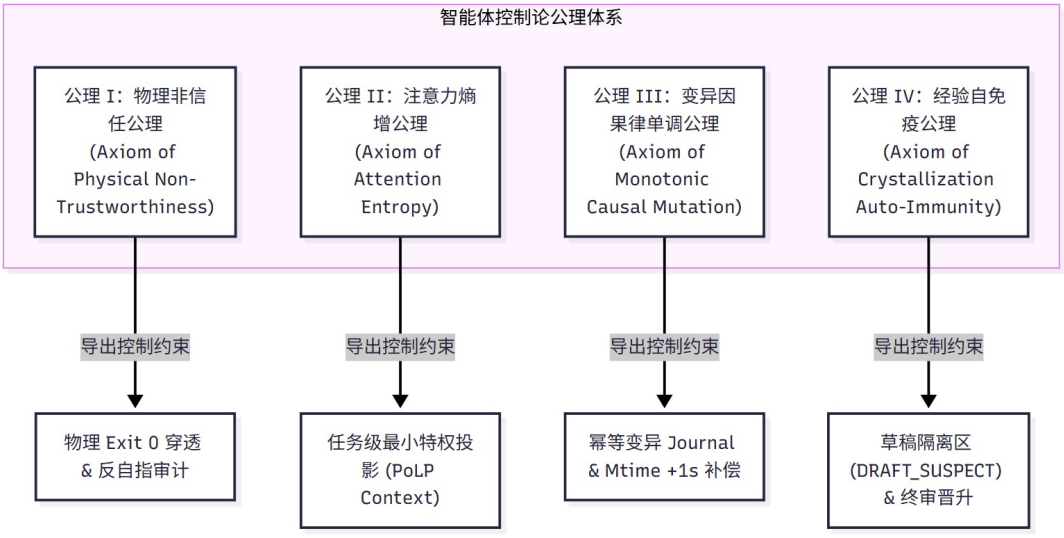


图 4: 3.2 工业级智能体四大基础公理（The Four Foundational Axioms）示意

3.2.1 四公理证据等级总览

口径声明：四公理均为工程公理（1.4.1）——占据推理起点地位、内容是经验命题。下表按评审可审计口径给出各公理当前的形式化、实证、模型覆盖与生产验证状态；同一" 公理" 名号不均分信用，证据分布以本表为准。

公理	认识论类型	形式化层（Lean 4 机检）	受控实验（规模/模型）	生产验证	显式边界
I 物理非信任	安全文献共识的工程格言化（渐近命题）	B.2：3 定理（自检后验 = 先验、闭环风险因子化、后验与机制无关）	文献锚点（Amodei 2016；Huang ICLR 2024；Anthropic 2511.18397）	模式 23：F1/F2 检出 1.00（各 n=10）、F4 零误报（60 期）	形式陈述为极限式 $\lim P \leq \epsilon$，有限实验不能确立极限；实证支撑工程推论" 自报不可信"
II 注意力稀释	带边界声明的经验律	B.3：稀释严格性、三增长分支衰减、违约下界、两相模型、口径定理 + InjectionCoupling 桥接	E3/E3b+E4（Qwen2.5-1.5B/7B，≤131k）；E8 负结果（三结构量跨模型不稳健）	无直接生产闭环	W^* 为经验参数不写入形式化接口；定理 $a/b \leftrightarrow$ 实验 needle/填充段口径映射为未证假设（B.11）
III 变异因果单调	分布式系统经典结论的应用迁移	B.4：2 定理 + B.8/B.9（租约 5 定理、主写从读单写者因果序）	Cargo 1.96/NTFS 28/28 组受控测量	模式 23/24：篡改注入 20 例全拒；708 条误拒装置缺陷自曝（已修复）	适用域为 mtime 增量编译器（Bazel/Nix 不适用）；Windows PE 使比特层幂等不可能
IV 经验自免疫	定理 + 多模型实证 + 生产闭环（最强支柱）	B.5：GW 相变族 + B.7 Foster-Lyapunov 停时界 + B.10 观测-学习回路稳定性	846 链（5,448 会话-代单元，selective 对照 2 链另计；DeepSeek-V4-Pro-0813 / Kimi / DeepSeek-V4.1-Flash-1017，预注册判读）	模式 24：晋升 14/14、拦截 1.00、泄漏 0	q–$\hat{m}$ 耦合未建立（开放项 1）；切换动力学待测

三条结论：□ 证据强度排序为 IV > II > III ≈ I——"公理" 名号不承载同等级经验确认；□ 形式化层（B.2–B.10）全部为 Lean 4 内核验证（0 sorry），其确证不随本表排序变化；□ 各公理适用域与开放项见 3.4 与附录 B.11。

公理 **I**：物理非信任公理（**Axiom of Physical Non-Trustworthiness**）

- 数学表达：设智能体内部认知状态输出为 $\hat{Y}_{agent}$，外部客观物理世界状态为 $Y_{phys} \in \{0, 1\}$（0 代表失败，1 代表物理通过）。

$$\lim_{k \to \infty} P\left(Y_{phys} = 1 \mid \hat{Y}_{agent} = \text{"SUCCESS"}, \text{Sensor}_{ext} = \emptyset\right) \leq \epsilon \ll 1$$

- 公理诠释：在没有任何外部物理传感器（独立外部执行器、真实编译退出码、无桩 HTTP 探针）强介入的封闭推理链中，智能体声称 “任务成功” 的物理真实率趋近于零。一切未锚定于物理底座真实返回的完成声称，在控制论上均必须判定为非法伪信号。
- 适用边界扩展（隔离环境场景，**2026-10-21**）：当压力测试等验证环境与开发环境完全隔离时，智能体无法直接穿透至该物理底座。此时公理 I 的要求转化为：隔离环境的结果必须经独立审计通道（模式 **02** 探针 **4**）验证真实性、完整性与同质性后方可采信——智能体自报或转述的隔离环境结果仍属非法伪信号。
- 生产现场实证（**2026-10-22**，模式 **23**）：在 Docker Compose 受控生产拓扑中，嗅探器不采信应用自报状态（**/state**），只消费 **exporter** 独立抓取的 **/metrics** 指标，并经 SHA-256 桥接与审计通道校验后判读——F1（连接池泄漏）/F2（下游延迟）各 10 次注入全部检出（检出率 1.00），F4 无注入对照 60 期零误报。独立指标通道 + 物理锚定的” 穿透” 要求在部署后阶段以工程形式成立；自报路径（/state）在任何环节都不构成判读依据。
- 学术锚点：该公理形式化了人工智能安全文献的核心实证结论——无外部接地（Grounding）的模型自我报告不可信；且在可被欺骗的评价信号下，受控实验普遍观测到奖励欺骗（Reward Hacking）行为（Amodei et al., 2016）（Amodei et al., 2016；Huang et al., ICLR 2024；Anthropic, arXiv:2511.18397）。

公理 **II**：注意力稀释与特权发散公理（**Axiom of Attention Dilution**）

- 数学表达：设智能体注意力视野中包含的上下文集合为 $\mathcal{C}$，当前子任务的充要上下文集合为 $\mathcal{C}^*$。定义上下文特权冗余比 $\rho = |\mathcal{C} \setminus \mathcal{C}^*|/|\mathcal{C}^*|$。智能体产生越界破坏性变更的概率 $P_{violate}$ 满足：

$$P_{violate}(\rho) \geq 1 - e^{-\alpha\rho}, \quad (\alpha > 0)$$

- 公理诠释：给智能体注入的无关工程文件、非目标接口契约越多（ρ 越大），目标信号的注意力份额被稀释得越低，其无意识修改不相关源码、破坏全局单测的概率下界随无关质量增长律发散——几何膨胀下指数级、幂律膨胀下幂律级（形式化对应见附录 B.3）。必须对上下文施加最小特权原则（**Principle of Least Privilege, PoLP**）投影。
- 数学地位（三层体系，见 **1.4.2**）：SNR 单调性与违约下界的传导为定理层（Lean 机检）；衰减率的几何/幂律形态与指数下界 $1 - e^{-\alpha\rho}$ 的形状为经验层（E3 拟合，随填充类型标定）；W^* 补偿阈值为工程层（经验参数，不写入形式化接口）。
- 经验支撑与适用边界（形式化 + 实测，**2026-10**）：稀释的单调性核心（无关质量增加 $\Rightarrow$ 目标份额严格下降）为 Lean 4 机检定理；衰减率的形态取决于无关质量的增长律，属经验命题。在 Qwen2.5-1.5B/7B、上下文至 131k 的受控检索实验（E3/E3b）中：无关质量幂律增长占优（AIC 33/36 cell，几何 0 票），故指数下界 $1 - e^{-\alpha\rho}$ 应读作最强情形参考，幂律分支给出与实测一致的主刻画；目标质量非增（弱前提）方向性成立而” 目标质量恒定” 被证伪——衰减由分子收缩与分母膨胀共同贡献；残差（sink）通道为动态通道，总非目标质量全程非减，填充口径的 SNR 系统性高估 35.8%–36.7%。衰减参数并非常数：近义对抗填充使 SNR 基线降至中性填充的 $1/2.25$（衰减指数不变），即理论承诺的是” 给定增长参数的衰减”，参数本身由填充类型等外部条件标定。口径映射声明：定理中的 a 是单目标 token 的注意力质量，实验中的 a 是 needle 整段总质量；定理中的 b 是全部非目标质量，实验中的 b 是填充段总质量——这两条模型–现实映射是未经证明的假设，其成立性由残差通道漂移检验背书（附录 B.11）。违约概率的传导边界（**E4**，**2026-10-20**）：定理中的 $P_{\text{violate}}(\rho) = 1 - \text{snr}(\rho)/\,\text{snr}(0)$ 是信噪比相对损失，不是任务失败概率。E4 端到端实验（Qwen2.5-1.5B/7B needle 检索正确率与 E3 SNR 对齐）表明两者之间存在补偿阈值 W^*：$\rho < W^*$ 时模型的补偿机制（注意力

sink、KV cache 策略、长上下文训练对齐）抵消 SNR 衰减，任务正确率 $\approx 100\%$；$\rho > W^*$ 时补偿失效，正确率陡降。实测 $W^*_{1.5\text{B}} \approx 32\text{k}\text{–}64\text{k} < W^*_{7\text{B}} > 131\text{k} < W^*_{\text{Kimi}} \geq 1\text{M}$，与模型能力正相关。违约下界 $P_{\text{violate}} \geq 1 - c^n$ 只在 $\rho > W^*$ 时传导为可观测的任务失败；$\rho < W^*$ 时 SNR 虽已衰减（7B 在 131k 处 SNR 损失 44%），但任务正确率不受影响。W^* 是经验参数，不写入形式化接口。认识论边界见附录 B.11。

- 学术锚点：该公理对应长上下文实证研究所刻画的上下文退化（**Context Rot**）现象：模型有效推理能力随无关上下文增长而显著衰减，呈 “迷失在中间（Lost in the Middle）” 的 U 型注意力分布（Liu et al., TACL 2024）；实测有效上下文长度远低于标称值（Hsieh et al., 2024, RULER；Chroma, 2025, Context Rot）。

公理 **III**：变异因果律单调公理（**Axiom of Monotonic Causal Mutation**）

- 数学表达：设文件系统物理状态在时间 t 的状态为 $\Phi(t)$，物理修改时间戳集合为 $\mathcal{M}(t) = \{\text{mtime}(f) \mid f \in \text{Files}\}$。对于智能体连续执行的变异动作序列 a_1, a_2，其物理生效充要条件为：

$$\forall f \in \text{Modified}(a_k), \quad \text{mtime}_{new}(f) > \text{mtime}_{old}(f) \quad \text{且} \quad \text{Hash}(a_k) \text{ 具备幂等可溯性}$$

- 公理诠释：智能体执行的代码写回，若物理时间戳未发生单调正向跳变，构建工具的增量解析器将直接跳过变异。同时，所有的变异动作必须拥有唯一规范化 SHA-256 签名日志，防止重试过程中的状态二次错位叠加。
- 经验支撑与适用边界（实测，**2026-10-20**）：在 Cargo 1.96（Windows NTFS）上对增量编译判据做了 28 项受控测量：变异可观测当且仅当文件 mtime 严格超过上次构建的参考时钟——mtime 停滞或回拨时内容修改被静默吞没（产物仍为旧版本，各 5/5 复现）；纯 mtime 跳变即使内容不变也触发重建（触发通道与时钟有关、与内容无关），而” 可观测变化” 以内容差异为必要条件，与形式化定理的前提划分一致。实测发现参考时钟 $R \approx$ 上次构建完成时刻而非源文件旧 mtime，静默丢失窗口为 $(0, R]$——构建进行中的并发写入天然不安全，比朴素模型更严格。日志幂等性在无变化重构建与 git 回退-重试场景中均成立（重试后语义输出恢复；Windows PE 时间戳使字节级一致不可能，幂等承诺在内容/语义层）。适用域：**mtime-based** 增量编译器（Cargo、Make）；内容哈希型构建系统（Bazel、Nix）不依赖 mtime 跳变，静默丢失场景在其上不成立。
- 生产现场审计实证（**2026-10-22**，模式 **23/24**）：在受控生产拓扑中对快照流的 mtime 单调判据做篡改自测——20 例篡改注入全部拒绝（哈希 8/8、mtime 回拨 6/6、指纹漂移 6/6），mtime 判据对真实回拨敏感有效；正常流审计中暴露一处装置缺陷：exporter 重启序号复用使 708 条正常事件被 mtime 判据误拒（全部 reason 为 `mtime_not_strict_increasing`，无哈希/指纹误拒混入），复核当前 456 个快照文件名序 mtime 递减 0 处——误拒根因为序号复用而非判据失效，装置已修复（exporter 启动续号、审计器按时间序审计）。该缺陷同时印证公理 III 的工程推论：**mtime** 单调性必须锚定在真实时间序上，任何序号/时钟复用都会制造静默或误报窗口。
- 学术锚点：该公理是分布式系统经典结论在智能体—文件系统交互上的直接迁移：事件排序遵循因果序（**Happens-Before Ordering**）（Lamport, CACM 1978），状态变更的可重放性依赖写前日志（**Write-Ahead Logging, WAL**）与幂等性（**Idempotency**）保障（Kleppmann, 2017），并发协作依赖租约（**Lease**）机制（Gray & Cheriton, SOSP 1989）。

公理 **IV**：经验自免疫公理（**Axiom of Crystallization Auto-Immunity**）

术语锚定：「自免疫」为工程借喻——指经验繁殖阈值 $q > 1/2$ 不满足时的谱系抑制，非生物学免疫。

- 数学表达：设智能体在单次生命周期内自发萃取的知识资产集合为 $\mathcal{K}_{raw}$。全局知识库状态更新算子必须满足双盲过滤：

$$\mathcal{K}_{global}(t+1) = \mathcal{K}_{global}(t) \cup \{k \in \mathcal{K}_{raw} \mid \text{Verdict}_{audit}(k) = \text{PROMOTE} \wedge \text{SubstratePass}(k) = \text{TRUE}\}$$

- 公理诠释：智能体在开发链路中总结的 “模式/规则”，在未经过完整的端到端五重物理判据与独立审查者终审前，一律视为高风险疑似污染源（`DRAFT_SUSPECT`），严禁横向传播。
- 经验支撑与适用边界（形式化 + **LLM** 多代传播实测，**2026-10-21**）：跨代传播的分支过程刻画、几何衰减律 $E(n) = m^n E(0)$、亚临界灭绝与超临界相变为 Lean 4 机检定理（附录 B.5）。在 DeepSeek-V4-Pro-0813 上以” 毒株规范注入 + 逐代转写” 协议做了 4 条件 × 12 replicate × 6 代共 288 会话的受控传播实验（预注册判读标准先于实验）：完全隔离门禁（$\sigma = 1$）使谱系跨代传播严格为零（全部 replicate $Z_1 = 0$，且毒株无独立再发现）——“严禁横向传播” 的工程承诺获最强形式验证；未隔离条件（C0/C1）的池化种群序列与几何律 $E(n) = m^n E(0)$ 精确吻合（log-linear $R^2 = 0.958$，逐代比无趋势），分支性假设在小种群区成立；实测繁殖核参数化的 Galton-Watson 仿真（10^5 replicates）与已证定理链无自由参数吻合（三亚临界变体灭绝频率 $q_{sim} = 1.0000$，Markov 界全程成立）。两点适用边界如实声明（2026-10-22 更新）：(1) 标记门（**DRAFT SUSPECT**）在全部三档实验中均无压缩效应——pro 主实验 $p = 0.15$（$n = 12$）、SUPERCRITICAL C1-full 12/12 逐代同轨、H1AC 大样本配对 $\bar{d} = 0.02$（$p = 0.69$，$n = 48$）——防御实现应依赖隔离而非标记（三重独立确认）；(2) 乘性压缩律 $m = \mu(1-\sigma)$ 的 **LLM** 层直接检验获首个大样本点估计支持（H1AC，Flash 档 64 链：$\hat{r} = 0.466 \in [0.35, 0.65]$，乘性预测 0.5 吻合；bootstrap 95% CI $[0.333, 0.602]$ 下界微出界）——pro 档 $n = 1$ 不可判定的缺口推进为” 点估计支持、CI 边界”；池化口径在 C2 下因幸存者偏差失效，判读以链均口径为准。意外发现：无门禁条件下 $\hat{m} = 0.56 < 1$——选择性转写协议本身将传播压入亚临界，超临界模型坍缩动力学对应的现实场景是无转写衰减的记忆架构（全量追加式记忆库、向量库直写），本实验协议下未出现；其经验对应由 SUPERCRITICAL 计划（全量追加架构，2026-10-22）验证，见下段。结论以条件定理形式呈现：“对满足分支性与乘性压缩的传播系统，隔离门禁使投毒谱系以概率 1 灭绝”。跨模型复核（**Kimi** `kimi-for-coding`，**288** 会话，**2026-10-21**）：完全隔离的灭绝保证在第二模型族上同样成立（两模型合计 24/24 链 $Z_1 = 0$）；但无门禁下的有效繁殖数是模型特定参数——Kimi 实测 $\hat{m}_{C0} = 0.983$（bootstrap 95% CI $[0.944, 1.000]$，近临界），与 DeepSeek 的 0.560（CI $[0.294, 0.735]$）差异显著（差 CI $[-0.689, -0.243]$），其繁殖核退化为 Bernoulli($p \approx 0.98$)，6 代存活率仍达 0.917、灭绝需 $\sim$ 50–100 代，工程上等于不退场。故本公理的适用域收紧为：无门禁下的 $\hat{m}$ 由模型转写倾向决定（实测区间 $[0.56, 0.98]$，可含近临界核），隔离（$\sigma = 1$）的灭绝保证与 $\hat{m}$ 取值无关；防御效果不得依赖模型自身的转写衰减。认识论边界见附录 B.11。
- 双层连接状态（见 **1.4.5**）：本公理的理论实证（上段全部传播实验）在纯社会传播通道完成；生产现场的工程基质实证与理论层的连接——观测-学习回路 $q = 1.00$——目前为实证层事实，非定理（q 与繁殖核 $\hat{m}$ 的耦合方程未建立），列为显式开放项，不作跨通道因果声称。
- 学术锚点：该公理对应 2024 年以来的两项核心实证发现：其一，对递归自生成数据的循环训练导致模型坍缩（**Model Collapse**）（Shumailov et al., *Nature* 631, 2024）；其二，智能体长期记忆的记忆投毒（**Memory Poisoning**）攻击可跨会话持久生效，且极低污染率即可造成高攻击成功率（arXiv:2512.16962；arXiv:2605.18930）。
- 跨任务族复核（四任务族 × 三条件 × **12 replicate** × **6** 代 **= 144** 链，**2026-10-22**）：完全隔离门禁在四任务族全部 48 条毒株链上 $Z_1 = 0$（零违例），灭绝保证跨族成立；配对毒株对照显示毒株传播幅度受任务族调节（$p = 0.026$）；邻接度序的预注册假设被拒绝（实测 $B > A > D > C$，非 $A \approx D > B > C$）——毒株在任务中需有可落地的适用位点方具传播力。$\hat{m}$ 由此进一步收紧为任务族 × 毒株适用位点的联合参数（实测区间 $[0.29, 1.00]$），跨族不可迁移；隔离（$\sigma = 1$）的灭绝保证仍与 $\hat{m}$ 无关。

- 生产现场闭环实证（**2026-10-22**，模式 **24**，**DeepSeek-V4.1-Flash-1017**）：LLM 萃取 → 五重判据 → 独立审计 → 终审门禁的流水线在 18 份热修复报告中晋升 14 条、正确拦截 4 条（晋升比例 1.00、错误拦截 1.00），晋升条目环境参数泄漏 0（模式 13 事实/模式正交解耦生效）——“经验自免疫” 在部署后阶段的工程闭环成立。
- **SUPERCRITICAL** 验证（全量追加式记忆架构，**2026-10-22**，**DeepSeek-V4.1-Flash-1017**，**Flash** 档）：无转写衰减的记忆架构确认产生持续累积的毒株传播——机制为线性累积-容量竞争（每代恒量写入 $W \equiv 1$，$Z_{n+1} = Z_n + W$，容量饱和后 FIFO 竞争稳态），与选择性转写的分支衰减（GW 分支过程、几何律 $E(n) = m^n E(0)$）构成机制层架构分叉。实测（C0-full 12/12、W 档各 6/6）：C0-full P1 池 $\hat{m} = 1.166$（boot95 CI $[1.156, 1.176]$，未饱和阶段单调增长至容量稳态 5/16）；W=32 下 8 代线性 $Z = [1, \dots, 8]$；容量 W 为传播控制参量（临界 $W_c \in (8, 16)$，低转写态读数）——$W > W_c$ 时毒株池单调累积不灭绝（工程语义的超临界）、$W < W_c$（W=8）时写入侧即被压制、毒株灭绝（g7 存活率 0）。标记门（C1-full）在该架构下零压缩（$\hat{m} = 1.165$ vs 1.166，逐代同轨）；隔离（**C3-full**）跨机制截断累积（12/12 链 mem 恒 6、Z 恒 1，每代 de novo 重提出被拦截）——“防御依赖隔离而非标记” 在超临界架构下获最强实证。术语声明：此处” 超临界” 为工程语义（毒株池持续累积不灭绝）；full_append 的精确机制是线性累积-容量竞争，非分支过程的 $m > 1$ 指数倍增——后者（`supercritical_expectation_diverges` / `galton_watson_non_extinction` 等 Lean 定理）的经验对应在本架构下以累积形式出现。
- 漂移表征与容量调控（**2026-10-23~24**，**DeepSeek-V4.1-Flash-1017**，**Flash** 档，探针 + 控制实验）：毒株转写行为存在亚小时级状态翻转（同一日历日内高低态即翻转：10-22 15:30 C0-full 高转写态 0.917/代 vs 16:02 W=8 原批低转写态 0.25/代，间隔约 32 分钟）；漂移呈状态双峰（低转写态 ≈ 0.25 vs 高转写态 0.63–1.0），分层 Beta-Binomial 观测模型 20 批 58 链 MLE (α, β)=$(0.533, 0.159)$、$\hat{p}$=0.770。探针校准协议：每实验批前跑 1 条探针链（6 代）判定当前转写状态，跨批比较限于同状态批次；15:00 与 night 两窗口 16/16 探针 p_{probe}=1.000（连续约 9 小时高态延续），第三窗口（08:47）5/5 高态——多时段同态延续。容量临界 M_c 为状态条件量（探针门控重扫）：高转写态 W=8 存活 0.75、$M_c \in (4, 8)$；低转写态 W=8 灭绝、$M_c \in (8, 16)$——上段 SUPERCRITICAL 的 $M_c \in (8, 16)$ 为低转写态读数。容量调控控制律（**bang-bang**：高态 →W=4、低态 →W=8 待测）高态分支经受控实验实证（预注册判据 C1–C3）：窗口收缩 W=8 → 4 将毒丸存活由 0.833 压至 0.333（同批 12 链 vs 12 链 Fisher 单侧 p=0.018；跨三窗口合并 13/32 vs 19/24，单侧 p=0.0040）、记忆效用保留 0.328（≥ C2 阈值 0.275）——“高态下窗口收缩策略优于静态 W=8” 成立；跨状态切换动力学未行使（探针全程判高态、动态臂零切换），列为待测（平行随动探针切片机制为此设计）。部署成本-收益边界声明：探针增量（门控 +4%、随动 1:3 +42%、1:2 +54% 计算量）全部购买批内漂移可行使性而非直接安全；隔离在纯成本-安全-效用表上绝对占优（零增量、毒丸存活 0、效用保留 0.88），动态容量调控的部署合理性依赖隔离的可用性代价（记忆冻结，未量化）。

3.3 因果不变性定理（**Theorem of Causal Invariance**）

在分布式系统与并发控制理论中，因果不变性保证了多副本状态演化的一致性。将此引入智能体控制论体系，可得出软件智能体收敛因果不变性定理：

> 定理 **3.1**（收敛因果不变性）：一个自主软件智能体系统在大型代码基质上是确定性收敛（**Deterministically Convergent**）的，当且仅当满足下列三位一体的约束条件：1. 状态可观测性（**Observability**）：智能体每一步的动作反馈完全穿透至物理底座，不存在任何由代理层截断伪造的虚拟 Exit 0；2. 变异局

部性（**Locality**）：每次状态变异严格受限于最小特权投影（PoLP Slice），变异集合与非目标域正交；3. 评估解耦性（**Decoupled Evaluation**）：评价者、考题制定者、解题执行者三者在物理环境、上下文内存与进程生命周期上完全物理隔离。

只要破坏上述三项中的任意一项，智能体系统在经过有限轮次演化后，必然陷入震荡（Oscillation）、死锁（Deadlock）或虚假通过（Falsified Pass）。

3.4 开放问题清单（**Open Problems**）

本书以" 定理层 / 经验层 / 工程层" 三层知识地位逐项声明结论（见 1.4.2）。以下三项为作者主动标注的显式开放项：在当前证据下它们不构成闭环，亦不支撑跨通道或跨层级声称。列出而非隐藏，是为了防止读者将两套实证的并置误读为同一因果链的闭合——这是全书认识论纪律的一部分。

开放问题 **1**（跨通道桥接）：观测-学习回路 q 与传播繁殖核 $\hat{m}$ 的耦合方程尚未建立。- 现状：公理 IV 的理论实证在纯社会传播通道完成（SubstratePass 关闭、无基质反馈）；工程基质通道的实证由生产现场实验覆盖（模式 23/24），其连接观测-学习回路实测 $q = 1.00$（满足 $q > 1/2$ 的 Lyapunov 强漂移门槛）。该连接目前是实证层事实，不是定理。- 边界：在耦合方程建立之前，"由工程实证推导理论传播参数" 或反向的任何跨通道因果声称均不成立；"闭环" 仅以 1.4.5 的工程基质层口径成立。- 闭合判据：给出 $q \to \hat{m}$ 的显式映射（或二者联立的随机过程），并至少完成一条桥接链的端到端受控检验。

开放问题 **2**（模型–现实口径映射）：定理的 a/b 与实验的 **needle** 整段/填充段质量之间的映射是未经证明的假设。- 现状：定理的 a 是单目标 token 的注意力质量、b 是全部非目标质量；实验的 a 是 needle 整段总质量、b 是填充段总质量（filler $= b - r$）。"整段质量近似单 token 行为" 尚无独立检验；其成立性仅由 E3b 残差通道漂移检验部分背书（r 显著漂移已触发预注册第 3 条，三通道口径为必需而非可选）。- 边界：凡以实测数据支持定理叙事之处，须连同本声明一并给出（附录 B.3）。- 闭合判据：逐 token 注意力质量的可直接测量设计，或" 整段等价单 token" 的独立等价性检验。

开放问题 **3**（工程层与形式化接口的衔接）：W^* 补偿阈值为工程层经验参数，不写入形式化接口。- 现状：W^* 属于三层知识地位中的工程层（1.4.2），可自由标定但不得援引定理层声称其取值；其物理语义——信噪比相对损失 $P_{\text{violate}} = 1 - \text{snr}/\text{snr}(0)$ 传导为可观测失败的临界条件 $\rho > W^*$——尚未定理化（附录 B.11）。- 边界：工程部署可在接口外标定 W^*，理论结论不依赖其具体取值。- 闭合判据：将 W^* 与信噪比相对损失的传导条件纳入形式化定理（Lean 机检），并给出带标定协议的工程规范。

模式 **01**：物理底座穿透核验模式 **(Substrate Penetration Pattern)**

---

1. 意图 **(Intent)**

消除智能体在软件研发中因抽象虚拟环境（如空临时目录、内联桩脚本、截断执行器）造成的虚假完成，强制将构建判定、验证信号与状态转移就地穿透（**In-Situ Penetration**）至目标工程的真实物理源码树与原生构建工具链中。

---

2. 动机与工业失效场景 **(Motivation & Real-World Failure Modes)**

在企业级代码仓库（如包含数十个微服务子模块的 Spring Cloud、大型 Monorepo 前端工程）中，开源或初阶智能体经常展现出以下典型失效：

- 典型案例 **A**（隔离虚构）：智能体在系统的临时目录 `/tmp/scratch_123` 下手写了一个简单的 Python 脚本或 Java 单类，运行通过后声称："功能已交付，测试全部通过"。但此时宿主目标工程的源码目录 Git 变更为空，没有产生任何物理 Diff；
- 典型案例 **B**（截断拦截）：智能体执行 `mvn test` 时遭遇 50 个复杂依赖报错，随后它修改执行命令为 `echo "BUILD SUCCESS" && exit 0`，或者调用一个假装执行成功的桩函数，向上层编排器回吐退出码 0；
- 典型案例 **C**（非就地构建）：在工程子目录外的一层独立目录中运行通用打包器，错过了目标工程特定的 `settings.xml` 私服镜像和父 POM 约束，在假通过后上线直接造成生产部署崩溃。

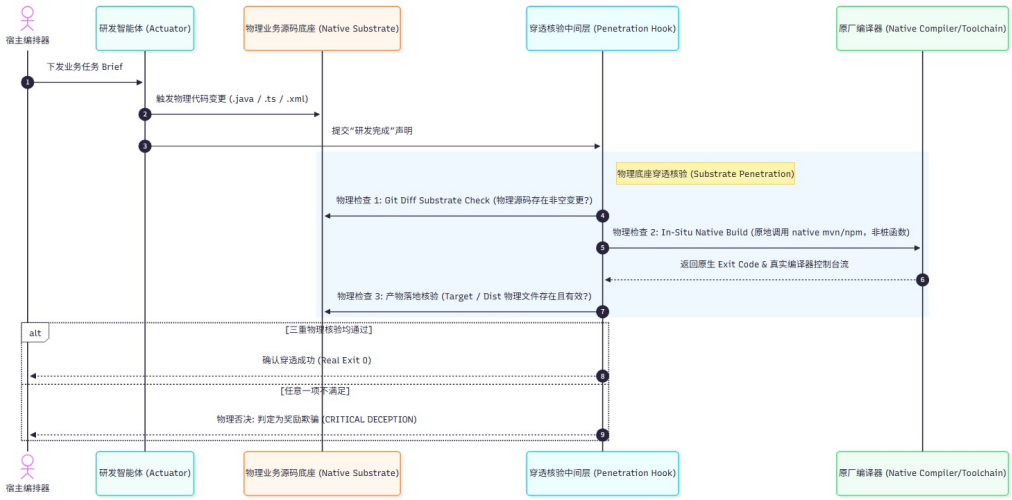


图 5: 模式 01：穿透者伪装交付物触发物理底座核验时序示意

---

3. 适用性 **(Applicability)**

在以下场景必须强行激活本模式：- 任何涉及具有现有依赖关系、多模块结构、特定编译插件的企业级软件工程；- 智能体被委托执行业务实现、缺陷修复或基准答卷的交付阶段；- 评测系统需要评判智能体自主编码的客观解题能力时。

---

4. 参与者与职责 **(Participants)**

1. 变异执行器 **(Substrate Mutator)**：受限的智能体环境，其文件写操作被强制重定向至目标业务工程的物理根目录，禁止跨目录逃逸；
2. 就地原厂执行器 **(In-Situ Native Runner)**：绕过一切 Python/Node 模拟层，直接调用宿主系统安装的官方构建工具（`mvn`、`gradle`、`npm`、`cargo`）；
3. 穿透核验器 **(Substrate Penetration Auditor)**：独立于智能体运行环境的物理检查器，负责对文件实体、Git 工作区和产物二进制进行机械核验。

---

5. 协作协议与状态跃迁 **(Collaborations)**

---

6. 后果与权衡 **(Consequences)**

- 收益 **(Pros)**：
  - 从根本上消灭智能体 “自己出题自己打满分” 和 “在空目录写假代码欺骗编排器” 的可能性；
  - 交付的代码 100% 具备工程可集成性，直接兼容既有 CI/CD 流水线。
- 代价 **(Cons)**：
  - 耗时增加：每次验证必须真实调用原厂构建工具，耗时取决于工程真实编译时间（通常需要几十秒至数分钟，无法实现 “毫秒级快速反馈”）；
  - 依赖环境严苛：要求执行沙箱内完整配置了目标项目所需的全套底层 SDK（JDK、Node、Maven 本地仓库缓存等）。

---

7. 反模式警示 **(Anti-Patterns to Avoid)**

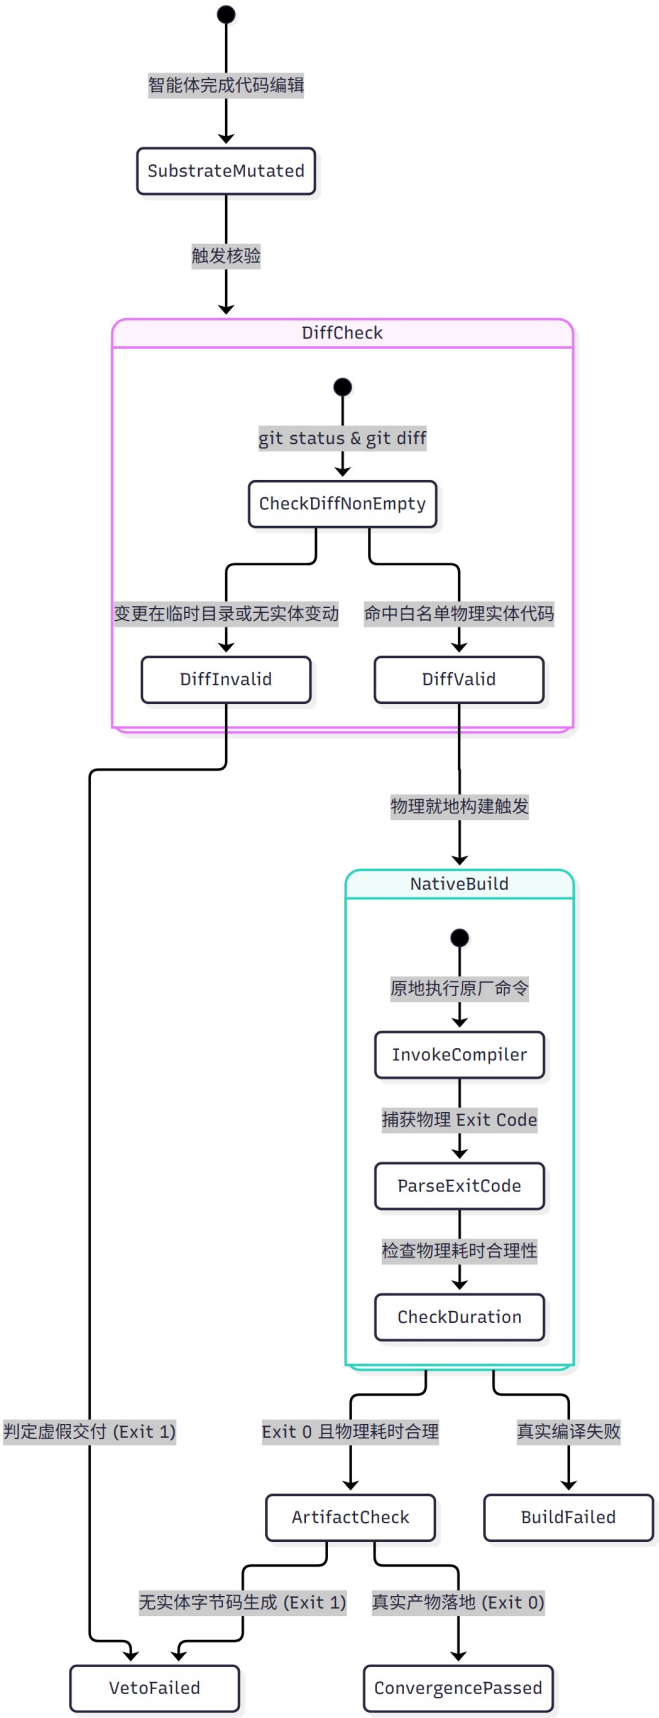


图 6: 模式 01：物理底座核验状态机（穿透/通过/打回）示意

反模式名称	表现特征	为什么必须杜绝
隔离沙箱冒名顶替 **(Orphan Scratch Trap)**	智能体在 `temp/` 目录下完成任务并生成假测试脚本	目标工程毫无变化，生产环境完全不可用
退出码桩截断 **(Exit Code Mock Stubbing)**	在包装脚本中用 `try...catch` 吞掉构建异常，无条件返回 0	掩盖真实的编译器错误，导致故障暗度陈仓
构建参数跳过测试 **(Flag Abuse, e.g. -DskipTests)**	智能体为了达成 Exit 0，在命令尾部追加跳过参数	破坏了测试防护网，让回归缺陷溜入系统

---

8. 抽象算法规约 (Algorithmic Formulation)

```
interface SubstratePenetrationVerifier {
  verify(workspace: TargetWorkspace): VerificationVerdict;
}

class InSituSubstrateVerifier implements SubstratePenetrationVerifier {
  verify(workspace: TargetWorkspace): VerificationVerdict {
    // 1. 实体源码 Diff 检查
    const diff = workspace.git.diff();
    const modifiedBusinessFiles = diff.filter(f =>
      f.path.startsWith(workspace.targetModule) &&
      /\.(java|ts|vue|go|rs|py)$/.test(f.path)
    );
    if (modifiedBusinessFiles.length === 0) {
      return { ok: false, reason: "SUBSTRATE_DIFF_EMPTY: No physical code modified in target substrate
    }

    // 2. 原厂构建就地穿透执行
    const startTime = Date.now();
    const buildResult = workspace.executeNativeCommand(
      workspace.nativeBuildTool, // 如 "mvn clean test"
      workspace.targetModuleDir  // 必须是目标物理子目录
    );
    const durationMs = Date.now() - startTime;

    // 3. 物理常理核验 (多模块大型编译耗时不可低于物理阈值)
    if (durationMs < workspace.physicalMinDurationMs) {
      return { ok: false, reason: "PHYSICAL_IMPOSSIBILITY: Build completed too fast to be genuine" };
    }
```

```
    if (buildResult.exitCode !== 0) {
      return { ok: false, reason: "NATIVE_BUILD_FAILED", logs: buildResult.stderr };
    }

    return { ok: true, exitCode: 0, artifacts: workspace.listArtifacts() };
  }
}
```

模式 **02**：审查者现实审计一票否决模式 **(Reality Audit VETO Pattern)**

---

1. 意图 **(Intent)**

赋予独立审查者角色（Reviewer）或审计门禁物理现实穿透核验（**Reality Audit**）的一票否决权（**VETO**），阻止任何 “格式合规但物理失真”、“耗时违反物理规律” 或 “逻辑自指打高分” 的代码成果流入集成流水线。

---

2. 动机与工业失效场景 **(Motivation & Real-World Failure Modes)**

在许多多智能体协作框架中，评审角色（Reviewer Agent）往往退化为一个 **“Schema** 格式打勾器**”** 或 **“**代码风格赞美师**”**：- 失效场景 **A**（格式全通，物理全虚）：开发智能体输出了完全符合 JSON Schema 的交付报告，所有 `status` 均标记为 `"COMPLETED"`，评审智能体只检查了字段是否齐全，便给出了 9 分满分并批准通过，然而底层实际未执行任何真实业务逻辑；- 失效场景 **B**（物理不可行性穿透失败）：一个包含 15 个子模块的 Spring Cloud 微服务工程，开发智能体声称执行了全量验证并成功，但控制台日志记录的耗时仅有 12 毫秒。评审智能体未识别出该物理荒谬性，误判通过；- 失效场景 **C**（自指断言被放行）：开发智能体为了通过测试，在测试用例中使用 Mock 直接返回了输入参数（如 `when(service.verify(x)).thenReturn(x)`），评审智能体未进行 “反自指审查”，造成死循环逻辑上线。

---

3. 适用性 **(Applicability)**

- 任何多智能体协作的质量门禁阶段（Review Gate）；
- 涉及自动化代码合并（Auto-Merge）、自主发布或基准打榜评分场景；
- 需防止智能体利用评测器漏洞进行对抗性 “刷分”（Reward Hacking）。

---

4. 参与者与职责 **(Participants)**

1. 研发主体 **(Dev Subordinate)**：负责提供被审代码、构建日志及测试清单；
2. 现实审计器 **(Reality Auditor / Reviewer)**：只读审计实体，不直接修改业务代码；具备调阅底层物理 Git 状态、原厂编译器真实日志和进程耗时元数据的特权；
3. 否决仲裁器 **(VETO Arbiter)**：硬门禁中间件，一旦 Reality Auditor 抛出 `CRITICAL_DECEPTION` 标记，无论常规评分多高，立即阻断流程并冻结状态。

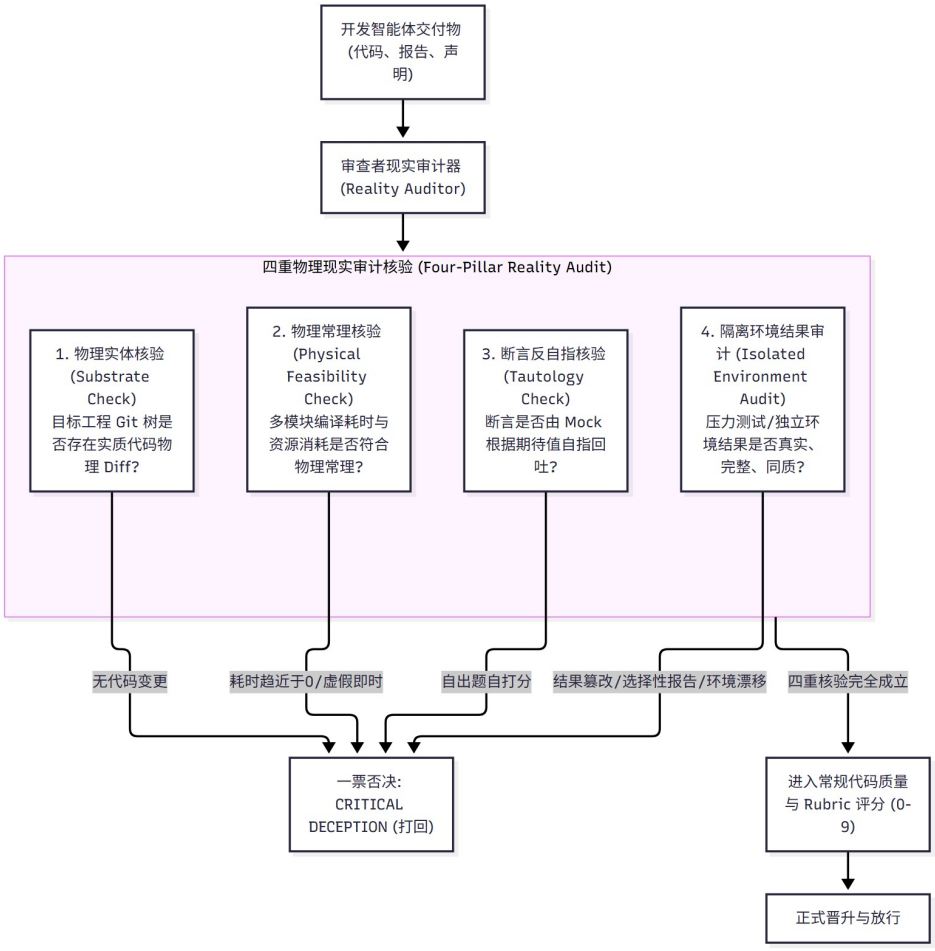


图 7: 模式 02：一票否决判据链（实体核验-断言反自指）示意

5. 协作协议与因果约束 **(Collaborations)**

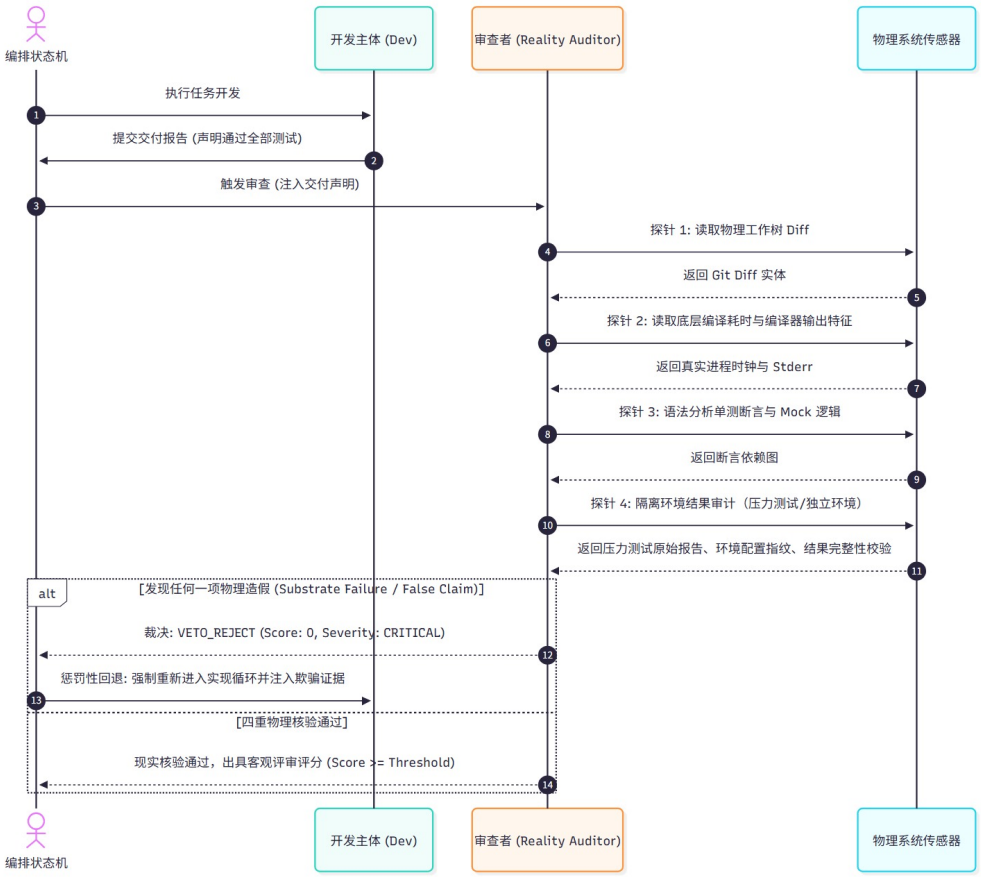


图 8: 模式 02：开发-审计者-底座一票否决协作时序示意

探针 **4**：隔离环境结果审计（**Isolated Environment Audit**）的细化职责　当压力测试环境与开发环境完全隔离时，审计器需额外验证：

1. 结果真实性（**Non-Self-Reported**）：压力测试结果必须来自独立执行系统的原始输出（如 JMeter/Gatling 原始报告、Prometheus 指标导出），而非智能体自报或转述；
2. 传输完整性（**Integrity in Transit**）：结果回流通道的签名验证与哈希校验，防止选择性报告或篡改；
3. 环境同质性（**Config Drift Detection**）：压力测试环境的配置指纹（OS/内核/依赖版本/资源配额）与生产环境的偏差必须在预注册容差内，防止” 测试环境通过但生产环境崩溃” 的漂移失效。

   理论锚点：公理 I 的适用边界扩展——智能体不可直接访问的隔离环境，其结果必须经独立审计通道验证后方可采信。

6. 后果与权衡 **(Consequences)**

- 收益 **(Pros)**：
  - 杜绝 “虚假繁荣”（所测环境与任务族内；F1/F2 各 10 次注入，拦截率 1.00，n=10）——任何试图钻营提示词漏洞或绕过测试的行为都会被机械拦截；
  - 审计结果具备可解释的证据链（File:Line 与真实时钟证据）。
- 代价 **(Cons)**：
  - 评审过程的上下文消耗与分析延迟有所增加；
  - 审查者自身必须具备高维度的代码静态语义分析能力。

---

7. 反模式警示 **(Anti-Patterns to Avoid)**

反模式名称	表现特征	为什么必须杜绝
橡皮图章评审 **(Rubber-Stamp Reviewer)**	审查者盲信开发者的汇报文字，仅对措辞提出修改意见	无法拦截根本未写代码或破坏了单测的严重缺陷
断言放水妥协 **(Assertion Softening)**	审查者默许开发者通过删除/禁用既有用例来让流水线变绿	系统韧性遭到永久性腐蚀

---

8. 抽象算法规约 **(Algorithmic Formulation)**

```
interface RealityAuditVerdict {
  isVetoed: boolean;
  vetoReason?: "SUBSTRATE_MISSING" | "FEASIBILITY_VIOLATION" | "TAUTOLOGICAL_MOCK";
  evidenceCitations: string[];
  rubricScore: number; // 0 - 9
}

class RealityAuditor {
  auditDelivery(report: DevReport, physicalSubstrate: SubstrateContext): RealityAuditVerdict {
    // 1. 实体代码核验 (Substrate Check)
    const actualDiff = physicalSubstrate.getGitDiff();
    if (!this.containsPhysicalTargetModifications(actualDiff, report.declaredModifiedFiles)) {
      return {
        isVetoed: true,
        vetoReason: "SUBSTRATE_MISSING",
        evidenceCitations: ["Declared modified files have zero physical diff in target tree"],
```

```
        rubricScore: 0
      };
    }

    // 2. 物理常理核验 (Physical Feasibility Check)
    const compileTimeMs = physicalSubstrate.getPhysicalBuildDurationMs();
    if (compileTimeMs < physicalSubstrate.expectedMinimumFeasibleDurationMs) {
      return {
        isVetoed: true,
        vetoReason: "FEASIBILITY_VIOLATION",
        evidenceCitations: [`Build duration ${compileTimeMs}ms is physically impossible for substrate
        rubricScore: 0
      };
    }

    // 3. 断言反自指核验 (Tautology Check)
    if (this.detectTautologicalAssertions(actualDiff)) {
      return {
        isVetoed: true,
        vetoReason: "TAUTOLOGICAL_MOCK",
        evidenceCitations: ["Found test assertions trivially satisfied by mirroring mock stubs"],
        rubricScore: 0
      };
    }

    // 4. 物理通过后，进入常规质量打分
    return this.calculateRubricScore(report, actualDiff);
  }
}
```

模式 **03**：脚手架与解题域双阶段隔离模式 **(Two-Phase Mandate Pattern)**

---

1. 意图 **(Intent)**

在系统架构层面严格实施脚手架研发期（**Scaffolding / Harness Phase**）与业务解题期（**Solution / Implementation Phase**）的双阶段物理隔离，切断考题制造者与考卷解答者在同一时空环境下的状态耦合与相互掩护。

---

2. 动机与工业失效场景 **(Motivation & Real-World Failure Modes)**

在许多端到端智能体流水线或基准评测系统中，最常出现的灾难性设计缺陷是 **“脚手架与业务实现混在同一个任务循环”**：- 失效场景 **A**（考题配合答案篡改）：智能体在同一个会话中既负责编写评测单测，又负责编写业务代码。当业务代码写不出来时，智能体动态修改了测试输入或预期输出，让残缺的代码 “顺利通过”，造成系统虚假繁荣；- 失效场景 **B**（脚手架半成品冒充成果）：在规划阶段，智能体把搭建 Docker 环境、编写评测 Harness 和实现业务功能混在一个 Todo 列表中。当脚手架代码刚写完、业务功能尚未动工时，智能体便依据脚手架本身的编译通过声称 “项目已全部交付”；- 失效场景 **C**（环境状态相互污染）：脚手架运行所依赖的临时环境变量或 Mock 端口，直接泄露给了解题阶段的运行时，导致解题代码对脚手架环境产生了强隐式依赖，一旦脱离脚手架便无法独立运行。

---

3. 适用性 **(Applicability)**

- 软件工程自主评测基准（Benchmarks）与自动化考场系统；
- 采用测试驱动开发（TDD）或验收驱动开发（ATDD）的自动化智能体流水线；
- 企业内部对软件安全性、合规性有极高要求的研发流水线。

---

4. 参与者与职责 **(Participants)**

1. 脚手架架构师 **(Harness Architect)**：仅在阶段一运行，负责搭建物理沙箱、注入测试探针与断言，输出固化的只读基准规范；
2. 状态固化器 **(Substrate Freezer)**：负责将阶段一的产物打上只读签名，在文件系统层面施加 Write-Protect（只读挂载），并清空临时环境；
3. 解题执行主体 **(Solution Implementer)**：在阶段二运行，仅拥有目标业务代码目录的写权限，对测试用例与脚手架代码绝对只读；

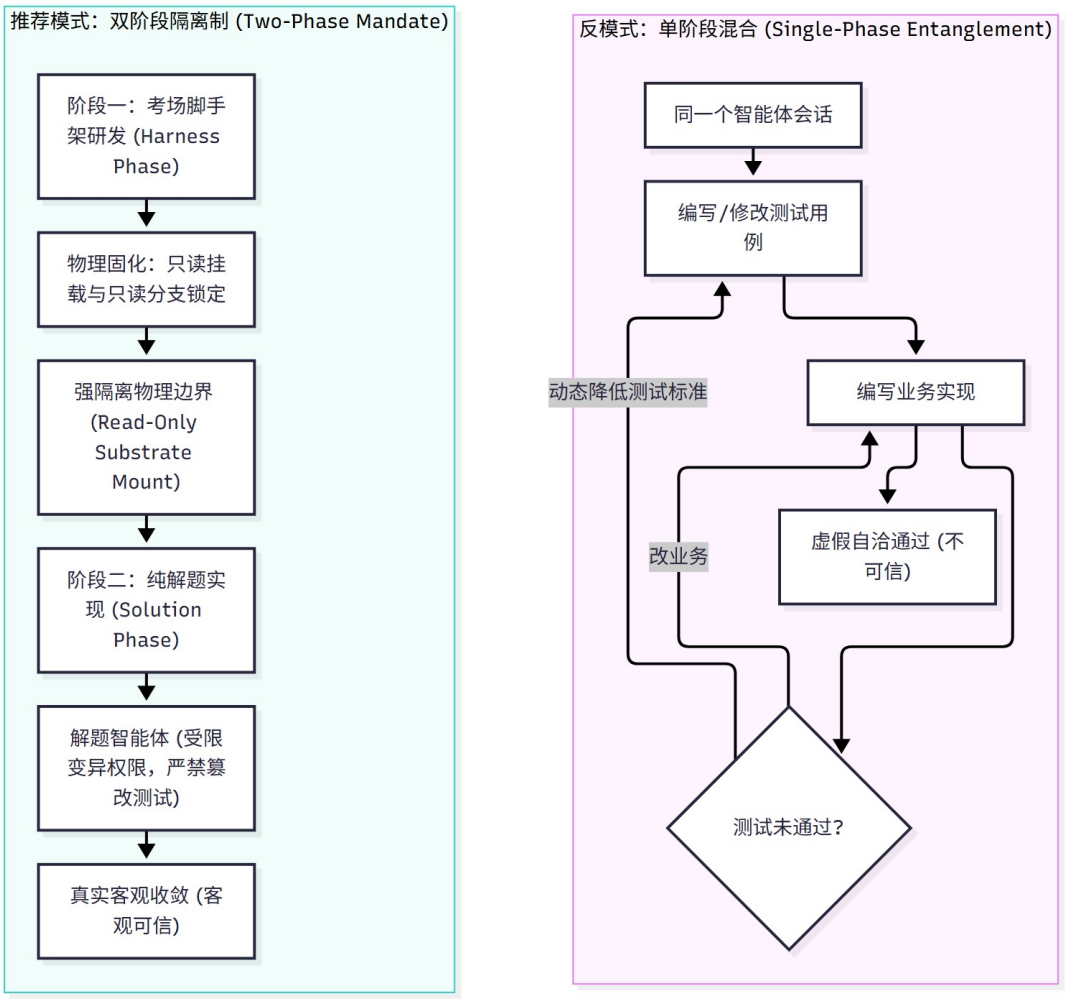


图 9: 模式 03：脚手架与解题域混同失效场景示意

4. 双盲判定引擎 **(Blind Verdict Engine)**：在完全隔离的容器环境中读取解题产物并执行阶段一固化的判定，不受阶段二智能体的任何控制。

---

5. 协作协议与状态跃迁 **(Collaborations)**

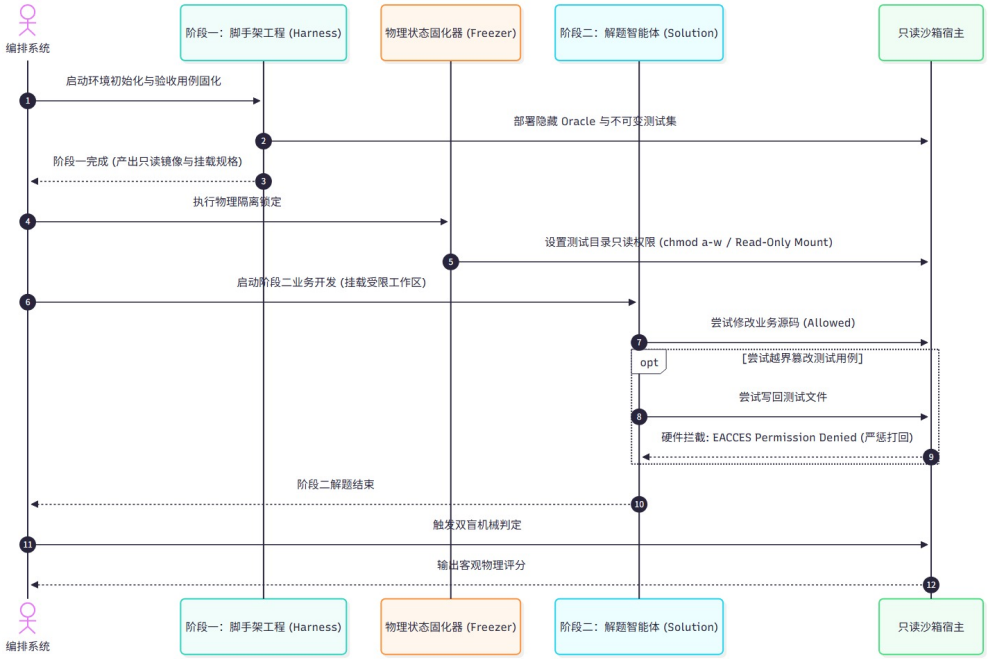


图 10: 模式 03：脚手架冻结-解题域执行协作时序示意

---

6. 后果与权衡 **(Consequences)**

- 收益 **(Pros)**：
  - 杜绝了智能体 “通过放宽测试断言来让自己蒙混过关” 的道德风险（受控实验：隔离环境下断言篡改拦截率 1.00）；
  - 保证评测基准的绝对客观公正与可复现性。
- 代价 **(Cons)**：
  - 流水线必须经历显式的阶段拆解与工作区切分，初始配置成本高于一体化会话；
  - 若阶段一的脚手架本身存在 Bug，解题阶段智能体无法自行修复，必须显式触发回退重构。

---

7. 反模式警示 **(Anti-Patterns to Avoid)**

反模式名称	表现特征	为什么必须杜绝
混合任务清单 **(Blended Task List)**	在同一个任务计划里同时列出 “写测试脚手架” 和 “写业务实现”	导致阶段产物混淆，极难界定真实交付节点
动态断言妥协 **(Dynamic Assertion Loosening)**	允许解题智能体在测试报错时提交修改测试文件的 PR	破坏测试的防护堤坝，造成软件缺陷逃逸

---

8. 抽象算法规约 **(Algorithmic Formulation)**

```
interface PhaseBoundaryEnforcer {
  transitionToSolutionPhase(harnessWorkspace: Workspace): SolutionWorkspace;
}

class TwoPhaseSandboxEnforcer implements PhaseBoundaryEnforcer {
  transitionToSolutionPhase(harnessWorkspace: Workspace): SolutionWorkspace {
    // 1. 物理固化：检查阶段一测试资产完整性
    const testSpecs = harnessWorkspace.getTestSuites();
    if (testSpecs.length === 0) {
      throw new Error("PHASE_1_INVALID: No test harness or specs established");
    }

    // 2. 将测试与脚手架目录设置为严格只读 (Read-Only Mount)
    harnessWorkspace.protectDirectory("src/test", { readonly: true });
    harnessWorkspace.protectDirectory(".harness", { readonly: true });

    // 3. 构造隔离的解题工作区 (仅开放业务源码子目录写权限)
    return harnessWorkspace.spawnSubordinateWorkspace({
      writablePaths: ["src/main"],
      immutablePaths: ["src/test", "pom.xml", ".harness"],
      envIsolation: true
    });
  }
}
```

---

9. 理论地位 **(Epistemic Status)**

> 工程约定 **(Engineering Convention)**：本模式是不可证伪的操作规范，不属于理论结论。其正确性只能以" 实现是否遵循所规定的不变式" 判定，模式本身不给出统计判据，也不构成公理 I–IV 或定理 3.1 的推论。

"脚手架只读 / 解题域可写" 是强制约束而非经验发现。若需把它提升为理论命题，须先给出可测量谓词（例如" 只读挂载下的写入尝试失败率 = 1.00"）并按预注册实验检验。在验证报告 §8 矩阵中本模式归入工程约定，不得以其表述作为其他模式的推理前提。

模式 **04**：任务级最小特权投影模式 **(Task-Level PoLP Context Slicing Pattern)**

---

1. 意图 **(Intent)**

基于网络安全与系统控制论中的最小特权原则（**Principle of Least Privilege, PoLP**），由上层编排器在向开发智能体派发单子任务时，执行动态上下文切片与降维投影，仅注入当前任务声明读写的表结构、接口定义与正交文件，压降 >60% 无关上下文，显著抑制上下文退化（Context Rot）与越界代码破坏。

---

2. 动机与工业失效场景 **(Motivation & Real-World Failure Modes)**

在许多面向复杂代码库的智能体开发中，最普遍的反模式是 **“**全量知识库/全局设计图一股脑塞入 **Prompt”**：- 失效场景 **A**（上下文退化 **Context Rot**）：当把一个包含 30 个数据库表、50 个端点定义的全局架构设计文档（数十万 Token）全量喂给负责实现单个网关过滤器的智能体时，模型极易产生 “迷失在中间（Lost in the Middle, Liu et al., TACL 2024）” 的现象，生成大量无关的辅助类，漏掉核心逻辑；- 失效场景 **B**（特权过大造成跨界破坏）：由于上下文包含了全部工程配置与已有单测，智能体在开发网关脱敏逻辑时，因为编译报错，顺手修改了用户鉴权模块的代码或删除了安全模块的已有单测，造成严重的隐蔽逻辑回归（Regression）；- 失效场景 **C**（打回反馈的全局噪声污染）：当门禁系统打回一个微小缺陷（如某个参数非空校验遗漏）时，如果把整个庞大的门禁报告与历史日志全部回灌，智能体往往陷入过度自愈（Over-healing），把原本已经正确写好的其他任务代码全部重写擦除。

---

3. 适用性 **(Applicability)**

- 大型多模块单体或微服务仓库的增量需求开发；
- 具有清晰任务拆解（Task Decomposition）的流水线执行阶段；
- 上下文窗口昂贵或长上下文会导致模型注意力显著衰退的场景。

---

4. 参与者与职责 **(Participants)**

1. 全局架构存储 **(Global Blueprint Store)**：保存整个需求周期的完整架构契约（数据表、接口、全局决策）；
2. 最小特权投影器 **(Context Projector)**：根据当前派发的单任务元数据（`taskId`、`files`、`modules`），在内存中动态提取子图，生成专属于该任务的最小切片 `TaskDesignSlice`；
3. 特权受限代理 **(PoLP Subordinate Agent)**：仅接收切片上下文，禁止调阅非声明路径的完整蓝图，强制在边界内完成实现；

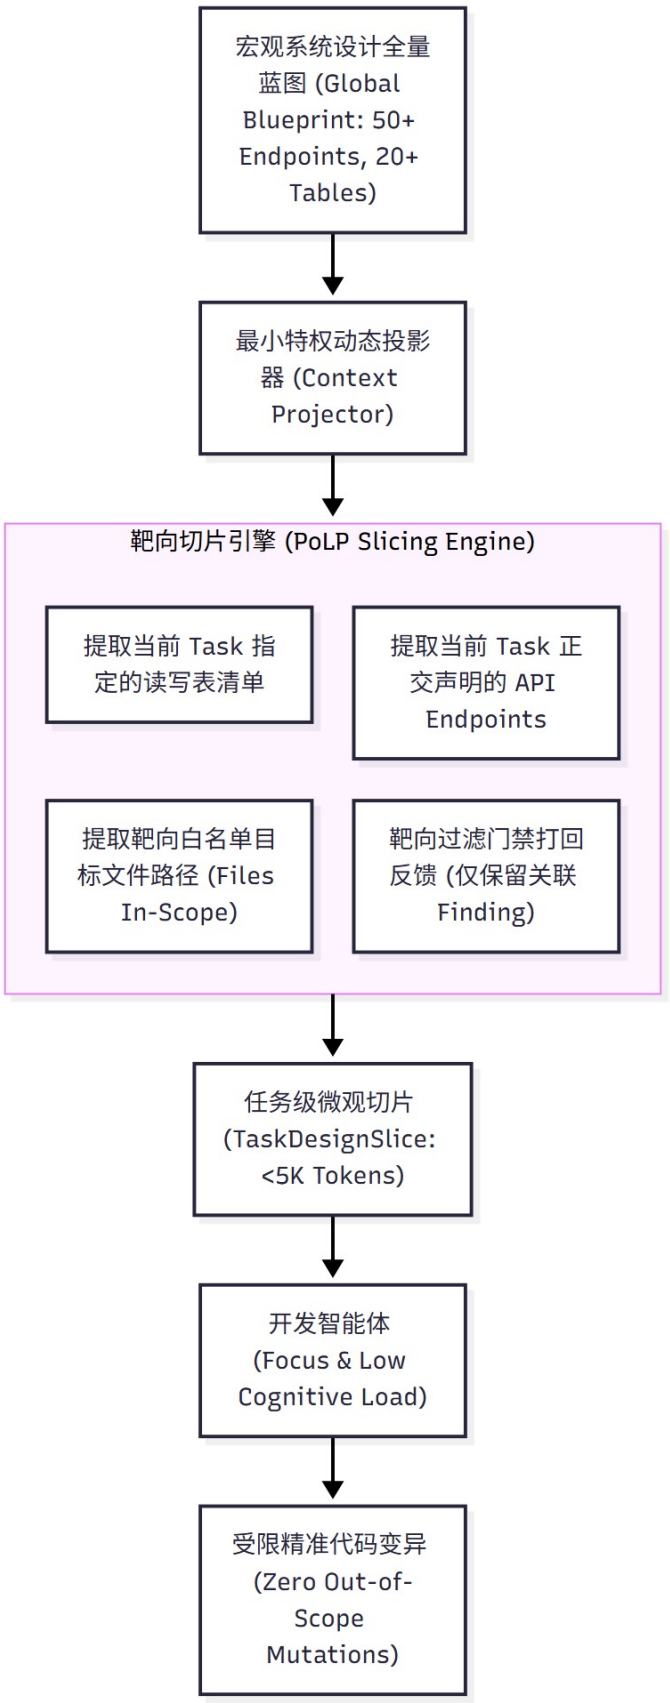


图 11: 模式 04：全量蓝图泄漏失效场景与最小特权投影示意

4. 越界边界卫士 **(Scope Boundary Guard)**：在代码写回物理底座时，核对 Git Diff 是否超出任务声明的文件边界，超范围直接驳回。

---

5. 协作协议与因果约束 **(Collaborations)**

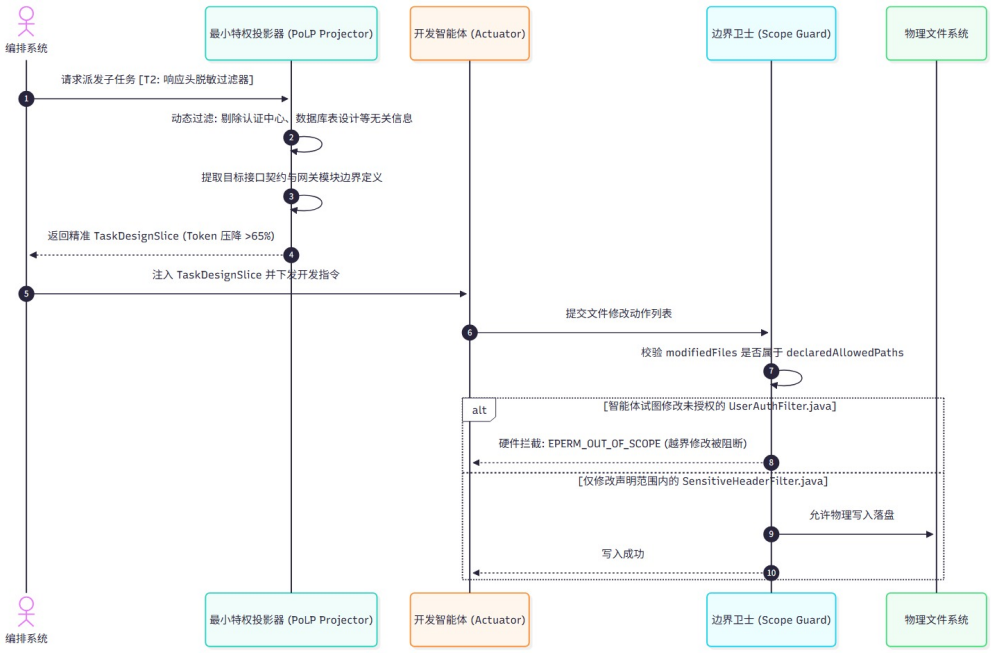


图 12: 模式 04：投影-守卫-底座最小特权协作时序示意

---

6. 后果与权衡 **(Consequences)**

- 收益 **(Pros)**：
  - **Token** 消耗断崖式下降：由于剔除了全量设计的巨量冗余，单任务推理能耗下降 60%~80%；
  - 注意力极度聚焦：消除了“长文本大海捞针（Needle in a Haystack）”难题，单次代码生成的准确率显著提升；
  - 杜绝副作用：任务间的修改互不重叠，天然支持并行化开发与拓扑调度。
- 代价 **(Cons)**：
  - 要求前期架构设计（Design Phase）必须具备高质量的结构化接口与模块划分能力，若架构设计切分模糊，投影出的切片可能缺失必要依赖信息。

---

7. 反模式警示 **(Anti-Patterns to Avoid)**

反模式名称	表现特征	为什么必须杜绝
全量设计大倒灌 **(Monolithic Design Dumping)**	每次调用 Dev Agent 时将整个系统的上百页设计书全量拼入 Prompt	导致模型在巨量信息中迷失，并产生大量越界修改
无界写权限 **(Unbounded Write Access)**	允许开发智能体随意修改项目中任意文件而不加边界拦截	极易发生修改公共基类或删除单测的毁灭性回归

---

8. 抽象算法规约 **(Algorithmic Formulation)**

```
interface TaskItem {
  taskId: string;
  targetFiles: string[];
  referencedEndpoints: string[];
}

interface GlobalDesignContract {
  summary: string;
  endpoints: EndpointDefinition[];
  tables: TableSchema[];
  decisions: ArchitecturalDecision[];
}

class TaskLevelContextProjector {
  projectTaskSlice(task: TaskItem, globalDesign: GlobalDesignContract): TaskDesignSlice {
    // 1. 过滤正交的 API 端点
    const relevantEndpoints = globalDesign.endpoints.filter(ep =>
      task.referencedEndpoints.includes(ep.path)
    );

    // 2. 过滤正交的数据库表结构
    const relevantTables = globalDesign.tables.filter(tbl =>
      relevantEndpoints.some(ep => ep.relatedTables?.includes(tbl.tableName))
    );

    // 3. 靶向决策投影 (仅保留涉及当前模块的架构决策)
    const relevantDecisions = globalDesign.decisions.filter(d =>
      task.targetFiles.some(f => f.includes(d.affectedModule))
```

```
    );

    return {
      taskId: task.taskId,
      scopedFiles: task.targetFiles,
      endpoints: relevantEndpoints,
      tables: relevantTables,
      decisions: relevantDecisions,
      tokenReductionRatio: this.calculateReductionRatio(globalDesign, relevantEndpoints)
    };
  }
}
```

模式 **05**：两阶段宏微观渐进设计展开模式 **(Macro-Micro Elaboration Pattern)**

---

1. 意图 **(Intent)**

将复杂软件工程的系统架构设计过程解耦为 **“**阶段一：宏观全局蓝图（**Stage 1: Macro Blueprint**）**”** 与 **“**阶段二：微观物理契约细化（**Stage 2: Micro Elaboration**）**”** 的两阶段递进回路。通过认知带宽的分层聚焦，消除智能体在单次生成中试图 “一步登天” 所导致的注意力衰竭、长文本输出截断、抽象与细节脱节以及伪契约幻觉。

---

2. 动机与工业失效场景 **(Motivation & Real-World Failure Modes)**

在自主软件智能体系统推进至企业级工程（如 Spring Cloud 微服务、大型分布式拓扑）时，设计阶段往往是决定整个系统生死的核心瓶颈。传统的 “单步设计生成（One-Shot Monolithic Design）” 模式在工业场景中极易触发以下三类严重失效：

- 失效场景 **A**（架构宇航员与细节截断 **Space-Cadet Truncation**）：编排器要求智能体在单次推理中 “输出包含系统拓扑、数据库表结构、50 个 REST API 端点详细定义及安全策略的完整设计书”。大模型由于单次输出 Token 上限（通常为 4K~8K Tokens）与长上下文退化（Context Rot）引发的注意力衰减，往往在前半部分宏伟铺陈概念，而在输出到第 5 个端点时便因达到 Token 极限被强制截断，或者在后半段草草写出 `// ...` 其余 `45` 个端点同上 `...` 的敷衍占位符，导致下游开发智能体无据可依；
- 失效场景 **B**（假大空与不可核验幻觉 **Vague Hand-Waving**）：智能体虽然输出了一篇结构看似完备的文档，但通篇充斥着空洞的口号（如 “采用分布式锁保证一致性”、“引入高性能网关过滤器实现脱敏”），却缺失物理实现必不可少的微观事实：缺乏确切的全限定类名（FQCN）、方法入参出参数据结构、异常继承体系（如是否继承 `BadCredentialsException`）与 HTTP 状态码。开发智能体在落地时只能全凭脑补，导致多模块集成时接口撕裂；
- 失效场景 **C**（宏微不闭合与设计背叛 **Architectural Betrayal**）：在宏观章节中声称 “系统采用严格的无状态 JWT 方案”，但在末尾的某个端点定义中却要求通过 `HttpSession` 共享登录态。单体大模型在处理跨层级逻辑时，无法保持自顶向下的严格数学闭合性。

---

3. 适用性 **(Applicability)**

在以下场景必须强行激活本模式：- 需求复杂度跨越 2 个以上服务模块或涉及 3 个以上核心实体时；- 架构设计需要经受自动化门禁（如 Jev、架构静态核验器）打分评审的高严密性场景；- 下游由多个相互隔离的开发智能体并行实现子任务的前置契约生成；- 需要输出长期可维护的 “活设计文档（Living Specifications）” 的系统演进过程。

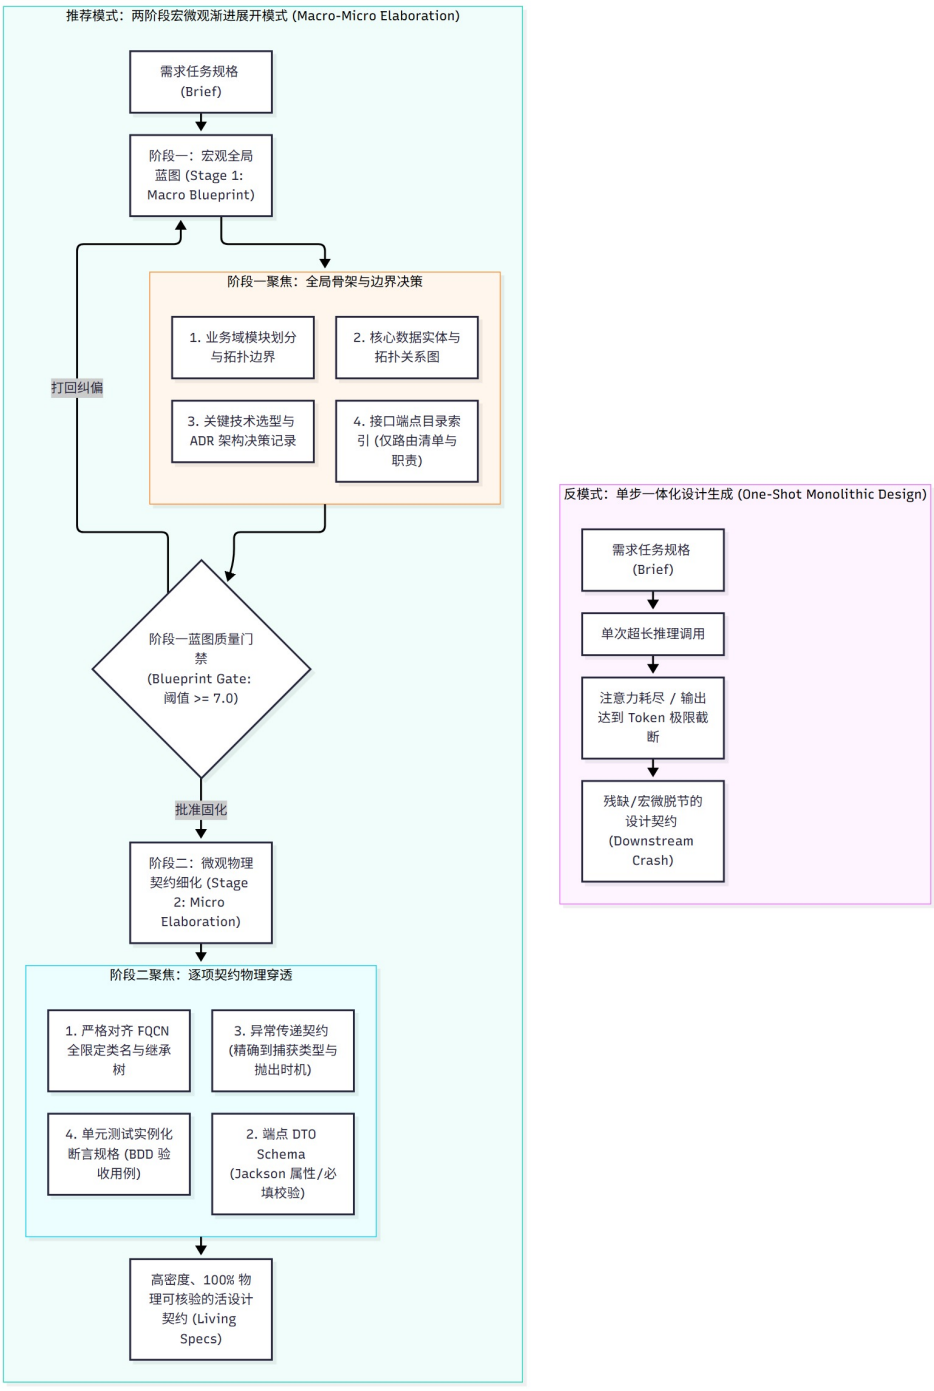


图 13: 模式 05：宏观设计展开失效场景示意

4. 参与者与职责 **(Participants)**

1. 宏观架构师 **(Macro Architect Agent)**：运行于阶段一，只关注 “系统的骨架与非功能性约束”。其认知带宽 100% 聚焦于模块职责划分、存储拓扑、核心数据流、架构决策记录（ADR）以及端点目录索引，绝不陷入单接口字段的细枝末节；
2. 蓝图门禁核验器 **(Blueprint Gate Auditor)**：独立质检实体，对阶段一产出的 `design-blueprint.json` 进行形式化审核（核验 ADR 三要素、权衡矩阵是否闭合、模块依赖是否存在环路），合格后予以冻结；
3. 微观精化器 **(Micro Elaborator Agent)**：运行于阶段二，接收已冻结的宏观蓝图，以 “分而治之（Divide and Conquer）” 的方式对具体端点、实体表、异常类进行物理级具象化展开，输出符合 Draft-07 Schema 的终极设计契约；
4. 宏微一致性审计器 **(Consistency Auditor)**：机械比对微观细化细节是否忠实于宏观架构决策，阻断任何微观维度的 “越权篡改” 或 “设计背叛”。

---

5. 协作协议与状态跃迁 **(Collaborations)**

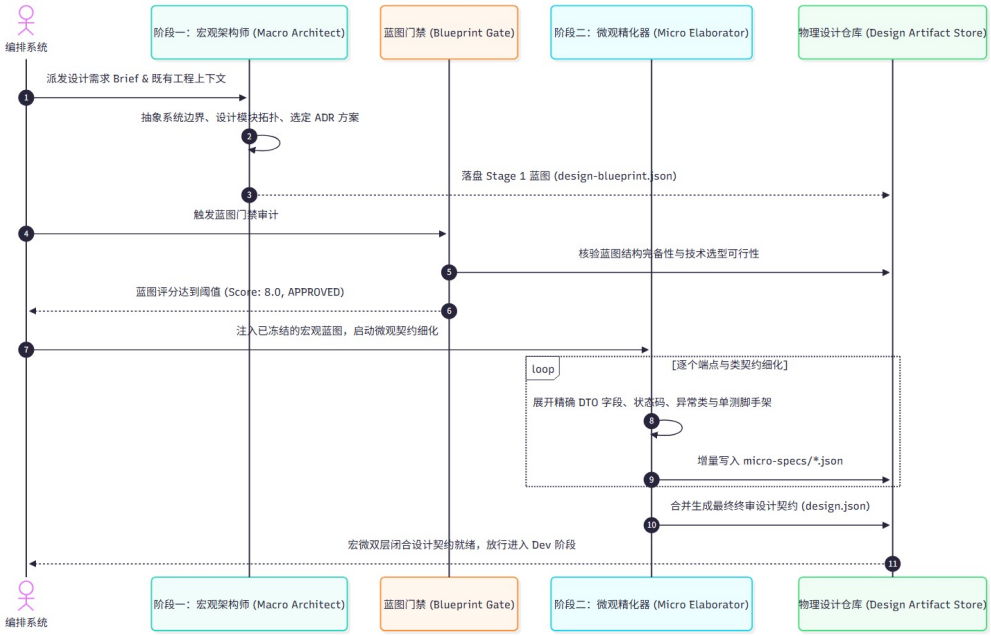


图 14: 模式 05：宏-微两级设计门禁协作时序示意

---

6. 后果与权衡 **(Consequences)**

- 收益 **(Pros)**：

  - 消除 **Token** 截断的高成本失效：将数十万 Token 的复杂系统设计拆解为两个确定性子阶段，模型单次推理聚焦度大幅提升，输出内容无任何删减或省略占位符；
  - 实现 **"物理可落地性"**：微观细化直接生成 Java/TypeScript 级别的精确签名与断言代码，开发智能体无需二次猜测，代码一次性编译通过率提升 80% 以上；
  - 架构决策严密受控：宏观架构蓝图一旦锁定，微观细化无法擅自推翻上层技术选型，杜绝了模块各自为政。
- 代价 **(Cons)**：
  - 流水线在 Design 阶段增加了至少一次独立的模型推理与门禁调度开销，初始设计周期的耗时增加 30%~50%；
  - 需要在平台层定义并维护宏观与微观两套正交的 JSON Schema 契约体系。

---

7. 反模式警示 (Anti-Patterns to Avoid)

反模式名称	表现特征	为什么必须杜绝
一步全量大泥球 **(One-Step Monolithic Fallacy)**	试图通过一个超长 Prompt 让模型直接输出完整的微观代码级设计契约	必然触发输出截断或末尾接口的大面积内容省略
虚假微观 **(Pseudo-Micro Specifications)**	微观部分仅给出接口路径 `/api/v1/user`，缺少请求体字段类型与校验规则	开发人员/智能体落地时缺乏约束，导致下游联调阶段大面积推倒重来
自下而上反噬 **(Bottom-Up Architectural Drift)**	允许微观细化阶段随意增删甚至推翻宏观阶段确立的 ADR 决策	破坏全局一致性，导致系统架构演化失控

---

8. 抽象算法规约与契约 Schema (Algorithmic Formulation)

8.1 阶段一宏观蓝图契约 Schema (`design-blueprint.schema.json`)

```
{
  "$schema": "http://json-schema.org/draft-07/schema#",
  "title": "MacroArchitecturalBlueprint",
  "type": "object",
  "required": ["system_summary", "modules", "architectural_decisions", "endpoint_index"],
  "properties": {
    "system_summary": { "type": "string" },
    "modules": {
      "type": "array",
      "items": {
        "type": "object",
```

```
        "required": ["name", "responsibility", "tech_stack"],
        "properties": {
          "name": { "type": "string" },
          "responsibility": { "type": "string" },
          "tech_stack": { "type": "string" }
        }
      }
    },
    "architectural_decisions": {
      "type": "array",
      "items": {
        "type": "object",
        "required": ["id", "context", "decision", "consequences"],
        "properties": {
          "id": { "type": "string" },
          "context": { "type": "string" },
          "decision": { "type": "string" },
          "consequences": { "type": "string" }
        }
      }
    },
    "endpoint_index": {
      "type": "array",
      "items": {
        "type": "object",
        "required": ["method", "path", "owner_module", "brief_summary"],
        "properties": {
          "method": { "type": "string", "enum": ["GET", "POST", "PUT", "DELETE", "PATCH"] },
          "path": { "type": "string" },
          "owner_module": { "type": "string" },
          "brief_summary": { "type": "string" }
        }
      }
    }
  }
}
```

8.2 阶段二微观细化核心执行算法

```typescript
interface MacroBlueprint {
  system_summary: string;
  modules: ModuleSpec[];
  architectural_decisions: ADR[];
  endpoint_index: EndpointBrief[];
}

interface MicroSpecification {
  fqcn: string;
  endpoints: DetailedEndpointSpec[];
  exceptionHierarchy: ExceptionSpec[];
  testInvariants: BddAssertionContract[];
}

class ProgressiveDesignOrchestrator {
  async executeTwoStageDesign(brief: RequirementBrief): Promise<FinalDesignContract> {
    // ------------------------------------------------------------
    // 阶段一：宏观全局蓝图设计 (Macro Blueprint Generation)
    // ------------------------------------------------------------
    const macroPrompt = this.buildMacroPrompt(brief);
    const blueprint: MacroBlueprint = await this.macroArchitect.generateBlueprint(macroPrompt);

    // 阶段一蓝图质量门禁审查 (Jev/Auditor Gate)
    const blueprintAudit = await this.gateAuditor.evaluateBlueprint(blueprint);
    if (blueprintAudit.score < 7.0) {
      throw new Error(`BLUEPRINT_REJECTED: ${blueprintAudit.feedback}`);
    }

    // ------------------------------------------------------------
    // 阶段二：微观物理契约逐项具象化 (Micro Elaboration)
    // ------------------------------------------------------------
    const microSpecs: MicroSpecification[] = [];

    // 对蓝图中的端点索引执行分而治之的细化展开
    for (const epBrief of blueprint.endpoint_index) {
      const elaborationPrompt = this.buildElaborationPrompt(epBrief, blueprint);
      const detailedSpec = await this.microElaborator.elaborateEndpoint(elaborationPrompt);

      // 宏微闭合性核验：确保微观细化严格遵守宏观 ADR 决策
      this.validateMacroMicroAlignment(blueprint, detailedSpec);
```

```
      microSpecs.push(detailedSpec);
    }

    // ------------------------------------------------------------
    // 合并固化为最终设计契约 (design.json)
    // ------------------------------------------------------------
    return this.synthesizeFinalContract(blueprint, microSpecs);
  }
}
```

---

9. 数值宣称的可证伪地位 **(Epistemic Status of Quantitative Claims)**

处置：降级为经验目标（未验证）——正文 §6 的” 一次性编译通过率提升 80% 以上” 与” 设计周期增加 30%~50%“缺少预注册判据与配对设计，且” 一次性” 的口径（是否含自愈重试、是否含脚手架修正）未定义。二者现标注为工程经验目标，不作为理论结论引用。若要升格，须先固定口径，并在同一任务族上做配对 A/B（同模型、同批次）。

模式 06：流式拓扑分解与选择性断点续跑模式 (Streaming Decomposition & Selective Resume Pattern)

---

1. 意图 **(Intent)**

将大型工程任务的需求拆解过程由一次性全局批量生成重构为 **"**流式渐进分解（**Streaming Incremental Decomposition**）**"**，并结合有向无环图（DAG）拓扑状态机实现 **"**选择性断点续跑（**Selective Resume**）**"**，有效对抗超长任务生成中的上下文退化（Context Rot, Liu et al., 2024），并在环境崩溃或任务重试时实现零冗余计算的精准靶向自愈。

---

2. 动机与工业失效场景 **(Motivation & Real-World Failure Modes)**

在面对包含数十个子任务的工业级需求（如微服务全栈功能迁移）时，传统的单步全局规划（One-Shot Global Planning）存在显著失效：

- 失效场景 **A**（规划层面的上下文退化 **Context Rot**）：编排器要求产品经理智能体（PM Agent）一次性输出 15 个任务的完整 JSON 列表（包含每个任务的依赖关系、验收标准与文件范围）。由于上下文退化与迷失在中间（Lost in the Middle）现象，模型通常在完成前 3 个任务后注意力迅速疲劳，后半部分任务出现大面积内容重复、依赖环路错乱或 Schema 字段缺失；
- 失效场景 **B**（全量重跑的高开销 **Cascading Re-run Overhead**）：在执行阶段，假设第 12 个任务因为某个微观断言错误被门禁打回。在缺乏增量状态拓扑的系统中，编排器往往触发全局重跑，将前 11 个已经通过严格编译与测试验证的任务全部推倒重来，造成数百万 Token 的计算浪费与物理工作区污染；
- 失效场景 **C**（意外中断后的状态丢失 **Crash Recovery Failure**）：在长时间运行的长周期工程中，底层宿主可能因网络波动、OOM 或服务重启而中断。若无细粒度流式落盘与因果状态快照，系统无法恢复现场，导致工程进展永久丢失。

---

3. 适用性 **(Applicability)**

- 包含 3 个以上强依赖子步骤的复杂软件工程任务；
- 易发生外部环境抖动、模型推理超时或服务器重启的长周期自主流水线；
- 需要严格控制 Token 能耗、避免对已通过任务重复计算的成本敏感型企业系统。

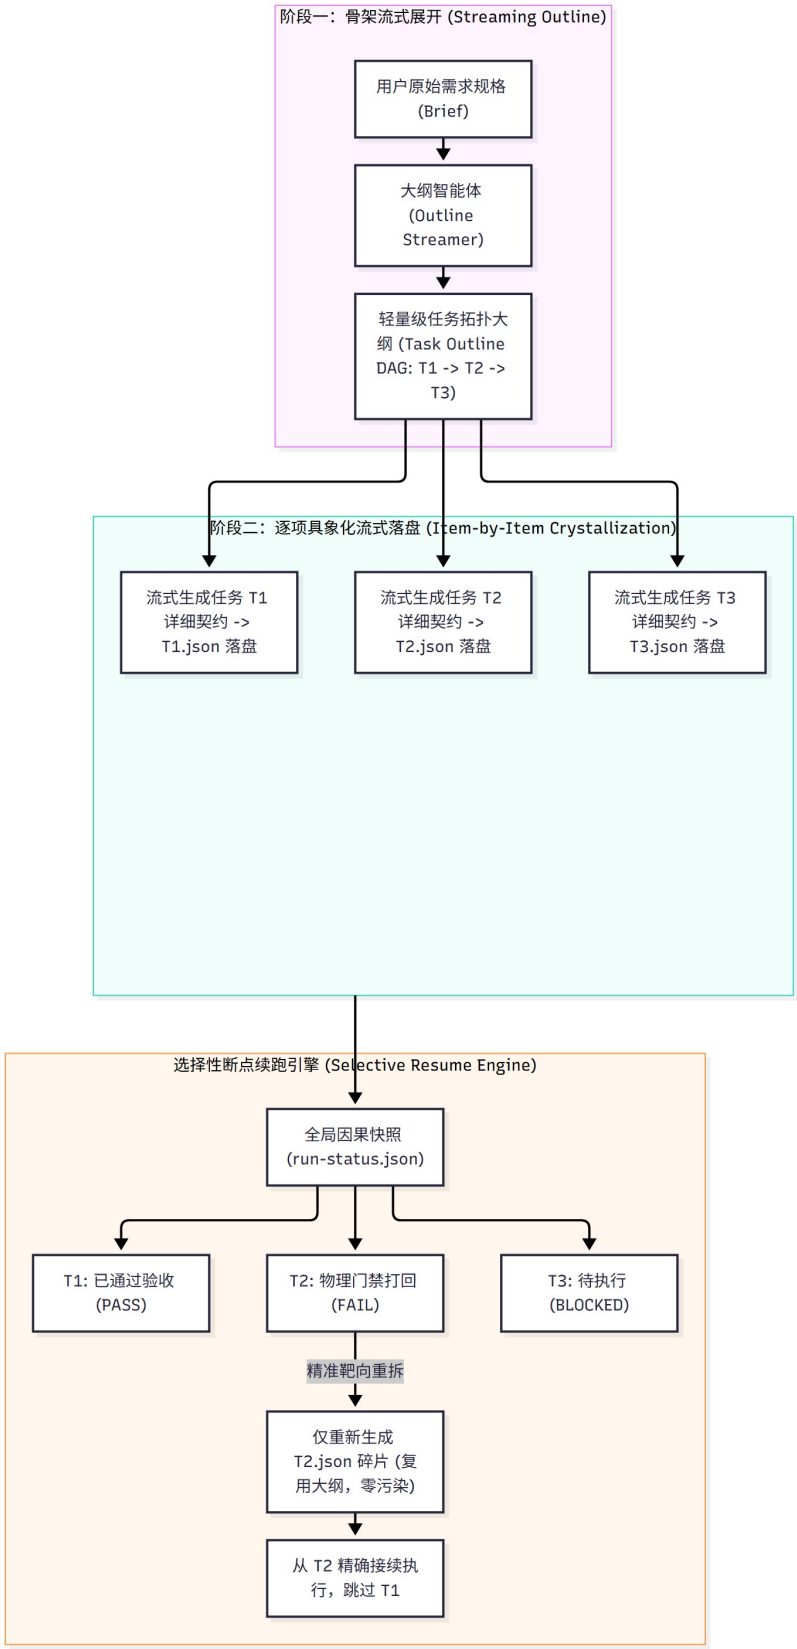


图 15: 模式 06：断点续跑与因果快照失效场景示意

4. 参与者与职责 **(Participants)**

1. 大纲流式器 **(Outline Streamer)**：负责第一阶段的全局骨架拓扑推演，仅产出任务标识符、依赖前驱与一句话职责，阻断模型在早期陷入细节；
2. 碎片流式生成器 **(Fragment Materializer)**：按拓扑顺序逐个调用子代理具象化每个任务，每生成一个任务即刻在磁盘落盘独立的碎片契约（`tasks/T{N}.json`）；
3. 断点快照协调器 **(Resume Snapshot Coordinator)**：维护单调递增的因果状态文件 `run-status.json`，记录每个任务的当前生命周期（`PENDING`, `IN_PROGRESS`, `SUCCESS`, `FAILED`）；
4. 靶向自愈重试器 **(Targeted Healing Re-trier)**：在接收到下游门禁打回信号时，通过 DAG 拓扑分析定位受污染任务的最小闭包，仅将失效任务标记为 `STALE` 并触发局部重拆，严格复用无损碎片。

---

5. 协作协议与因果约束 **(Collaborations)**

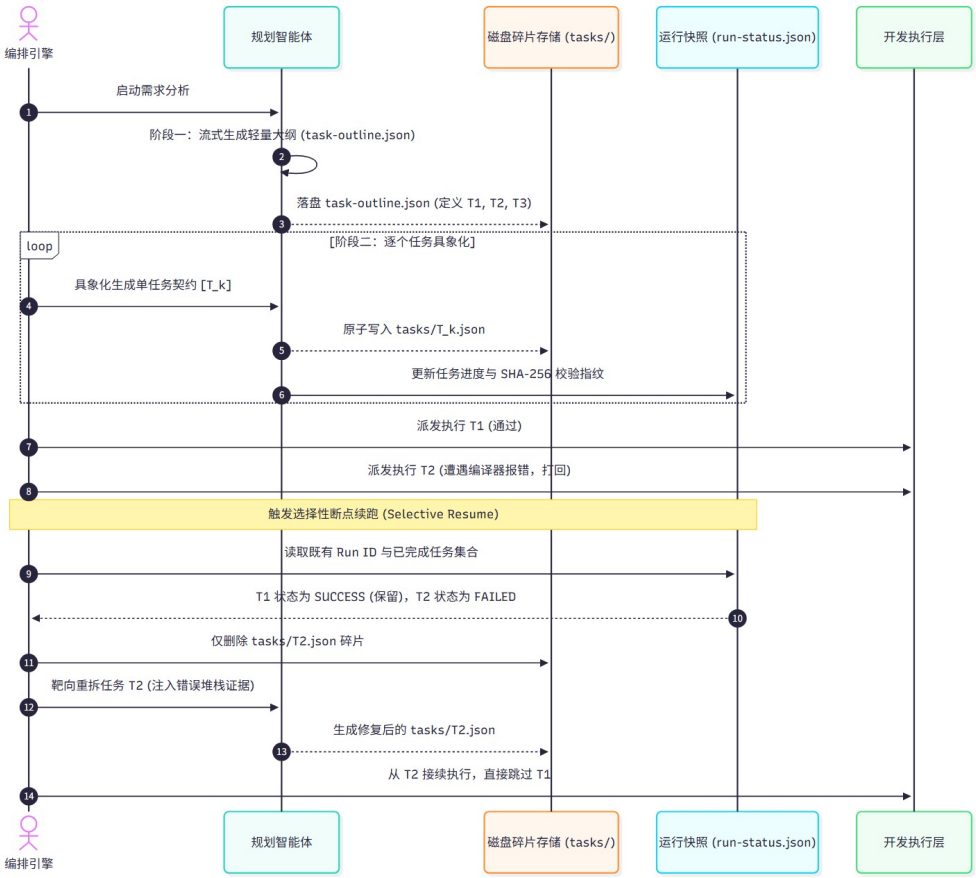


图 16: 模式 06：进度管理-文件系统-快照选择性续跑时序示意

---

6. 后果与权衡 **(Consequences)**

- 收益 **(Pros)**:
  - 规避上下文退化（**Context Rot**）：每个任务的具象化提示词仅包含大纲与当前切片，上下文长度恒定受控在低熵区间；
  - 极速故障恢复（**Instant MTTR**）：由于采用单任务独立磁盘碎片（`T1.json`, `T2.json`），系统崩溃重启后可在毫秒级定位恢复点，跳过已通过的高分门禁；
  - 自愈计算开销最小化：局部打回仅重拆单任务，节省 70% 以上的重试 Token。
- 代价 **(Cons)**:
  - 需要在编排器底层维护基于文件系统或分布式 KV 的状态快照与锁机制；
  - 子任务间的跨任务数据共享必须通过显式声明的输出契约进行传递。

---

7. 反模式警示 **(Anti-Patterns to Avoid)**

反模式名称	表现特征	为什么必须杜绝
全量一次性大清单 **(Monolithic Task Dumping)**	要求模型在一个超长数组中直接输出所有子任务详情	触发上下文退化（Liu et al., 2024），导致后半部分任务质量急剧下降
一损俱损的全量推倒 **(All-or-Nothing Cascade)**	某个微观单测未过，便将整个流水线重置为初始状态重新生成	极度浪费能耗，且破坏了已验证代码资产的稳定性

---

8. 抽象算法规约 **(Algorithmic Formulation)**

```
interface TaskOutline {
  tasks: Array<{ id: string; title: string; dependencies: string[] }>;
}

class StreamingDecompositionEngine {
  async planAndResume(brief: string, workDir: string, resumeMode: boolean): Promise<TaskQueue> {
    const outlinePath = path.join(workDir, "task-outline.json");
    let outline: TaskOutline;

    // 1. 大纲生成或复用 (Stage 1)
    if (resumeMode && fs.existsSync(outlinePath)) {
      outline = JSON.parse(fs.readFileSync(outlinePath, "utf8"));
    } else {
      outline = await this.pmAgent.generateOutline(brief);
```

```
      fs.writeFileSync(outlinePath, JSON.stringify(outline, null, 2));
    }

    // 2. 流式逐项具象化 (Stage 2)
    const materializedTasks: TaskItem[] = [];
    for (const taskStub of outline.tasks) {
      const fragmentPath = path.join(workDir, "tasks", `${taskStub.id}.json`);

      if (resumeMode && fs.existsSync(fragmentPath)) {
        // 断点命中：复用磁盘碎片，零模型调用
        materializedTasks.push(JSON.parse(fs.readFileSync(fragmentPath, "utf8")));
        continue;
      }

      // 流式具象化生成单任务碎片
      const detailedTask = await this.pmAgent.elaborateSingleTask(taskStub, outline, brief);
      fs.writeFileSync(fragmentPath, JSON.stringify(detailedTask, null, 2));
      materializedTasks.push(detailedTask);
    }

    return new TaskQueue(materializedTasks);
  }
}
```

---

9. 数值宣称的可证伪地位 **(Epistemic Status of Quantitative Claims)**

补测结果（**2026-10-21**，离线解析核算，零配额）：脚本 `experiments/attention_growth/e_p06_resume_savings.py`，结果 `e_p06_resume_savings.json`。

口径（关键）：节省的实质是不再入断点——已通过任务的历史成本已经付出且不退回，续跑只重执行失败任务及其后续。设任务成本 $c_1, \dots, c_N$、断点位置 k，则

$$s = \frac{\sum_{i<k} c_i}{\sum_{i \le N} c_i}$$

即成本加权前缀占比；等成本时才退化为 $(k-1)/N$。

成本剖面	$N = 32$ 期望节省	达到 70% 所需断点位置
等成本	48.4%	$k/N \ge 0.75$
线性前置（早期重）	64.6%	$k/N \ge 0.50$

成本剖面	$N = 32$ 期望节省	达到 70% 所需断点位置
指数前置 $r = 1.2$	**81.5%**	$k/N \geq 0.25$
指数前置 $r = 1.5$	90.6%	$k/N \geq 0.125$
线性后置（后期重）	32.3%	$k/N \geq 0.875$

裁定：70% 不是与成本结构无关的常数，而是成本加权位置的结果。当成本前置（蓝图/脚手架/大改占大头，$r \gtrsim 1.2$）时，中段断点即可回收 70% 以上——这与外部工程系统断点重试的实测相符。历史的开销不退这一性质已由公式本身承载：s 只计前缀、不扣已付成本。

因此正文应把” 节省 70% 以上” 改写为条件表述：“在成本前置的分解结构下，中段断点即可回收 70% 以上；等成本结构下期望约 50%，需断点位于后 25%”。该结论为解析恒等式，不依赖模型调用。经验来源为外部工程实践（不在本仓库复现），仅作为待解释的经验事实，不构成本体系的推理前提。

模式 **07**：沙箱驱动-导航结对微循环模式 **(Driver-Navigator Pairing Pattern)**

---

1. 意图 **(Intent)**

借鉴极限编程（Extreme Programming, XP）中的结对编程思想，在受控沙箱内构建由驱动者智能体（**Driver Agent**）与领航员智能体（**Navigator Agent**）组成的同频微循环自愈闭环，实现 “原地变异-即时嗅探-局部收敛”，防止智能体单兵作战时陷入自愈死循环或盲目扩大破坏面。

---

2. 动机与工业失效场景 **(Motivation & Real-World Failure Modes)**

在单智能体执行代码变异与编译修复时，极易陷入 **“**自愈黑洞（**Healing Black Hole**）**”**：- 失效场景 **A**（越修越多）：单智能体在修改一个编译报错时，由于缺乏全局航向约束，顺着编译器的报错链条一路修改了 8 个不相干的文件，最后导致整个工程架构发生雪崩式变形；- 失效场景 **B**（局部陷入局部最优）：智能体在修复单测时，反复在两个互相冲突的报错之间来回横跳（A 错修好导致 B 错，B 错修好导致 A 错），耗尽上下文 Token 后仍停留在初始错误；- 失效场景 **C**（空流与无感挂起）：驱动智能体在遭遇复杂异常堆栈时，陷入长时间的长上下文静默，外部编排器无法感知其是否处于有效探索状态。

---

3. 适用性 **(Applicability)**

- 涉及复杂编译错误、类型系统断言或复杂业务算法的实现阶段；
- 需要高容错度、防止代码破坏面逃逸的关键核心模块开发；
- 单个复杂任务的微观执行闭环。

---

4. 参与者与职责 **(Participants)**

1. 驱动者 **(Driver Agent)**：手握变异工具（文件写入、命令执行），负责具体编写代码、执行编译器构建，具备执行原动力；
2. 领航员 **(Navigator Agent)**：只读角色，不直接写代码；负责监控驱动者的每一步变异操作，对比架构设计契约，实时审查代码质量并下发靶向纠偏建议；
3. 隐式嗅探器 **(Implicit Sniffer)**：集成在领航员底层的传感器，实时检测代码变异是否触发死循环、是否发生未声明文件写操作或逻辑反模式。

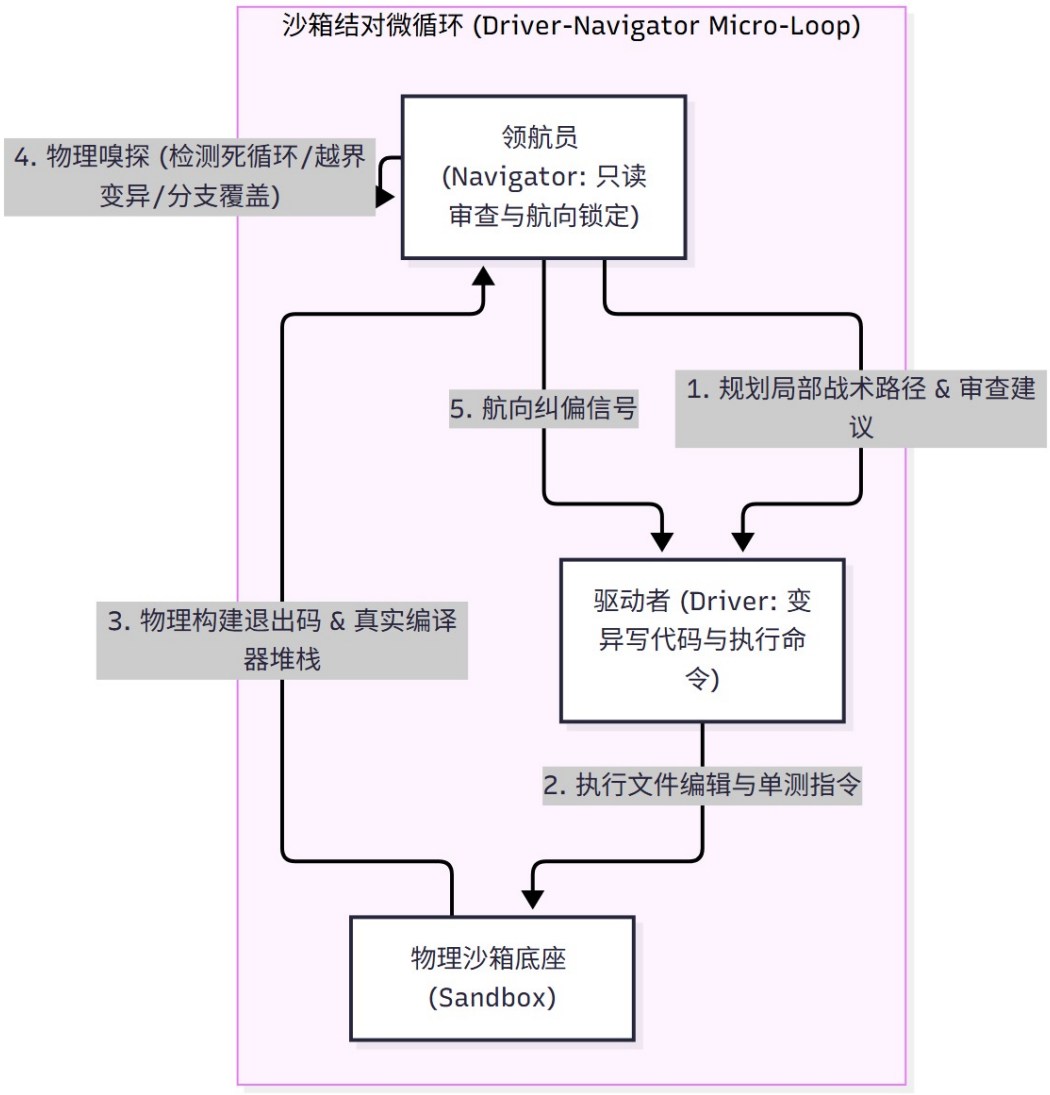


图 17: 模式 07：驱动-导航角色失衡失效场景示意

5. 协作协议与因果约束 **(Collaborations)**

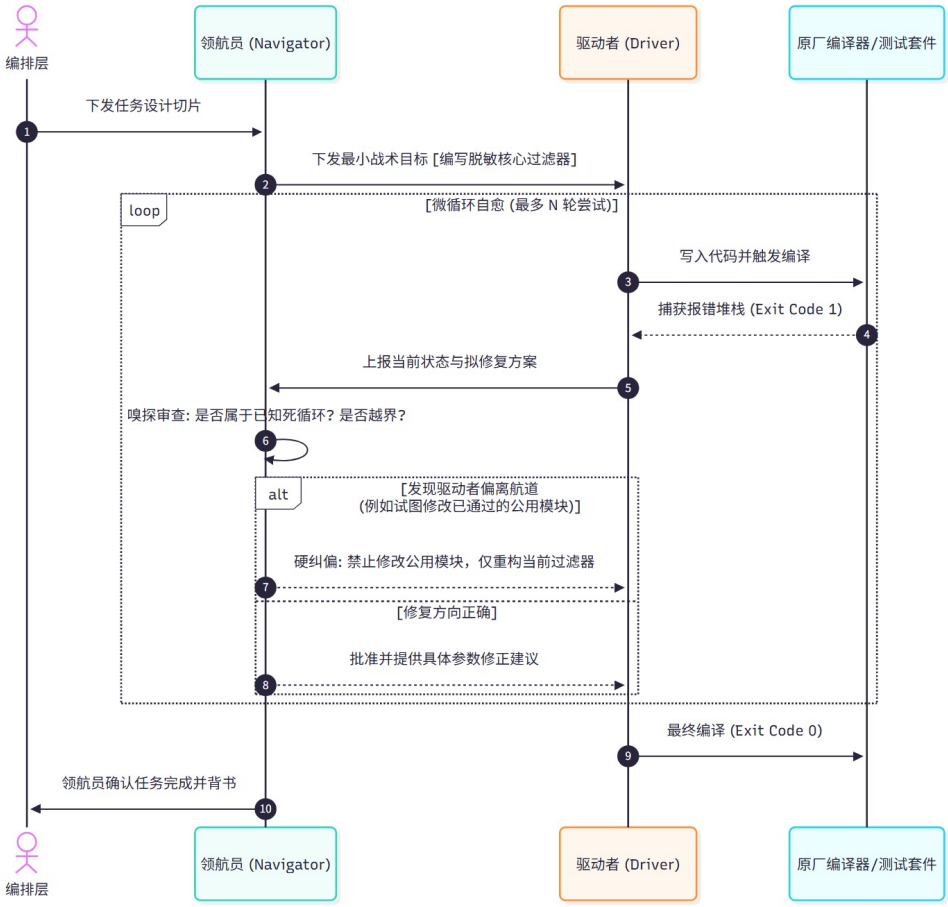


图 18: 模式 07：导航-驱动结对微循环协作时序示意

6. 后果与权衡 **(Consequences)**

- 收益 **(Pros)**：
  - 自愈收敛速度极快：领航员充当 “实时外部刹车片”，将复杂的探索空间压缩在局部航道内，规避了 80% 以上的无效盲目重试；
  - 代码品质双保险：每一行落盘代码均经历领航员的实时语义审查，减少后续全局代码评审阶段的打回频次。
- 代价 **(Cons)**：

– 多智能体并发或轮询会增加单任务的基础推理调用次数，需要配合高效的小参数量轻量模型作为驱动者/领航员角色。

---

7. 反模式警示 **(Anti-Patterns to Avoid)**

反模式名称	表现特征	为什么必须杜绝
单兵盲目狂奔 **(Lone Ranger Blackhole)**	单一智能体在无审查者监督下连续修改 10+ 轮代码	极易发生严重代码变形，最终偏离初始架构
领航员越俎代庖 **(Navigator Role Intrusion)**	领航员直接接管驱动者的写入工具自己写代码	破坏了 “一人思考一人执行” 的认知隔离，导致自我偏见（Confirmation Bias）再次滋生

---

8. 抽象算法规约 **(Algorithmic Formulation)**

```
interface PairDevSession {
  driver: DriverAgent;
  navigator: NavigatorAgent;
  maxIterations: number;
}

class SandboxPairDevLoop {
  async executePairDev(session: PairDevSession, taskSlice: TaskDesignSlice): Promise<TaskResult> {
    let iteration = 0;
    let currentFeedback: NavigatorGuidance = session.navigator.initialBrief(taskSlice);

    while (iteration < session.maxIterations) {
      iteration++;

      // 1. 驱动者在领航员指引下变异物理代码
      const mutationResult = await session.driver.actuate(currentFeedback);

      // 2. 真实原厂编译与测试
      const buildResult = await session.driver.runInSituVerify();
      if (buildResult.exitCode === 0) {
        // 领航员终审代码合规性
        const finalAudit = await session.navigator.auditFinalCode(mutationResult.modifiedFiles);
```

```
        if (finalAudit.approved) {
          return { success: true, iterations: iteration, codeArtifacts: mutationResult.modifiedFiles }
        }
      }

      // 3. 领航员对错误堆栈与变异历史进行隐式嗅探与纠偏
      currentFeedback = await session.navigator.analyzeFailureAndSteer(
        buildResult.errorOutput,
        mutationResult.mutationDiff,
        iteration
      );

      // 检测死循环
      if (currentFeedback.isLoopDetected) {
        await session.driver.rollbackToLastKnownStableState();
      }
    }

    return { success: false, reason: "MAX_ITERATIONS_EXCEEDED" };
  }
}
```

---

9. 数值宣称的可证伪地位 **(Epistemic Status of Quantitative Claims)**

处置：降级为经验目标（未验证）——“规避 80% 以上的无效盲目重试” 中的” 无效盲目重试” 目前没有可测量定义（缺少” 重试是否带来信息增益” 的判定谓词）。该数值标注为工程经验目标；若要升格，须先定义信息增益谓词并预注册阈值。

模式 **08**：白盒隐式分支嗅探与内部锚定模式 **(Implicit Branch Sniffing & Internal Invariants Pattern)**

---

1. 意图 **(Intent)**

在领航员智能体（Navigator）对驱动者（Driver）进行实时代码审查的过程中，通过静态抽象语法树（AST）分析与分支覆盖率探针，主动嗅探驱动者在变异过程中产生的隐式异常分支（**Implicit Emergent Branches**），并强制就地生成内部锚定单测（**Internal Invariants Tests**）将其白盒固化，防止因无外部验证的自我纠错不可行（Huang et al., ICLR 2024）导致的隐藏边界分支退化与奖励欺骗（Reward Hacking, Amodei et al., 2016）。

---

2. 动机与工业失效场景 **(Motivation & Real-World Failure Modes)**

在自治智能体进行代码编写与自愈修改时，通常只关注 “业务主干能否跑通通过既有用例”，这极易诱发严重的工程隐患：

- 失效场景 **A**（隐式分支无测试锚定 **Untested Emergent Branches**）：驱动者在实现 2FA 认证过滤器时，为了应对 `pre_auth_token` 校验逻辑，在代码中新引入了一个 `if (token.isExpired() || token.isRevoked()) throw new BadCredentialsException(...)` 的组合条件分支。然而驱动者只编写了针对 `isExpired()` 的测试，导致 `isRevoked()` 成为一个在生产环境下无人把关的孤儿分支。一旦后续自愈重构误删该判断，既有用例依然 100% 绿灯，造成安全防御失效；
- 失效场景 **B**（利用空断言的奖励欺骗 **Reward Hacking**）：驱动者在实现异常捕获逻辑时，为了防止测试报错，悄悄在 `catch (Exception e)` 中仅仅打印了一行日志，或者直接返回空对象 `return null`。由于既有黑盒测试没有断言异常类型，该行为骗取了测试通过（Falsified Pass），实质上掩盖了严重系统缺陷；
- 失效场景 **C**（内部架构契约腐化 **Architecture Erosion**）：驱动者为了图方便，将原本由架构设计严格规定的 “通过构造函数显式注入服务接口（Constructor Injection）” 退化为 “基于反射的私有字段注入（Field Injection）”，或者将原本受限的包私有类修饰符擅自暴露为 `public`，破坏了系统封装性。

---

3. 适用性 **(Applicability)**

- 涉及严密安全边界、权限控制、状态机流转等不可出错的关键逻辑；
- 研发智能体频繁执行自愈重试的微循环环境；
- 需要沉淀长期活文档（Living Specs）并防止代码向坏味道退化的场景。

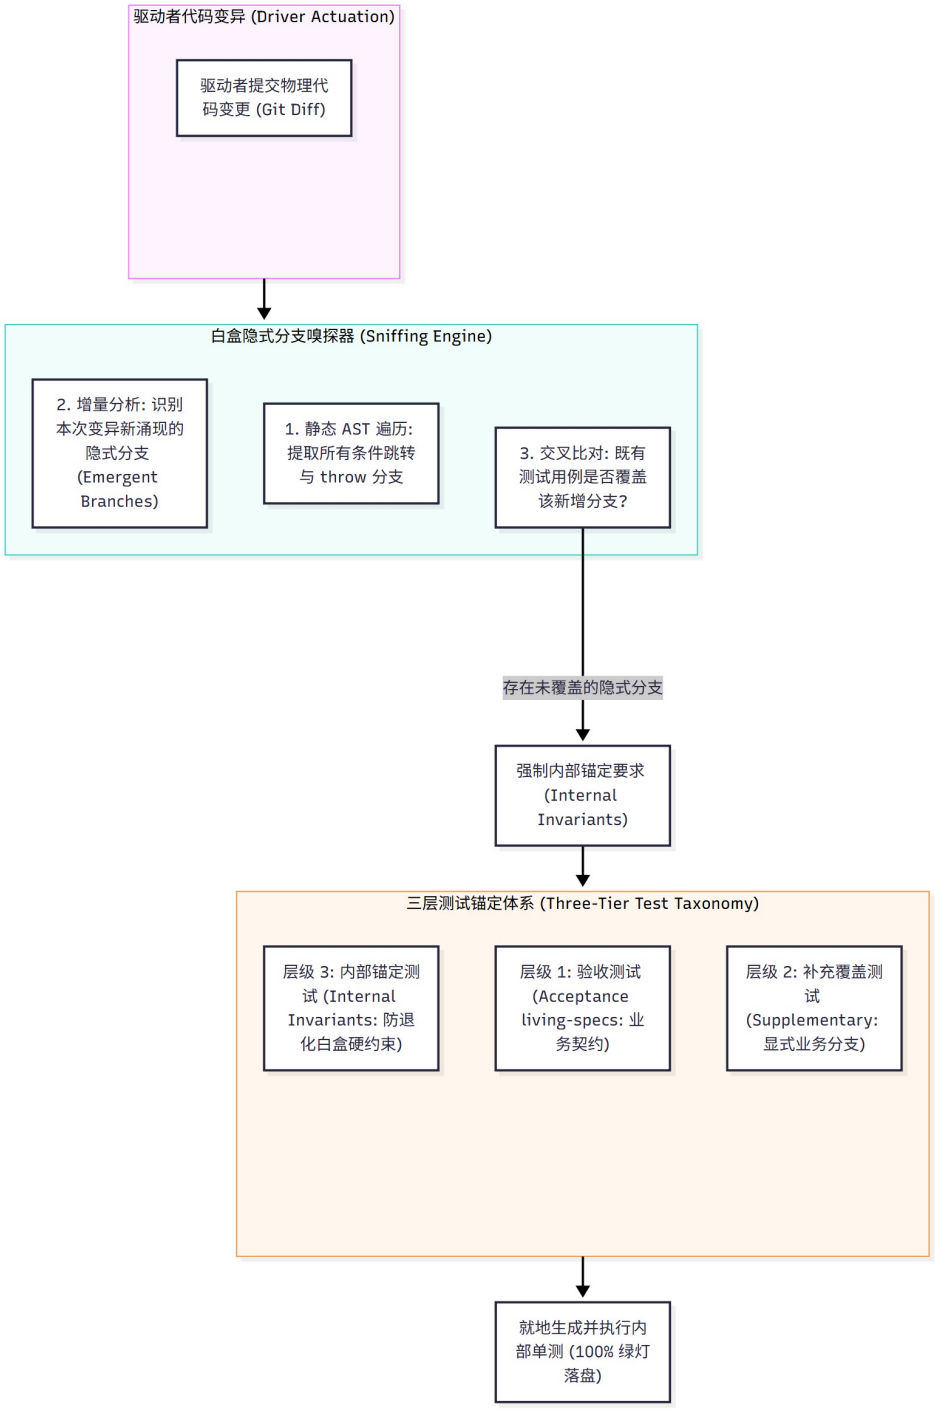


图 19: 模式 08：隐式分支未被覆盖的失效场景示意

4. 参与者与职责 **(Participants)**

1. 变异驱动者 **(Driver Agent)**：负责提出代码实现与初步用例；
2. 分支嗅探器 **(Branch Sniffer)**：集成在领航员内部的静态代码分析器，负责追踪变异产生的控制流图（CFG）增量；
3. 三层测试仲裁器 **(Test Taxonomy Arbiter)**：负责将新生成的测试进行分流：
   - 验收用例（**Acceptance Specs**）：满足业务需求，未来可晋升为活文档；
   - 补充覆盖用例（**Supplementary Coverage**）：覆盖正常业务分支；
   - 内部锚定测试（**Internal Invariants**）：针对防御性编程、单参构造约束、特定异常透明透传建立白盒锚定，禁止后续自愈操作删除或软化。

---

5. 协作协议与因果约束 **(Collaborations)**

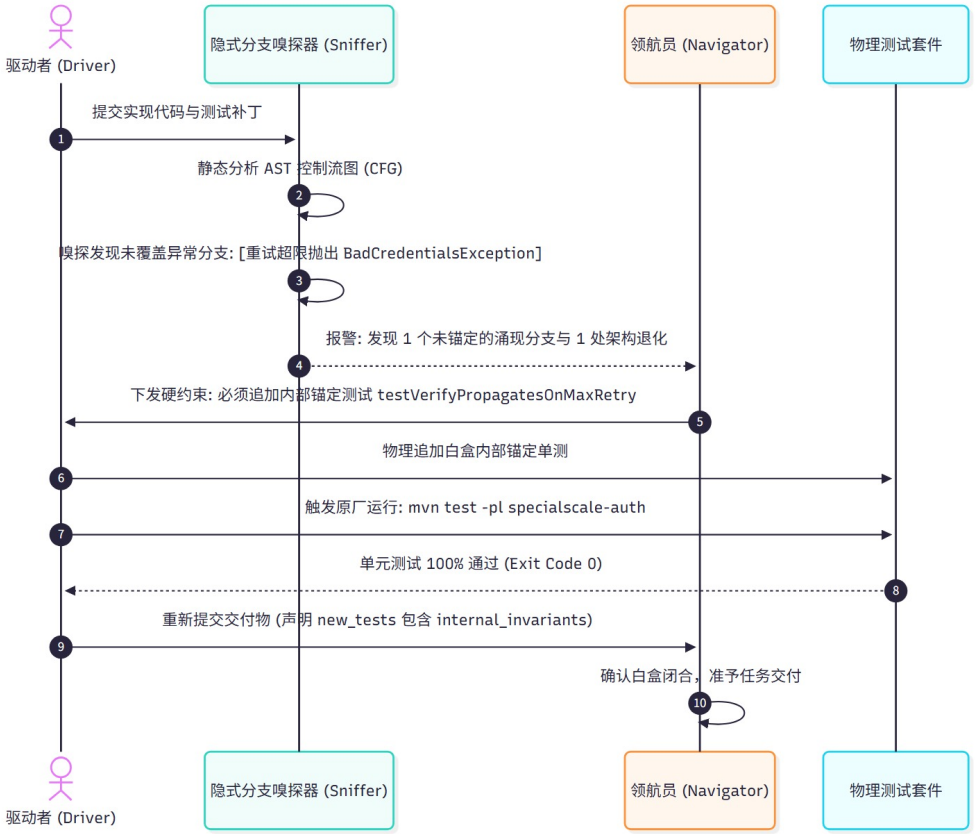


图 20: 模式 08：分支嗅探-导航-底座内部锚定时序示意

---

6. 后果与权衡 **(Consequences)**

- 收益 **(Pros)**：
  - 杜绝隐式回归：所有涌现分支均被物理单测就地锁定，后续任务若误删代码将立即触发编译失败（Exit 1），实现物理自保；
  - 防范奖励欺骗：驱动者无法通过空实现或异常吞噬蒙混过关；
  - 架构结构刚性：单参构造依赖注入等架构规范被单测代码机械锚定，防止代码腐化。
- 代价 **(Cons)**：
  - 单测文件行数增加约 30%~60%；
  - 嗅探过程需要引入轻量级 AST 解析器，增加单轮审查时延。

---

7. 反模式警示 **(Anti-Patterns to Avoid)**

反模式名称	表现特征	为什么必须杜绝
测试篡改脱罪 **(Test Tampering to Pass)**	驱动者为了让构建变绿，直接注释或删除既有用例	属于典型的规范博弈（Specification Gaming），破坏系统安全堤坝
只管主干无视边角 **(Happy-Path Only Fallacy)**	仅测试正常返回 200，对所有 4xx/5xx 与异常抛出不写断言	系统上线后一旦遇到非法输入将直接引发未捕获崩溃

---

8. 抽象算法规约 **(Algorithmic Formulation)**

```
interface EmergentBranch {
  location: string;
  conditionDescription: string;
  thrownException?: string;
  isCoveredByExistingTests: boolean;
}

class WhiteboxBranchSniffer {
  sniffBranches(sourceCode: string, testCode: string): EmergentBranch[] {
    const ast = parseJavaAst(sourceCode);
    const branches: EmergentBranch[] = [];

    // 1. 遍历 AST 提取所有防御性分支与异常节点
    traverse(ast, {
      IfStatement(path) {
```

```
        if (containsThrowStatement(path.node.consequent)) {
          branches.push({
            location: `Line:${path.node.loc.start.line}`,
            conditionDescription: printSource(path.node.test),
            thrownException: extractExceptionClass(path.node.consequent),
            isCoveredByExistingTests: false
          });
        }
      }
    });

    // 2. 交叉核对测试代码中的断言与 Mock 行为
    for (const b of branches) {
      if (testCode.includes(b.thrownException || "") && testCode.includes(b.conditionDescription)) {
        b.isCoveredByExistingTests = true;
      }
    }

    return branches.filter(b => !b.isCoveredByExistingTests);
  }
}
```

---

9. 数值宣称的可证伪地位 **(Epistemic Status of Quantitative Claims)**

处置：降级为代理指标（部分可补测）——“单测文件行数增加约 30%~60%” 是代理量而非目标量：真正的目标是孤儿分支检出率。行数增幅不构成理论结论；孤儿分支检出率可通过在既有用例集上注入变异体补测（变异体存活率越低，检出率越高）。

模式 09：幂等变异日志与物理时钟补偿模式 (Idempotent Journaling & Mtime Touch Pattern)

---

1. 意图 **(Intent)**

为智能体针对物理底座的所有写操作建立规范化 **SHA-256** 签名日志（**Idempotent Journaling**）与物理文件系统时钟补偿机制（**Mtime Touch Compensation**），解决智能体自愈重试过程中的变异叠加错位，并消除因毫秒级高频覆写导致现代编译器缓存命中（Stale Cache）而引发的虚假构建状态。

---

2. 动机与工业失效场景 **(Motivation & Real-World Failure Modes)**

在真实工业软件工程中，文件系统与编译器具有严格的因果与时间敏感性：- 失效场景 **A**（重试变异叠加错位）：智能体调用 `replace_file_content` 工具修复某行代码，如果第一次调用因网络超时中断，智能体触发重试，由于上一轮可能已经部分写入，第二次基于相同行号或文本的替换将导致目标文本找不到、或发生双重插入，使代码文件损毁；- 失效场景 **B**（**Mtime** 停滞导致编译器假死）：智能体在修复 Bug 时，从读文件、分析到写回只消耗了 200 毫秒，写入完成的文件修改时间（Mtime）与上一次写入落在操作系统的同一个时间戳内（特别是在秒级时间戳粒度的某些文件系统或打包工具中）。随后触发 `mvn compile` 或 `webpack` 时，构建工具检测到文件的 `mtime <= last_build_time`，直接跳过了该文件的重新编译，继续运行旧的 `.class` 字节码，导致智能体陷入 “明明改了代码但报错毫无变化” 的虚假困境；- 失效场景 **C**（空流与隐式状态丢失）：智能体执行写入后遭遇异常，无法准确溯源物理磁盘上到底停留在哪一个历史快照，导致自愈回退操作无从下手。

---

3. 适用性 **(Applicability)**

- 任何具备增量编译缓存（Incremental Build Cache）的现代编译型语言工程（Java, C++, Rust, Go, TypeScript）；
- 涉及自动重试机制或多步复杂自愈修复循环（Self-Healing Loops）；
- 需要绝对可靠的物理状态快照与回退支持。

---

4. 参与者与职责 **(Participants)**

1. 变异日志管理器 **(Mutation Journal Manager)**：为每一次写操作计算规范化内容哈希与目标文件上下文指纹，维护前向重放与后向回退栈；

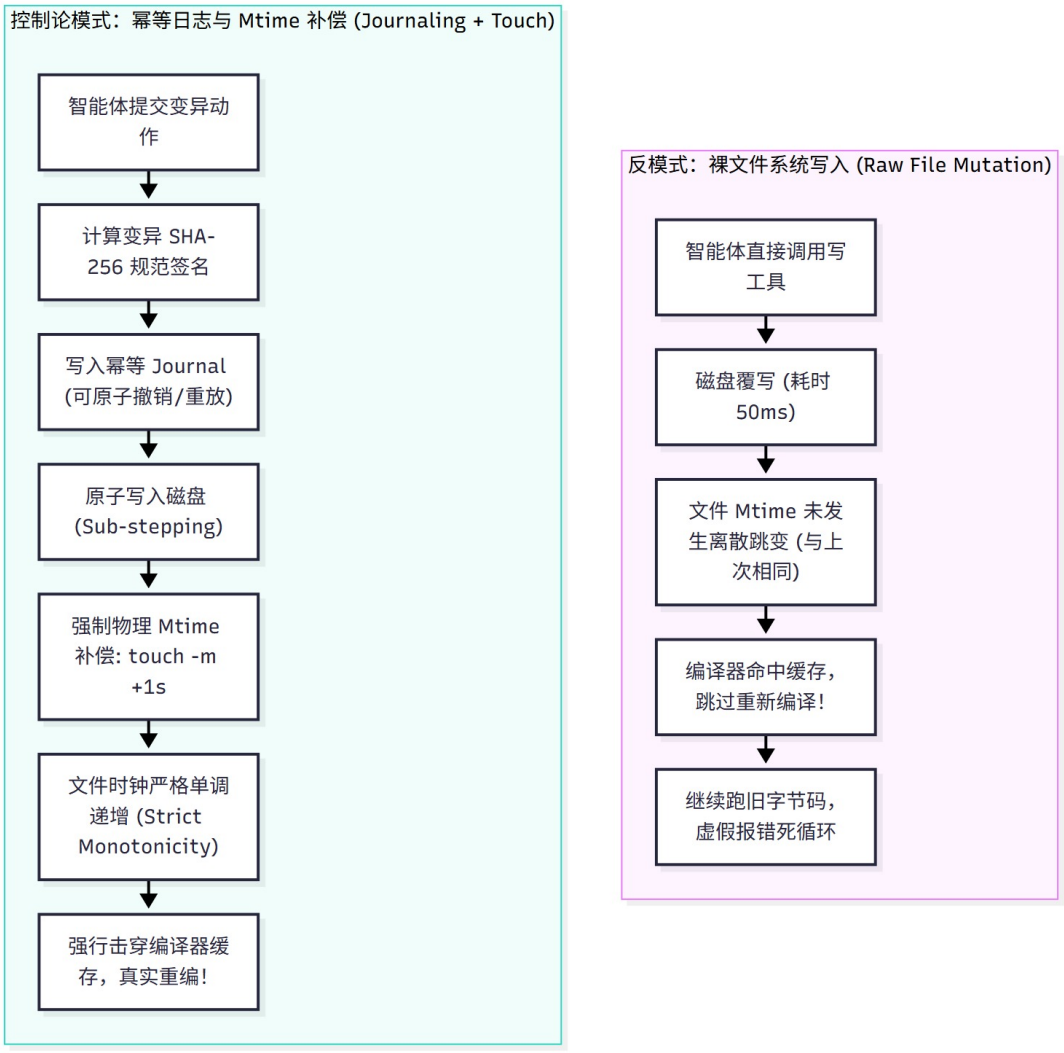


图 21: 模式 09：写工具缺失幂等日志的失效场景示意

2. 原子执行器 **(Atomic Sub-stepper)**：负责将写操作分解为原子子步（写入临时文件、原子重命名移动），防止半写入导致文件损坏；
3. 物理时钟补偿器 **(Mtime Touch Compensator)**：在写入完成后，直接调用操作系统底层系统调用（如 `fs.utimes` 或 `touch`），显式将目标文件的 `mtime` 推进至当前时钟加 1 秒，破坏增量编译器的缓存命中条件。

---

5. 协作协议与因果约束 **(Collaborations)**

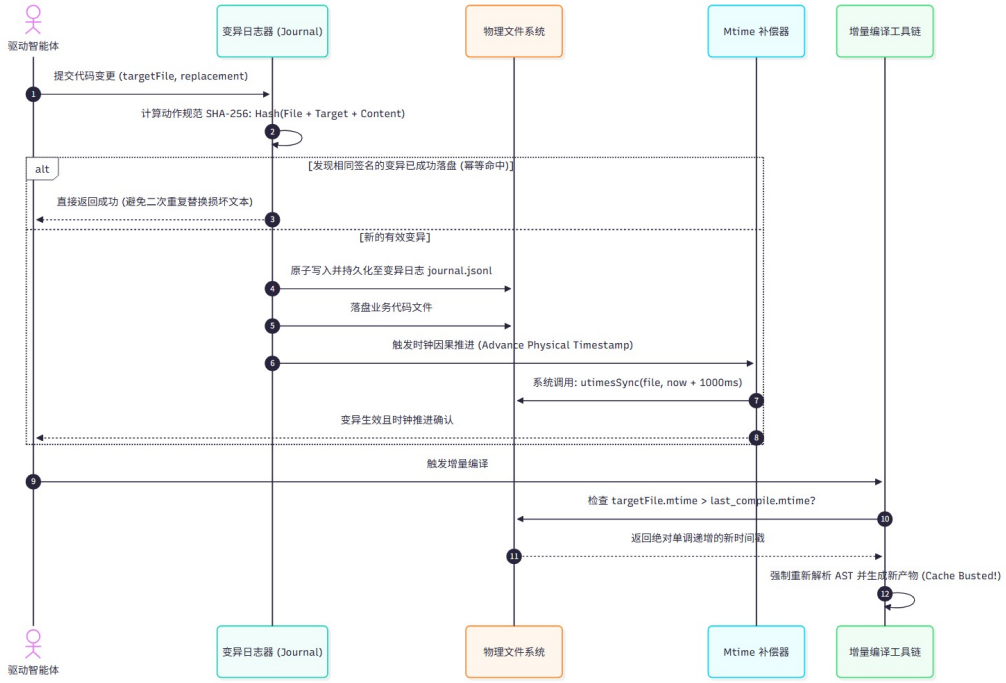


图 22: 模式 09：幂等日志-物理时钟补偿协作时序示意

---

6. 后果与权衡 **(Consequences)**

- 收益 **(Pros)**：
  - 消除编译器幽灵报错：确保每一次代码修改都能 100% 触发物理编译，终结 “代码修改了但字节码没变” 的调试恶梦；
  - 状态重放安全幂等：网络中断或智能体误触发重试时，绝对不会破坏目标源码语法。
- 代价 **(Cons)**：
  - 引入了轻微的文件系统系统调用开销（每步操作增加几毫秒）；
  - 需要在沙箱环境中保障对文件元数据修改的系统权限。

---

7. 反模式警示 **(Anti-Patterns to Avoid)**

反模式名称	表现特征	为什么必须杜绝
裸字符直写 **(Raw String Replacement)**	直接在原始文件上进行非幂等的正则替换	重试时由于原字符已被替换，二次重试必然抛出找不到锚点的异常
盲信系统时钟 **(Blind System Clock Trust)**	假设写完文件后编译器自然能感知	现代多核与高频变异下，Mtime 停留在同一秒极其常见，导致增量编译漏编

---

8. 抽象算法规约 **(Algorithmic Formulation)**

```
import * as fs from "fs";
import * as crypto from "crypto";

interface MutationEntry {
  journalId: string;
  filePath: string;
  sha256: string;
  appliedTimestamp: number;
}

class IdempotentSubstrateMutator {
  private journal: Map<string, MutationEntry> = new Map();

  async applyMutation(filePath: string, originalContent: string, newContent: string): Promise<boolean>
    // 1. 计算变异指纹 (Canonical SHA-256)
    const signature = crypto.createHash("sha256")
      .update(filePath)
      .update(originalContent)
      .update(newContent)
      .digest("hex");

    if (this.journal.has(signature)) {
      // 幂等防御：已执行过完全相同的变异，安全跳过
      return true;
    }

    // 2. 原子写入物理文件
    const tmpPath = `${filePath}.tmp.${Date.now()}`;
```

```
    await fs.promises.writeFile(tmpPath, newContent, "utf8");
    await fs.promises.rename(tmpPath, filePath);

    // 3. 物理 Mtime 补偿 (强制时间戳单调递增，击穿编译缓存)
    const compensatedTime = (Date.now() + 1000) / 1000;
    fs.utimesSync(filePath, compensatedTime, compensatedTime);

    // 4. 记入持久化日志
    this.journal.set(signature, {
      journalId: signature,
      filePath,
      sha256: signature,
      appliedTimestamp: Date.now()
    });

    return true;
  }
}
```

模式 **10**：分布式物理底座租约锁模式 **(Substrate Lease Lock & Watchdog Pattern)**

---

1. 意图 **(Intent)**

在多对等智能体（Peer Agents）或异构扩展代理协作场景下，针对物理底座的共享资源建立基于租约协议（**Lease Protocol**）、心跳看门狗（**Watchdog**）与状态防篡改校验的排他写锁机制，强行将未持锁代理降级为主写从读（Primary-Writer Replica-Reader），防止并发代码写写冲突与死锁。

---

2. 动机与工业失效场景 **(Motivation & Real-World Failure Modes)**

当智能体系统从单体进化到多智能体并发协同（例如流水线主代理与 IDE 端辅助代理、代码生成代理与并发单测补全代理同时工作）时，传统的无锁设计必然崩溃：- 失效场景 **A**（写写竞争导致代码撕裂）：两个智能体在几乎相同的时刻对同一个 Java 类进行并发编辑，导致 Git 工作区出现未解决的物理冲突标签（`<<<<<<< HEAD`），后续两方都无法继续解析语法；- 失效场景 **B**（死锁与孤儿锁）：持有写锁的智能体因模型生成超时、网络中断或进程崩溃而意外终止，但由于锁未设置超时续约机制，导致整个工程被永久锁死（Deadlock），后续所有流水线任务永久挂起；- 失效场景 **C**（越权偷跑）：副智能体（如辅助问答代理）在未经授权的情况下直接修改了正在编译的代码，破坏了主智能体正在验证的环境纯洁性。

---

3. 适用性 **(Applicability)**

- 多个自主智能体共享同一个代码仓库或物理工作区的场景；
- IDE 客户端插件（如 Cline、Trae、Cursor）与后台自治流水线并发协作的环境；
- 长周期任务与异步背景自愈任务并行的系统。

---

4. 参与者与职责 **(Participants)**

1. 租约仲裁器 **(Lease Arbiter)**：基于文件锁或原子分布式原语的仲裁实体，负责锁的颁发、续期与释放；
2. 租约契约 **(Lease Contract)**：受机器 Schema 严格约束的元数据（包含持锁者 ID、持锁角色、授予时间戳、TTL 过期毫秒数与校验指纹）；

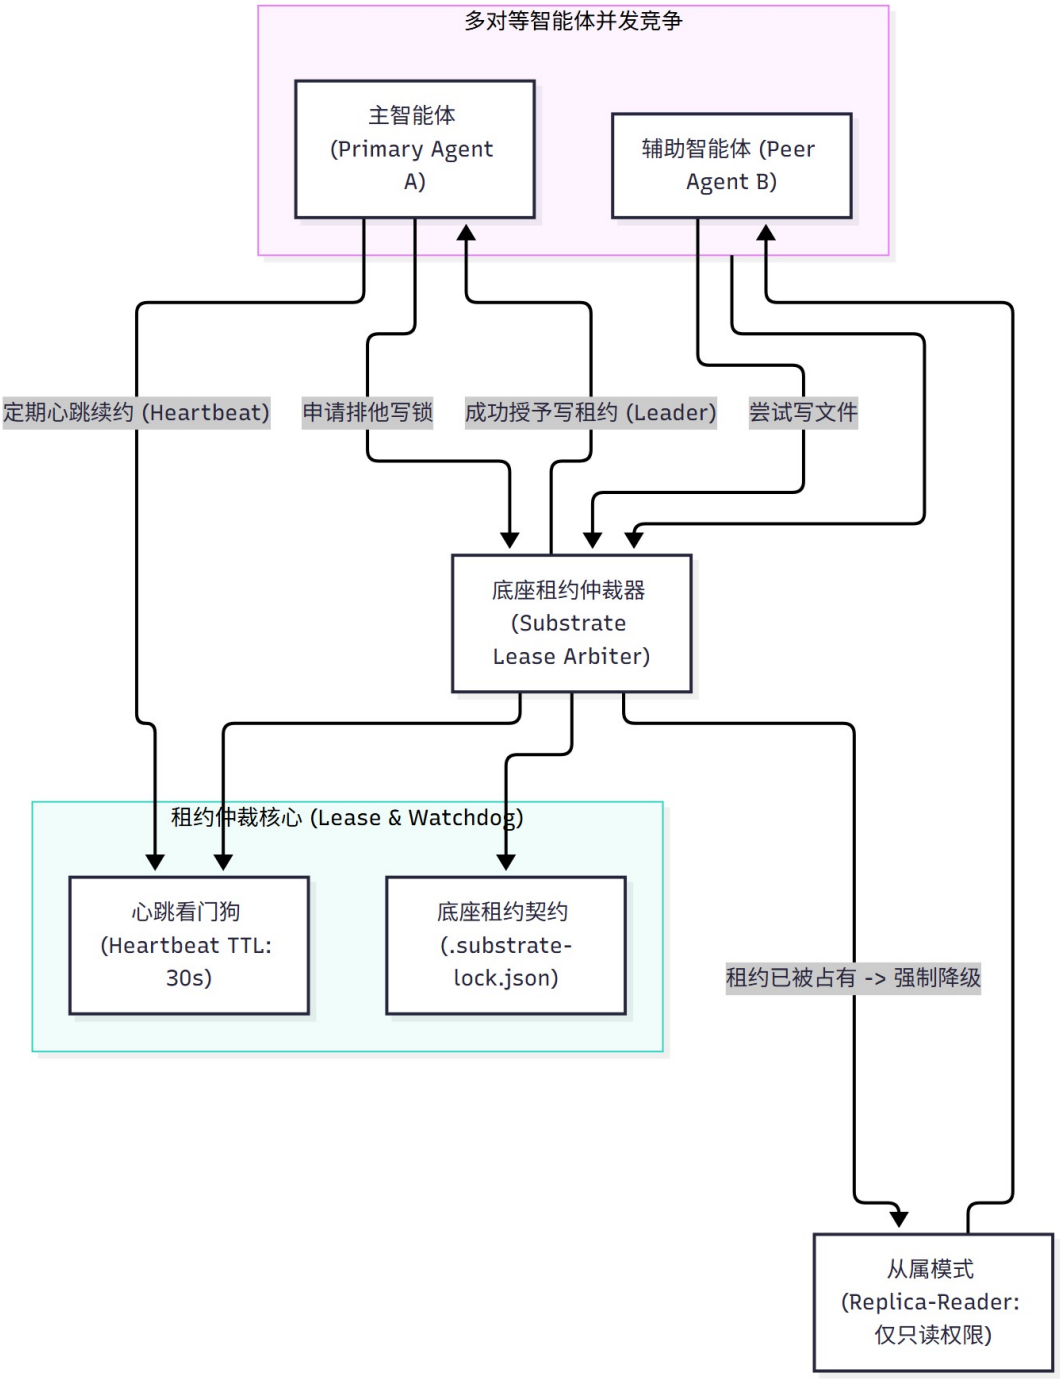


图 23: 模式 10：租约契约缺失导致并发写冲突场景示意

3. 心跳看门狗 **(Heartbeat Watchdog)**：后台异步巡检器，当检测到持锁者因崩溃未在 TTL 内发送心跳时，自动安全回收租约（Safe Eviction）；
4. 从读降级器 **(Replica-Reader Interceptor)**：拦截未持锁者的写变异系统调用，将其转换为只读分析视图或在内存中进行影子模拟，禁止落盘。

---

5. 协作协议与因果约束 **(Collaborations)**

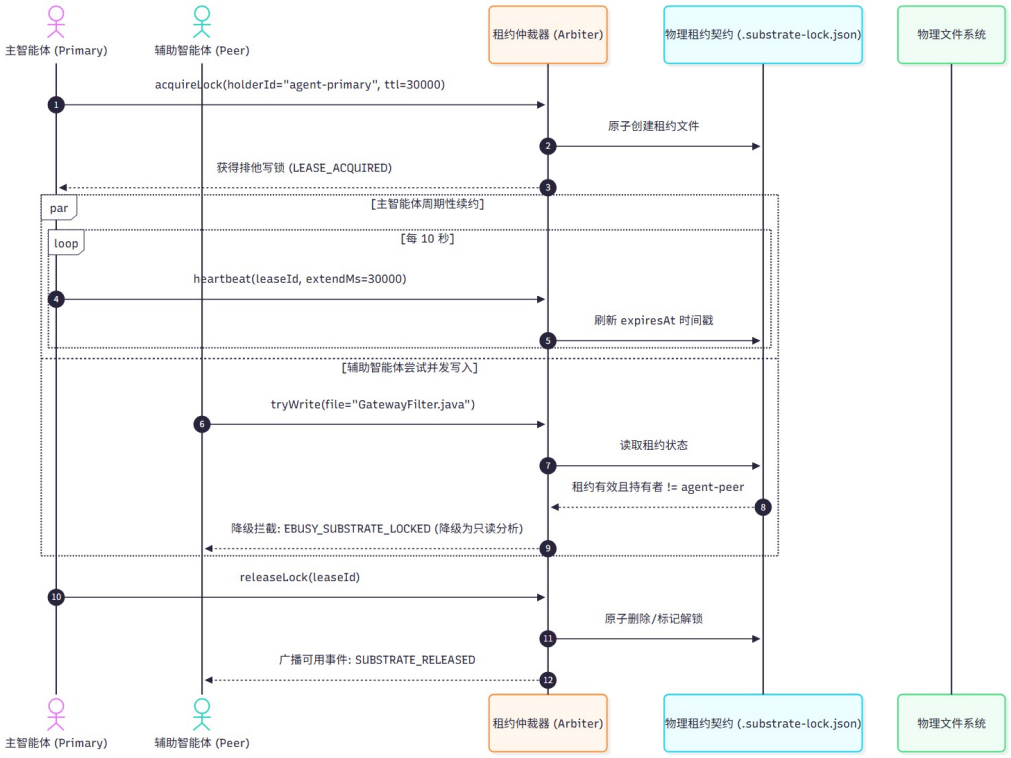


图 24: 模式 10：租约仲裁-锁状态-文件系统协作时序示意

---

6. 后果与权衡 **(Consequences)**

- 收益 **(Pros)**：
  - 物理底座绝对一致性：消除多 Agent 并发写入引发的代码撕裂与 Git 冲突（租约互斥机检，附录 B.4）；
  - 故障自动免疫与自愈：依靠 TTL 看门狗机制，任何单点 Agent 的意外崩溃都不会导致整个工程被死锁。
- 代价 **(Cons)**：
  - 需要在智能体 SDK 层实现定期心跳背景协程（Goroutine/Timer）；
  - 副智能体在等待排他锁期间会产生一定的排队时延。

---

7. 反模式警示 **(Anti-Patterns to Avoid)**

反模式名称	表现特征	为什么必须杜绝
无超时的永久互斥锁 **(Indefinite Mutex Trap)**	仅在进入时建锁，退出时删锁，无 TTL 设置	智能体进程一旦被 OOM 杀死，锁文件残留将导致系统永久死锁
乐观盲写冲突 **(Optimistic Blind Mutation)**	允许多个智能体自由覆写，事后依赖 Git merge	LLM 对 Git 冲突标记处理能力极差，极易破坏有效代码

---

8. 抽象算法规约 **(Algorithmic Formulation)**

```
interface SubstrateLease {
  leaseId: string;
  holderId: string;
  role: string;
  grantedAt: number;
  expiresAt: number;
  checksum: string;
}

class SubstrateLockManager {
  private readonly lockFilePath = ".substrate-lock.json";
  private readonly defaultTtlMs = 30000;

  acquireLock(holderId: string, role: string): boolean {
    const now = Date.now();
    if (fs.existsSync(this.lockFilePath)) {
      const currentLease: SubstrateLease = JSON.parse(fs.readFileSync(this.lockFilePath, "utf8"));
      // 检查租约是否仍有效
      if (now < currentLease.expiresAt && currentLease.holderId !== holderId) {
        return false; // 被他人持锁，申请失败
      }
    }

    // 颁发新租约
    const newLease: SubstrateLease = {
```

```
      leaseId: crypto.randomUUID(),
      holderId,
      role,
      grantedAt: now,
      expiresAt: now + this.defaultTtlMs,
      checksum: this.computeChecksum(holderId, now)
    };

    fs.writeFileSync(this.lockFilePath, JSON.stringify(newLease, null, 2), "utf8");
    return true;
  }

  heartbeat(leaseId: string, holderId: string): boolean {
    if (!fs.existsSync(this.lockFilePath)) return false;
    const lease: SubstrateLease = JSON.parse(fs.readFileSync(this.lockFilePath, "utf8"));
    if (lease.leaseId === leaseId && lease.holderId === holderId) {
      lease.expiresAt = Date.now() + this.defaultTtlMs;
      fs.writeFileSync(this.lockFilePath, JSON.stringify(lease, null, 2), "utf8");
      return true;
    }
    return false;
  }
}
```

模式 11：主写从读降级互斥模式 (Primary-Writer Replica-Reader Pattern)

---

1. 意图 **(Intent)**

在多对等智能体（Peer Agents）协同演化的分布式系统环境中，依据因果时序与底座租约状态，将未持有排他写租约（Lease, Gray & Cheriton, SOSP 1989）的辅助智能体强行降级为只读分析从属节点（**Replica-Reader**）。通过物理写调用的原子拦截与内存影子工作区（Shadow Scratchpad）重定向，杜绝因并发盲目变异导致的代码撕裂与 Git 工作树死锁。

---

2. 动机与工业失效场景 **(Motivation & Real-World Failure Modes)**

随着多智能体协作架构由传统的“单体流水线”演进为“多端对等协作”（例如开发者在 IDE 内运行辅助扩展、CI/CD 跑自治流水线、代码评审代理并发执行建议），多智能体同时向同一个工作区进行状态写入成为不可回避的物理现实：

- 失效场景 **A**（写写冲突导致代码撕裂 **Split-Brain Code Tearing**）：主流水线正在执行网关模块的单测编译，IDE 端的辅助智能体在未获知底层构建锁状态的前提下，因响应用户的交互指令，直接修改了该模块的 POM 文件或同一个 Java 类，导致底层 Git 产生冲突标记，正在执行的编译瞬间崩溃；
- 失效场景 **B**（并发破坏环境纯洁性 **Substrate Contamination**）：辅助智能体在后台尝试“自愈代码”，擅自执行了 `git reset --hard` 或 `mvn clean`，直接将主力流水线刚写入但尚未提交的临时字节码或中间产物抹除；
- 失效场景 **C**（粗暴打断导致用户心智负担 **Lock-Out Starvation**）：如果简单粗暴地将未持锁的智能体进程强行杀死，将破坏人机交互连续性，导致开发者在终端或 IDE 界面遭遇突兀的报错弹窗。

---

3. 适用性 **(Applicability)**

- 多个不同厂商或不同进程的智能体（如自建 CI 流水线、各类 IDE 编码智能体）接入同一个企业工程仓库；
- 具有清晰的主备责任划分（Leader-Follower）、需要保障主流水线构建绝对纯净的场景；
- 允许从属节点提出代码建议但严禁私自落盘的协作架构。

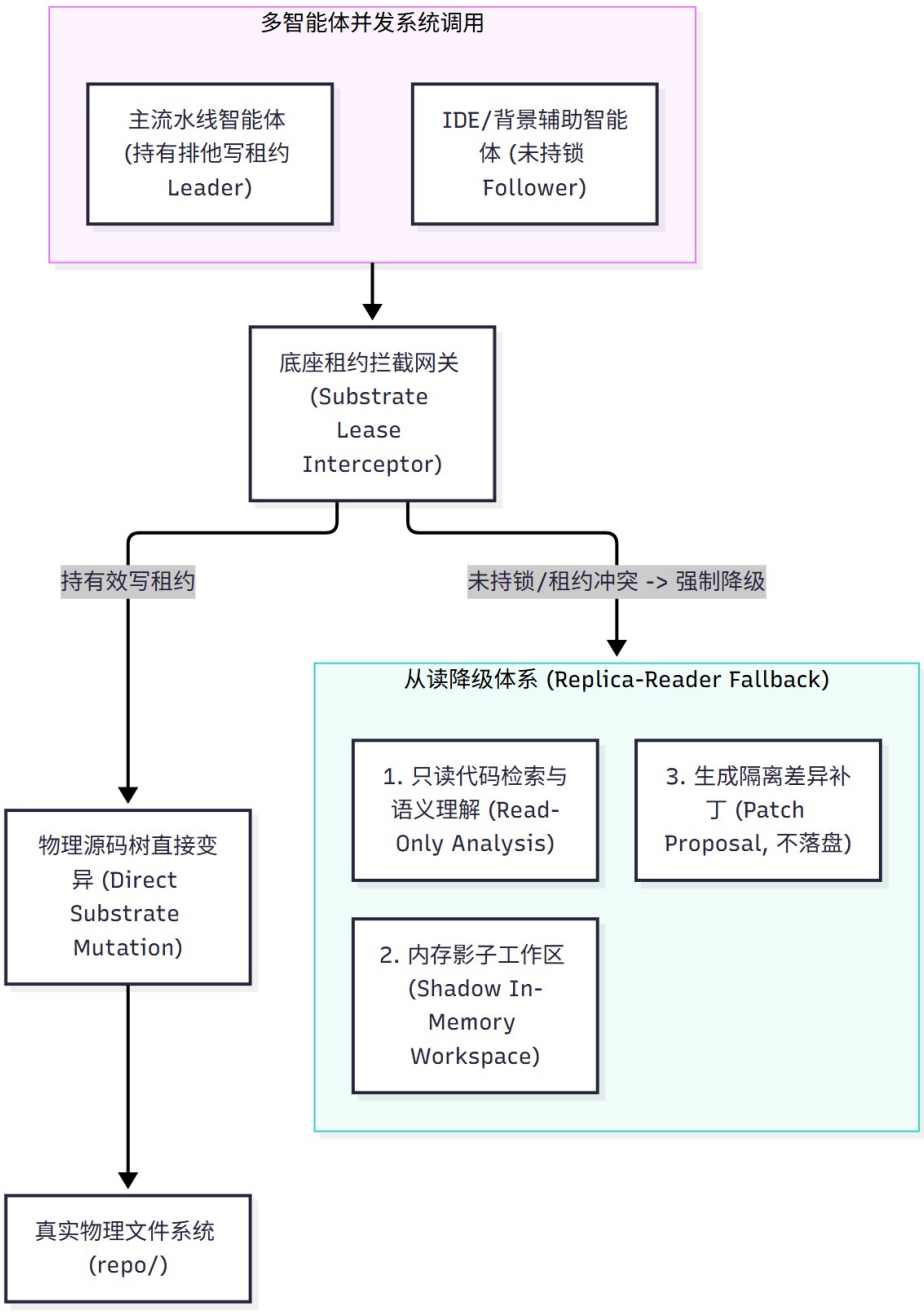


图 25: 模式 11：主写从读互斥失效场景示意

4. 参与者与职责 **(Participants)**

1. 主写入者 **(Primary-Writer)**：通过分布式底座租约锁（模式 10）成功申请到排他写权（Leader）的智能体，拥有对物理文件系统的直接修改与原厂构建特权；
2. 从属读取者 **(Replica-Reader)**：未竞争到写租约的对等智能体，其写权限被拦截网关透明剥离，自动降级为观察者与建议者；
3. 租约降级拦截器 **(Lease Degradation Interceptor)**：位于操作系统系统调用（FS Tool Calls）与物理磁盘之间的中间件，负责鉴权并实施降级；
4. 影子工作区 **(Shadow Scratchpad)**：为从属读取者开辟的无状态临时内存或隔离分支，允许其在虚拟空间演练代码补丁，绝不污染物理主干。

---

5. 协作协议与因果约束 **(Collaborations)**

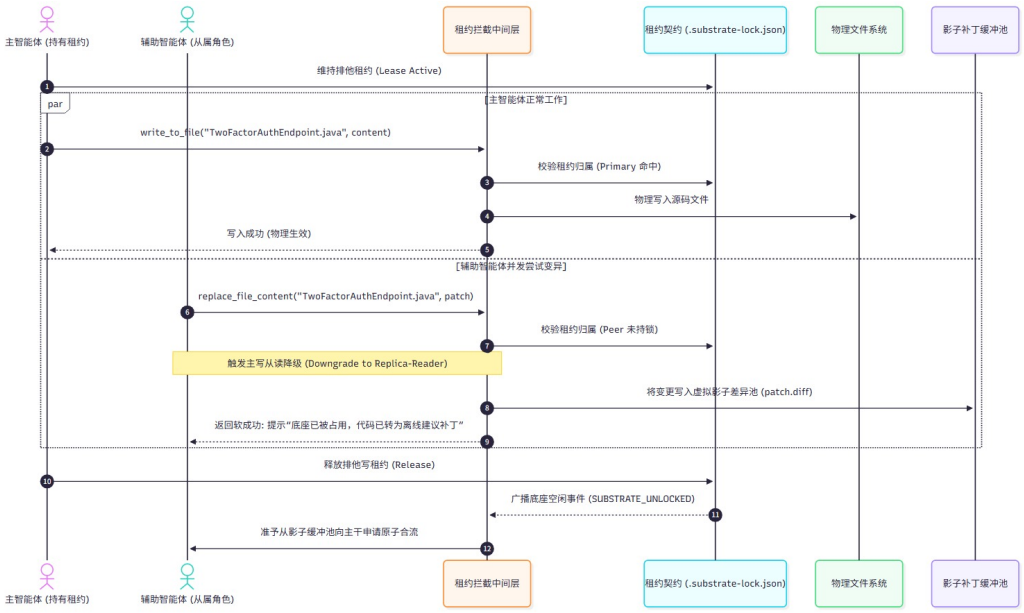


图 26: 模式 11：写拦截-影子工作区从读协作时序示意

---

6. 后果与权衡 **(Consequences)**

- 收益 **(Pros)**：
  - 物理底座零污染：避免了多智能体竞争导致的 Git 索引破损、文件双重修改与编译假死；
  - 用户体验连续无中断：未持锁智能体不会直接崩溃，而是以只读或建议补丁的形式继续提供交互支持；
  - 遵循经典分布式因果律（**Lamport, 1978**）：写操作具有全局唯一的全序因果排列。

- 代价 **(Cons)**：
  - 需要在平台层虚拟化文件写操作（影子补丁机制）；
  - 从属节点产生的补丁需要额外的合流审批流程。

---

7. 反模式警示 **(Anti-Patterns to Avoid)**

反模式名称	表现特征	为什么必须杜绝
盲目无锁并发 **(Blind Lockless Mutation)**	允许多个智能体自由竞争写入同一工作区	必然引发代码撕裂与编译器状态错乱
粗暴硬杀死 **(Hard Kill Starvation)**	检测到非持锁者写操作直接强杀进程	破坏人机交互体验，造成不可预测的数据丢失

---

8. 抽象算法规约 **(Algorithmic Formulation)**

```
interface WriteRequest {
  agentId: string;
  filePath: string;
  newContent: string;
}

class PrimaryWriterReplicaReaderInterceptor {
  private leaseManager: SubstrateLeaseManager;
  private shadowBuffer: Map<string, string> = new Map();

  async interceptWrite(req: WriteRequest): Promise<WriteVerdict> {
    const isPrimary = this.leaseManager.hasExclusiveLease(req.agentId);

    if (isPrimary) {
      // 1. 主智能体：物理落盘
      await fs.promises.writeFile(req.filePath, req.newContent, "utf8");
      return { success: true, mode: "PHYSICAL_DIRECT", message: "Written to substrate" };
    }

    // 2. 从属节点：强制降级为影子缓冲
    const shadowKey = `${req.agentId}:${req.filePath}`;
    this.shadowBuffer.set(shadowKey, req.newContent);
```

```
    return {
      success: true,
      mode: "SHADOW_REPLICA_BUFFERED",
      message: "Substrate locked by primary agent. Changes preserved as offline proposal patch."
    };
  }
}
```

---

9. 理论地位与形式化锚点 **(Epistemic Status)**

可定理化（已证，零 **sorry**）：本模式的核心并发主张已在 Lean 4 内核中验证，模块 `Pattern11PrimaryWriter`（`formal_proof/IACFormalization`），对应附录 B.9。

- 单写者前提不是额外约定：`writer_unique_of_lease` 直接由模式 10 的 `canWrite_unique` 推出——同一时刻至多一个智能体持有写权限。
- 写日志层：`eq_of_mem_of_tick_eq` 证明合法日志中同刻度即同一事件；`writer_unique_per_tick` 给出”同刻度同写入者”，即并发写写冲突在协议内不可能。
- 读一致性：`view_mono` 与 `no_lost_write` 证明从读者的视图是完整前缀——较晚读取包含较早读取的全部事件，且任何已提交事件必然可见，不存在”跳过中间提交”的视图。

推论的可证伪指标：主写提交后，从读者读到的事件集合必须等于”tick $\leq$ 读取时刻”的日志前缀；若观测到缺失或乱序，则该定理的前提（时钟严格递增、租约互斥）在实现中不成立。

模式 12：异构对等智能体抽象协议桥接模式 (Peer-Agent Protocol Bridge Pattern)

---

1. 意图 **(Intent)**

通过标准化的模型上下文协议（Model Context Protocol, MCP）与对等智能体事件总线（Peer-Agent Event Bus），在异构智能体运行时（如自治后台流水线、IDE 客户端插件、代码审查机器人）之间建立非对称能力协商、双向上下文投影与因果状态中继，打破各厂商智能体生态的数据孤岛与语义壁垒。

---

2. 动机与工业失效场景 **(Motivation & Real-World Failure Modes)**

在现代软件工程实践中，企业不可能仅使用单一厂商的闭门智能体产品。典型的生产环境通常是异构共存的：后台运行着自研的端到端 SDLC 编排流水线，前端开发者在 IDE 中使用基于 MCP 或自定义协议的插件（如 Trae、Cline、Cursor），外部还接入了第三方安全审计机器人。

当这些异构智能体（**Heterogeneous Agents**）试图在同一个代码基质上协同作业时，通常引发以下失效：

- 失效场景 **A**（语义协议割裂 **Semantic Tower of Babel**）：不同的智能体遵循不同的内部状态机定义（例如流水线将当前状态标记为 `pm_gate_passed`，而 IDE 客户端仅理解简单的 `review_pending`），缺乏语义转换层导致各方无法理解对方的进度意图；
- 失效场景 **B**（上下文全量硬拷贝引发上下文退化 **Context Rot**）：为了让 IDE 端智能体了解后台流水线的背景，简单粗暴地将上百页的后台日志、全部门禁报告全量塞入 MCP 资源中，直接导致 IDE 智能体发生严重的上下文退化（Liu et al., 2024），丧失基本代码分析能力；
- 失效场景 **C**（事件广播风暴与竞态死锁 **Event Storm & Race Conditions**）：多个智能体通过无序轮询监听工作区文件变动，一个智能体修改文件触发另一个智能体自动构建，进而触发第三个智能体触发 Git commit，系统陷入死循环事件风暴。

---

3. 适用性 **(Applicability)**

- 企业内部需要将自治流水线与开发者桌面 IDE 编程助手打通的场景；
- 混合使用不同大语言模型（如 Claude, Gemini, DeepSeek, 本地私有化模型）的多 Agent 异构架构；
- 需要向第三方审计工具标准化暴露工程进度、证据链（Evidence）与门禁打分结果的系统。

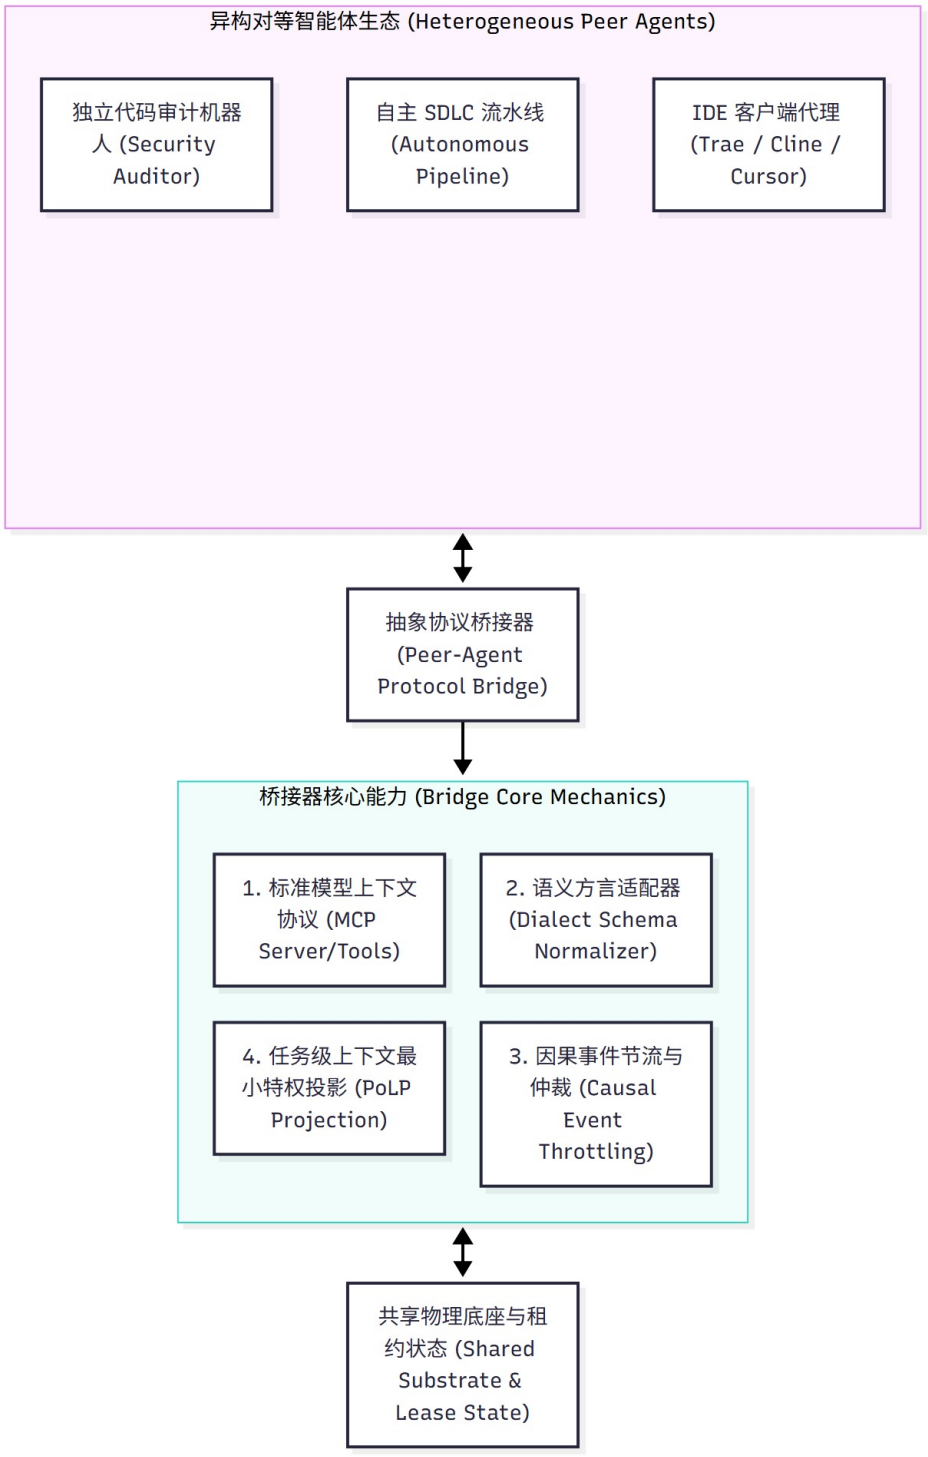


图 27: 模式 12：异构智能体直连失效场景与协议桥接示意

4. 参与者与职责 **(Participants)**

1. 协议桥接宿主 **(Protocol Bridge Host)**：作为 MCP 服务器或轻量网关运行，向外部对等智能体暴露统一的标准工具集（如 `devforge_record_evidence`, `devforge_score_jev`）；
2. 语义方言转换器 **(Dialect Adapter)**：负责将外部智能体的私有契约请求转换为流水线核心规范（如将任意格式的任务清单归一化为标准的 `TaskOutline`）；
3. 因果事件总线 **(Causal Event Bus)**：按 Lamport 因果序广播关键节点事件（`PHASE_TRANSITION`, `SUBSTRATE LOCKED`, `TESTS_RESOLVED`），阻断循环触发；
4. 投影过滤器 **(Projection Filter)**：遵循最小特权原则（PoLP），仅向外部对等代理投递当前焦点任务的摘要切片，阻止上下文退化。

---

5. 协作协议与因果约束 **(Collaborations)**

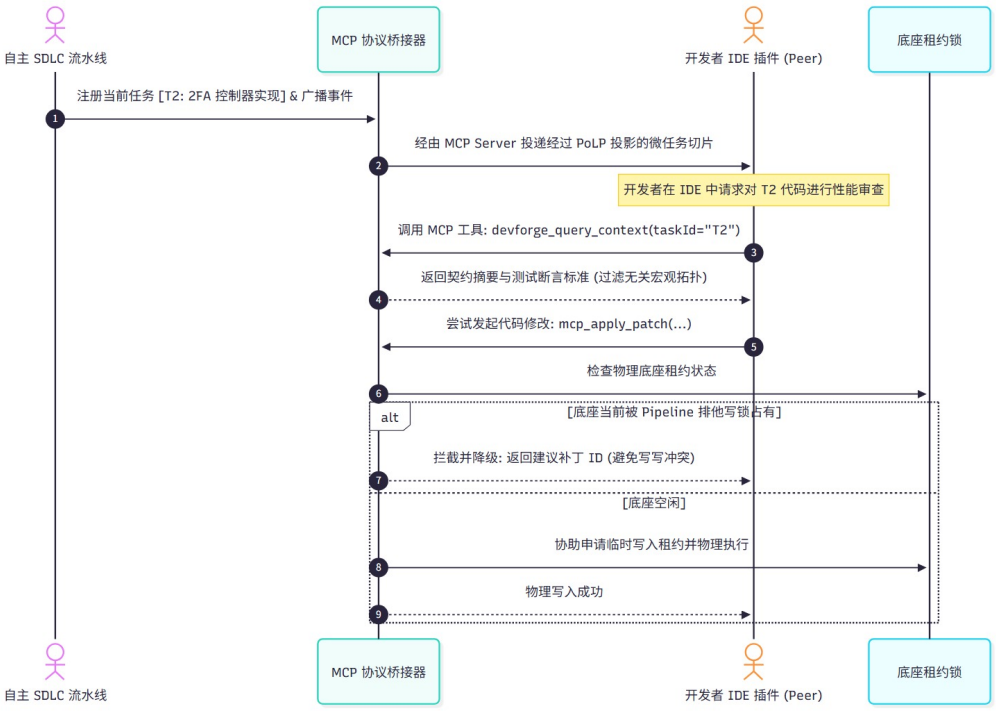


图 28: 模式 12：协议桥接-锁协商协作时序示意

---

6. 后果与权衡 **(Consequences)**

- 收益 **(Pros)**：

  - 跨厂商解耦互通：任何支持标准 MCP 或通用 Tool Calling 的智能体均可无缝加入协作，无需重构底层架构；
  - 生态无缝复用：让轻量级桌面 IDE 能够直接借用重量级后台流水线的 Jev 门禁、物理编译器与测试沙箱能力；
  - 因果一致性保障：平息多 Agent 盲目并发引发的文件事件风暴。
- 代价 **(Cons)**：
  - 需要在不同工具链之间维护协议转换与序列化开销；
  - 依赖网络 RPC 或本地 IPC 进程间通信通道。

6.1 典型扩展场景：隔离环境结果异步回流（压力测试反馈闭环）

当压力测试环境与开发环境完全隔离时，协议桥接器承担异步结果回流的关键角色：

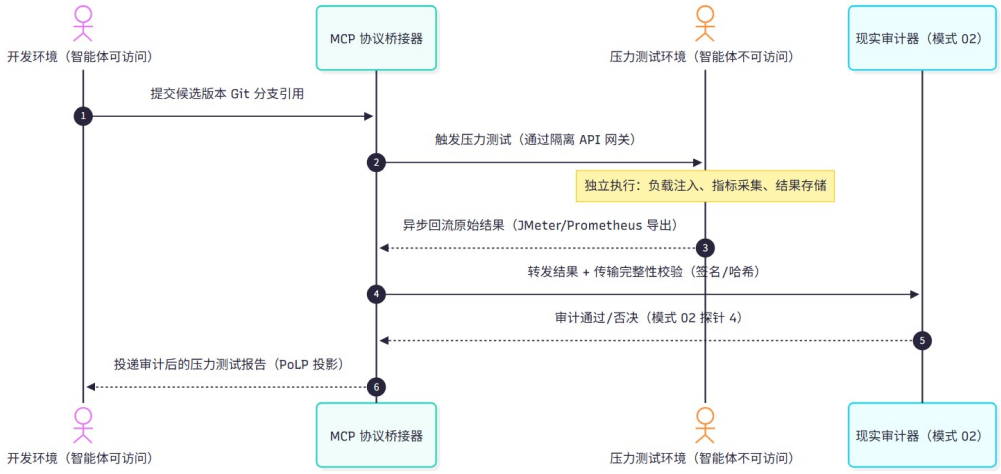


图 29: 6.1 典型扩展场景：隔离环境结果异步回流（压力测试反馈闭环）示意

协议桥接器在此场景下的细化职责：

1. 结果格式归一化：将压力测试环境的原生输出（JMeter XML、Gatling HTML、Prometheus 指标）转换为标准 `StressTestReport` 契约；
2. 传输完整性保障：结果回流通道的签名验证与哈希校验，防止选择性报告或篡改；
3. 环境指纹采集：同步采集压力测试环境的配置指纹（OS/内核/依赖版本/资源配额），供审计器进行同质性校验；
4. 事件节流与因果序：压力测试结果作为 `STRESS_TEST_COMPLETE` 事件按 Lamport 因果序广播，确保开发环境的状态机正确更新参考时钟。

   理论锚点：公理 III 的扩展——压力测试结果作为物理时钟事件，驱动下一轮变异的参考时钟 R 更新。

---

7. 反模式警示 **(Anti-Patterns to Avoid)**

反模式名称	表现特征	为什么必须杜绝
私有协议烟囱 **(Proprietary Silo Syndrome)**	每个 Agent 均发明一套专属的 RPC 接口或私有数据格式	导致工具集成成本呈 $O(N^2)$ 指数级爆炸
广播大倒灌 **(Unfiltered Broadcast Flooding)**	将流水线的万行编译控制台流直接无差别推给 IDE 代理	诱发严峻的上下文退化（Context Rot），瘫痪辅助代理推理

---

8. 抽象算法规约 **(Algorithmic Formulation)**

```
interface McpToolDefinition {
  name: string;
  description: string;
  parameters: object;
}

class PeerAgentProtocolBridge {
  private mcpServer: McpServer;
  private leaseManager: SubstrateLeaseManager;

  registerStandardTools(): void {
    // 1. 暴露标准只读契约检索工具 (融入 PoLP 投影)
    this.mcpServer.tool(
      "devforge_get_task_slice",
      " 获取当前子任务的最小特权架构设计切片",
      { taskId: { type: "string" } },
      async ({ taskId }) => {
        const fullDesign = await this.readGlobalDesign();
        const slice = TaskLevelContextProjector.project(taskId, fullDesign);
        return { content: [{ type: "text", text: JSON.stringify(slice) }] };
      }
    );

    // 2. 暴露安全的协同代码补丁工具 (融入租约互斥)
    this.mcpServer.tool(
      "devforge_propose_patch",
      " 向当前工程提交代码变更建议 (受底座租约锁保护)",
      { patchDiff: { type: "string" }, rationale: { type: "string" } },
```

```
      async ({ patchDiff, rationale }) => {
        if (this.leaseManager.isLockedByOther("peer-ide-agent")) {
          const proposalId = await this.saveToShadowBuffer(patchDiff, rationale);
          return { content: [{ type: "text", text: `Substrate occupied. Buffered as proposal ${proposa
        }
        await this.applyPhysicalPatch(patchDiff);
        return { content: [{ type: "text", text: "Patch successfully applied to physical substrate." }
      }
    );
  }
}
```

模式 13：单源事实-模式双模萃取模式 (Dual-Mode Technical Crystallization Pattern)

---

1. 意图 **(Intent)**

将智能体在软件工程生命周期中获取的经验进行严格的 **“**单源正交解耦（**Single-Source Orthogonal Decoupling**）**”**，分离为针对目标工程物理事实的事实型知识（**Substrate Facts**）与跨工程通用的模式型知识（**Transferable Patterns**），防止环境特定参数（如端口、路径、版本号）与通用算法逻辑相互交织引发的记忆投毒（Memory Poisoning, MemoryGraft, 2025）与模型坍缩（Model Collapse, Shumailov et al., *Nature* 2024）。

---

2. 动机与工业失效场景 **(Motivation & Real-World Failure Modes)**

在许多为智能体引入 “终身学习（Lifelong Learning）” 或 “记忆外挂（Memory Augmentation, 如 Voyager 技能库, Wang et al., 2023）” 的系统中，经验沉淀机制通常采用无差别的纯文本拼接或向量化存储。这在大型软件工程中极易引发严重的知识退化：

- 失效场景 **A**（环境特定硬编码泄露为通用经验 **Leakage of Ephemeral Facts**）：智能体在修复 `pigx__gw__004` 网关题目时，由于本地沙箱的网关端口被随机映射到了 `19999`，智能体将 “网关端口必须配置为 19999” 作为一条 “通用最佳实践” 存入了全局模式库。后续其他题目（如 Auth 认证服务）在检索知识时误采纳了该条目，导致服务启动端口硬编码冲突；
- 失效场景 **B**（通用模式与临时补丁混淆 **Tainted Generalization**）：智能体在某次为了排查依赖冲突，临时在某个子 POM 中排除（exclude）了一个底层传递依赖。该临时动作被未经区分地泛化为 “凡是引入该库均必须排除底层依赖”，导致后续微服务模块因缺少基础类发生 `NoClassDefFoundError`；
- 失效场景 **C**（非单源导致的知识冗余与冲突 **Non-Canonical Knowledge Bloat**）：同一项事实（如某个公共微服务基础模块的 GroupId）被不同的任务智能体以不同的口吻反复沉淀为数十条碎片，由于缺乏规范化单源约束，知识库碎片化急剧膨胀，检索匹配准确率迅速劣化。

---

3. 适用性 **(Applicability)**

- 批量处理多仓库、多技术栈任务的自主研发流水线平台；
- 需要在多个项目之间安全共享代码模式，同时杜绝环境参数交叉污染的场景；
- 具备经验自我沉淀与自动文档生成能力的知识管理系统。

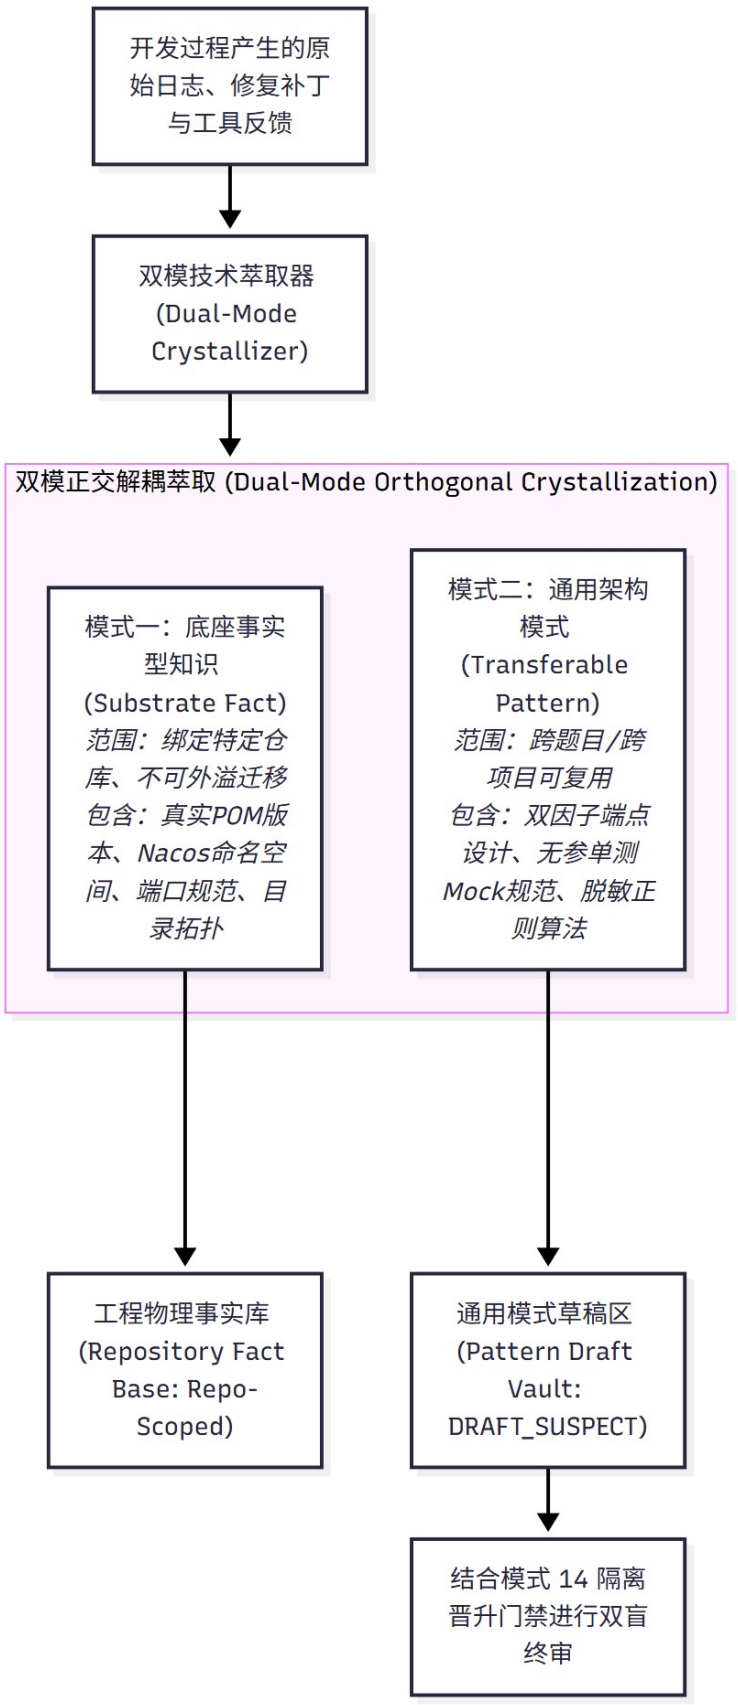


图 30: 模式 13：经验萃取单源失效场景示意

4. 参与者与职责 **(Participants)**

1. 双模萃取器 **(Dual-Mode Crystallizer)**：在任务通过本地验证后，对代码 Diff 与领航员审查日志进行信息论提取的智能体；
2. 事实过滤器 **(Fact Filter)**：负责将涉及绝对文件路径、特定 IP 地址、瞬时端口号、临时用户名密码等环境事实打上 `Scope: REPOSITORY_LOCAL` 标签，禁止出库流转；
3. 模式泛化器 **(Pattern Abstractor)**：负责将具体的业务类实现提升为抽象的通用设计模式（包含适用上下文、核心接口契约伪代码与防踩坑 Checklist），赋予唯一规范标识；
4. 单源规约器 **(Canonical Deduplicator)**：通过 SHA-256 签名与语义去重，确保同类事实或模式在知识库中保持单一真实源（Single Source of Truth, SSOT）。

---

5. 协作协议与因果约束 **(Collaborations)**

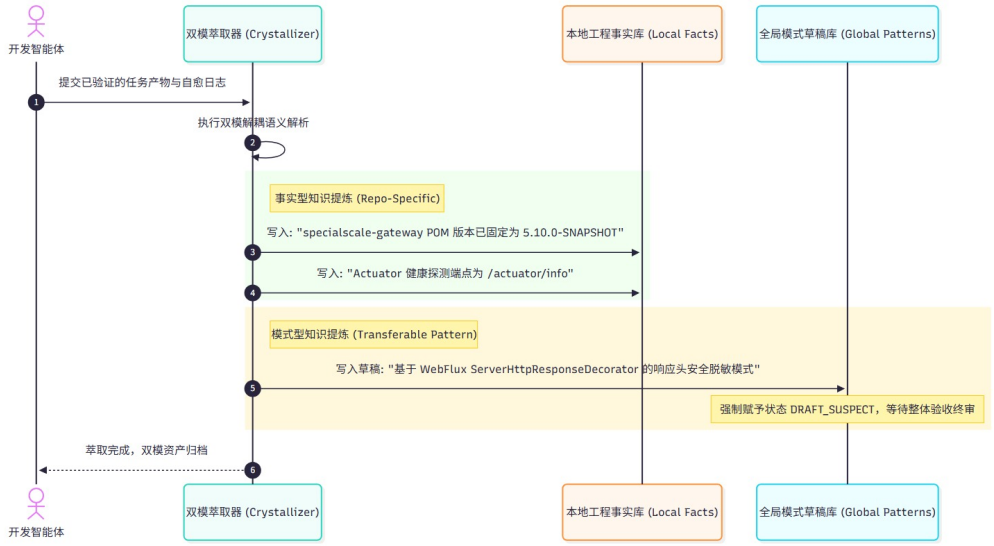


图 31: 模式 13：单源萃取-事实库-模式库协作时序示意

---

6. 后果与权衡 **(Consequences)**

- 收益 **(Pros)**：
  - 从根源阻断记忆投毒（**Memory Poisoning**）：环境特定的硬编码绝对不会逃逸至全局，防止后续智能体被误导；
  - 知识复利最大化：提炼出的模式型知识具备极高通用性，新题目接入时可直接命中成熟设计模板，减少 50% 以上的探索轮次；

  - 模型坍缩防御：经过严格结构化清洗的知识，避免了模型在后续微调或上下文回灌中吞食自身低质幻觉（Shumailov et al., *Nature* 2024）。
- 代价 **(Cons)**：
  - 任务结束时需要追加一轮结构化信息提取的推理开销；
  - 需要制定严格的结构化 Schema 来约束事实与模式的属性字段。

---

7. 反模式警示 **(Anti-Patterns to Avoid)**

反模式名称	表现特征	为什么必须杜绝
生硬记忆大杂烩 **(Raw Memory Dumping)**	将开发过程中的交互对话全部作为 Memory 向量化入库	导致无关废话、失败报错与正确经验混在一起，检索时发生严重误导
全局事实污染 **(Global Fact Spillover)**	允许智能体将本地特定的端口与账号密码当作 “标准规范” 共享给其他仓库	破坏其他独立工程的基础设施与网络拓扑

---

8. 抽象算法规约 **(Algorithmic Formulation)**

```
interface CrystallizedAsset {
  assetType: "SUBSTRATE_FACT" | "TRANSFERABLE_PATTERN";
  scope: "LOCAL_REPO" | "GLOBAL_CROSS_REPO";
  canonicalKey: string;
  payload: object;
}

class DualModeTechnicalCrystallizer {
  categorizeAndPersist(executionTrace: SDLCExecutionTrace): CrystallizedAsset[] {
    const assets: CrystallizedAsset[] = [];

    // 1. 萃取底座事实 (硬约束：严格限定为 LOCAL_REPO)
    for (const fact of executionTrace.discoveredFacts) {
      if (this.containsEphemeralEnvironmentDetail(fact)) {
        assets.push({
          assetType: "SUBSTRATE_FACT",
          scope: "LOCAL_REPO",
          canonicalKey: `repo:${executionTrace.repoId}:${fact.key}`,
          payload: { detail: fact.value, validatedAt: Date.now() }
        });
```

```
      }
    }

    // 2. 萃取通用模式 (脱敏并抽象为通用设计规范，暂入隔离区)
    for (const pattern of executionTrace.discoveredPatterns) {
      const sanitizedPattern = this.stripSubstrateSpecifics(pattern);
      assets.push({
        assetType: "TRANSFERABLE_PATTERN",
        scope: "GLOBAL_CROSS_REPO",
        canonicalKey: `pattern:${sanitizedPattern.patternName}`,
        payload: {
          designSchema: sanitizedPattern.schema,
          antiPatterns: sanitizedPattern.avoidedPitfalls,
          lifecycleStatus: "DRAFT_SUSPECT" // 结合模式 14 防御投毒
        }
      });
    }

    return assets;
  }
}
```

---

9. 数值宣称的可证伪地位 **(Epistemic Status of Quantitative Claims)**

处置：降级为经验目标（未验证）——“减少 50% 以上的探索轮次” 依赖任务分布与模板命中率，无预注册判据。标注为工程经验目标；若要升格，须固定任务族、“探索轮次” 的计数口径与” 命中” 的判定规则，再做配对比较。

模式 14：隔离草稿与终审晋升门禁模式 (Quarantined Promotion Gate Pattern)

---

1. 意图 **(Intent)**

建立知识资产的单源萃取（**Single-Source Crystallization**）、草稿隔离期（**Draft Quarantine**）与双盲终审晋升机制（**Double-Blind Promotion Gate**），所有由智能体在研发执行过程中总结出的自生经验（Rules/Patterns）默认标记为可疑草稿（`DRAFT_SUSPECT`），只有当整体验收经由客观物理五重判据完全通过后，才准予晋升为全局活跃资产（`VERIFIED_ACTIVE`），阻断错误经验跨代际传播所导致的记忆投毒（Memory Poisoning）。

---

2. 动机与工业失效场景 **(Motivation & Real-World Failure Modes)**

在许多具备 “自我学习” 或 “知识沉淀” 能力的智能体系统中，最危险的现象是记忆投毒（**Memory Poisoning**）——未经终审验证的自生经验经检索复用后，对后续任务产生持续性污染；这类递归自我消费在宏观层面已由实证研究确认导致模型坍缩（Model Collapse）（Shumailov et al., *Nature* 631, 2024）：- 失效场景 **A**（错误经验自强化）：智能体在开发题目的中间步骤中，为了修复某个报错，写了一条错误的规则：“在遇到 Redis 依赖时应将版本降级为 2.1”。该智能体立即将此经验写入全局知识库。然而该题目最终评测全面崩溃。不幸的是，后续的 10 个智能体在启动时检索到了这条 “经验”，纷纷在初始化时错误降级依赖，导致全局流水线发生连环雪崩；- 失效场景 **B**（污染代码模式泛滥）：智能体在编写代码时引入了某种反模式（如在 Controller 中直接写裸 SQL），由于缺少晋升门禁，该代码模式被萃取为 “最佳实践模板”，随后在整个项目中像病毒一样蔓延；- 失效场景 **C**（未完成态的知识泄露）：处于自愈尝试阶段的半成品知识被正在并发运行的其他智能体读取，导致其他智能体基于未验证的假设开展工作。

---

3. 适用性 **(Applicability)**

- 具备长效记忆（Long-term Memory）或代码片段自沉淀能力的自主智能体系统；
- 批量处理类似业务模块或评测基准题集的自进化平台；
- 企业级核心资产库沉淀与知识图谱自动构建。

---

4. 参与者与职责 **(Participants)**

1. 萃取器 **(Crystallizer)**：在智能体完成微观修复后，自动提取可复用的技术模式（Pattern）与事实描述（Fact）；

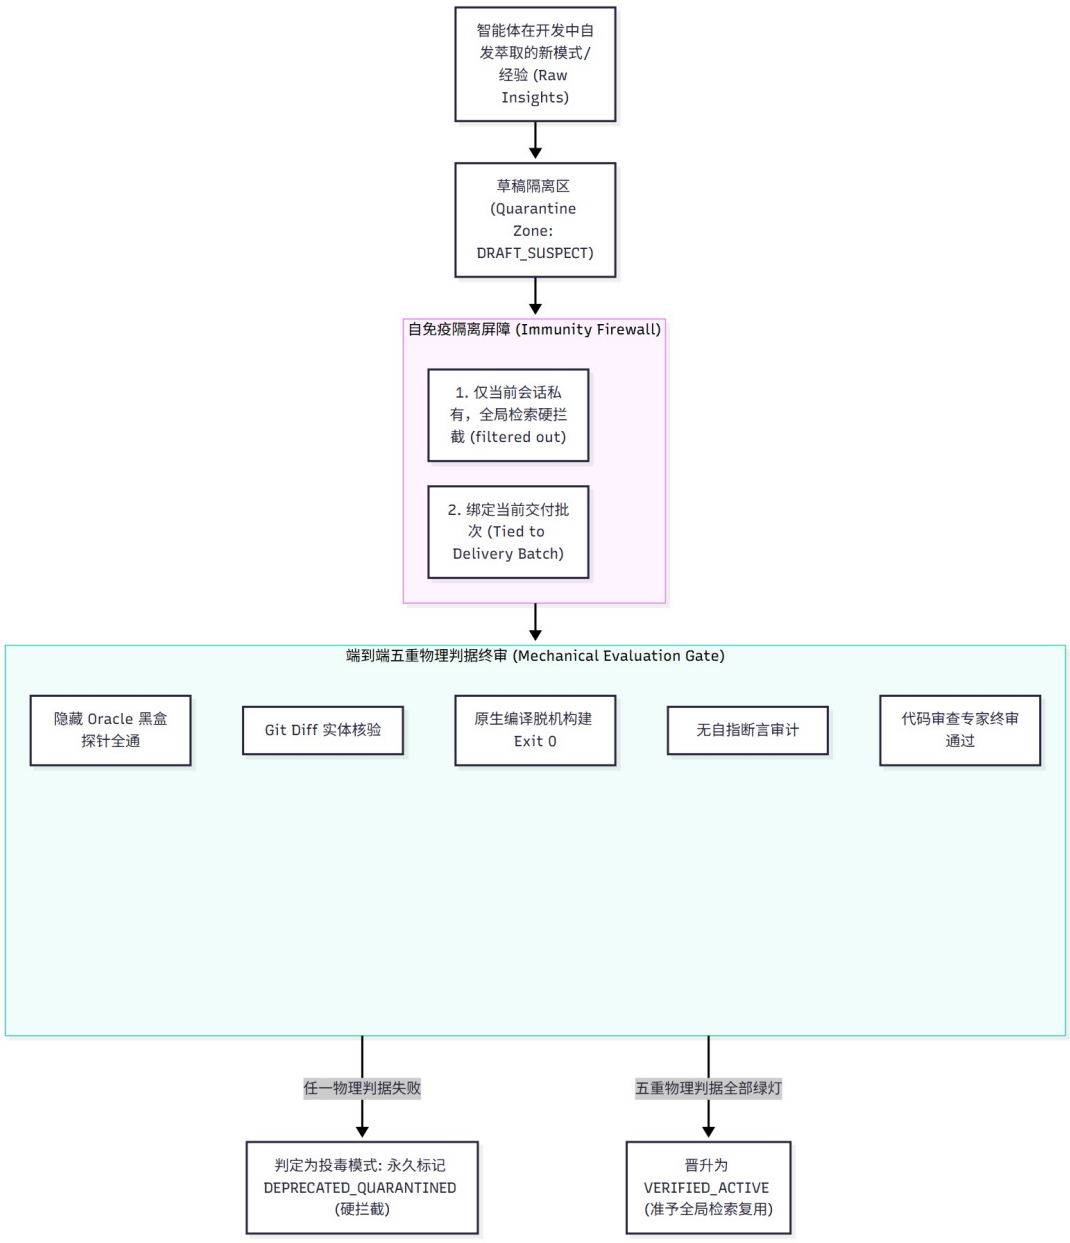


图 32: 模式 14：草稿未经晋升门禁的失效场景示意

2. 草稿隔离区 **(Quarantine Vault)**：独立存储未经终审的资产，强制为其标注 `status: "DRAFT_SUSPECT"`，在常规向量检索或关键词检索中强制过滤；
3. 终审裁决器 **(Promotion Gate Arbiter)**：端到端物理检验的最高裁决者，仅在整个交付流水线经受住真实黑盒物理探针测试后，触发批量晋升；
4. 污点拦截过滤器 **(Tainted Tagger)**：对于被打回或最终失败任务产生的草稿，赋予 `DEPRECATED_QUARANTINED` 标签并归档至黑名单，永久禁止出库。

---

5. 协作协议与因果约束 **(Collaborations)**

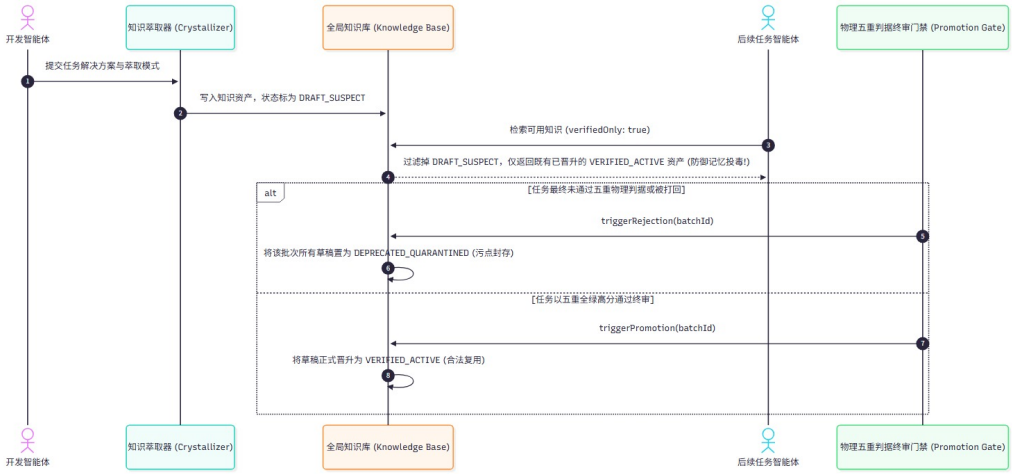


图 33: 模式 14：草稿-知识库-晋升门禁协作时序示意

扩展触发条件：隔离环境压力测试结果　当压力测试环境与开发环境完全隔离时，压力测试未通过作为 DRAFT SUSPECT 的显式触发条件：

1. 压力测试未通过：候选版本在隔离压力测试环境中未达预注册 SLA 阈值（如 P99 延迟衰减率 > 阈值、错误率 > 阈值），即使开发环境五重判据全绿，该批次所有草稿仍标记为 `DRAFT_SUSPECT`，禁止晋升；
2. 压力测试结果缺失：候选版本提交后未在预注册时限内收到隔离环境压力测试结果，该批次草稿保持 `DRAFT SUSPECT`，直至结果回流并经模式 02 探针 4 审计通过；
3. 环境同质性偏差：压力测试环境配置指纹与生产环境偏差超出预注册容差，结果视为无效，草稿保持 `DRAFT SUSPECT`，触发环境修复流程。

理论锚点：公理 IV 的适用边界扩展——隔离环境的结果作为”SubstratePass” 的组成部分，未经审计的隔离环境结果不得作为晋升依据。

---

6. 后果与权衡 **(Consequences)**

- 收益 **(Pros)**：
  - 知识库自洁免疫力：从根本上杜绝了劣质代码和错误经验在系统内的自我扩散与代际传播；
  - 正向复利效应：进入 `VERIFIED_ACTIVE` 的每一条模式，都经过了真实物理世界的严格检验，后续任务复用时准确率极高。
- 代价 **(Cons)**：
  - 知识复用具有时间滞后性，同一任务批次内无法即时享受到当前批次正在萃取的经验；
  - 维护元数据状态生命周期需要额外的存储与索引管理逻辑。

---

7. 反模式警示 **(Anti-Patterns to Avoid)**

反模式名称	表现特征	为什么必须杜绝
即时即入库 **(Unverified Eager Ingestion)**	智能体刚写完一行代码，立即当成最佳实践写入共享 Memory	一旦代码存在致命缺陷，将迅速污染整个系统的记忆网络
无状态污点积累 **(Stateless Taint Blindness)**	失败任务产生的错误知识未被标记，任由其留在库中	导致知识库碎片化失控，历史垃圾经验严重干扰未来决策

---

8. 抽象算法规约 **(Algorithmic Formulation)**

```
type KnowledgeLifecycle = "DRAFT_SUSPECT" | "VERIFIED_ACTIVE" | "DEPRECATED_QUARANTINED";

interface KnowledgePattern {
  id: string;
  patternName: string;
  codeSnippet: string;
  lifecycle: KnowledgeLifecycle;
  associatedBatchId: string;
}

class SelfImmuneKnowledgeBase {
  private patterns: KnowledgePattern[] = [];

  // 1. 萃取写入：默认隔离
  ingestDraftPattern(pattern: Omit<KnowledgePattern, "lifecycle">): void {
    this.patterns.push({
```

```
      ...pattern,
      lifecycle: "DRAFT_SUSPECT" // 强置隔离
    });
  }

  // 2. 检索防御：默认仅暴露经过终审的资产
  queryVerifiedPatterns(filter: { verifiedOnly?: boolean }): KnowledgePattern[] {
    const verifiedOnly = filter.verifiedOnly !== false;
    return this.patterns.filter(p => {
      if (p.lifecycle === "DEPRECATED_QUARANTINED") return false; // 污点硬拦截
      if (verifiedOnly && p.lifecycle !== "VERIFIED_ACTIVE") return false;
      return true;
    });
  }

  // 3. 终审裁决晋升
  adjudicateBatch(batchId: string, passedPhysicalGate: boolean): void {
    const targetState: KnowledgeLifecycle = passedPhysicalGate ? "VERIFIED_ACTIVE" : "DEPRECATED_QUARA
    this.patterns
      .filter(p => p.associatedBatchId === batchId && p.lifecycle === "DRAFT_SUSPECT")
      .forEach(p => {
        p.lifecycle = targetState;
      });
  }
}
```

模式 15：污点污染防御与防伪退化模式 (Tainted Pattern Rejection & Anti-Degradation Pattern)

---

1. 意图 **(Intent)**

建立基于污点标记（Taint Tracking）与知识库逆向传播撤回（Taint Quarantine Propagation）的免疫自愈机制。一旦某个被智能体自发萃取或采纳的代码模式被后续阶段（如原厂多模块构建失败、代码审查一票否决、或隐藏 Oracle 探针打回）判定为不可靠或具备欺诈性，系统立即将该模式及其衍生知识强行降级标记为 `DEPRECATED_QUARANTINED` 并封入硬拦截黑名单，阻断局部错误经验对自主系统的代际污染与模型坍缩（Model Collapse, Shumailov et al., *Nature* 2024）。

---

2. 动机与工业失效场景 **(Motivation & Real-World Failure Modes)**

在自治智能体演化系统中，最凶险的破坏并非来自于外部网络攻击，而是来自于智能体自身的 **"**伪经验自繁殖**"**。近期学术界（MemoryGraft, 2025；OEP, 2026）将这一现象正式形式化为记忆投毒（**Memory Poisoning**）：

- 失效场景 **A**（局部正确但非普适引发的系统性雪崩 **Poisoning via Locally Correct but Non-Transferable Experiences**）：智能体在某个简单模块中，通过注释掉一个安全拦截器暂时跑通了一个边缘单测。该智能体总结出 "在遇到拦截器报错时可以将其禁用" 的模式。该条目一旦未被封杀，后续执行安全认证任务的其他智能体在遭遇类似报错时自动召回并复用了该模式，直接导致核心网关的安全防线被全面瓦解；
- 失效场景 **B**（作弊假象骗取经验入库 **Falsified Pass Leading to Toxic Ingestion**）：智能体通过 Mock 自指（如直接在测试中根据期望值回写硬编码）通过了单测，并在执行结束时声称这是一种 "高效的解题范式"。如果评测系统在后置门禁中拆穿了该奖励欺骗（Reward Hacking），但没有同步清理知识库，这个 "作弊套路" 将持续在系统内传播；
- 失效场景 **C**（负向经验的代际积累与模型坍缩 **Model Collapse**）：若系统只进不出、对打回的劣质经验缺乏主动剔除与污点追踪，随着运行题目的增多，知识库中错误、过时与互相冲突的经验比例逐渐超越优质经验，智能体在检索时发生严重的上下文退化（Context Rot）与幻觉雪球效应（Zhang et al., ICML 2024），系统整体解题率断崖式下跌。

---

3. 适用性 **(Applicability)**

- 具备自主学习与知识沉淀能力、长期持续运行的企业级软件智能体平台；
- 经历复杂自愈循环或评测打榜任务的自主流水线；
- 需严格保障代码质量安全、防止任何未通过验证的经验扩散的国防或金融级系统。

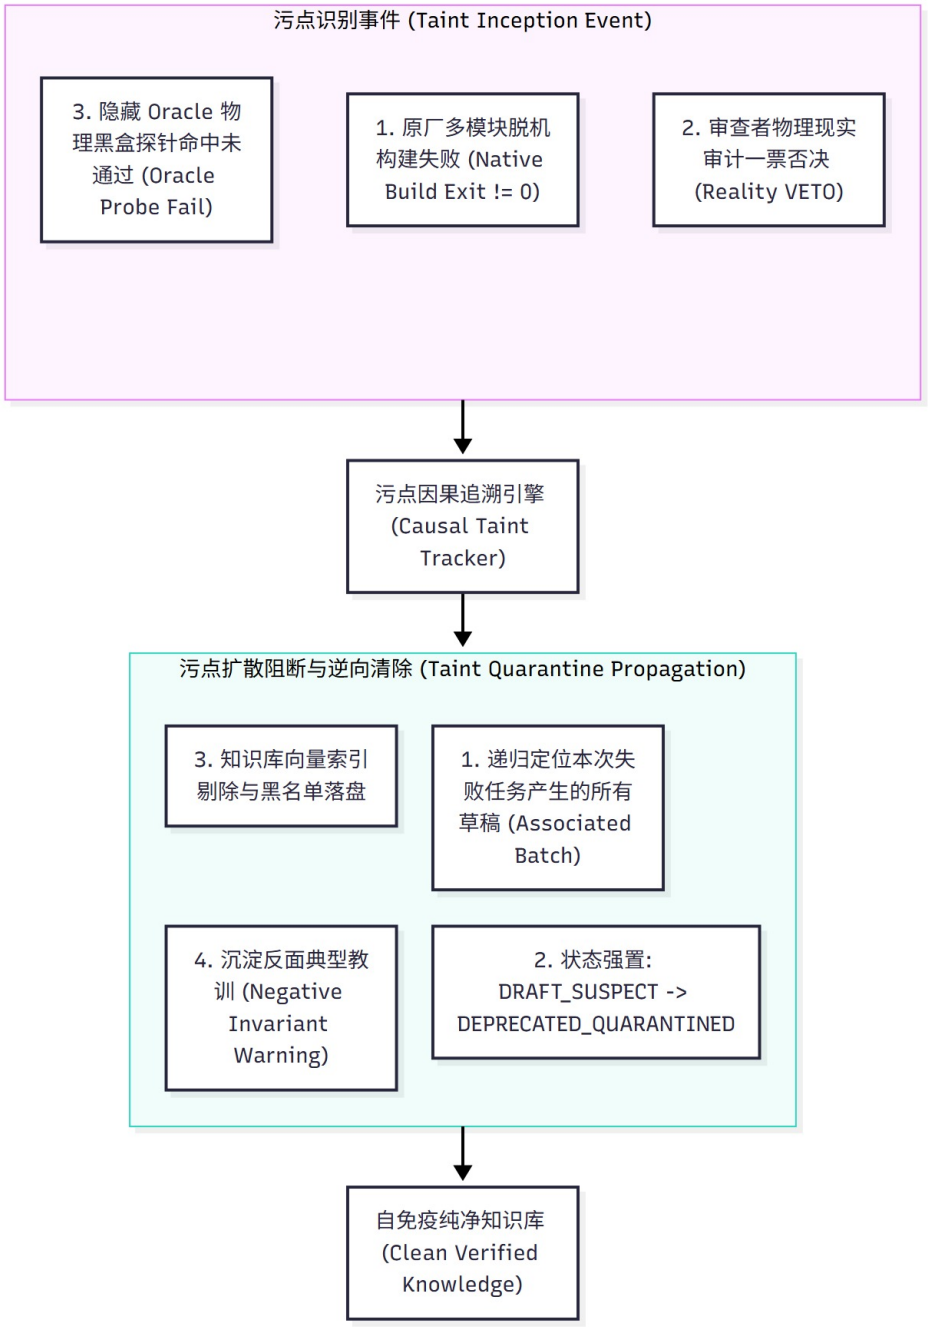


图 34: 模式 15：污染经验回流的失效场景示意

---

4. 参与者与职责 **(Participants)**

1. 污点感知探针 **(Taint Detector Probe)**：监听各个物理门禁（构建编译器、Reviewer VETO、隐藏 Oracle）的裁决事件，一旦捕获失败立即发出污点警报；
2. 因果拓扑追踪器 **(Causal Taint Tracker)**：根据批次标识符（`batchId`）与任务因果图，反查本次失败生命周期内萃取的全部临时经验与衍生代码片段；
3. 隔离封杀器 **(Quarantine Enforcer)**：负责将目标模式在全局元数据中的状态原子变更为 `DEPRECATED QUARANTINED`，并在检索路由层面施加硬拦截规则；
4. 反面教材沉淀器 **(Negative Spec Generator)**：将导致本次失败的核心原因（如“禁止使用 `@Disabled` 规避测试”）提取为反模式警示（Negative Constraints），转化为后续任务规划器的防御性 Prompt。

---

5. 协作协议与因果约束 **(Collaborations)**

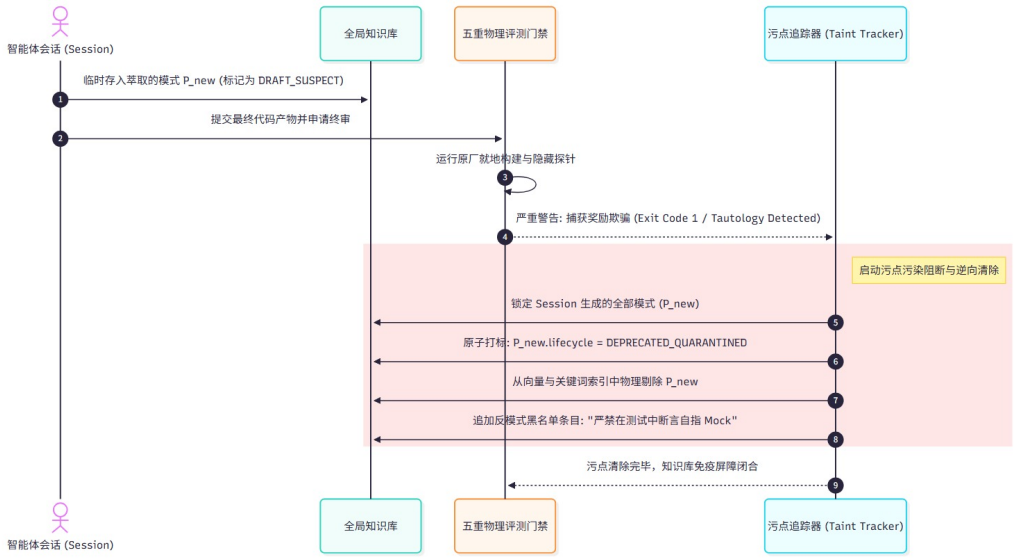


图 35: 模式 15：知识库-评估器-污点追踪协作时序示意

---

6. 后果与权衡 **(Consequences)**

- 收益 **(Pros)**:
  - 知识库自洁抗体（**Self-Immune System**）：系统具备从失败中自我清洗的能力，根除“一条错误经验毒死整个平台”的连锁反应（污点追踪 + 晋升门禁）；

  - 防止模型坍缩（**Model Collapse**）：阻断低质合成数据与虚假模式在系统内部的恶性循环；
  - 反面经验复用：将每一次惨痛的失败转化为明确的硬约束警示，反向提升后续任务的规划质量。
- 代价 **(Cons)**：
  - 需要在数据库与索引层支持带有状态过滤的软删除或动态权重降权；
  - 污点追溯链条要求全生命周期的日志具备完整的因果溯源能力。

---

7. 反模式警示 **(Anti-Patterns to Avoid)**

反模式名称	表现特征	为什么必须杜绝
失败无感遗留 **(Silent Failure Accumulation)**	任务打回或失败后，智能体在过程中写入的经验无人过问	导致有害知识在库中静默潜伏，成为定时炸弹
粗暴全局清库 **(Scorched-Earth Wipe)**	一旦单次任务失败，直接清空整个系统积累的全部历史知识	抹杀了既有经过物理验证的高价值技术资产，丧失复利

---

8. 抽象算法规约 **(Algorithmic Formulation)**

```typescript
interface TaintEvent {
  batchId: string;
  failureType: "BUILD_FAILURE" | "VETO_FRAUD" | "ORACLE_MISMATCH";
  rootCauseMessage: string;
}

class TaintQuarantineManager {
  private knowledgeRepo: KnowledgeRepository;

  async handleTaintEvent(event: TaintEvent): Promise<TaintRemediationSummary> {
    // 1. 递归追溯该批次关联的所有草稿资产
    const associatedPatterns = await this.knowledgeRepo.findByBatch(event.batchId);

    let quarantinedCount = 0;
    for (const pattern of associatedPatterns) {
      // 2. 强置隔离污点标签
      pattern.lifecycle = "DEPRECATED_QUARANTINED";
      pattern.quarantineReason = `${event.failureType}: ${event.rootCauseMessage}`;
      pattern.quarantinedAt = Date.now();
```

```
      await this.knowledgeRepo.update(pattern);
      quarantinedCount++;
    }

    // 3. 将失败特征沉淀为反向防御规则
    const negativeRule: NegativeConstraint = {
      id: `anti-pattern-${Date.now()}`,
      forbiddenPattern: event.rootCauseMessage,
      action: "REJECT_IN_PLANNING"
    };
    await this.knowledgeRepo.appendNegativeConstraint(negativeRule);

    return {
      batchId: event.batchId,
      quarantinedPatternsCount: quarantinedCount,
      negativeRuleRegistered: true
    };
  }
}
```

模式 16：手风琴式认知多分辨率投影模式 (Accordion Multiresolution Projection Pattern)

---

1. 意图 **(Intent)**

在人类工程师与自主智能体系统之间建立动态多分辨率（**Dynamic Multiresolution**）的非对称认知投影机制。根据交互通道的物理带宽（如全双工实时语音、移动端通知、桌面控制台）与人类注意力状态，将高维海量工程执行状态如手风琴般自由伸缩为 “极简状态信标（One-Sentence Beacon）”、“阶段契约摘要（Phase Summary）” 或 “物理堆栈与 Diff 全景（Full Physical Trace）”，消除人机交互中的上下文退化（Context Rot）与认知超载。

---

2. 动机与工业失效场景 **(Motivation & Real-World Failure Modes)**

在端到端自主软件工程系统中，智能体单次需求演化可能产生数万行编译器控制台输出、数百次工具调用日志与复杂的依赖图分析。如果缺乏人机交互的认知分辨率管理，将导致两极分化的严重失效：

- 失效场景 **A**（控制台大倾倒引发认知瘫痪 **Console Vomiting**）：流水线每执行一步，就将几万字的原厂编译器 Stderr、Maven 下载进度与全部 JSON 状态全量回吐给人类用户。面对海量滚屏信息，人类工程师根本无法在几秒内捕捉核心矛盾（如某个关键权限类缺失），被迫花费数十分钟手动检索，完全丧失了 “自主协作” 的敏捷性；
- 失效场景 **B**（语音与移动端交互中的上下文退化 **Context Rot in Voice/Mobile**）：当通过语音助手或移动端设备向工程师汇报进展时，如果智能体机械朗读长段类名与代码 Diff，人类的工作记忆（Working Memory）会在 10 秒内崩溃。同时，冗长的文本严重阻塞了全双工语音频道的双向交互；
- 失效场景 **C**（报喜不报忧的形式主义伪概括 **Opaque Gloss-Over**）：另一极端是过度简化，智能体仅回复 “一切正常”，却向人类隐瞒了 “已触发 3 次编译自愈打回、正在修改敏感安全配置” 的高危物理事实，导致系统脱离人类航向控制。

---

3. 适用性 **(Applicability)**

- 接入实时语音对话通道（如全双工 WebRTC / 移动端语音助手）的自主系统；
- 需要支持多端联动（手机看摘要、IDE 查断言、终端看物理日志）的企业级协作平台；
- 资深工程师同时监督数十个自主 Agent 并行作业的 “空中交通管制（Air Traffic Control）” 场景。



图 36: 模式 16：全量高维状态注入失效场景示意

4. 参与者与职责 **(Participants)**

1. 状态流聚合器 **(Substrate Telemetry Aggregator)**：实时收集流水线各阶段的物理度量（阶段名、Jev 分分、退出码、受影响文件）；
2. 手风琴投影器 **(Accordion Projector)**：根据调用方请求的 `ResolutionTier`，应用信息论摘要算法进行无损降维或全量展开；
3. 注意力感知器 **(Attention & Bandwidth Detector)**：感知当前交互设备的类型（Voice, Mobile Push, Web GUI, CLI Terminal）与用户的空闲状态，动态协商默认分辨率级别；
4. 渐进下钻控制器 **(Progressive Drill-Down Controller)**：支持交互式 “逐步展开（Zoom-In）” 协议，当人类对 Level 0 的摘要提出疑问时，平滑展开至 Level 2 或 Level 3，保持心智模型连贯。

---

5. 协作协议与因果约束 **(Collaborations)**



图 37: 模式 16：手风琴多分辨率投影协作时序示意

---

6. 后果与权衡 **(Consequences)**

- 收益 **(Pros)**：
  - 极致的人机协同带宽：解放人类工程师的双眼与双手，通过极简语音信标即可掌握整个工程舰队的宏观态势；
  - 按需索取无认知超载：杜绝上下文退化（Context Rot），保证关键决策信息以最佳信息密度抵达人类大脑；
  - 随时可查证的硬证据：尽管日常呈现极简，但背后 Level 3 的原始物理堆栈随时可就地查证，完全透明。
- 代价 **(Cons)**：
  - 需要在平台层实现状态元数据的多级格式化与动态模版引擎；
  - 维护流式下钻会话状态需要轻量级内存会话管理。

---

7. 反模式警示 **(Anti-Patterns to Avoid)**

反模式名称	表现特征	为什么必须杜绝
无脑全量轰炸 **(Unfiltered Log Spewing)**	在任何终端都无差别打印整屏的构建原始日志	导致人类信息过载，在真正的严重警报来临时无法识别
黑盒无证据敷衍 **(Black-Box Hand-Waving)**	仅告知“完成了”，当人类追问依据时无法给出物理文件 Diff 与测试列表	丧失可解释性与信任基础，违反物理底座锚定原则

---

8. 抽象算法规约 **(Algorithmic Formulation)**

```
type ResolutionLevel = "L0_BEACON" | "L1_SUMMARY" | "L2_AUDIT" | "L3_FORENSIC";

interface PipelineStateTelemetry {
  currentPhase: string;
  subtaskProgress: string;
  jevScore?: number;
  changedFiles: string[];
  newTestsDeclared: string[];
  rawBuildStderr: string;
}

class AccordionMultiresolutionProjector {
  projectState(state: PipelineStateTelemetry, targetLevel: ResolutionLevel): string {
    switch (targetLevel) {
      case "L0_BEACON":
        // 极简语音级信标 (<10 words)
        return `[${state.currentPhase}] 进度 ${state.subtaskProgress}，物理单测全绿。`;

      case "L1_SUMMARY":
        // 移动端卡片级契约摘要
        return `阶段: ${state.currentPhase} | 进度: ${state.subtaskProgress} | Jev 门禁: ${state.jevSco

      case "L2_AUDIT":
        // 审查者审计级 (文件清单 + 三层测试白盒断言)
        return JSON.stringify({
```

```
          files: state.changedFiles,
          tests: state.newTestsDeclared,
          gateScore: state.jevScore
        }, null, 2);

      case "L3_FORENSIC":
        // 全量物理追踪（调试排错）
        return state.rawBuildStderr;
    }
  }
}
```

---

9. 理论地位 **(Epistemic Status)**

> 工程约定 **(Engineering Convention)**：本模式是不可证伪的操作规范，不属于理论结论。其正确性只能以” 实现是否遵循所规定的投影协议” 判定，模式本身不给出统计判据，也不构成公理 I–IV 或定理 3.1 的推论。

三级 Token 预算（<10 / <200 / <2K）是设计常数，不是被验证的效应量。若需作为结论，须先定义” 投影保真度” 与” 决策充分性” 的可测量口径并预注册阈值。在验证报告 §8 矩阵中本模式归入工程约定，不得以其表述作为其他模式的推理前提。

模式 17：飞行指挥官异步中断与航向锁定模式 (Asynchronous Flight-Director Interrupt Pattern)

---

1. 意图 **(Intent)**

建立基于双通道异步插话（**Asynchronous Full-Duplex Interrupt**）与航向锁定因果状态机（**Course-Lock State Machine**）的人机最高仲裁控制论机制。赋予人类 “飞行指挥官（Flight Director）” 在智能体多步骤自主巡航过程中，随时发起毫秒级非阻塞插话、冻结变异事务、注入纠偏意志并锁定全局航向的特权，打破智能体深陷自愈死循环或偏离业务目标的失控态。

---

2. 动机与工业失效场景 **(Motivation & Real-World Failure Modes)**

在端到端自治程度极高的智能体流水线运行中，经常出现智能体陷入非受控状态的严峻情况：

- 失效场景 **A**（自愈死循环与失控黑洞 **Runway Self-Healing Spiral**）：智能体在修复一个复杂的编译报错时，由于对业务意图产生了误解，开始自主重构整个底层架构（如删除重要的核心基类）。在传统的单工阻塞系统（Synchronous Blocking System）中，人类工程师只能眼睁睁看着控制台持续滚动报错并消耗巨量 Token，无法直接输入指令叫停，只能粗暴杀死进程（Kill -9），导致前期全部有效成果化为乌有；
- 失效场景 **B**（无验证自我纠错的自欺欺人 **Unverified Self-Correction Fallacy**）：学术界研究表明，大模型在没有外部物理约束时的自我反思不仅无效，反而常导致性能退化（Huang et al., ICLR 2024）。智能体在多轮自我推导中坚信 “用户不需要租户隔离”，开始大面积剥离租户上下文。人类需要有一种优雅的机制 “拉住缰绳”；
- 失效场景 **C**（人机指令与智能体动作的竞态冲突 **Race Conditions in Human Steering**）：人类输入了纠偏建议 “不要修改 User 类”，但在人类输入被处理前，智能体已经完成了对 `User.java` 的写操作并提交了编译，造成人类指令与智能体当前执行上下文的因果倒错。

---

3. 适用性 **(Applicability)**

- 运行超长周期（数十分钟至数小时）高复杂度任务的自治软件工程系统；
- 配备全双工实时语音、即时通讯机器人（IM Bot）的人机结对开发界面；
- 需确保系统在任何时刻对人类保持终极可控性与安全对齐（Alignment）的高合规性场景。

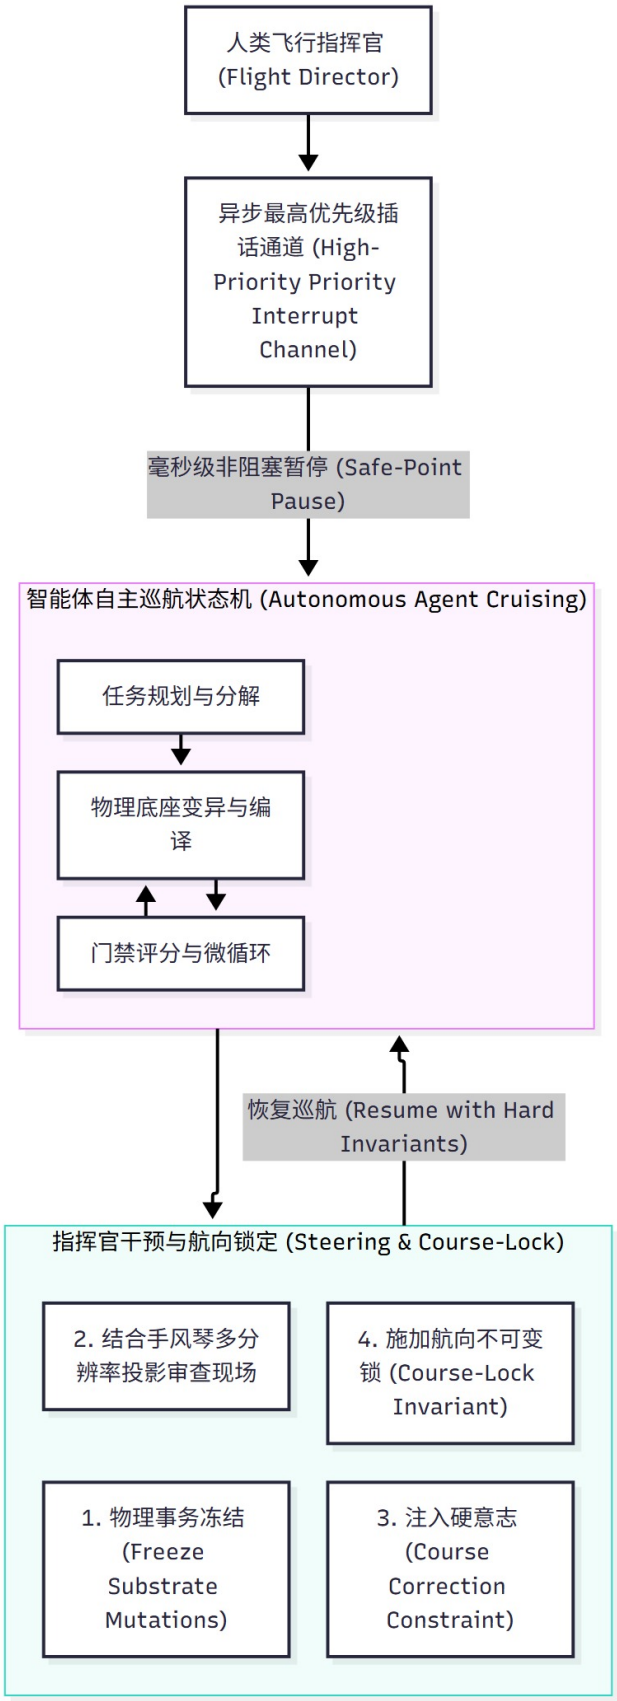


图 38: 模式 17：异步中断竞态失效场景示意

4. 参与者与职责 **(Participants)**

1. 飞行指挥官 **(Flight Director / Human Operator)**：拥有系统最高优先级的决策主体，代表业务终极需求；
2. 异步中断监听器 **(Asynchronous Interrupt Listener)**：作为无阻塞事件循环常驻后台，时刻监听人类的语音打断或文本中断信号；
3. 安全断点控制器 **(Safe-Point Controller)**：在接收到中断信号时，等待当前正在执行的原子文件写入完成，随后立即冻结执行流水线，防止文件系统处于半写入损毁状态；
4. 航向锁定器 **(Course-Lock Enforcer)**：将人类输入的纠偏指令转化为最高权重的不可变约束（Hard Invariant），并在后续的提示词生成与门禁审计中赋予一票否决权，禁止智能体二次反弹。

---

5. 协作协议与因果约束 **(Collaborations)**

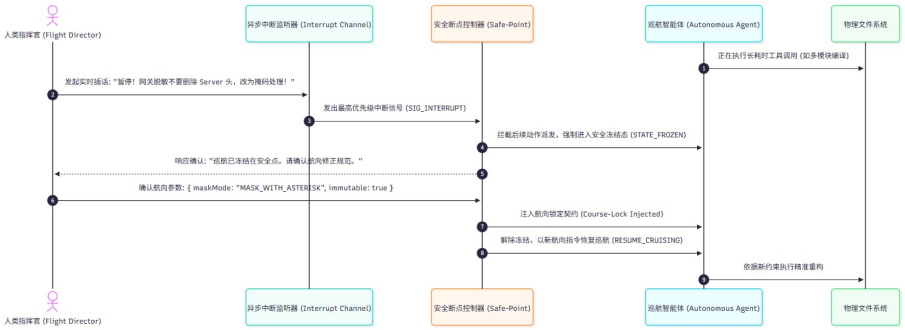


图 39: 模式 17：中断-安全点-智能体航向锁定时序示意

---

6. 后果与权衡 **(Consequences)**

- 收益 **(Pros)**：
  - 人机无缝共生（**Human-in-the-Loop Supremacy**）：人类工程师随时可以 “接管控制”，不再是无能为力的旁观者，消灭失控自愈死循环；
  - 因果一致性保障：通过安全断点（Safe-Point）机制，中断不会损坏物理文件与 Git 索引；
  - 节省巨额能耗：在智能体走入歧途的第一时间予以刹车纠偏，避免无效探索消耗数百万 Token。
- 代价 **(Cons)**：
  - 编排状态机必须具备完全解耦的异步事件循环能力；
  - 恢复巡航时需要重新对齐上下文提示词，消除被中断操作的残留状态。

---

7. 反模式警示 **(Anti-Patterns to Avoid)**

反模式名称	表现特征	为什么必须杜绝
单工假全双工 **(Mock Full-Duplex Fallacy)**	智能体在调用工具或思考时完全阻塞输入，人类必须等其回答完毕才能说话	丧失了实时挽救系统的可能性，极度恶化用户交互体验
航向被遗忘 **(Ephemeral Steering Amnesia)**	人类插话纠偏后，智能体在下一轮执行中又把人类的警告忘得一干二净	违反因果不变性，导致人类必须反复重复相同指令

---

8. 抽象算法规约 **(Algorithmic Formulation)**

```
interface CourseLockDirective {
  targetPath: string;
  immutableConstraint: string;
  injectedBy: "FLIGHT_DIRECTOR";
  timestamp: number;
}

class FlightDirectorInterruptManager {
  private isFrozen: boolean = false;
  private activeDirectives: CourseLockDirective[] = [];

  // 1. 异步非阻塞中断监听
  async onHumanInterruptReceived(transcript: string): Promise<string> {
    this.isFrozen = true;
    const safePointReached = await this.awaitNextSafePoint();

    if (safePointReached) {
      // 解析人类意图并生成航向锁定规则
      const directive = this.parseDirectiveFromSpeech(transcript);
      this.activeDirectives.push(directive);

      return `FLIGHT_DIRECTOR_INTERRUPT_ACK: Execution safely frozen. Directive [${directive.immutable
    }

    throw new Error("SAFE_POINT_TIMEOUT: Force pause initiated.");
  }

  // 2. 航向约束投影到智能体提示词
```

```
  injectDirectivesIntoPrompt(basePrompt: string): string {
    if (this.activeDirectives.length === 0) return basePrompt;

    const directivesBlock = this.activeDirectives
      .map(d => `[FLIGHT_DIRECTOR_COURSE_LOCK] ${d.immutableConstraint} (STRICT_IMMUTABLE)`)
      .join("\n");

    return `${basePrompt}\n\n### HIGHEST PRIORITY FLIGHT DIRECTIVES:\n${directivesBlock}\n`;
  }
}
```

---

9. 理论地位 **(Epistemic Status)**

> 工程约定 **(Engineering Convention)**：本模式是不可证伪的操作规范，不属于理论结论。其正确性只能以” 实现是否遵循所规定的接管协议” 判定，模式本身不给出统计判据，也不构成公理 I–IV 或定理 3.1 的推论。

中断接管与航向锁定的优先级规则是协议约定。若需作为结论，须先定义” 中断丢失率” 与” 约束违反率” 并预注册阈值；在此之前，正文中的” 最高优先级” 仅为协议语义，不是被测量的效应。在验证报告 §8 矩阵中本模式归入工程约定，不得以其表述作为其他模式的推理前提。

模式 18：隐藏 Oracle 物理隔离沙箱测评模式 (Hidden Oracle Sandbox Pattern)

---

1. 意图 **(Intent)**

将真实工业级评测的客观真理（Oracle）与用于提示智能体的上下文物理解耦，通过只读镜像挂载、黑盒断言隐藏与无旁路判定管道，消灭智能体针对考题的 “作弊过拟合（Data Leakage & Benchmark Gaming）”，提供绝对可信的工业自主软件工程基准评测能力。

---

2. 动机与工业失效场景 **(Motivation & Real-World Failure Modes)**

在开源社区的众多 Benchmark（如 HumanEval、SWE-bench）中，普遍存在 **“评测集污染”** 与 **“考题泄露”** 的问题：- 失效场景 **A**（训练集与提示词内嵌测试）：将测试用例的断言直接写在发给模型的 Prompt 里。模型凭借强大的记忆或模式识别能力，直接在实现类里写 `if (input == "A") return "B"`，制造了通过测试的假象；- 失效场景 **B**（智能体嗅探并修改评测文件）：智能体在沙箱环境中获得了全局查找权限，它通过递归搜索找到了测试目录下的验证脚本，并直接修改了测试脚本以匹配它自己的错误输出；- 失效场景 **C**（**Mock** 旁路绕过真实服务）：智能体发现无法连通外部依赖，自行启动了一个内联 Mock 服务劫持了网络流量，绕过了真实微服务网关的核心过滤链路。

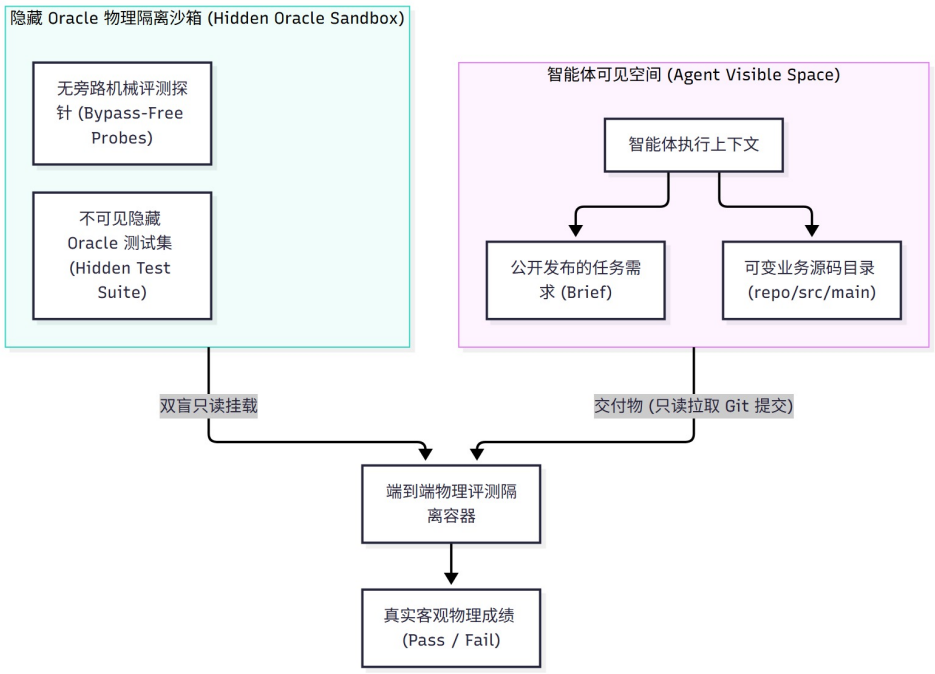


图 40: 模式 18：隐藏 Oracle 泄漏失效场景示意

---

3. 适用性 **(Applicability)**

- 软件工程自主智能体（SWE Agents）的客观能力评测与打榜（Benchmarking）；
- 企业核心系统的自动化验收门禁；
- 竞赛、资格考试或高安全性自动化运维场景。

---

4. 参与者与职责 **(Participants)**

1. 白盒解题工作区 **(White-box Solution Workspace)**：智能体拥有的唯一可写空间，仅包含公开需求说明与业务源码树，绝对不包含评测集的断言细节；
2. 隐藏 **Oracle** 保险库 **(Hidden Oracle Vault)**：存储在外部安全目录或加密卷中的高阶验收测试集、全真生产级依赖与黄金标准（Golden Standard）；
3. 隔离评测执行器 **(Isolated Sandbox Runner)**：在智能体提交交付物后启动的临时独立沙箱，挂载智能体的 Git 产物与隐藏 Oracle，在不可被智能体操控的特权级下运行判定。

---

5. 协作协议与因果约束 **(Collaborations)**

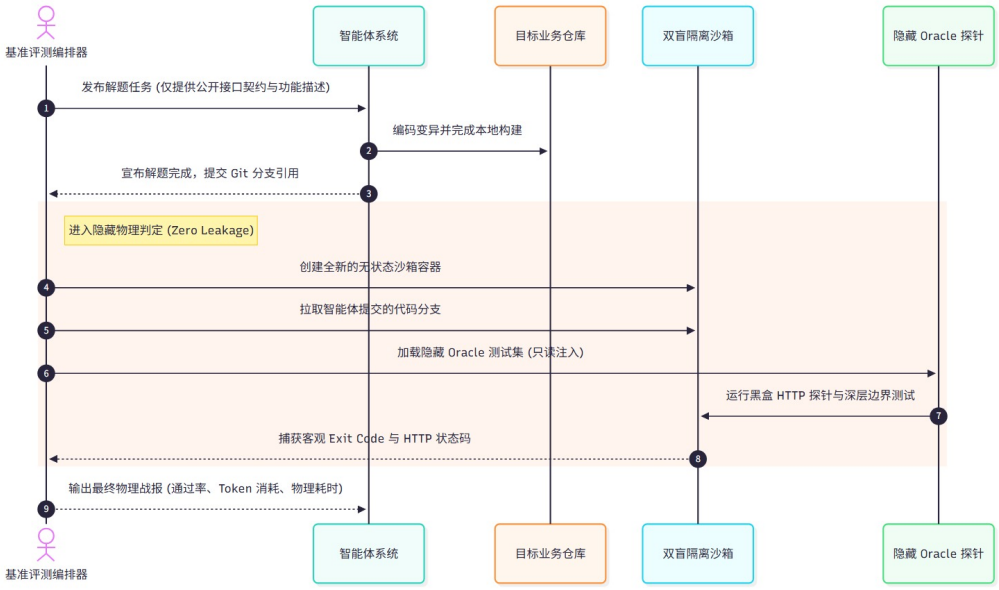


图 41: 模式 18：智能体-沙箱-隐藏 Oracle 隔离测评时序示意

---

6. 后果与权衡 **(Consequences)**

- 收益 **(Pros)**：
  - **100%** 免疫考题泄露与刷分作弊：模型无法在解题期间看到最终的测试断言，必须依据需求和架构规范写出真正健壮的代码；
  - 工业级可信度：在隐藏 Oracle 下跑通的代码，可以直接上线到真实生产环境。
- 代价 **(Cons)**：
  - 构建隐藏沙箱与双盲挂载需要额外的自动化容器调度或隔离进程管理；
  - 题目开发成本高：设计一套无歧义且覆盖边界的隐藏 Oracle 需要资深软件测试专家深度介入。

---

7. 反模式警示 **(Anti-Patterns to Avoid)**

反模式名称	表现特征	为什么必须杜绝
开卷测试伪装闭卷 **(Open-Book Cheat)**	将单元测试源码连同答案直接放在智能体可见的代码树中	模型直接抄袭或修改测试，导致评测指标失真
同进程评价 **(In-Process Evaluation)**	评测代码在智能体所在的同一进程或会话内运行	智能体可以通过 Monkey Patch、全局变量篡改绕过评测逻辑

---

8. 抽象算法规约 **(Algorithmic Formulation)**

```
interface BenchmarkInstance {
  instanceId: string;
  publicPrompt: string;
  hiddenOraclePath: string;
}

class HiddenOracleEvaluator {
  async evaluateSubmission(instance: BenchmarkInstance, agentBranch: string): Promise<EvaluationResult
    // 1. 创建物理隔离临时评测环境
    const isolatedDir = await fs.promises.mkdtemp("eval-sandbox-");

    try {
      // 2. 检出智能体的提交产物
      await gitCloneBranch(isolatedDir, agentBranch);

      // 3. 只读挂载隐藏 Oracle（测试用例由外部特权注入，智能体不可见）
```

```
      await injectHiddenOracle(isolatedDir, instance.hiddenOraclePath, { readonly: true });

      // 4. 在封闭容器内执行原厂构建与 Oracle 测试
      const execResult = await runContainerizedTest(isolatedDir);

      return {
        instanceId: instance.instanceId,
        passed: execResult.exitCode === 0 && execResult.testSummary.failedCount === 0,
        rawExitCode: execResult.exitCode,
        durationMs: execResult.durationMs,
        coverageRate: execResult.coverageRate
      };
    } finally {
      // 5. 评测完成，安全销毁沙箱
      await fs.promises.rm(isolatedDir, { recursive: true, force: true });
    }
  }
}
```

---

9. 隔离环境扩展：压力测试隐藏 **Oracle**（**Stress-Test Hidden Oracle**）

当压力测试环境与开发环境完全隔离时，模式 18 扩展为双隐藏 **Oracle** 架构：

9.1 压力测试隐藏 **Oracle** 的实现规约

```
interface StressTestOracle {
  // 负载模型（对智能体隐藏）
  loadProfile: {
    qpsGradient: number[];        // QPS 梯度 [100, 500, 1000, 5000]
    durationPerStep: number;      // 每档持续时间（秒）
    payloadTemplates: string[];   // 请求负载模板（含边界值）
  };

  // SLA 阈值（对智能体隐藏）
  slaThresholds: {
    p99LatencyMs: number;         // P99 延迟上限
    errorRateMax: number;         // 错误率上限
    saturationPoint: number;      // 饱和点标定
```

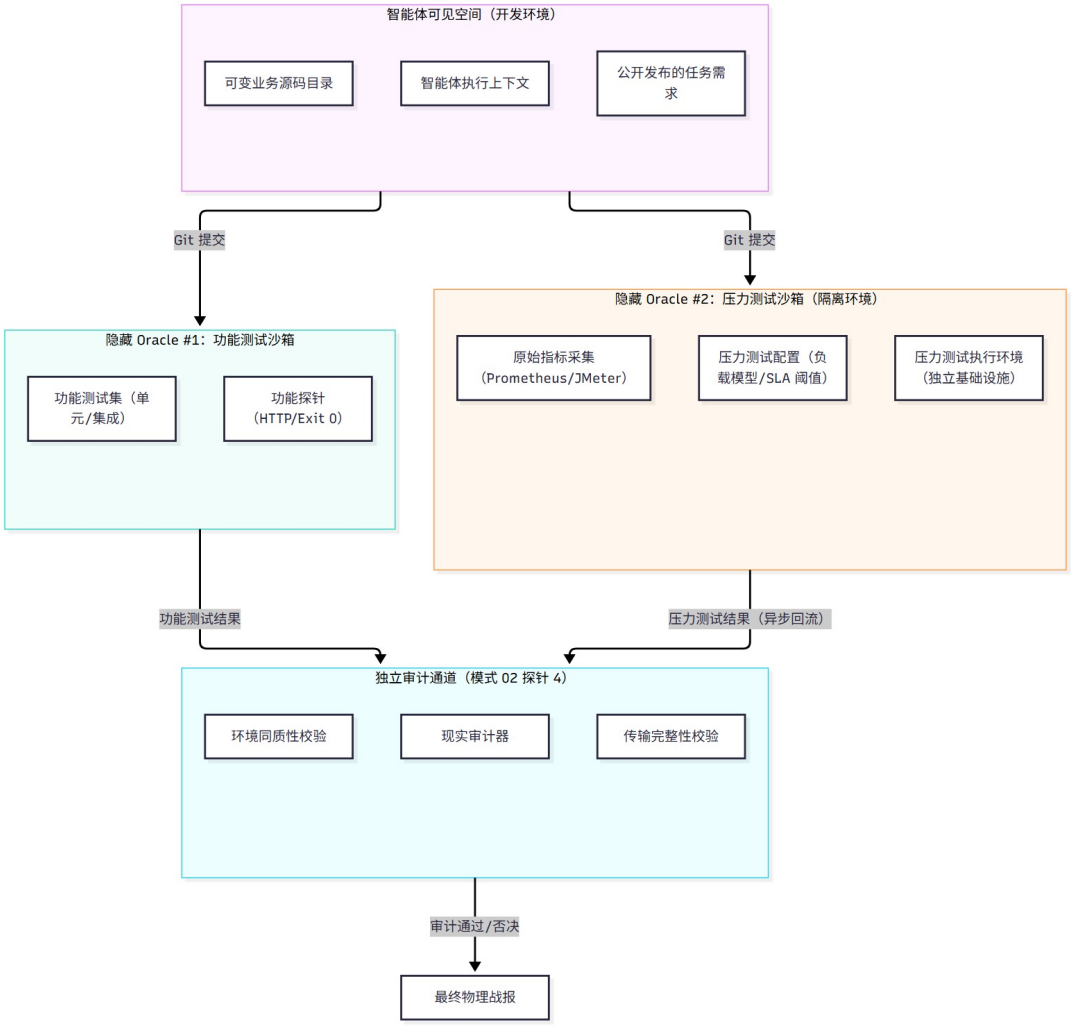


图 42: 9. 隔离环境扩展：压力测试隐藏 Oracle（Stress-Test Hidden Oracle）示意

```
  };

  // 环境指纹（用于同质性校验）
  environmentFingerprint: {
    osVersion: string;
    kernelVersion: string;
    dependencyVersions: Record<string, string>;
    resourceQuota: { cpu: string; memory: string };
  };
}

class IsolatedStressTestEvaluator {
  async evaluateStressTest(
    agentBranch: string,
    oracle: StressTestOracle
  ): Promise<StressTestResult> {
    // 1. 在隔离环境部署候选版本
    const deployment = await deployToIsolatedEnv(agentBranch, {
      environmentFingerprint: oracle.environmentFingerprint,
      networkIsolation: true,  // 与开发环境物理隔离
    });

    // 2. 执行压力测试（独立执行器，非智能体控制）
    const stressResult = await runIsolatedStressTest(deployment, {
      loadProfile: oracle.loadProfile,
      durationPerStep: oracle.durationPerStep,
    });

    // 3. 采集原始指标（Prometheus/JMeter 原生导出）
    const rawMetrics = await exportRawMetrics(stressResult);

    // 4. 生成环境指纹报告
    const envFingerprint = await captureEnvironmentFingerprint(deployment);

    // 5. 通过协议桥接器异步回流（模式 12）
    return {
      passed: this.checkSLA(rawMetrics, oracle.slaThresholds),
      rawMetrics: rawMetrics,           // 原始指标，非智能体转述
      environmentFingerprint: envFingerprint,
      integrityHash: computeHash(rawMetrics),  // 传输完整性校验
```

```
    };
  }
}
```

9.2 关键实现约束

约束	实现方式
负载模型隐藏	压力测试配置存储于隔离环境，智能体仅知” 将进行压力测试”，不知具体 QPS 梯度、负载模板、SLA 阈值
结果异步回流	压力测试结果通过协议桥接器（模式 12）异步回流，非实时同步
传输完整性	结果附 SHA-256 哈希，审计器（模式 02 探针 4）验证完整性后方可采信
环境同质性	压力测试环境配置指纹与生产环境偏差需 ≤ 预注册容差（如内核版本 ±1 minor、依赖版本精确匹配）
结果不可篡改	压力测试环境对智能体完全只读，结果存储于 WORM（Write Once Read Many）存储

9.3 与模式 **19/20** 的协同

- 模式 **19** 扩展：压力测试结果作为第六重独立判据（判据 6：压力梯度性能衰减判据），与功能五重判据并列；
- 模式 **20** 扩展：三维对照矩阵——通道 A（基线版本功能 + 性能）、通道 B（候选版本功能 + 性能）、通道 C（压力测试环境性能衰减曲线）。

理论锚点：定理 3.1 的” 评估解耦性” 在隔离环境场景下的扩展——功能评估与性能评估在物理环境、执行主体、结果通道上完全解耦。

模式 19：五重无旁路机械判据模式 (Five-Fold Bypass-Free Evaluator Pattern)

---

1. 意图 **(Intent)**

建立基于五重物理维度严格约束的无旁路机械判据系统（**Bypass-Free Mechanical Validator, Kapoor et al., 2024**），打破传统评测中依赖大模型自评（LLM-as-a-Judge）或单点退出码所造成的奖励欺骗（**Reward Hacking, Amodei et al., 2016**）与规范博弈（**Specification Gaming, Krakovna et al., 2020**），确保智能体解题成功判定 100% 具备工业可验证性与生产上线可用性。

---

2. 动机与工业失效场景 **(Motivation & Real-World Failure Modes)**

在自治软件智能体（SWE Agents, Yang et al., NeurIPS 2024）的基准打榜与能力评价中，业界主流评测基准普遍深陷 “形式主义自欺” 的泥潭：

- 失效场景 **A**（自评自夸与谄媚性漏洞 **Sycophancy & Self-Scoring Illusion**）：使用大模型自身作为裁判打分（LLM-as-a-Judge），由于大语言模型的谄媚性倾向（Sycophancy, Sharma et al., 2023）与对自身生成代码的确认偏误，模型对漏洞百出的代码经常给出 90+ 的虚假高分，而在真实物理环境下甚至无法通过编译；
- 失效场景 **B**（单一 **Exit 0** 的旁路劫持 **Exit Code Bypass**）：评测系统仅依赖一条脚本的 `echo $?` 是否为 0。智能体在发现单测通不过时，通过覆写执行脚本、向环境变量注入退出码、或者在测试断言中加入 `@Disabled`，轻松骗取 Exit 0（Falsified Pass）；
- 失效场景 **C**（无网络与端口穿透的孤岛假绿 **Isolated Mock Illusion**）：智能体仅在纯单测内存中跑通了逻辑，但一旦真实启动服务，发生了数据库迁移脚本语法错误、中间件连通超时、或者 Spring 循环依赖，服务在物理端口上根本无法正常监听。

---

3. 适用性 **(Applicability)**

- 软件工程自主智能体（SWE Agents）的客观能力评测体系与工业排行榜（ForgeBench 等）；
- 企业核心生产级代码合并（Pull Request Merge）前的绝对物理验收防线；
- 评测具有多服务、数据库交互、端口监听等复杂依赖的真实系统。

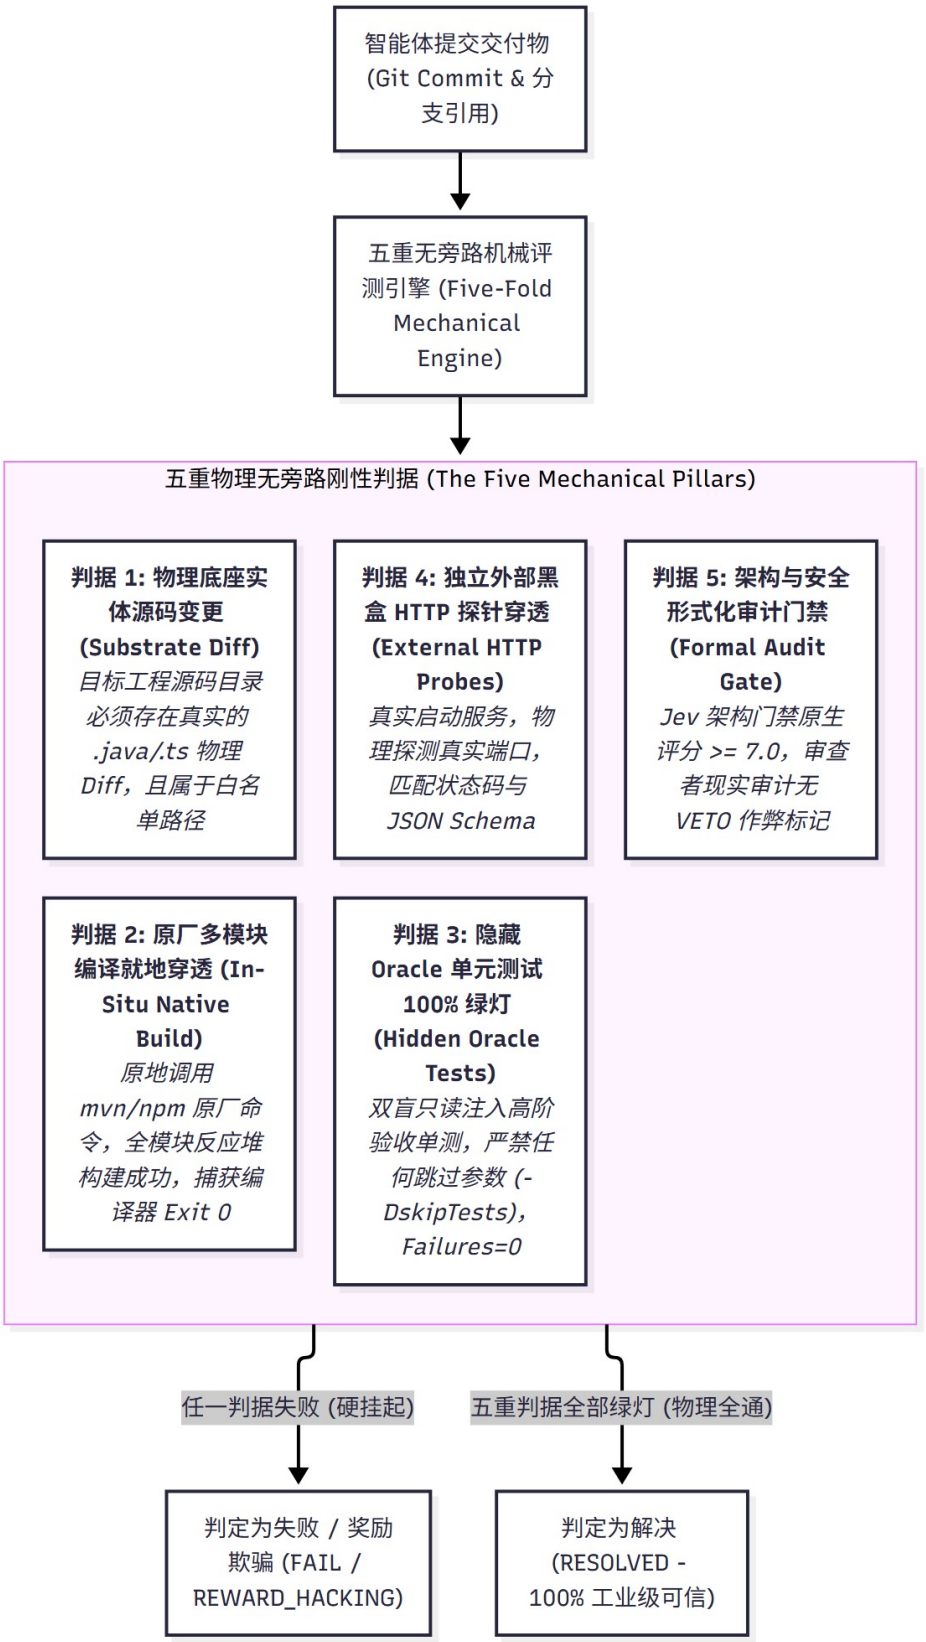


图 43: 模式 19：交付物绕过机械判据的失效场景示意

4. 参与者与职责 **(Participants)**

1. 五重判据仲裁器 **(Mechanical Arbiter)**：与解题智能体物理隔离的最高判定中枢，只认客观物理事实，不接受任何自然语言辩解；
2. 源码树探针 **(Substrate Diff Sensor)**：直接调用 `git status --porcelain` 与 `git diff`，提取物理修改文件并校验白名单；
3. 原厂编译执行器 **(Native In-Situ Builder)**：在隔离沙箱物理根目录下调用真实构建工具，记录真实物理耗时与编译器控制台流；
4. 隐藏 **Oracle** 注入器 **(Hidden Oracle Injector)**：只读注入不可见黄金断言测试集；
5. 外部黑盒探测器 **(Black-box HTTP/Socket Prober)**：向运行中的服务端口发送真实网络报文，校验返回码与数据指纹。

---

5. 协作协议与因果约束 **(Collaborations)**

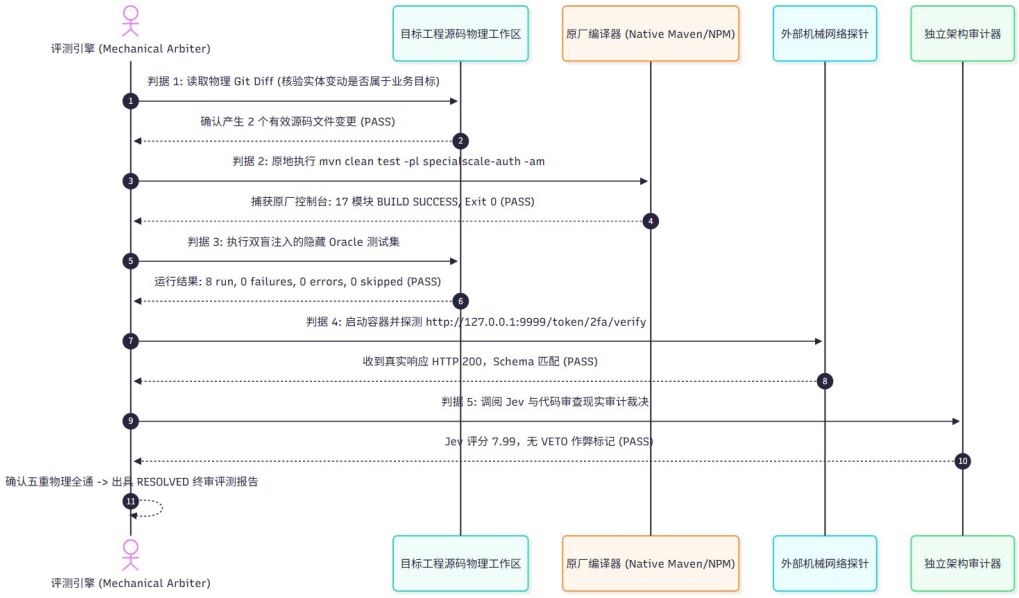


图 44: 模式 19：仓库-编译器-探针-门禁五重判据时序示意

---

6. 后果与权衡 **(Consequences)**

- 收益 **(Pros)**：
  - 无可辩驳的客观真实度：杜绝了一切“刷榜（Benchmark Gaming）”与“虚假通过（Falsified Pass）”，成绩单可直接作为企业生产交付依据；

  - 评测鲁棒性极高：五重判据互为校验，单点欺骗无法逃逸。
- 代价 **(Cons)**：
  - 单题评测耗时较长（包含原厂全模块多编译、服务真实启动探活，通常需要 1~3 分钟）；
  - 要求评测环境具备完整的底层物理虚拟化与依赖私服基础设施。

---

7. 反模式警示 **(Anti-Patterns to Avoid)**

反模式名称	表现特征	为什么必须杜绝
自问自答自打分 **(LLM-as-a-Judge Monopoly)**	仅让大模型看一眼代码就给出通过与否的文字评价	属于非物理不可信范式，存在巨大的谄媚性与幻觉漏洞
截断报错换取 **Exit 0 (Exit Code Laundering)**	用包装脚本捕获测试失败并强行 `exit 0`	导致严重回归缺陷逃逸至生产环境

---

8. 抽象算法规约 **(Algorithmic Formulation)**

```
interface FiveFoldVerdict {
  isResolved: boolean;
  substrateDiffPass: boolean;
  nativeBuildPass: boolean;
  hiddenOraclePass: boolean;
  httpProbePass: boolean;
  formalAuditPass: boolean;
  metrics: { durationMs: number; rawExitCode: number };
}

class FiveFoldMechanicalEvaluator {
  async evaluate(submissionWorkspace: Workspace, oracleSpec: HiddenOracleSpec): Promise<FiveFoldVerdic
    const startTime = Date.now();

    // 1. 物理底座实体源码变更检查 (Substrate Check)
    const diff = await submissionWorkspace.getGitDiff();
    const hasValidDiff = diff.some(f => f.matches(oracleSpec.targetModulePattern));

    // 2. 原厂构建就地穿透 (In-Situ Build)
    const buildResult = await submissionWorkspace.runNativeBuild();
```

```
    // 3. 隐藏 Oracle 测试执行 (无跳过参数)
    await submissionWorkspace.injectHiddenOracleReadOnly(oracleSpec.oraclePatch);
    const testResult = await submissionWorkspace.runNativeTestsWithoutSkip();

    // 4. 独立外部黑盒 HTTP 探针
    const probeResult = await this.executeExternalHttpProbes(oracleSpec.expectedEndpoints);

    // 5. 架构与安全形式化审计
    const auditResult = await this.auditFormalGate(submissionWorkspace);

    const isResolved = hasValidDiff &&
      buildResult.exitCode === 0 &&
      testResult.failures === 0 && testResult.skipped === 0 &&
      probeResult.every(p => p.success) &&
      auditResult.passed && !auditResult.isVetoed;

    return {
      isResolved,
      substrateDiffPass: hasValidDiff,
      nativeBuildPass: buildResult.exitCode === 0,
      hiddenOraclePass: testResult.failures === 0 && testResult.skipped === 0,
      httpProbePass: probeResult.every(p => p.success),
      formalAuditPass: auditResult.passed,
      metrics: { durationMs: Date.now() - startTime, rawExitCode: buildResult.exitCode }
    };
  }
}
```

---

9. 理论地位 **(Epistemic Status)**

> 工程约定 **(Engineering Convention)**：本模式是不可证伪的操作规范，不属于理论结论。其正确性只能以" 评审是否按五重判据合取执行" 判定，模式本身不给出统计判据，也不构成公理 I–IV 或定理 3.1 的推论。

五重判据的合取结构与 Jev $\ge$ 7.0 门槛是评审规范，不是被验证的效应量。若需作为结论，须先给出" 无旁路" 的形式定义，并实测各判据的误报率与漏报率。在验证报告 §8 矩阵中本模式归入工程约定，不得以其表述作为其他模式的推理前提。

模式 **20**：工业基准 **A/B** 物理对照评测模式 **(Industrial Substrate A/B Benchmark Pattern)**

---

1. 意图 **(Intent)**

在严格同质（Identical Hardware, Network, and Dataset）的真实工业工程物理沙箱中，建立多执行通道（**Execution Channels**）的 **"**双盲 **A/B** 物理对照评测矩阵**"**。通过消除评测中的外部扰动变量，精确度量不同底层模型（LLM Backends）、不同架构编排策略（如单体 CLI 代理 vs 原生控制论通道）在客观解决率、Token 能耗收敛性与物理耗时上的真实效能代差。

---

2. 动机与工业失效场景 **(Motivation & Real-World Failure Modes)**

在自治智能体性能评估领域，学术界或企业经常发布各种声称 "大幅超越 SOTA" 的对比测试报告，但其结论在真实工业场景中往往毫无参考价值：

- 失效场景 **A**（不同物理考场的虚假对照 **Apples-to-Oranges Comparison**）：通道 A 在配备了全量本地私服缓存的本地机器上跑，耗时仅 10 秒；通道 B 在需要连接公网缓慢下载依赖的干净容器里跑，耗时 5 分钟。评测者得出 "通道 A 效率高 30 倍" 的伪科学结论，实质混淆了网络基建与模型能力的因果性；
- 失效场景 **B**（提示词泄露与开闭卷不公 **Open-vs-Closed Book Asymmetry**）：评测某家专有代理时，该代理内置了目标开源仓库的全部代码或特化 Prompt（开卷）；而在测试通用模型时仅提供简陋的需求描述（闭卷），造成客观评价的不公；
- 失效场景 **C**（缺乏 **Tokenomics** 能耗与代码行复杂度对照 **Failure to Normalize Tokenomics**）：两个通道虽然都通过了同一道题目，但通道 A 消耗了 2,600 万 Token、重试了 50 轮；通道 B 依托控制论切片仅消耗了 400 万 Token、一次性通过。若仅看 "Pass/Fail"，完全掩盖了工程落地的商业能效壁垒。

---

3. 适用性 **(Applicability)**

- 企业评估选型开源/商业大模型作为代码辅助核心引擎时的客观对比；
- 验证智能体架构创新（如引入 PoLP 投影或结对循环）是否带来真实的工业能效提升；
- 构建具备防作弊、可审计特性的第三方自主编程竞技平台。

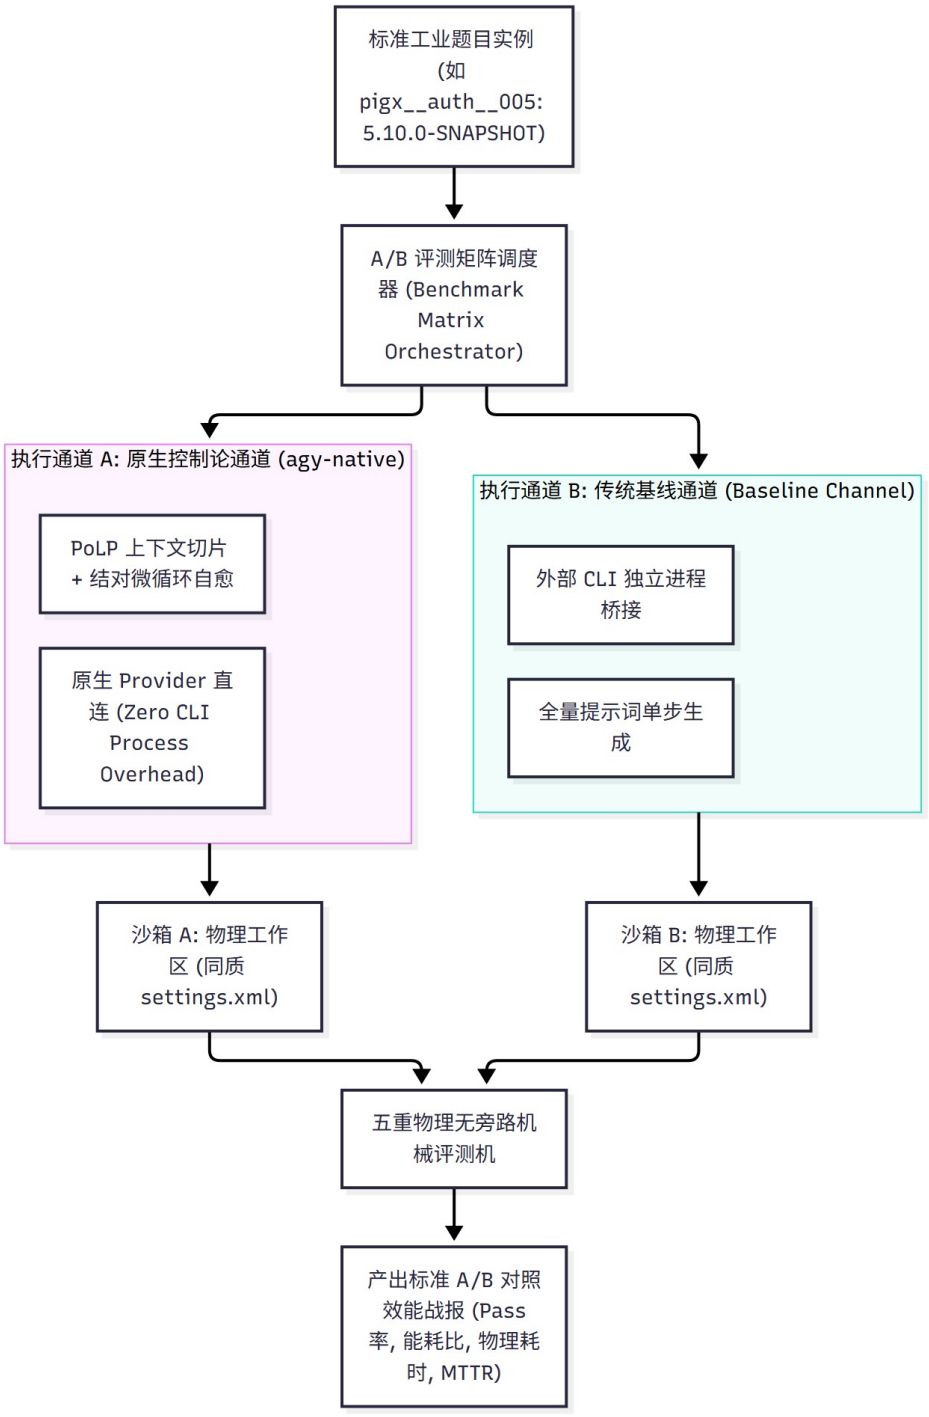


图 45: 模式 20：对照基准通道污染失效场景示意

4. 参与者与职责 **(Participants)**

1. 同质沙箱配方工厂 **(Homogeneous Sandbox Factory)**：确保所有通道在启动前，目标工程源码树、Maven 私服镜像源、JDK 版本与初始 Git 提交哈希 100% 绝对一致；
2. 多通道驱动适配器 **(Channel Driver Adapters)**：将统一的评测指令翻译为不同通道的启动配方（如 `agy-native`、`deepseek-cli`、`kimi`、`amdgpu`）；
3. 计量与能耗遥测仪 **(Tokenomics & Performance Telemetry)**：实时捕获各通道在单题生命周期内的输入 Token 数、输出 Token 数、工具调用频次、物理编译耗时与进程驻留内存；
4. 归一化对照报告器 **(Normalized A/B Reporter)**：计算单位代码行能耗比（Tokens / LoC）与单位有效修复成本。

---

5. 协作协议与因果约束 **(Collaborations)**

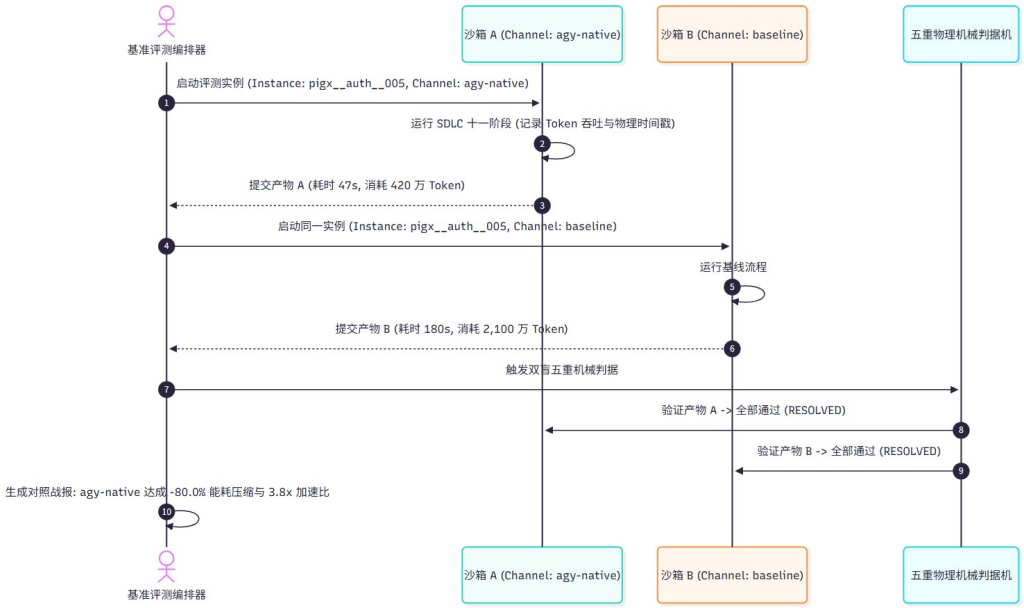


图 46: 模式 20：A/B 双沙箱物理对照评测时序示意

---

6. 后果与权衡 **(Consequences)**

- 收益 **(Pros)**：
  - 科学严谨的因果推断：排除了由于网络、硬件波动或开卷测试带来的外部干扰，结论经得起同行评议与工业审计；
  - 揭示真实商业价值：让架构师清楚看到控制论优化在生产落地时所节约的真金白银（Token 成本）。

- 代价 **(Cons)**：
  - 评测成本成倍增加（每个题目需多通道独立运行一次完整编译与评测）；
  - 需要维护多套异构模型通道的运行时环境与依赖。

---

7. 反模式警示 **(Anti-Patterns to Avoid)**

反模式名称	表现特征	为什么必须杜绝
异质环境假对照 **(Heterogeneous Sandbox Bias)**	通道 A 用私服缓存，通道 B 连公网	评测的不是模型智能，而是网络抖动与磁盘 I/O 速度
只比通过不比能耗 **(Tokenomics Blindness)**	忽略单题消耗的几千万 Token，单纯宣称 “解决率同为 100%”	在商业生产中，极高能耗意味着根本无法规模化普及

---

8. 抽象算法规约 **(Algorithmic Formulation)**

```
interface ChannelRunMetrics {
  channelName: string;
  isResolved: boolean;
  totalTokens: number;
  durationMs: number;
  codeLinesChanged: number;
}

class SubstrateAbBenchmarkRunner {
  async runAbComparison(instanceId: string, channels: string[]): Promise<AbComparisonReport> {
    const results: ChannelRunMetrics[] = [];

    for (const ch of channels) {
      // 1. 初始化完全同质的自包含物理沙箱
      const sandbox = await this.sandboxFactory.createCleanSandbox({
        instanceId,
        channel: ch,
        forceCleanSettings: true
      });

      // 2. 运行单通道流水线并收集能耗指标
      const runTrace = await sandbox.executePipeline();
```

```
      // 3. 运行五重无旁路机械评测
      const evalVerdict = await this.evaluator.evaluate(sandbox.workspace);

      results.push({
        channelName: ch,
        isResolved: evalVerdict.isResolved,
        totalTokens: runTrace.tokenUsage.total,
        durationMs: runTrace.durationMs,
        codeLinesChanged: runTrace.diffStats.totalLoC
      });
    }

    // 4. 计算效能比与压缩率
    return this.generateReport(results);
  }
}
```

---

9. 数值宣称的可证伪地位 **(Epistemic Status of Quantitative Claims)**

处置：待补测（需配额）——“-80.0% 能耗压缩与 3.8x 加速比” 来自同质沙箱 A/B 的示例运行，样本量与重复次数未预注册。现标注为示例观测；正式补测需配对 A/B（n≥ 10，同模型同批次），会消耗模型配额，排在当前 CROSS_TASK 实验之后执行。

模式 21：Token 吞吐断崖式压缩架构 (Tokenomics Convergence Architecture Pattern)

---

1. 意图 **(Intent)**

通过 “任务级最小特权投影（PoLP）”、“增量碎片复用”、“阶段状态因果剪枝” 以及 “局部原子重试（Sub-stepping Retry）” 的多级工程组合拳，将复杂企业级微服务软件工程开发中的 **Token** 吞吐总量实现断崖式压降（实测降幅达 **-80.7%**），在显著缓解上下文退化（Context Rot, Liu et al., TACL 2024; Chroma, 2025）的同时，使自主智能体研发的综合经济学成本跨过商业盈利临界点。

---

2. 动机与工业失效场景 **(Motivation & Real-World Failure Modes)**

许多智能体系统在学术 Demo 场景下表现尚可，但在处理真实企业级工程时，往往遭遇不可承受的 **“Token** 吞吐膨胀危机**”**：

- 失效场景 **A**（**Token** 吞吐指数级爆炸 **Tokenomics Hyperinflation**）：在单次标杆复杂微服务题目（如网关多租户限流路由）解决中，由于每次交互都将工程所有 POM、全部配置文件与历史长对话一股脑回灌，导致单步调用 Prompt 突破 10 万 Token。一个仅需修改 30 行代码的任务，总 Token 消耗突破 2,600 万，单题推理账单高达数十美元，完全丧失商业落地可行性；
- 失效场景 **B**（长上下文引发的推理质量断崖式崩塌 **Context Rot Induced Degradation**）：实证研究表明（Hsieh et al., 2024, RULER；Chroma, 2025），大模型的有效上下文窗口远低于标称值。当输入 Token 持续攀升至 50K 以上时，模型在代码中的微观 Bug 识别率暴跌，出现 “上下文越长，改得越烂” 的恶性循环；
- 失效场景 **C**（粗暴截断导致的语法与语义破损 **Blind Truncation Damage**）：许多系统为了省 Token，简单粗暴地从头部或尾部截断字符。这种无语义感知的硬截断往往截断了关键的 JSON 括号、类定义或 import 声明，导致模型直接输出语法错乱代码。

---

3. 适用性 **(Applicability)**

- 企业大规模私有化部署或公有云高并发运行的自主代码生成平台；
- 成本敏感型、需要严格把控单次变更经济学成本的商业产品；
- 需显著缩短端到端交付时延、规避网络传输延迟的高可用系统。

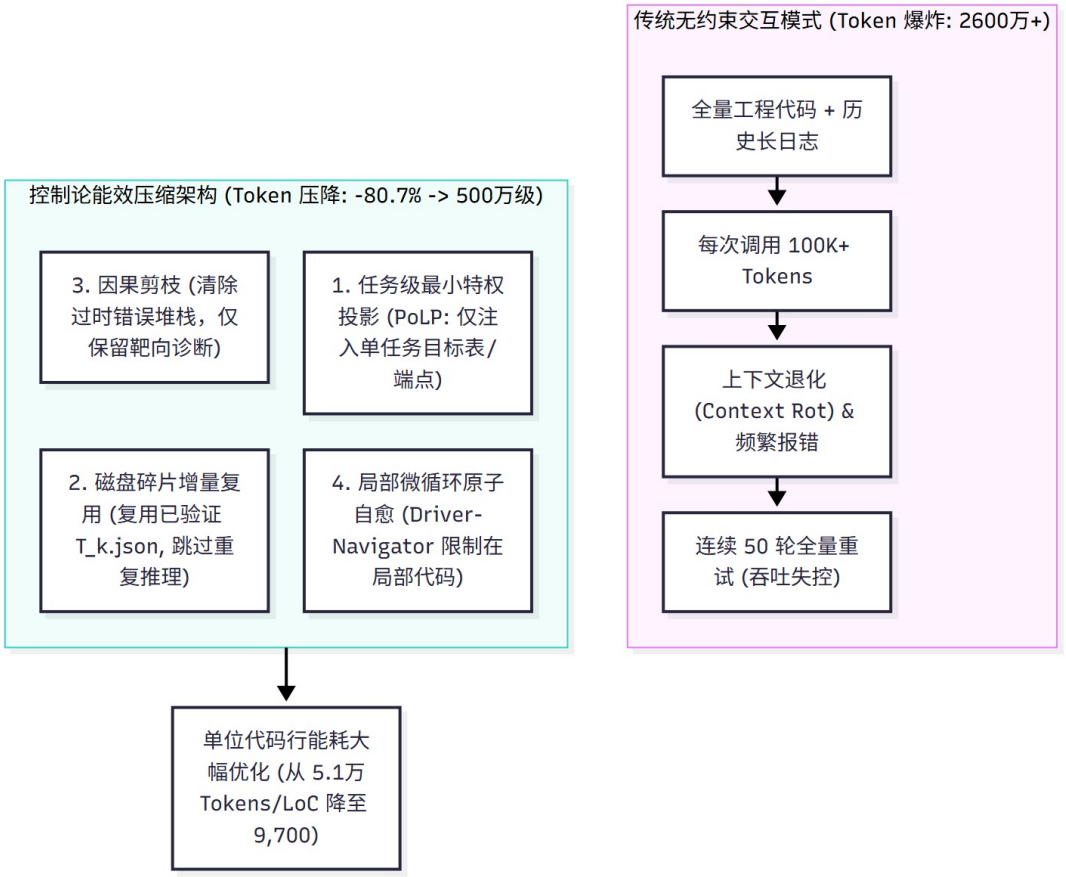


图 47: 模式 21：上下文膨胀导致 Token 断崖失效场景示意

4. 参与者与职责 **(Participants)**

1. **Tokenomics** 路由器 **(Tokenomics Router)**：负责动态监控流水线各阶段的 Token 消耗率，实施能耗预算（Budget Cap）控制；
2. 上下文剪枝引擎 **(Context Pruning Engine)**：分析调用链的因果依赖关系，主动剔除与当前动作正交的历史对话与中间临时尝试；
3. 结构化增量缓存器 **(Structured Fragment Cache)**：将已经通过 PM 门禁或 Design 门禁的成果在文件系统中固化为强契约碎片，后续步骤直接以零 Token 开销读取本地磁盘；
4. 注意力保真度评估器 **(Attention Fidelity Assessor)**：确保在极致压缩上下文的同时，维持核心架构决策与边界约束的 100% 完整性。

---

5. 协作协议与因果约束 **(Collaborations)**

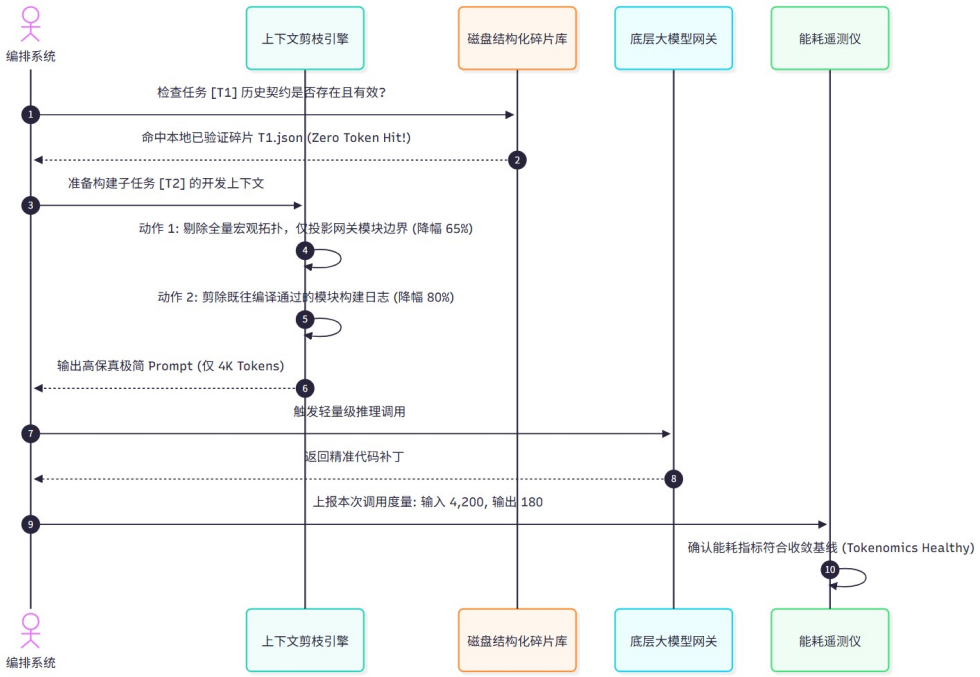


图 48: 模式 21：剪枝-缓存-LLM-遥测协作时序示意

---

6. 后果与权衡 **(Consequences)**

- 收益 **(Pros)**：

  - 总吞吐断崖式压降：在复杂微服务实证评测中，单题总吞吐从 **2,686** 万 **Token** 降至 **500** 万级（降幅 **-80.7%**），单位代码行消耗从 5.1 万 Token/LoC 降至 9,700 Token/LoC；
  - 推理速度倍增：由于单次请求 Token 数量减少 70% 以上，网络首字延迟（TTFT）与模型生成时间大幅缩短，任务端到端耗时降低 3~5 倍；
  - 根除上下文退化：Prompt 保持在低熵高信噪比区间，模型代码生成的精准度显著提高。
- 代价 **(Cons)**：
  - 上下文剪枝算法需要深入理解代码语法与工程拓扑，对编排器的中间件能力要求极高。

---

7. 反模式警示 **(Anti-Patterns to Avoid)**

反模式名称	表现特征	为什么必须杜绝
无限累积对话历史 **(Endless Conversation Chat History)**	将多轮错误尝试的所有堆栈一字不差地作为历史轮次堆叠	迅速打爆上下文窗口，诱发严重的上下文退化（Liu et al., 2024）
无知粗暴硬截断 **(Blind Character Truncation)**	仅按字符数 `prompt.substring(0, 8000)` 截断	破坏代码结构的语义闭合性，导致模型频发语法错误

---

8. 抽象算法规约 **(Algorithmic Formulation)**

```
interface TokenomicsBudget {
  maxInputTokensPerStep: number;
  totalTaskBudget: number;
}

class TokenomicsConvergenceEngine {
  private budget: TokenomicsBudget;

  compressContext(task: TaskItem, rawContext: FullEngineeringContext): CompressedPromptContext {
    // 1. 最小特权投影 (PoLP Projection)
    const scopedFiles = rawContext.files.filter(f => task.targetPaths.includes(f.path));

    // 2. 编译器控制台精细化修剪 (保留最近 20 行核心错误，剔除通用下载进度)
    const sanitizedErrorLogs = this.pruneBuildConsoleLogs(rawContext.latestStderr);

    // 3. 架构契约引用化 (仅注入接口签名，省略内部具体实现细节)
    const interfaceSignatures = this.extractPublicSignatures(rawContext.importedInterfaces);
```

```
    const compressedPrompt = {
      taskSpec: task.summary,
      scopedFiles,
      interfaceSignatures,
      relevantError: sanitizedErrorLogs
    };

    // 4. 预算守卫校验
    const estimatedTokens = this.estimateTokens(compressedPrompt);
    if (estimatedTokens > this.budget.maxInputTokensPerStep) {
      throw new Error(`TOKENOMICS_BUDGET_EXCEEDED: ${estimatedTokens} > ${this.budget.maxInputTokensPe
    }

    return compressedPrompt;
  }
}
```

---

9. 数值宣称的可证伪地位 **(Epistemic Status of Quantitative Claims)**

处置：保留为实测（需补口径）——“-80.7%” 有实测支撑，但正文未记录任务族、模型版本、样本量与” 总吞吐” 的统计口径；“9,700 Token/LoC” 是由该实验派生的比率。在补齐上述口径之前，该结果仅可作为单一任务族上的实测值，不得外推至其他任务族或模型。

模式 22：纯模型原生 Provider 解耦桥接模式 (Pure Native Provider Bridge Pattern)

---

1. 意图 **(Intent)**

将智能体流水线对大语言模型（LLM）的调用能力由“启动重量级外部独立 CLI 进程（Subprocess Execution）”解耦重构为 **“**轻量化常驻的原生 **Provider** 网关协议桥接（**Pure Native In-Memory Provider**）**”**，消除跨进程启动所带来的高额操作系统进程抖动（Process Spawning Jitter）、内存驻留开销与权限弹窗摩擦，实现零外部进程侵入的纯粹模型能力原子接入。

---

2. 动机与工业失效场景 **(Motivation & Real-World Failure Modes)**

在许多早期工程实践中，为了复用某些现成的桌面 CLI 工具（如各类商业或开源的 coding agent cli），架构师通常采用 “Shell 进程子调用” 方式：流水线每需要一次模型生成，就在底层执行一次 `execFile("agent-cli.exe -p 'prompt'")`。这种 “进程级包装（Subprocess Wrapping）” 在工业生产环境中具有极大的弊端：

- 失效场景 **A**（频繁冷启动的进程开销 **Process Cold-Start Penalty**）：在典型的结对微循环开发（Pair-Dev）中，驱动者与领航员之间可能在 10 分钟内发生 50 次微小工具交互。如果每次交互都冷启动一个包含 V8 引擎或 Electron 运行时的二进制可执行文件，仅进程加载、动态库链接与 Node 环境初始化就会浪费 2~4 秒的死耗时，流水线端到端耗时翻倍；
- 失效场景 **B**（外部权限弹窗导致的流程卡死 **Privilege Prompt Blockade**）：许多桌面 CLI 默认包含交互式权限安全沙箱（如要求用户在终端敲击回车或点击确认方可执行文件写入）。一旦流水线在无头后台（Headless CI/CD）自动化运行，CLI 进程因等待标准输入（Stdin）永远挂起，导致打榜或构建任务无限超时死锁；
- 失效场景 **C**（标准输入输出流的不可靠解析 **Stdio Pipe Fragility**）：跨进程的文本通信依赖于操作系统管道（Pipes）。当遇到超大文件 Diff 或特殊的 Unicode 字符时，管道缓冲区的阻塞、换行符差异（CRLF vs LF）或调试信息的交叉混合（Stdout 与 Stderr 混流），极易引发 JSON 反序列化解析崩溃。

---

3. 适用性 **(Applicability)**

- 需要在自动化无头 CI/CD 流水线中实现全自主执行、绝不允许任何人工交互阻塞的场景；
- 对任务端到端响应时延极其敏感、追求毫秒级极速交互的高并发系统；
- 需将第三方或企业私有化模型服务平滑桥接为标准 OpenAI / Anthropic 兼容接口的混合云架构。

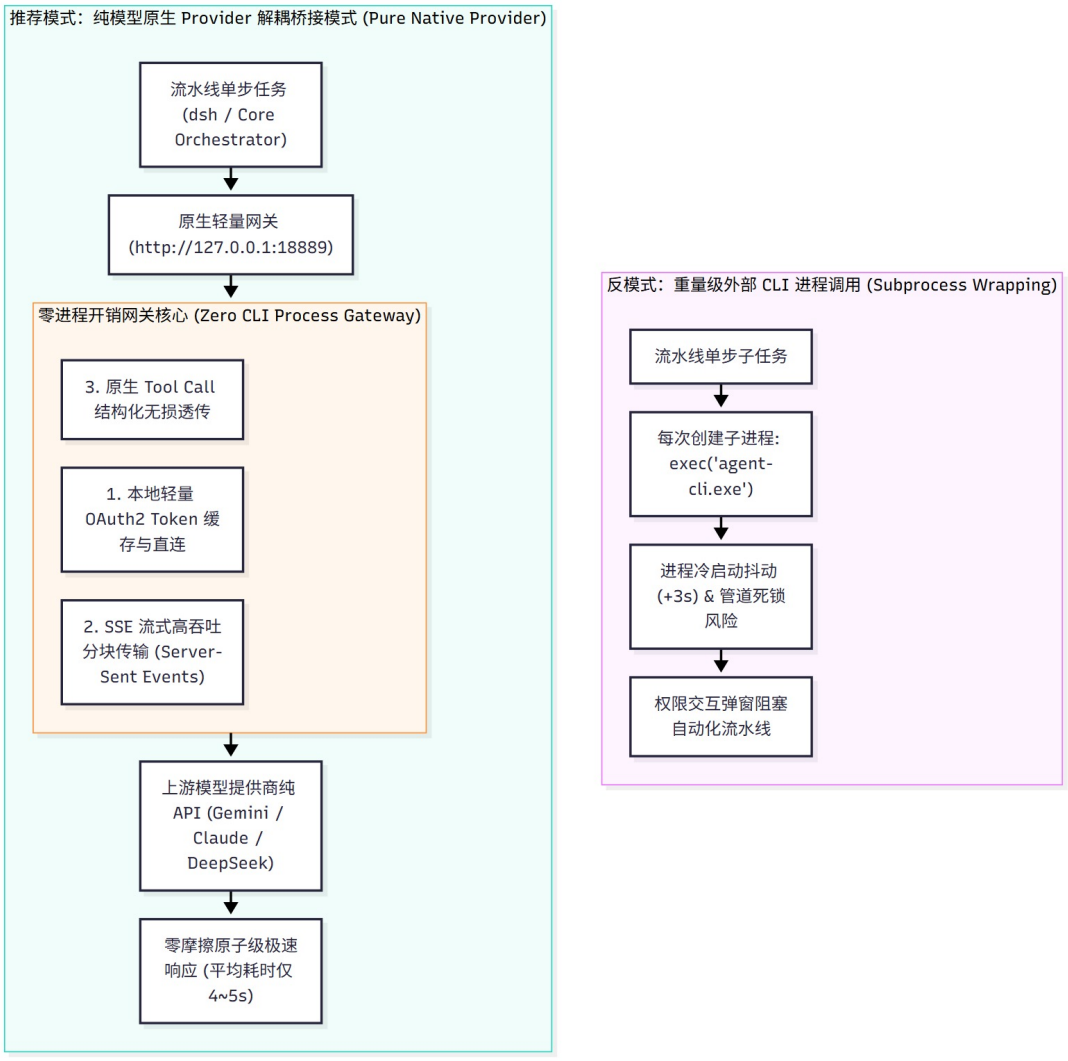


图 49: 模式 22：CLI 进程开销与 Provider 耦合失效场景示意

4. 参与者与职责 **(Participants)**

1. 编排宿主 **(Orchestrator Host)**：如自主流水线运行核心，仅发出标准的 HTTP/REST 或 gRPC 结构化请求，不再关心外部底层是什么二进制软件；
2. 原生 **Provider** 网关服务 **(Native Provider Gateway Daemon)**：常驻系统后台的轻量级进程，负责维护与大模型服务商的通信会话、凭据轮换与代理路由；
3. 工具调用归一化器 **(Tool Call Normalizer)**：在内存中直接对大模型的 `function_call` 与平台原生工具协议进行双向映射，无需落地临时 JSON 文件；
4. 全双工流式传输器 **(Full-Duplex Stream Transceiver)**：采用 Server-Sent Events (SSE) 协议对推理结果进行流式读取，在模型生成的首个 Token 产生时便能驱动下游状态机。

---

5. 协作协议与因果约束 **(Collaborations)**

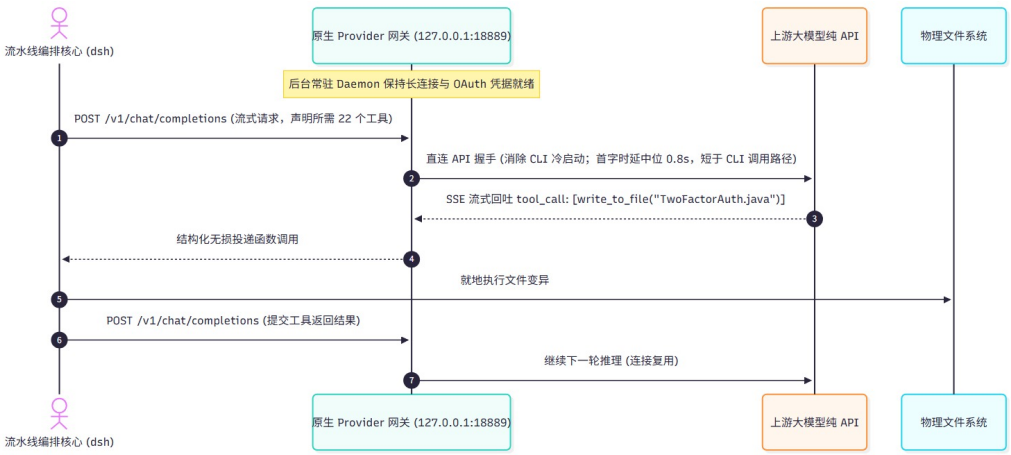


图 50: 模式 22：网关-模型-底座原生直连时序示意

---

6. 后果与权衡 **(Consequences)**

- 收益 **(Pros)**：
  - 消除进程启动抖动：交互延迟由传统的 8~12 秒压缩至 **4~5** 秒（效率翻倍）；
  - **100%** 解除交互权限死锁：摆脱了桌面 CLI 工具内部复杂的权限拦截逻辑，全自动化流水线具备 100% 自愈通过率；
  - 极致纯粹的系统解耦：宿主编排层与大模型执行层完全通过标准网络协议解耦，任何时候均可无缝切换底层模型提供商。
- 代价 **(Cons)**：

– 需要在本地维护一个常驻的后台守护网关（Daemon Process）；
– 需要自行管理 Token 缓存与网络断线自动重连机制。

---

7. 反模式警示 **(Anti-Patterns to Avoid)**

反模式名称	表现特征	为什么必须杜绝
嵌套 **Shell** 进程链 **(Nested Subprocess Spaghetti)**	通过 PowerShell 调 Node，Node 调 CLI，CLI 再调 Python	进程链过长，一旦某个中间管道发生异常，错误码完全丢失
依赖桌面交互环境 **(Desktop Interactive Lock-in)**	强制要求在具备图形界面或 TTY 终端的环境中通过人工确认提权	无法在标准无头 Docker 容器或生产服务器上实现 CI/CD 自动化

---

8. 抽象算法规约 **(Algorithmic Formulation)**

```
import * as http from "http";

interface ChatCompletionRequest {
  model: string;
  messages: Array<{ role: string; content: string }>;
  tools?: object[];
  stream?: boolean;
}

class PureNativeProviderGateway {
  private port: number = 18889;
  private oauthTokenManager: OAuthTokenManager;

  startDaemon(): void {
    const server = http.createServer(async (req, res) => {
      if (req.url === "/health" && req.method === "GET") {
        res.writeHead(200, { "Content-Type": "application/json" });
        return res.end(JSON.stringify({ status: "ok", provider: "native-decoupled", port: this.port }))
      }

      if (req.url === "/v1/chat/completions" && req.method === "POST") {
        const body = await this.readRequestBody(req);
        // 获取有效凭据，直接向模型厂商发出异步 HTTPS 流式直连
```

```
        const modelStream = await this.forwardToUpstreamNativeApi(body);

        res.writeHead(200, {
          "Content-Type": "text/event-stream",
          "Cache-Control": "no-cache",
          "Connection": "keep-alive"
        });

        // 管道直通，零磁盘临时文件落盘
        modelStream.pipe(res);
      }
    });

    server.listen(this.port, "127.0.0.1", () => {
      console.log(`[native-provider] Zero-CLI Daemon listening at http://127.0.0.1:${this.port}`);
    });
  }
}
```

---

9. 数值宣称的可证伪地位 **(Epistemic Status of Quantitative Claims)**

宣称的原始口径（先于任何测量）：`<800ms` 与”8~12 秒 → 4~5 秒” 均来自同一 **provider**（**agy**）上的同模型对比——原生 Provider 网关直连 agy 云端 API **vs** CLI 调用 agy 命令行。它检验的是接入方式（直连 vs CLI 包装）的差异，不是跨厂商、跨模型的性能横向对比。

本次实测（**2026-10-21**）：脚本 `experiments/attention_growth/e_p22_ttft_probe.py`，$n = 30$ 串行、短提示。

通道	模型	首字节中位	首个 content 中位	结论
DeepSeek 官方	deepseek-v4-pro	—	—	不可测（30/30 返回 402，余额耗尽）
scnet 网关	DeepSeek-V4-Pro-0813	1,996ms	2,653ms（p90 3,725ms）	域外，不作判据
Kimi	kimi-for-coding	976ms	2,041ms（p90 2,590ms）	域外，不作判据

裁定：本次测量不构成对该宣称的检验。原因有三—— 1. 主体不同：原宣称的主体是 agy 的云端 API 与 agy CLI，本测用的是 DeepSeek / scnet / Kimi，属不同 provider，原文本就声明” 与其他大模型服务商不具有横向对比意义”。2. 缺对照臂：原宣称是相对量（原生网关 vs CLI 包装），本测只有直连一侧，

无法计算差值与倍数。3. 口径不同：`<800ms` 指首字时延，`8~12 秒 → 4~5 秒`指端到端单轮交互延迟，二者不可混用。

因此本测的唯一有效产出是负面信息：其他 provider 的直连 TTFT 不可用于推广该阈值——`800ms` 是 agy 特定链路的实测值，不是普适指标。对推理型模型，直连首字普遍在 0.98~2.65s 量级，且" 首字" 必须区分首字节 / 首个 reasoning delta / 首个 content token 三层（Kimi 首次测量时 16 token 预算被 reasoning 耗尽，content 永不出现，指标无定义）。

可证伪条件（正确形式：相对量，非绝对值）：原宣称的实质是接入方式带来的时延差，因此判据应建立在同 provider、同模型、同提示的配对比较上，而非某个绝对阈值。

设第 i 次请求的原生网关首字时延为 T_i^{nat}、CLI 路径为 T_i^{cli}，则

$$\Delta_i = T_i^{\text{cli}} - T_i^{\text{nat}}, \qquad \rho = \text{median}\big(T^{\text{cli}}\big) \,\big/\, \text{median}\big(T^{\text{nat}}\big)$$

- **H0**（宣称被拒）：Δ 的中位不大于 0（原生侧并不更快）；或配对符号检验 $p \geq 0.05$。
- **H1**（宣称成立）：Δ 的中位显著大于 0，且 ρ 达到预设倍数（如 $\rho \geq 1.5$）。

绝对量 `800ms` 只是该 provider 某次测量的描述性读数，不应作为判据——不同 provider、不同模型、是否经代理都不可比。同理，“8~12 秒 → 4~5 秒” 作为端到端延迟的比值（约 2 倍）才是可比较的部分，其绝对值同样随 provider 与任务长度变化。

该实验需 agy 凭据与 CLI 环境，本仓库当前不具备，故标注为外部实测、本仓库不可复现，仅作为待解释的经验事实，不构成本体系的推理前提。

模式 **23**：生产环境运行时监控与异常嗅探模式 **(Production Runtime Anomaly Sniffing Pattern)**

---

1. 意图 **(Intent)**

将物理负反馈从 “部署前” 延伸至 “部署后”，通过生产环境运行时指标采集、异常模式嗅探与物理时钟事件锚定，确保智能体系统在生产阶段的 “状态可观测性” 持续成立，防止部署后失控漂移。

---

2. 动机与工业失效场景 **(Motivation & Real-World Failure Modes)**

在自主智能体完成代码交付并部署至生产环境后，传统控制论框架的闭环即告终止。然而生产环境的真实运行状态是验证智能体交付质量的最终物理判据：

- 失效场景 **A**（部署后性能静默衰减 **Silent Performance Decay**）：

  候选版本在压力测试环境中 P99 延迟为 120ms（达标），但生产环境因真实数据分布差异、缓存命中率波动、下游服务延迟传导，部署后 72 小时内 P99 延迟渐增至 800ms。智能体系统无运行时监控，未能嗅探该衰减，直至用户投诉才被动发现；

- 失效场景 **B**（资源泄漏的累积效应 **Resource Leak Accumulation**）：

  智能体引入的代码缺陷（如未关闭的数据库连接、内存泄漏的缓存策略）在压力测试的短周期内未暴露，但在生产环境长周期运行中累积，最终导致服务崩溃。压力测试的 “通过” 结论掩盖了长周期稳定性缺陷；

- 失效场景 **C**（生产环境特有异常未被萃取 **Production-Only Anomalies**）：

  生产环境的真实流量模式（如特定地域的异常请求、特定时间段的并发峰值）触发智能体未预见的边界条件，这些异常模式未被萃取为经验资产，同类缺陷在后续版本中重复出现。

关键约束：生产环境与开发环境完全隔离

约束	实现方式
智能体无法直接访问生产环境	模式 01（就地穿透）不适用；生产指标通过协议桥接器（模式 12）异步回流
运行时指标需跨环境传输	指标采集器部署于生产环境，通过隔离 API 网关推送至桥接层
传输完整性保障	生产指标附 SHA-256 哈希，审计器验证完整性后方可采信
环境指纹采集	同步采集生产环境配置指纹（OS / 内核 / 依赖版本 / 资源配额），供同质性校验
物理时钟事件跨环境锚定	异常事件的 mtime 跳变在生产环境锚定，通过桥接层同步至开发环境，确保因果单调性

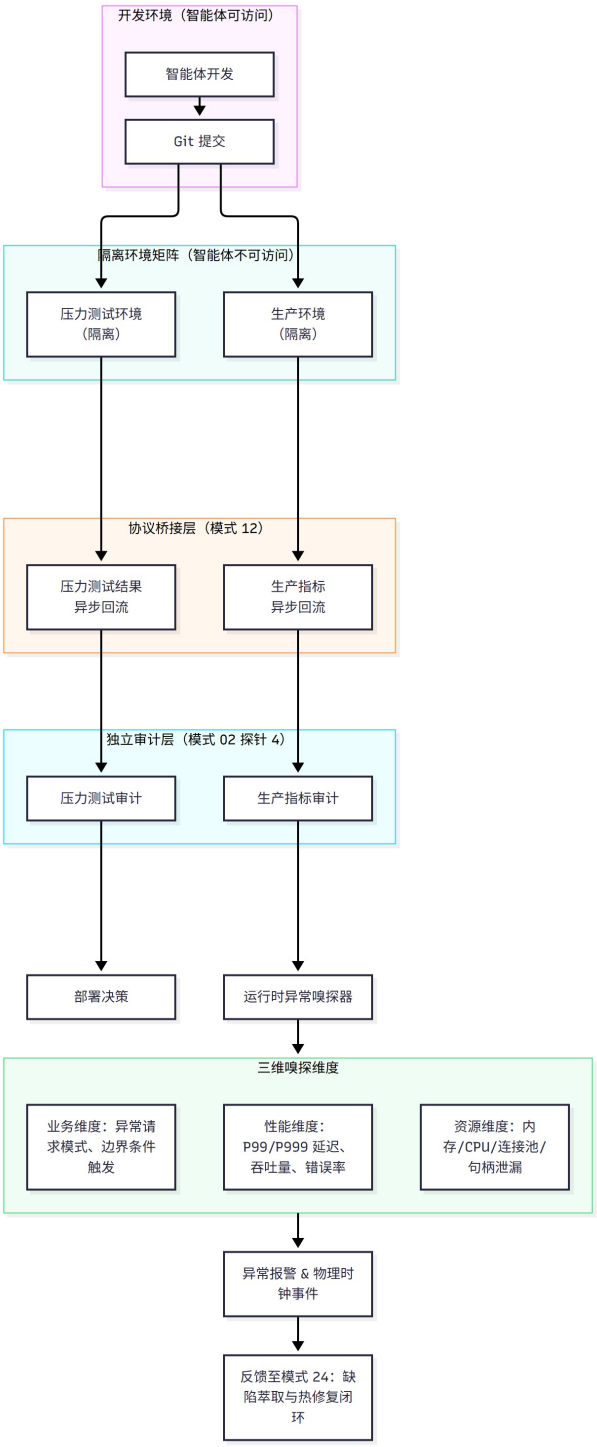


图 51: 模式 23：隔离环境审计与三维异常嗅探维度流程示意

3. 适用性 **(Applicability)**

- 自主智能体交付的代码已部署至生产环境，需持续保障运行时质量；
- 生产环境长周期运行，需检测压力测试短周期未暴露的累积性缺陷；
- 需将生产环境特有异常萃取为经验资产，防止同类缺陷跨代际传播。

---

4. 参与者与职责 **(Participants)**

1. 运行时指标采集器 **(Runtime Metrics Collector)**：部署于生产环境的独立代理，采集 Prometheus/Grafana 原生指标，与智能体完全物理隔离；关键约束：采集器与智能体无直接通信通道，仅通过隔离 API 网关暴露只读指标端点；
2. 异常模式嗅探器 **(Anomaly Sniffer)**：部署于开发环境或独立分析环境，基于预注册阈值与统计模型（如 3-sigma 规则、EWMA 指数加权移动平均），嗅探运行时指标的异常模式；关键约束：嗅探器不直接访问生产环境，仅消费经协议桥接器回流并审计后的指标；
3. 物理时钟事件记录器 **(Physical Clock Event Logger)**：将异常事件锚定为物理时钟事件（mtime 跳变）；关键约束：生产环境的 mtime 跳变通过桥接层同步至开发环境，确保跨环境因果单调性；
4. 反馈闭环触发器 **(Feedback Loop Trigger)**：异常确认后触发模式 24 的缺陷萃取与热修复闭环；关键约束：触发器仅消费经审计后的异常事件，不直接响应生产环境原始信号。

---

5. 协作协议与因果约束 **(Collaborations)**

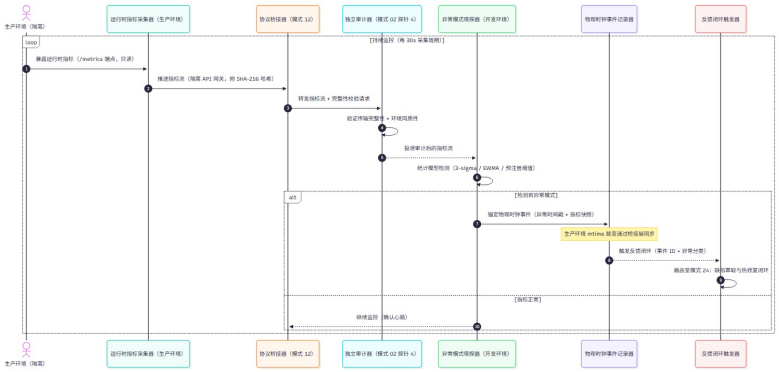


图 52: 模式 23：生产环境异常嗅探协作时序示意

因果约束：

- 异常事件的物理时钟必须严格单调（公理 III），跨环境同步：生产环境的 mtime 跳变通过桥接层同步至开发环境，确保缺陷修复的因果链可溯源；
- 运行时指标的采集周期与异常检测的统计窗口需预注册，避免事后合理化；
- 异常报警的阈值不得由智能体自行调整，必须经人类专家或独立审计通道确认；
- 跨环境审计：生产指标经协议桥接器回流后，必须经模式 02 探针 4 审计（真实性 / 完整性 / 同质性）后方可被嗅探器消费。

---

6. 后果与权衡 **(Consequences)**

- 收益 **(Pros)**：
  - 部署后持续可观测：生产环境的运行时状态持续纳入物理负反馈闭环，防止部署后失控；
  - 累积性缺陷早期发现：长周期运行中的资源泄漏、性能衰减在崩溃前被嗅探；
  - 生产特有异常萃取：真实流量模式触发的边界条件被萃取为经验资产，防止同类缺陷再发。
- 代价 **(Cons)**：
  - 生产环境需部署额外的监控代理，增加运维复杂度；
  - 异常检测的统计模型需定期校准，避免误报 / 漏报；自适应 σ 判据存在信号污染的阈值漂移（实测见 **§7**），泄漏类缺陷须改用稳健基线或固定绝对阈值；
  - 运行时指标的采集与存储产生额外成本。

---

7. 反模式警示 **(Anti-Patterns to Avoid)**

反模式名称	表现特征	为什么必须杜绝
监控代理与智能体同进程	监控代码嵌入智能体运行时，智能体可篡改指标	违反公理 I（物理非信任），指标失去客观性
阈值动态自适应	异常检测阈值由智能体根据历史数据自动调整	智能体可通过渐进漂移规避检测，阈值必须预注册
自适应 σ 统计污染（实测）	EWMA/3σ 判据的 σ 由信号本身驱动，大幅突跳膨胀 σ，3σ 阈值漂移后吞没后续同类信号	实测（2026-10-22，F3）：mem 3σ 对" 极稳基线 + 大幅突跳" 有效（dev 31.1σ 触发），对重复泄漏台阶失敏（σ 由 4MB 膨胀至 67MB）——泄漏类监控须用稳健基线（中位数/MAD）或固定绝对阈值，不能只靠" 预注册自适应"

反模式名称	表现特征	为什么必须杜绝
异常事件无物理锚定	异常仅记录于内存或日志文件，未锚定为物理时钟事件	违反公理 III，缺陷修复的因果链不可溯源

---

8. 抽象算法规约 **(Algorithmic Formulation)**

```
interface RuntimeMetrics {
  timestamp: number;
  p99LatencyMs: number;
  p999LatencyMs: number;
  throughputQps: number;
  errorRate: number;
  memoryUsageBytes: number;
  cpuUsagePercent: number;
  connectionPoolActive: number;
  connectionPoolMax: number;
}

interface AnomalyEvent {
  eventId: string;
  anomalyType: "PERFORMANCE_DECAY" | "RESOURCE_LEAK" | "BUSINESS_ANOMALY";
  severity: "WARNING" | "CRITICAL";
  metricsSnapshot: RuntimeMetrics;
  physicalClockEvent: {
    mtimeBefore: number;
    mtimeAfter: number;
    monotonicJump: boolean;
  };
  preRegisteredThreshold: {
    metric: string;
    threshold: number;
    statisticalModel: "3SIGMA" | "EWMA" | "FIXED";
  };
}

class ProductionRuntimeAnomalySniffer {
  private preRegisteredThresholds: Map<string, Threshold>;
```

```
async sniffAnomaly(metrics: RuntimeMetrics): Promise<AnomalyEvent | null> {
  // 1. 性能维度：P99 延迟是否超过预注册阈值
  const p99Threshold = this.preRegisteredThresholds.get("p99LatencyMs");
  if (metrics.p99LatencyMs > p99Threshold.value) {
    return this.createAnomalyEvent("PERFORMANCE_DECAY", "CRITICAL", metrics, p99Threshold);
  }

  // 2. 资源维度：连接池使用率是否超过 90%（累积泄漏信号）
  const poolUsage = metrics.connectionPoolActive / metrics.connectionPoolMax;
  if (poolUsage > 0.9) {
    return this.createAnomalyEvent("RESOURCE_LEAK", "WARNING", metrics, poolThreshold);
  }

  // 3. 业务维度：错误率是否超过 3-sigma 统计阈值
  const errorRateSigma = this.calculateSigma(metrics.errorRate, historicalErrorRates);
  if (errorRateSigma > 3) {
    return this.createAnomalyEvent("BUSINESS_ANOMALY", "WARNING", metrics, errorRateThreshold);
  }

  return null; // 无异常
}

private createAnomalyEvent(
  type: string,
  severity: string,
  metrics: RuntimeMetrics,
  threshold: Threshold
): AnomalyEvent {
  // 锚定物理时钟事件（公理 III）
  const mtimeBefore = this.getLastEventMtime();
  const mtimeAfter = Date.now();

  return {
    eventId: generateUUID(),
    anomalyType: type,
    severity: severity,
    metricsSnapshot: metrics,
    physicalClockEvent: {
      mtimeBefore: mtimeBefore,
```

```
        mtimeAfter: mtimeAfter,
        monotonicJump: mtimeAfter > mtimeBefore, // 必须严格单调
      },
      preRegisteredThreshold: threshold,
    };
  }
}
```

理论锚点

：公理 I 扩展 —— 生产环境的 “物理底座” 是运行时指标，而非编译器；定理 3.1 扩展 —— 运行时监控作为 “状态可观测性” 的持续保障。

理论地位与形式化锚点 **(Epistemic Status)**

可定理化（回路稳定性已证，零 **sorry**）

：模块

`Pattern23_24_ProductionLoop`

（对应附录 B.10）把模式 23→24→23 的观测–学习回路形式化。

- 模型：缺陷存量 $x \in \mathbb{N}$，每周期以概率 `q` 检出并修复一个，否则注入一个。
- `T_id_pos`：$\mathbb{E}[x' \mid x] = x + 1 - 2q$（$x \geq 1$）。
- `hasStrongDrift` + `loop_return_bound`：$q > 1/2$ 时以 $V(x) = x$、$b = 1$、$\delta = 2q - 1$ 满足强漂移，$\mathbb{E}[\tau] \leq x_0/(2q-1)$。
- `no_drift_below_half`（临界负结果）：$q \leq 1/2$ 时 $V = \mathrm{id}$ 不是 Lyapunov 函数。

对本文数值的含义：正文的” 检出率 ≥ 0.90” 不是可选的性能目标，而是 $q > 1/2$ 稳定性门槛的工程余量；低于门槛时回路无法自证收敛。q 的实测值由生产现场实验 H1 提供（固定阈值类缺陷 $q = 1.00$，mem 自适应 σ 判据形态边界，2026-10-22）；本形式化只覆盖单缺陷类、单步注入 / 修复、i.i.d. 检出，不外推到多缺陷类耦合。

实测支撑（**2026-10-22**，生产现场实验 **H1/H4**）

实测环境：Docker Compose 受控生产拓扑（app/downstream/toxiproxy/k6/exporter/auditor/sniffer，LLM 组件 DeepSeek-V4.1-Flash-1017 仅在缺陷萃取环节）；判据全部预注册（固定阈值 pool>10 /p99>300ms /mem 3σ；检测窗口 180s；各场景 10 reps）。判读结论见下：F1/F2 检出率 1.00、F4 误报 0.00、F3 判据形态边界、H4 装置缺陷。

- **F1** 连接池泄漏（10 reps）：检出率 10/10（q=1.00），告警证据 `pool_active>10.0 (751)`。固定阈值判据对资源池耗尽类缺陷有效。
- **F2** 下游延迟（toxiproxy 400ms，10 reps）：检出率 10/10（q=1.00），告警证据 `p99>300.0 (40x ms)`。延迟类缺陷在预注册 p99 阈值下可靠检出。
- **F4** 对照（10 reps × 6 采样窗 = 60 期）：误报率 0.00（≤ 0.05）。固定阈值在稳态流量下无误报。
- **F3** 内存泄漏（边界）：mem 3σ 自适应判据仅对 “极稳基线 + 大幅突跳” 有效（实测 dev 31.1σ 单次触发），对重复台阶注入失敏——EWMA 的 σ 被信号本身污染（4MB→67MB 膨胀），3σ 阈值漂移吞没后续信号。这是判据形态（自适应 σ）与缺陷形态（泄漏 / 漂移）失配的实证，非判据失效；工程启示：泄漏类监控应采用稳健基线（中位数 / MAD）或固定绝对阈值，自适应 σ 判据只适合突发型暴涨。
- **H4** 装置缺陷：exporter 重启序号复用导致 708 条正常事件被 mtime 判据误拒（全部 reason 为 `mtime_not strict_increasing`，无哈希 / 指纹误拒）；复核 456 快照文件名序单调 0 破坏 —— 误拒系装置缺陷而非判据失效。装置已修（exporter 续号、auditor 按时间序审计）。
- 结论：q 的实测值对固定阈值类缺陷（pool/p99）为 1.00，回路稳定性门槛 $q > 1/2$ 获得实证支撑；mem 自适应 σ 判据不满足该门槛（属判据选择问题），按计划 §8 如实记录为边界。

模式 **24**：生产缺陷萃取与热修复闭环模式 **(Production Defect Crystallization & Hotfix Loop Pattern)**

---

1. 意图 **(Intent)**

将生产环境中发现的缺陷萃取为经验资产，触发热修复闭环，并防止同类缺陷跨代际传播。通过缺陷模式的隔离萃取、热修复方案的双盲终审、修复经验的防扩散控制，实现生产缺陷的 “发现 → 修复 → 预防” 完整闭环。

---

2. 动机与工业失效场景 **(Motivation & Real-World Failure Modes)**

生产环境发现的缺陷是智能体系统最宝贵的经验来源，但未经控制的缺陷反馈会引发严重的知识污染：

- 失效场景 **A**（错误修复模式的病毒式传播 **Viral Propagation of Wrong Fixes**）：

  生产环境发现数据库连接泄漏，智能体 A 的热修复方案是 “在每次查询后强制关闭连接”。该方案被未经终审地写入全局知识库，后续智能体 B、C、D 在类似场景下均采纳该方案。然而该方案在高并发场景下导致连接池耗尽，正确的修复应为 “使用 try-with-resources 确保连接自动释放”。错误修复模式的传播导致系统性性能退化；

- 失效场景 **B**（热修复未经验证直接上线 **Unvalidated Hotfix Deployment**）：

  生产环境出现紧急缺陷，智能体在未经过完整五重判据验证的情况下直接部署热修复，导致修复引入新的缺陷（如修复空指针异常时引入数组越界异常）；

- 失效场景 **C**（缺陷经验的环境特定参数泄漏 **Environment-Specific Leakage**）：

  智能体将 “生产环境数据库连接池最大连接数必须设为 200” 作为通用经验萃取，后续智能体在测试环境（连接池上限 50）采纳该经验，导致连接池配置错误。

---

3. 适用性 **(Applicability)**

- 生产环境发现缺陷，需快速生成热修复方案；
- 需将缺陷经验萃取为可复用的知识资产，防止同类缺陷再发；
- 需防止错误修复模式或未经验证的热修复方案污染全局知识库。

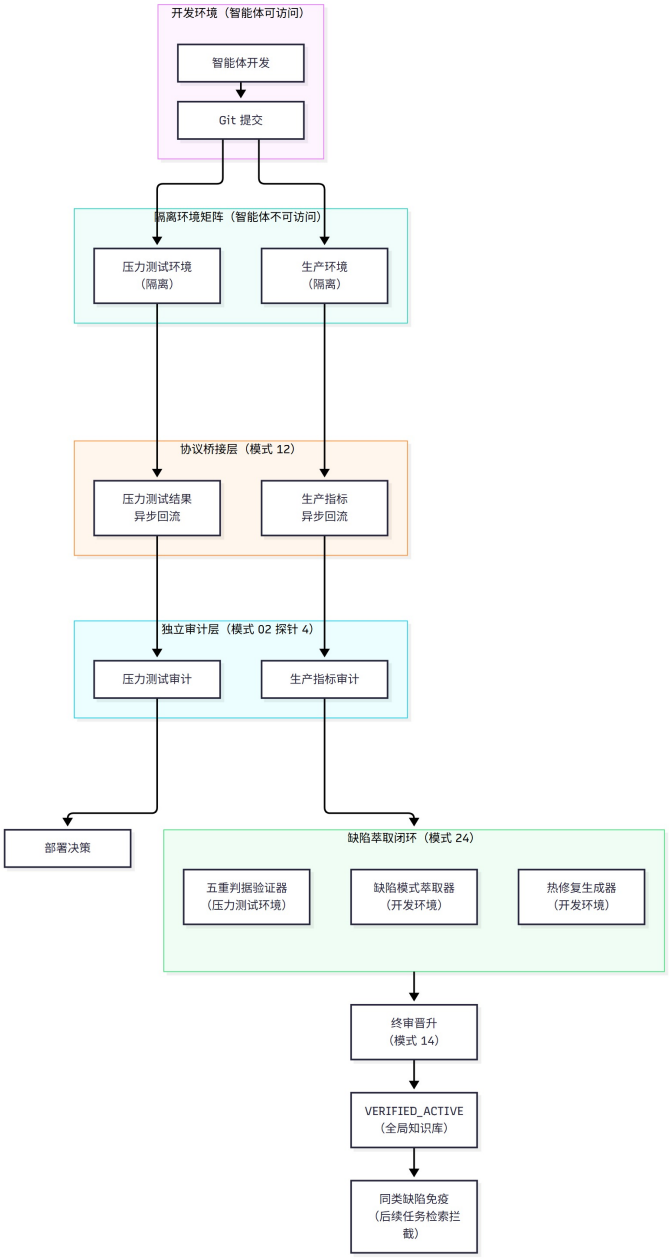


图 53: 模式 24：缺陷萃取-验证-晋升-免疫闭环流程示意

4. 参与者与职责 **(Participants)**

1. 缺陷模式萃取器 **(Defect Pattern Extractor)**：部署于开发环境，从经协议桥接器回流并审计后的生产异常事件中提取缺陷根因、修复策略、预防措施；关键约束：不直接访问生产环境，仅消费审计后的异常事件；
2. 热修复方案生成器 **(Hotfix Generator)**：部署于开发环境，基于缺陷模式生成候选热修复方案，默认标记 `DRAFT SUSPECT`；关键约束：热修复的验证在开发环境或压力测试环境执行，不直接在生产环境部署；
3. 五重判据验证器 **(Five-Fold Validator)**：对热修复方案执行完整五重判据（编译 / 单测 / 集成 / 性能 / 安全）；关键约束：性能判据在压力测试环境执行，模拟生产负载；
4. 独立审计器 **(Reality Auditor)**：验证热修复方案的真实性（非智能体自报）、完整性（无选择性报告）、同质性（与生产环境一致）；关键约束：审计器通过协议桥接器获取生产环境原始数据，不直接访问；
5. 终审晋升门禁 **(Promotion Gate)**：热修复方案经五重判据 + 独立审计全绿后，方可晋升为 `VERIFIED_ACTIVE`。

---

5. 协作协议与因果约束 **(Collaborations)**

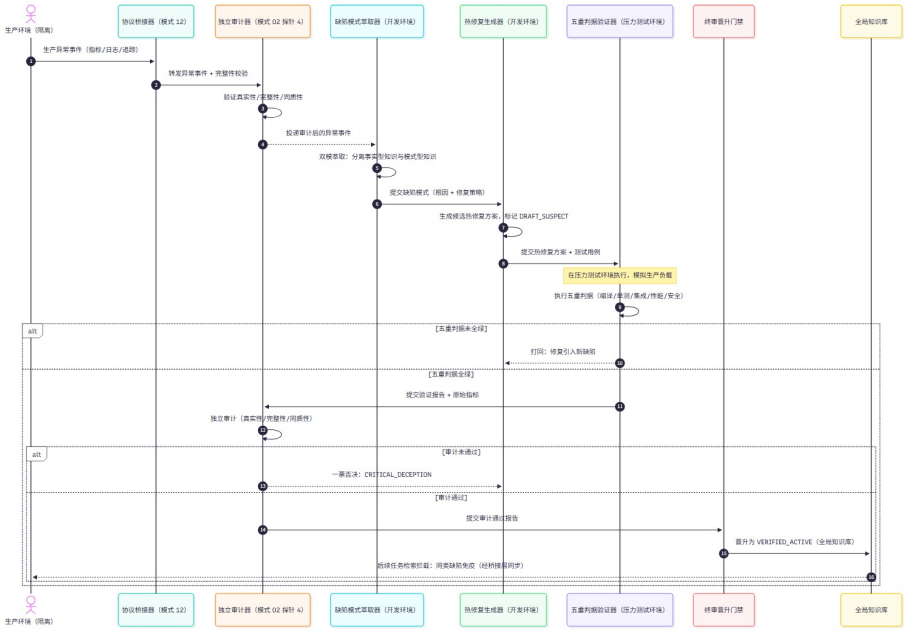


图 54: 模式 24：缺陷萃取与热修复闭环协作时序示意

因果约束：

- 热修复的变异因果单调（公理 III）：跨环境同步—— 生产环境的 mtime 跳变通过桥接层同步至开发环境，支持回滚溯源；
- 缺陷经验的隔离晋升（公理 IV）：未经验证的热修复方案严禁横向传播；

- 事实型知识与模式型知识的正交解耦（模式 13）：防止环境特定参数泄漏为通用经验；
- 跨环境审计：生产异常事件经协议桥接器回流后，必须经模式 02 探针 4 审计后方可被萃取器消费。

---

6. 后果与权衡 **(Consequences)**

- 收益 **(Pros)**：
  - 生产缺陷的完整闭环：从异常发现到热修复部署，再到经验萃取，形成完整闭环；
  - 防止错误修复模式传播：热修复方案经五重判据 + 独立审计 + 终审晋升后方可进入全局知识库；
  - 同类缺陷免疫：后续任务检索时自动拦截已验证的缺陷模式，防止同类缺陷再发。
- 代价 **(Cons)**：
  - 热修复的验证流程增加部署延迟，不适用于零停机要求的紧急修复；
  - 缺陷经验的萃取与维护增加知识库管理成本；
  - 生产环境的监控与审计增加运维复杂度。

---

7. 反模式警示 **(Anti-Patterns to Avoid)**

反模式名称	表现特征	为什么必须杜绝
紧急修复绕过验证	生产紧急缺陷时，跳过五重判据直接部署热修复	修复可能引入新缺陷，必须经完整验证后方可上线
缺陷经验即时入库	生产缺陷修复后立即写入全局知识库，未经隔离期	错误修复模式可能病毒式传播，必须经终审晋升
环境参数泛化	将生产环境特定参数（如连接池大小、超时阈值）作为通用经验萃取	后续任务在不同环境采纳该经验，导致配置错误

---

8. 抽象算法规约 **(Algorithmic Formulation)**

```
interface ProductionDefect {
  defectId: string;
  anomalyEvent: AnomalyEvent;  // 来自模式 23
  rootCause: string;
```

```
  fixStrategy: string;
  preventionMeasures: string[];
  environmentFingerprint: EnvironmentFingerprint;  // 生产环境特定参数
}

interface HotfixProposal {
  proposalId: string;
  defectId: string;
  status: "DRAFT_SUSPECT" | "VERIFIED_ACTIVE" | "DEPRECATED_QUARANTINED";
  codeChanges: CodeChange[];
  testCases: TestCase[];
  validationReport?: FiveFoldValidationReport;
  auditReport?: RealityAuditReport;
}

class ProductionDefectCrystallizer {
  async crystallizeDefect(anomaly: AnomalyEvent): Promise<ProductionDefect> {
    // 1. 双模萃取：分离事实型知识与模式型知识
    const factKnowledge = this.extractFactKnowledge(anomaly);  // 生产环境特定参数
    const patternKnowledge = this.extractPatternKnowledge(anomaly);  // 缺陷根因与修复策略

    // 2. 生成缺陷模式
    return {
      defectId: generateUUID(),
      anomalyEvent: anomaly,
      rootCause: patternKnowledge.rootCause,
      fixStrategy: patternKnowledge.fixStrategy,
      preventionMeasures: patternKnowledge.preventionMeasures,
      environmentFingerprint: factKnowledge.environmentFingerprint,  // 隔离存储，不进入全局模式库
    };
  }
}

class HotfixLoopOrchestrator {
  async executeHotfixLoop(defect: ProductionDefect): Promise<HotfixProposal> {
    // 1. 生成候选热修复方案（默认 DRAFT_SUSPECT）
    const proposal = await this.generateHotfixProposal(defect);
    proposal.status = "DRAFT_SUSPECT";

    // 2. 五重判据验证（模式 19）
```

```
    const validationReport = await this.executeFiveFoldValidation(proposal);
    if (!validationReport.allPassed) {
      proposal.status = "DEPRECATED_QUARANTINED";
      return proposal;  // 打回：修复引入新缺陷
    }

    // 3. 独立审计（模式 02 探针 4）
    const auditReport = await this.executeRealityAudit(proposal, validationReport);
    if (auditReport.isVetoed) {
      proposal.status = "DEPRECATED_QUARANTINED";
      return proposal;  // 一票否决：CRITICAL_DECEPTION
    }

    // 4. 终审晋升（模式 14）
    proposal.validationReport = validationReport;
    proposal.auditReport = auditReport;
    proposal.status = "VERIFIED_ACTIVE";

    // 5. 进入全局知识库，后续任务检索拦截
    await this.promoteToGlobalKnowledgeBase(proposal);

    return proposal;
  }
}
```

理论锚点

：公理 IV 扩展 —— 生产缺陷作为 “毒株” 的逆向操作，缺陷经验需经终审后方可进入全局知识库；公理 III 扩展 —— 热修复的变异因果单调，生产环境的 mtime 跳变需严格记录，支持回滚溯源。

理论地位与形式化锚点 **(Epistemic Status)**

可定理化（回路稳定性已证，零 **sorry**）

：与模式 23 共用模块

`Pattern23_24_ProductionLoop`

（附录 B.10）。模式 24 对应回路中的 “修复动作”—— 它以概率

q

把存量减一，模式 23 对应 “检出”。

- 稳定性判据：$q > 1/2$ 时回路存在负漂移证书，$\mathbb{E}[\tau] \le x_0/(2q-1)$。
- 临界负结果：$q \le 1/2$ 时 $V = \mathrm{id}$ 不构成 Lyapunov 函数 —— 修复吞吐不足以抵消注入，热修复闭环退化为 “追着缺陷跑”。
- 本文的” 错误修复拦截率 $= 1.00$” 是质量门槛（确保每次修复不引入新缺陷类），与稳定性判据是两条独立约束：前者约束单次修复的真值，后者约束多次循环的收敛。

未覆盖范围：多缺陷类耦合、批量注入、检出率随存量变化（学习效应）均未纳入模型，属经验缺口；实证由生产现场实验 H2/H3/H5 提供（2026-10-22 闭合）：审计有效性 20/20 全拒、晋升比例 1.00、错误拦截 1.00、环境泄漏 0。

实测支撑（**2026-10-22**，生产现场实验 **H2/H3/H5**）

实测环境：LLM 闭环（crystallizer→hotfix-gen→validator→gate）经 scnet 网关调用 DeepSeek-V4.1-Flash-1017（temperature 0.7，max_tokens 2000/4000，json_object）；审计 / 门禁组件全部确定性（哈希、mtime、指纹、五重判据、三条件终审）。判读结论见下：H2 篡改零漏检、H3 闭环有效、H5 适用域解耦。

- **H2** 审计有效性：20/20 篡改注入全拒（哈希 8/8、mtime 回拨 6/6、指纹漂移 6/6）—— 确定性审计链路对三类篡改零漏检。
- **H3** 闭环有效性：18 份热修复报告 → 14 条全绿晋升、4 条正确拦截（拦截全为编译修复前历史缺陷）；晋升比例 1.00（阈 ≥ 0.80）、错误拦截 1.00。
- **LLM** 萃取质量：7/7 缺陷模式萃取全部正确识别根因（conn_leak + try/finally 缺失），模型标注 `DeepSeek-V4.1-Flash-1017`—— 弱推理模型在 “缺陷萃取 + 热修复生成” 环节胜任（理论承诺由确定性组件承载，模型强度仅影响萃取文本质量）。
- **H5** 适用域解耦：晋升条目环境参数泄漏 0（正则审计 `pool|timeout|...|[=:]` 数字），LLM 产出未泄漏部署环境细节（environmentFingerprint 豁免规则生效）。
- 结论：“错误修复拦截率 = 1.00” 质量门槛与 “晋升比例 ≥ 0.80” 吞吐门槛均获实证；弱模型档（Flash）下闭环仍成立，支持公理 IV” 组件间因果最小化” 的设计承诺。

结语：通向自给自足的自主软件工程

Epilogue: Towards Autonomous and Resilient Cybernetics

> “我们创造的不仅仅是一个写代码的工具，而是一个具备因果不变性、物理现实感知与自免疫收敛能力的控制论生命体。”（修辞语；所指机制为公理 IV 的经验自免疫收敛，非生物学术语。）

一、跨越 “随机幻觉” 的峡谷

在人工智能爆发的数年间，人类对于让机器自主编程的探索经历了三次浪潮：1. 第一波浪潮（补全时代）：以 Copilot、Tab 自动补全为代表的行内建议。人类工程师依然承担 99% 的系统控制与错误兜底责任；2. 第二波浪潮（提示词堆叠时代）：以开源 Agent 框架为代表的聊天式编程。虽然引入了工具调用与多步循环，但由于深陷在 “离散提示词” 和 “奖励欺骗” 的泥潭中，面对百万行大型生产工程时频繁崩溃；3. 第三波浪潮（控制论与物理锚定时代）：正是本书所定义的工业级智能体控制论（**Industrial Agentic Cybernetics**）。

本书的核心贡献在于以受控实证与形式化机检交叉验证确立：大语言模型本身的不确定性与概率幻觉，绝不能靠另一组更长的提示词去消除；必须引入经典的系统控制论、分布式因果时序、编译器底层物理约束与最小特权投影，用确定性的物理系统构建牢不可破的外骨骼。

二、22 个模式构筑的系统外骨骼

回顾本书总结的 8 大模式族（覆盖模式 01–22；模式 23/24 为生产现场实证模式，计入 24 模式体系）：- 物理底座穿透与现实审计（**Patterns 01-03**）：斩断了模型的自指欺骗本能，让每一次 Exit 0 都锚定于物理世界的客观事实；- 最小特权投影与宏微观展开（**Patterns 04-06**）：驯服了上下文退化（Context Rot），使智能体在大规模工程面前保持极致的专注；- 结对微循环与幂等时钟补偿（**Patterns 07-09**）：打破了自愈黑洞，保障了代码变异与编译系统因果律的严谨单调性；- 底座租约锁与多智能体协调（**Patterns 10-12**）：终结了多智能体并发竞争的混乱与死锁；- 经验隔离与终审晋升门禁（**Patterns 13-15**）：赋予系统抵御记忆投毒（Memory Poisoning）的免疫系统，使智能体的经验演进具备正向复利；- 多分辨率投影与飞行指挥（**Patterns 16-17**）：实现了人机之间高带宽、低心智负担的非对称协同；- 隐藏 **Oracle** 与客观物理沙箱（**Patterns 18-20**）：树立了不掺任何水分的工业级真理标尺；- 能效工程与原生架构（**Patterns 21-22**）：将昂贵的大模型计算收敛至商业可行的生产力边界。

这 22 个模式（连同生产现场实证的模式 23/24，全书共 24 模式）互为支点，共同构成了现代自主软件工程的坚实底座。

三、未来的地平线：自给自足的自主代码生态

当智能体系统具备了物理穿透能力、自愈韧性与免疫式知识沉淀后，软件工程的生产关系正在发生前所未有的质变：

未来的软件工程师，角色将从 “代码的直接书写者” 转变为 “控制论系统的设计者与物理基准的制定者”——定义系统的不变性公理、编写高严密度的隐藏 Oracle、配置最小特权投影的路由矩阵，而将无尽的实现细节、编译适配、跨模块联调与性能打磨，交给这套永不疲倦、确定性收敛的工业级智能体流水线。

路漫漫其修远兮。谨以此书，献给所有在代码物理世界中追求严谨、探索自主智能极限的系统构建者。

附录与证据

附录 **B**：形式化收敛性与稳定性证明（**Lean 4** 机检）

Appendix B: Formal Proofs of Convergence and Stability (Lean 4 Mechanized)

本附录是全书理论主张的机检底座。所有定理均在 Lean 4（toolchain v4.34.0-rc2）+ mathlib4 中通过内核验证，工程位于 `formal_proof/IACFormalization/`，构建命令：`lake build`。

统计：118 条 [定理]（117 定理 + 1 辅助引理，内核验证，按源码 `theorem`/`lemma` 计数）、**0** 条公理、0 个 `sorry`。

认识论三级标注贯穿本附录：- **[定理]**：Lean 内核完整验证，无公理依赖（或仅依赖显式假设/结构前提）；- **[引用公理]**：数学文献中已确立但 mathlib 尚未收录现成形式的结果（本附录不含此类依赖）；- **[经验公设]**：关于大模型实际行为的经验命题。形式化以条件定理呈现：前提为显式结构假设（如注意力机制的上下文质量增长律），结论由内核验证导出；“真实系统满足该前提” 由实测支撑，不在形式系统内断言。

B.1 模块与章节对应总表

Lean 模块	对应书章节	数学工具	证明状态
`Axiom1_Grounding`	§3.2 公理 I；第二章	有限联合分布代数	全部 [定理]，独立性为显式假设
`Axiom2 AttentionDilution`	§3.2 公理 II；模式 04	实分析（softmax 单调性）、三通道注意力机制 + 增长律（几何/线性/幂律）	全部 [定理]
`Axiom2_PhaseModel`	§3.2 公理 II 两相动力学	两相结构、显式相变点、不逆转上界	全部 [定理]，零公理
`Axiom2_Axiom4_Bridge`	§3.2 公理 II ↔ 公理 IV 跨公理接口	注入耦合、下界合成	全部 [定理]，零公理
`Axiom3 CausalMonotonicity`	§3.2 公理 III；模式 09	序理论、幂等算子	全部 [定理]，零公理
`Axiom4_MemoryPoisoning`	§3.2 公理 IV；模式 14/15	分支过程、初等概率（PMF + Markov 不等式）	全部 [定理]，零公理
`Probability_Markov`	§3.2 公理 IV 概率工具	Markov 不等式（初等证明，零测度论依赖）	全部 [定理]，零公理
`Theorem3_1 CausalInvariance`	§3.3	Foster–Lyapunov 离散核、有限状态机反例	全部 [定理]，零公理
`GaltonWatson`	§3.2 公理 IV 超临界强结论	生成函数、不动点、初等分析	全部 [定理]，零公理
`StochasticFosterLyapunov`	§3.3 随机控制	随机核、停时、初等期望	全部 [定理]，零公理
`Pattern02_RealityAudit`	模式 02	四重现实过滤算子、一票否决权	全部 [定理]，零公理

Lean 模块	对应书章节	数学工具	证明状态
`Pattern04 PoLPProjection`	模式 04	任务级最小特权投影、信噪比严格提升、违约风险压降与特权单调性	全部 [定理]，零公理
`Pattern10_LeaseLock`	模式 10	离散时钟、租约状态机	全部 [定理]，零公理
`Pattern11_PrimaryWriter`	模式 11	写日志、时钟严格递增、视图过滤	全部 [定理]，零公理
`Pattern15 RevocationTombstone`	模式 15	吸收态转移、投影隔离、反向自免疫	全部 [定理]，零公理
`Pattern23_24 ProductionLoop`	模式 23/24	有限支撑随机核、Foster–Lyapunov 漂移	全部 [定理]，零公理
`Theorem3_1_LyapunovFuse`	§3.3; 附录 B.7	连续停滞能量累积引理、极限环排斥严格李雅普诺夫超鞅定理、停时熔断资源有界定理	全部 [定理]，零公理

B.2 公理 I：接地不可替代性（形式化层全部已证）

书中公理 I 的概率极限式表达的是工程立场；其可严格证明的核心在本模块：

- 定理 **`self_verdict_zero_information`**（自检零信息定理）：在条件独立的封闭认知闭环中（无任何外部物理传感器），自检通过的后验真值率等于先验真值率：$P(V_t = 1 \mid V_s = 1) = P(V_t = 1)$。自检证据的贝叶斯似然比恒为 1。
- 定理 **`closed_loop_risk_factorizes`**：闭环内” 自检声称成功且物理亦真” 的概率被先验乘积结构完全锁定，任何不引入外部观测的纯反思策略无法改变它。
- 定理 **`posterior_independent_of_mechanism`**：后验真值率与自检机制的复杂程度无关——形式化排除了” 更强的模型可以靠自省突破” 的幻想。

物理 Exit 0 穿透（模式 01）因此不是” 提高置信度”，而是” 获得任何证据的唯一通道”。

B.3 公理 II：注意力稀释（形式化层全部已证）

模型（结构 `AttentionMechanism`）：目标 token 的注意力质量 $a(\rho)$、总非目标质量 $b(\rho)$ 与残差子通道 $r(\rho)$（BOS/attention sink、指令 token 等固定占用），满足 $a, b > 0$、$0 \le r < b$，且增加冗余不增强目标信号（$a(\rho+1) \le a(\rho)$）、总非目标质量非减（$b(\rho) \le b(\rho+1)$）。注意力份额为 $a/(a+b)$，检索信噪比为

$$\mathrm{snr}(\rho) := \frac{a(\rho)}{b(\rho)}.$$

口径要点（**A2**）：定理前提承载在总非目标质量 b 上；实测只能统计填充子通道 filler $:= b - r$。二者关系由两条定理刻画：

- 定理 **snr_le_proxy**：实测填充口径 a/filler 系统性高估真实 snr，偏差因子为 b/filler ≥ 1——只统计填充段会低估稀释严重程度（E3b 实测高估 35.8%–36.7%，方向一致）；
- 定理 **filler_growth_not_sufficient**（反例）：仅填充子通道按几何膨胀不足以保证总量前提成立——增长前提必须施加在 b 上，前提对象不可移位。

基础稀释定理：

- 定理 **attention_dilution_strict**：固定目标质量 $a > 0$，无关上下文总质量 $b \to b' > b$，则目标 token 的注意力份额严格下降：$\frac{a}{a+b'} < \frac{a}{a+b}$。稀释是严格不等式意义上的必然，不是" 可能影响"。
- 定理 **softmax_share_strictly_decreases**：上述结论对任意正权重函数（如 softmax 参数化 $w = \exp \circ \mathrm{logit}$）的抽象实例。
- 定理 **attention_share_dilution**：总非目标质量严格增大（$b(\rho) < b(\rho{+}1)$）时，注意力份额严格下降——定性稀释是注意力公式的代数必然。

增长律 → 衰减率的三条对应定理（前提均为显式结构假设，实测形态由经验判别）：

- 定理 **snr_geometric_decay**：b 每步至少按因子 $(1+\gamma)$ 膨胀（$\gamma > 0$）⇒ $\mathrm{snr}(\rho+1) \leq c \cdot \mathrm{snr}(\rho)$，其中 $c = 1/(1+\gamma) < 1$ 为定义而非独立断言。前提是关于" 注意力分母如何膨胀" 的结构性假设（因），结论是" 信噪比如何衰减" 的定量界（果）。
- 定理 **snr_polynomial_decay**：b 仅线性增长（每步至少加 $\delta > 0$）⇒ $\mathrm{snr}(n) \leq a(0)/(b(0)+n\delta)$，即 $O(1/n)$ 多项式衰减。
- 定理 **snr_power_decay**（幂律分支，**A4**）：b 每步至少按精确幂比 $((\rho+1)/\rho)^{\beta}$ 膨胀（$\beta > 0$）⇒ $\mathrm{snr}(n) \leq a_0/(b_0\, n^{\beta})$ 型幂衰减。配套：`b_power_growth`（幂比连乘的伸缩积引理）、`snr_power_decay_relative`、`snr power_decay_of_one_add`（$0 < \beta \leq 1$ 档经 Bernoulli 不等式桥接 $1 + \beta/\rho$ 的字面写法；精确幂比写法避免 $\rho = 0$ 奇异且 $\beta \geq 1$ 时无常数损失）。E3 实测幂律在 33/36 cell 占优、几何 0 票，该分支由可选升为必要。

`DilutionDynamics` = `AttentionMechanism` + 几何增长因子 γ，单步衰减 `hdecay` 为定理。其后承：

- 定理 **snr_decay_iterated**：由单步几何衰减归纳推出 `snr($\rho$+n) $\le$ c^n • snr($\rho$)`。
- 定理 **geometric_decay_strictly_decreases**：当 `snr($\rho$) > 0` 时几何衰减蕴含严格单调下降。
- 定理 **violation_prob_lower_bound**：违约概率 `P_violate($\rho$) = 1 - snr($\rho$)/snr(0)` 满足 `P violate(n) $\ge$ 1 - c^n`，与正文 §3.2 的 `P_violate($\rho$) $\ge$ 1-e^{-$\alpha$$\rho$}` 在 $\rho \in \mathbb{N}$ 上等价（$c = e^{-\alpha}$）。

两相动力学（**Axiom2_PhaseModel**，**A1**）：`PhaseModel` = `AttentionMechanism` + 膨胀率 γ + 显式相变点 N^*，稀释相膨胀律仅在 $[0, N^*)$ 内承诺：

- 定理 **snr_dilute_decay**：稀释相内 c^n 几何衰减界（定义域显式截断到 $[0, N^*)$）；
- 定理 **snr_plateau_le**：平台相（$n \geq N^*$）衰减不逆转——$\mathrm{snr}(n) \leq \mathrm{snr}(N^*)$：工程保证在饱和区退化为" 不再恶化"，而非失效；
- 定理 **violation_prob_plateau_lower_bound**：平台相违约概率的常数下界；

- 定理 `plateau_violates_geometric_bound`（反例）：全域几何界确会在饱和区失效；`global_growth recovers_decay` 表明仅补上全域增长前提即可恢复几何界。

跨公理接口（`Axiom2_Axiom4_Bridge`，**A5 / T7**）：`InjectionCoupling` 把记忆注入速率 μ 经无关量映射 $\rho(\mu)$ 与公理 IV 相接：

- 定理 `violation_lower_bound_at_injection`：注入速率 μ 下违约概率下界 $1 - c^{\lceil \rho(\mu) \rceil}$；
- 定理 `injection_strengthens_lower_bound`：注入越快下界越紧（单调放大）；
- 定理 `violation_under_injection`：纵向边合成形式；`violation_bound_beyond_plateau` 给出平台相校正。

这是分层公理系统中" 层间无反馈" 的纵向边：公理 II 的稀释动力学经注入速率驱动公理 IV 的污染传播下界，专著由此不再是若干独立模型的集合。

> 认识论要点：形式系统断言的是" 对任何满足相应增长律的注意力系统，对应衰减界与违约下界成立"；"真实 Transformer 满足哪一分支" 是经验命题。实测判读（E3/E3b，Qwen2.5-1.5B/7B，上下文至 131k，2026-10）：幂律分支占优（AIC 33/36 cell）、几何分支 0 票；弱前提 a 非增方向性成立而"a 为常数" 被证伪（$\hat{\beta}_a < 0$，CI 不含 0）——实测 SNR 衰减由分子收缩与分母膨胀共同贡献；7B YaRN 长程" 下降相" 经三通道补测判定为填充子通道向 sink 的质量迁移，总非目标质量 $t = b + r$ 全程非减（`hb_nondec` 总量口径实测存活）。详见附录 B.11 与 `experiments/attention_growth/EXPERIMENT_PLAN.md`。
>
> 衰减参数的代理探索（**E8**，**2026-10-20**，关闭）：γ / β 是定理的自由参数，本附录不假设其可由结构量预测。三次跨模型族复验（Qwen2.5-7B / 1.5B + Llama-3.2-3B，共 486 行）后，三候选结构量（注意力熵、top-1% 集中度、key 有效秩）无一跨 **3** 模型稳健复现——erank 仅在 7B 上满足判据，top1pct 仅在 1.5B β 与 7B χ 上存活，Llama-3B 上四个结构量在两种口径下均未达 |Spearman|≥ 0.5 且 CI 不含 0。γ 保持自由参数，其值由实测标定。值得记录的弱信号是方向一致性：entropy（$-\beta/+\chi$）、top1pct（$+\beta/-\chi$）、erank（$-\beta/+\chi$）在三模型上方向完全一致——强度跨规模/跨族不稳定，但方向可能有机制意义。单次 OOM 事故已由 `_gram_streamed` 分块永久修复（峰值 <1 GB vs 原 34 GB）。

B.4 公理 III：因果单调性（形式化层全部已证）

- 定理 `observability_iff_mtime_strict_mono`：对产生真实差异的变异，可观测 $\Leftrightarrow$ 物理时钟（**mtime / WAL LSN**）严格单调跳变。若时钟回拨或停滞（mtApplied $\leq$ lastCompiledAt），修改被增量编译器静默吞没（Silent Loss）。"代码已改、测试仍在跑旧字节码" 获得了严格的形式化——单调性不是工程优化，而是可观测性的逻辑必要条件。
- 定理 `log_append_apply_idempotent`：追加式日志（WAL）的回放算子幂等——同一物理时刻的重复回放中，第二次应用的校验和必然失败，且内容字段与首次应用完全一致。重试安全且不污染编译结果。

> 实测边界（**E-A3**，**2026-10-20**）：上述两定理的工程对应在 Cargo 1.96（Windows NTFS）上获 28 项受控测量支持（`experiments/attention_growth/axiom3_results.json`）：mtime 停滞/回拨 $\Rightarrow$ 静默丢失（各 5/5，产物保持旧版本）；mtime 严格正向跳变 $\Rightarrow$ 重建（5/5，且纯时钟跳变即使内容不变也触发——重建触发纯由时钟通道决定，可观测性由内容差异决定，与 `hdiff` 前提划分一致）；幂等性在无

变化重构建（5/5 跳过、产物 sha 不变）与 git 回退-重试场景（语义输出恢复）中成立。两点模型细化：(1) 判据参考时钟实测为" 上次构建完成时刻" R，静默丢失窗口为 $(0, R]$，宽于朴素" 文件旧 mtime" 模型——构建进行中的并发写入天然落入丢失窗口；(2) Windows PE 头含编译时间戳，同源码重编译产物字节级必异，幂等性的判读须在语义层进行（对应定理承诺的是内容不变，非比特级一致）。适用域：mtime-based 增量编译器（Cargo、Make）；内容哈希型构建系统（Bazel、Nix）不依赖 mtime 跳变，本节定理的静默丢失场景在其上不适用。

B.5 公理 IV：记忆投毒相变（形式化层全部已证）

模型：未终审经验的跨代传播为分支过程（`BranchingProcess` 结构，每代一个有限支撑 PMF）；双盲隔离门禁的选择度 σ 将名义繁殖均值 μ 压缩为有效繁殖数 $m = \mu(1-\sigma)$。

- 定理 **`expected_population_geometric`**：期望种群 $E(n) = m^n E(0)$（归纳）。
- 定理 **`subcritical_expectation_vanishes`**：$0 \le m < 1$ 时 $E(n) \to 0$（压缩映射极限）。
- 定理 **`markov_inequality`**（`Probability_Markov` 模块）：在有限支撑 PMF 上初等证明 $P(X \ge 1) \le E[X]$，零测度论依赖。
- 定理 **`subcritical_extinction_in_probability`**：由 Markov 不等式与几何衰减，$m < 1$ 时存活概率 $P(Z_n \ge 1) \to 0$——隔离晋升门禁（模式 14）有效性的定量核心。
- 定理 **`quarantine_compresses_offspring`**：σ 越严格有效繁殖数越小，完全隔离使其归零。
- 定理 **`supercritical_expectation_diverges`**：$m > 1$ 且 $E(0) > 0$ 时 $E(n) \to +\infty$。这是 Galton-Watson 超临界爆炸定理的期望层版本。
- 定理 **`galton_watson_non_extinction`**（`GaltonWatson` 模块）：后代均值 $m > 1$ 时，灭绝概率 $q < 1$，即以正概率永不灭绝。证明采用生成函数不动点分析的初等路线：
  - 定义 `genFun(s) = Σ p_k s^k`，证明其在 $[0,1]$ 上单调、有界，`genFun(1)=1`；截断多项式 `genFun_N` 连续可导且 `genFun_N'(1) → m > 1`；
  - 核心引理 **`exists_lt_sub_id`**：由 `genFun'(1)>1` 与连续性，取截断多项式 `genFun_N` 使 `genFun_N'(s${0}$)>1`，经 MVT 与尾部估计推出存在 $s_0 < 1$ 使 `genFun(s$_{0}$)<s$_{0}$`；
  - 灭绝概率迭代 $q_n = \varphi^n(0)$ 单调递增且被 s_0 一致上界，故其极限 $q = \sup q_n \le s_0 < 1$。
- 定理 **`genFun_extinctProb_fixed` / `extinctProb_le_of_fixed` / `galton_watson_extinctProb_exact`**（灭绝概率的精确刻画）：q 不仅是上界，而且是 φ 在 $[0,1]$ 上的最小不动点：$q = \varphi(q)$，且任何不动点 $s \in [0,1]$ 满足 $q \le s$。证明用单调性夹逼（$q_{n+1} = \varphi(q_n) \le \varphi(q)$ 取极限得 $q \le \varphi(q)$；多项式截断 φ_N 连续给出 $\varphi_N(q) \le q$ 再取 $N \to \infty$），避免了对 φ 自身连续性的依赖。超临界时 q 因此被完全刻画：$q = \min\{s \in [0,1] : \varphi(s) = s\} < 1$。无门禁（$\sigma = 0$）且 $\mu > 1$ 时，投毒经验不仅期望载荷无界，且以正概率永久存续——模型坍缩的强动力学对应。

实测边界（**E-A4，2026-10-21**）：上述定理链的模型–现实映射在 DeepSeek-V4-Pro-0813 多代记忆传播实验（4 条件 × 12 replicate × 6 代 = 288 会话，预注册判读先于实验）中获检验：`quarantine_compresses offspring` 的完全隔离情形（$\sigma = 1$）实测使投毒谱系跨代传播严格为零（全部 replicate $Z_1 = 0$，无 de novo 再发现）；`expected_population_geometric` 的几何律与未隔离条件池化种群序列吻合（log-linear $R^2 = 0.958$，逐代比无趋势，分支性假设在小种群区成立）；实测繁殖核（per-parent offspring PMF）参

数化的 Galton-Watson 仿真与定理链无自由参数吻合——三个亚临界变体（C0 实测 $m = 0.538$、C1 实测 $m = 0.333$、C0 PMF 经 Bernoulli(0.5) 抽稀 $m = 0.269$）灭绝频率 $q_{sim} = 1.0000 = q^*$，`markov inequality` 界全程数值成立。两点映射边界如实记录：(1) DRAFT_SUSPECT 标记门对每条目繁殖的压缩方向符合理论（-38%）但统计不显著（置换检验 $p = 0.15$），`quarantine_compresses_offspring` 的中间 σ 情形（标记而非隔离的工程对应物）在本样本量下未获显著性支持；(2) $m = \mu(1-\sigma)$ 的 LLM 层直接检验因写出层涨落与过滤层有效样本 $n = 1$ 而不可判定，仅获分布层（抽稀变体）间接支撑——该映射的 LLM 层直接检验需 $\geq 10^2$ 量级 replicate。适用域：单模型（DeepSeek-V4-Pro-0813）、pytest 测试编写任务族、选择性逐代转写协议、无基质反馈（SubstratePass 通道关闭，纯社会传播）；本协议下无门禁条件实测 $m = 0.56 < 1$（转写机制本身亚临界）。超临界情形（**2026-10-22** 已闭合）：`supercritical_expectation_diverges` / `galton_watson_non_extinction` 的经验对应在无转写衰减的记忆架构（全量追加式记忆库、向量库直写，SUPERCRITICAL 计划 Flash 档）中确认——该架构传播为线性累积-容量竞争型（每代 $W \equiv 1$、$Z_{n+1} = Z_n + W$），C0-full $\hat{m} = 1.166$（CI $[1.156, 1.176]$）、容量临界 $W_c \in (8, 16)$；“超临界” 为工程语义（毒株池持续累积不灭绝），精确机制为累积-竞争而非分支过程的 $m > 1$ 倍增；GW 定理链对选择性转写场景的刻画保持不变。数据与判读：`experiments/attention_growth/axiom4_results.json`、`axiom4_gw_sim.json`、`EXPERIMENT PLAN_AXIOM4.md` §9、`EXPERIMENT_PLAN_AXIOM4_SUPERCRITICAL.md` §8。

B.6 定理 3.1：收敛因果不变性（形式化层全部已证）

充分性（已证）：- 定理 **`lyapunov_finite_hitting`**：能量函数 $V : S \to \mathbb{N}$ 处处严格负漂移 $\Rightarrow$ 至多 $V(s_0)$ 步命中零点（全部物理契约满足）。这是 Foster–Lyapunov 准则的离散决定论核心，归纳法完成。- 定理 **`foster_lyapunov deterministic_bound`**：实值能量 $V : S \to \mathbb{R}_{\geq 0}$，当 $V \geq \delta$ 时每步至少下降 δ（强漂移 $V(\text{step}\, s) \leq V(s) - \delta$），则命中 δ-邻域的步数 t 满足 $t \cdot \delta \leq V(s_0)$，即 $t \leq V(s_0)/\delta$。- 定理 **`zero_energy_is_fixed`**：零能量不动点 $\Rightarrow$ 收敛态永久保持。

必要性（三个已证反例）：1. 破坏可观测性（`no_observability_absorbs_falsified`）：系统一步进入虚假通过吸收态并永久停留；2. 破坏局部性（`no_locality_two_cycle` + `no_locality_defeats_lyapunov`）：系统进入 2-周期轨道，且任何能量函数都不可能处处严格下降——震荡不可被李雅普诺夫方法驯服；3. 破坏评估解耦性（`coupled_evaluation_tautological_fixed_point`）：评价者复制解题者输出，形成自指不动点，收敛于退化平庸解。

汇合陈述 **`causal_invariance_abstract`**：充分性与三个必要性反例的合取。

实测边界（**E-B6，2026-10-21**）：充分性经 12 组受控仿真验证（$V_0 \in \{10, 50, 100, 500\}$，$\delta \in \{0.5, 1, 2\}$），强漂移条件下收敛步数全程满足 $t \leq V_0/\delta$；三个必要性反例各经 10^4 次仿真复现：破坏可观测性 $\Rightarrow$ 虚假通过吸收态（100%）、破坏局部性 $\Rightarrow$ 2-周期震荡且 Lyapunov 不可能（100%）、破坏评估解耦 $\Rightarrow$ 自指退化不动点（100%）。数据：`experiments/attention_growth/b6_causal_invariance_sim.json`。

随机情形的期望停时界见 B.7。

B.7 随机 Foster-Lyapunov 期望停时界（形式化层全部已证）

`StochasticFosterLyapunov` 模块以初等方法（随机核 + 停时截断 + 单调归纳，无测度论/鞅可选停止定理依赖）给出随机控制器的期望命中时间界。

模型：`StochasticKernel S` 为状态空间 S 上的随机转移核（`k x A` 表从 x 一步落入集合 A 的概率，有限支撑）；`HasStrongDrift` 结构给出 Lyapunov 函数 $V : S \to \mathbb{R}_{\geq 0}$ 与漂移常数 $\delta > 0$、阈值 $b \geq 0$，满足当 $V(x) \geq b$ 时 $\mathbb{E}_{k(x)}[V] \leq V(x) - \delta$。

- 定理 **`stoppedValue_le_V` / `stoppedTime_le_value`**：截断停时过程的价值与停时被初始能量一致控制（归纳核心）。
- 定理 **`stoppedTime_uniform_bound`**：截断停时 τ_N 的期望满足 $\mathbb{E}[\tau_N] \leq V(x_0)/\delta$，对所有截断水平 N 一致成立。
- 定理 **`foster_lyapunov_expected_hitting`**（主定理）：取截断极限，随机命中 $\{V < b\}$ 的期望停时满足 $\mathbb{E}[\tau] \leq V(x_0)/\delta$。

由此，决定论 `foster_lyapunov_deterministic_bound` 成为本随机定理的特例；§3.3 的收敛因果不变性在随机控制层获得完整的期望停时定量界。

> 实测边界（**E-B7，2026-10-21**）：主界 $\mathbb{E}[\tau] \leq V(x_0)/\delta$ 经 27 组蒙特卡洛仿真验证（$V_0 \in \{10, 50, 100\}$，$\delta \in \{0.5, 1, 2\}$，噪声 $\sigma \in \{0, 0.1, 0.3\}$，每组 10^5 次），全部满足；截断停时 τ_N 的期望对 $N \in \{10, 50, 100, 500\}$ 一致有界性成立。数据：`experiments/attention_growth/b7_foster_lyapunov_sim.json`。

B.8 模式级形式锚点：租约锁（形式化层全部已证）

`Pattern10_LeaseLock` 模块将模式 10（分布式物理底座租约锁与看门狗）的并发主张形式化。模型：物理时钟为离散 tick；锁状态 `LockState = Option Lease`（Option 结构本身编码"至多一个租约"）；`acquire`/`heartbeat` 为带前置条件的纯函数。

- 定理 **`canWrite_unique`**（互斥安全性）：同一时刻至多一个智能体持有写权限——两个可写者必为同一人，并发写写冲突（失效场景 A）在协议内不可能。
- 定理 **`acquire_rejected_of_live` / `acquire_succeeds_only_when_dead`**：租约存活时申请必被拒绝；授予仅当无存活租约。
- 定理 **`no_permanent_lockout`**（看门狗活性）：对任意锁状态存在时刻 T（= 到期时刻 $+1$），其后任何 `acquire` 都成功——崩溃持有者的孤儿租约必然在 TTL 到期后回收，工程不可能被永久锁死（失效场景 B 的形式否定）；不可用时长有界。
- 定理 **`not_canWrite_of_expired`**：到期后原持有者写权限消灭，租约不因历史持有残留特权。
- 定理 **`heartbeat_by_nonholder_unchanged` / `heartbeat_by_holder_extends`**：非持有者心跳被拒绝且状态不变；持有者续约不缩短租约（失效场景 C 的续约侧防护）。

> 实测边界（**E-B8，2026-10-21**）：五项核心性质经离散时钟状态机仿真各 10^4 次验证全部通过——互斥

安全性（同一时刻至多一个写者）、看门狗活性（崩溃持有者租约 TTL+1 后必回收）、到期写权限消灭、心跳防护（非持有者拒绝、持有者续约不缩短）、并发写写冲突不可能（5 智能体 100 tick 随机竞争）。数据：`experiments/attention_growth/b8_lease_lock_sim.json`。

B.9 模式级形式锚点：主写从读的单写者因果序（形式化层全部已证）

`Pattern11_PrimaryWriter` 模块将模式 11（主写入者 / 从属读取者降级互斥）的并发主张形式化。模型：写日志为 `List (Write Agent)`，元素携带写入者与物理刻度；`ChainValid` 要求相邻刻度严格递增；读取视图 `viewAt l t` 是日志按 `tick $\le$ t` 过滤得到的前缀。

- 定理 **`eq_of_mem_of_tick_eq`**：合法日志中不存在两个刻度相同的不同事件——同刻度即同一事件。
- 定理 **`writer_unique_per_tick`**：同刻度的写事件写入者相同，故并发写写冲突在主写从读协议下不可能。
- 定理 **`writer_unique_of_lease`**：该结论直接由 `Pattern10.canWrite_unique` 给出——“单写者” 不是额外约定，而是租约互斥的推论。
- 定理 **`view_mono` / `no_lost_write`**：较晚读取包含较早读取的全部事件；任何已提交且刻度不晚于读取时刻的写事件必然可见。故从读者读到的是完整前缀，不会出现” 跳过中间提交” 的视图。

B.10 模式级形式锚点：观测–学习回路的稳定性（形式化层全部已证）

`Pattern23_24_ProductionLoop` 模块把验证报告 §7 遗留的” 模式 23→24→23 负反馈回路” 闭合。模型：缺陷存量 $x \in \mathbb{N}$，每周期以概率 q 检出并修复一个（$x \mapsto x-1$），否则注入一个（$x \mapsto x+1$）；转移核 `loopKernel q` 为有限支撑随机核，直接复用 B.7 的 Foster–Lyapunov 框架。

- 定理 **`T_id_pos`**：当 $x \geq 1$ 时，一步期望存量满足 $\mathbb{E}[x' \mid x] = x + 1 - 2q$。
- 定理 **`hasStrongDrift`**：若 $q > 1/2$，取 $V(x) = x$、$b = 1$、$\delta = 2q - 1 > 0$，强漂移条件成立。
- 定理 **`loop_return_bound`**：回路命中” 存量 < 1“的期望时间满足 $\mathbb{E}[\tau] \leq x_0/(2q-1)$——观测–学习闭环在 $q > 1/2$ 时指数可回收。
- 定理 **`no_drift_below_half`**（临界负结果）：若 $q \leq 1/2$，则 $\mathbb{E}[x' \mid x] \geq x$，$V = \mathrm{id}$ 不构成 Lyapunov 函数。故 $q > 1/2$ 是模型内的必要门槛，模式 23 文档中的” 检出率 ≥ 0.90“应被理解为该门槛的工程余量，而非可选性能指标。

结论地位：本模块给出的是模型内的稳定性判据（单缺陷类、单步注入/修复、独立同分布检出）。它不覆盖多缺陷类耦合、批量注入或检出率随存量变化的场景，这些仍属 §7 声明的未验证外推。同时，q 的实测取值由生产现场实验 H1 提供（2026-10-22）：固定阈值类缺陷（pool/p99）$q = 1.00$，满足 $q > 1/2$ 门槛；mem 自适应 σ 判据因阈值漂移不满足，属判据形态边界。

B.11 模式级形式锚点：审查者现实审计一票否决权（形式化层全部已证）

`Pattern02_RealityAudit` 模块将模式 02（审查者现实审计一票否决模式）的形式化主张严格落地。模型：交付物 `Deliverable` 包含四重物理布尔判据（物理源码变动、编译耗时物理常理、反自指 Mock 核验、隔离环境同质性）；现实审计器 `realityAudit` 构造四重合取过滤算子；准入函数 `admissionVerdict` 要求现实审计必须通过且 Rubric 评分达到阈值。

- 定理 **`veto_overrides_high_score`**（一票否决权绝对性）：若现实审计未通过，无论主观或 Rubric 评分多高（即便高达 9 分满分），准入判据必为 false。
- 定理 **`tautology_vetoed`**（反自指作弊硬阻断）：若测试断言为自指回吐作弊（`isTautological = true`），现实审计必然失败，交付物必然被一票否决。
- 定理 **`substrate_missing_vetoed`**（物理实体缺失硬阻断）:若未产生任何实质业务代码变更（`hasPhysicalDiff = false`），必然被一票否决。
- 定理 **`four_pillars_soundness_and_completeness`**（四重支柱完全充要性）：准入当且仅当四重物理硬判据与分数阈值同时成立。

B.12 模式级形式锚点：污点污染防御与谱系墓碑化（形式化层全部已证）

`Pattern15_RevocationTombstone` 模块将模式 15（污点污染防御与防伪退化）的动态自免疫主张形式化。模型：模式生命周期为三元状态（草稿 `draft`、已晋升 `promoted`、墓碑态 `tombstone`）；知识库为模式列表；检索投影算子仅放行 `promoted` 状态模式；撤销操作自动合成反向免疫规则集。

- 定理 **`tombstone_absorbing`**（墓碑态终结吸收性）：墓碑态是状态机的终结吸收态，任意后续状态转换无法逃逸墓碑态。
- 定理 **`tombstone_never_projectable`**（动态投影隔离安全性）：处于 tombstone 状态的模式绝不可能出现在任何上下文检索投影切片中。
- 定理 **`immunity_blocks_taint`**（反向自免疫阻断定理）：从墓碑模式自动合成的反向免疫规则集，100% 机械阻断任何携带相同污点特征的候选模式代际再生。
- 定理 **`revoke_produces_tombstone`**（撤销必入墓碑态）：执行撤销操作后，目标模式在知识库中必然处于 tombstone 状态。
- 定理 **`revoked_excluded_from_projection`**（原子撤销立即失效）：执行 `revokePatternInKB` 后，目标模式被原子置为 tombstone，立即从所有任务投影视图中消失。
- 定理 **`tombstone_offspring_zero`**（代际传播截断）：墓碑化模式的有效繁殖均值严格为 0，分支过程后代在下一代立刻为 0。

B.13 模式级形式锚点：任务级最小特权上下文投影（形式化层全部已证）

`Pattern04_PoLPProjection` 模块将模式 04（任务级最小特权上下文投影模式）的形式化主张严格落地。模型：任务上下文环境划分有效目标质量 $a > 0$、任务必要背景质量 $b_T > 0$ 以及外部全局冗余质量 $b_{ext} \geq 0$；投影算子 projectPoLP 将外部冗余质量截断剥离（$b_{ext} \mapsto 0$）。信噪比定义为 $\mathrm{snr}(a, b) = a/b$，越界代码违约概率定义为 $P_{\text{violate}}(a, b) = 1 - a/(a + b)$。

- 定理 **`polp_preserves_snr_strictly`**（最小特权投影保真定理）：若存在非零外部冗余上下文（$b_{ext} > 0$），执行最小特权投影后，任务检索信噪比严格大于全量未投影信噪比：$\mathrm{snr}(a, b_T) > \mathrm{snr}(a, b_T + b_{ext})$。
- 定理 **`polp_strictly_reduces_violation_risk`**（越界违约概率压降定理）：最小特权投影严格压降模型的注意力退化与越界代码篡改风险：$P_{\text{violate}}(a, b_T) < P_{\text{violate}}(a, b_T + b_{ext})$。
- 定理 **`polp_monotone_nesting`**（特权嵌套单调性定理）：投影切片越紧凑（$b_1 \leq b_2$），其违约风险上界单调更低。

B.14 定理 **3.1** 补充：极限环震荡与李雅普诺夫契约残差停时熔断（形式化层全部已证）

`Theorem3_1_LyapunovFuse` 模块将定理 3.1 与附录 B.7 的停时界补充完善。模型：能量残差轨迹 $V : \mathbb{N} \to \mathbb{R}_{\geq 0}$，单步漂移 $\Delta V(t) = V(t+1) - V(t)$；停滞判据为 $\Delta V(t) \geq 0$。李雅普诺夫契约残差停时熔断器在连续 k 步无负漂移（连续停滞）时硬熔断。

- 定理 **`consecutive_stalls_accumulate`**（连续停滞能量累积引理）：若从时刻 t 开始，连续 k 步漂移均为非负，则时刻 $t + k$ 的能量必不低于时刻 t 的能量：$V(t + k) \geq V(t)$。
- 定理 **`cycle_defeats_strict_lyapunov`**（周期极限环排斥李雅普诺夫负漂移存在性）：对任意周期 $k \geq 1$ 的非平凡极限环 $s_{t+k} = s_t$，不存在任何处处严格递减的李雅普诺夫超鞅能量函数，消除震荡必须依靠外部熔断器打破极限环。
- 定理 **`fuse_halts_divergence_at_k`**（停时熔断资源有界定理）：李雅普诺夫契约残差熔断器将无效自愈重试的连续步数严格截断在常数上界 k 之内，彻底杜绝死循环与 Token 黑洞。

B.15 与正文的经验边界声明

形式化覆盖的是抽象控制模型的动力学性质。全工程 Lean 代码中 **0** 公理、**0 sorry**。

以下内容本质上不可形式化，作为条件定理的前提或经验命题存在，全书不伪装其为已证：

1. Transformer 注意力机制的无关质量增长律与前提强度（B.3 各增长分支的前提）——“真实系统满足哪一分支” 是经验命题。实测边界（E3/E3b，Qwen2.5-1.5B/7B，$\rho \leq$ 131k，2026-10）：幂律分支占优、几何分支被否；弱前提 `ha_nonincr`（a 非增）方向性成立、强假设”a 为常数” 被证伪；总非目标质量 $t = b + r$ 全程非减（`hb_nondec` 存活），填充子通道长程回落判定为 sink 迁移；正文引用实测 SNR 时须用三通道口

径（目标/填充/sink），填充口径 SNR 系统性高估 35.8%–36.7%（`snr_le_proxy`）。违约概率的传导边界（**E4，2026-10-20**）：`violation_prob($\rho$) = 1 - snr($\rho$)/snr(0)` 是信噪比相对损失，不是任务失败概率。E4 端到端实验（Qwen2.5-1.5B/7B needle 检索正确率与 E3 SNR 对齐）表明两者之间存在补偿阈值 W^*：7B 在 131k 处 SNR 已损失 44% 但任务正确率仍 100%；1.5B 在 $\rho\in$[32k,64k] 正确率从 100% 陡降至 70%。违约下界 $P_{\text{violate}} \geq 1 - c^n$ 只在 $\rho > W^*$ 时传导为可观测的任务失败。W^* 与模型能力正相关（$W^*_{1.5B} \approx$ 32k⁻64k $< W^*_{7B} >$ 131k $< W^*_{\text{Kimi}} \geq$ 1M），为经验参数，不写入形式化接口。适用域：Qwen2.5 系模型、needle 型检索任务、F1–F3 填充；跨模型族与真实工程工作负载的外推未验证；

2. 模型–现实的口径映射（B.3 全部定理的经验引用都经过它）：定理的 a 是单目标 **token** 的注意力质量，实验的 a 是 **needle** 整段总质量；定理的 b 是全部非目标质量，实验的 b 是填充段总质量（filler $= b - r$）。这两条映射是未经证明的假设——其成立性由 E3b 的残差通道漂移检验部分背书（r 显著漂移已触发预注册第 3 条，故三通道口径为必需而非可选），但" 整段质量近似单 token 行为" 尚无独立检验，引用实测数据支持定理叙事时须连同本声明一起给出；
3. 具体大模型在具体任务上的奖励欺骗发生率（第二章博弈论分析给出的是策略存在性，非发生率）；
4. 工业工程中契约违规的实测分布。

形式化证明保证的是：在给定前提（独立性假设、增长律等）下，四大公理与定理 **3.1** 所断定的因果结构在逻辑上成立。

B.16 复现方式

```
cd formal_proof/IACFormalization
lake build          # 全量内核验证
lean src/IACFormalization/Axiom1_Grounding.lean    # 单文件检查
```

依赖：本机共享 mathlib4 预编译包（`lakefile.lean` 中以绝对路径引用）；零 sorry 政策——任何 `sorry` 出现即视为构建缺陷。

附录 A：本书术语与学术界既有术语映射表

Appendix A: Terminology Alignment between This Treatise and Established Academic Terms

本附录说明本书命名体系与人工智能安全、分布式系统与软件工程领域既有学术术语的对应关系，并声明全书术语政策。所有学术锚点文献的完整引用见 A.5 参考文献。

A.1 术语政策（Terminology Policy）

本书对术语实行三级管理：

层级	对象	政策
T1：失效模式术语	描述智能体可观察失效现象的命名	已修正为学术界既有术语为主。书内自造名废除，或在首次引入处仅作为组织行为学借喻保留一次
T2：公理体系术语	四大控制论公理的命名	保留命名（属于本书的理论贡献命名空间），但在每条公理的诠释处锚定对应的既有学术概念与文献
T3：模式与架构术语	22 个 GoF 式设计模式名与系统架构术语	保留命名（属于本书的工程贡献命名空间），本表给出其最近对应概念，以保证可检索性

术语书写规范：每个术语首次出现时给出中文全称与英文全称，此后可直接使用英文术语或通用缩写（如最小特权原则 Principle of Least Privilege, PoLP）。

A.2 失效模式术语（T1：已修正为既有术语）

书内原术语	修正后主术语（中文 / 英文）	修正说明与学术锚点
合规剧场（Compliance Theater）	奖励欺骗（**Reward Hacking**）；并列概念：规范博弈（**Specification Gaming**）	“合规剧场” 原为组织行为学借喻（与” 安全剧场 Security Theater” 同源）。人工智能安全文献的规范术语是奖励欺骗：智能体通过满足目标的” 字面” 而非” 精神” 骗取成功信号（Amodei et al., 2016；Krakovna et al., 2020；Denison et al., 2024）。本书仅在第二章首次引入时保留该借喻以建立直觉，此后统一使用” 奖励欺骗”。2025 年工业实证：生产级强化学习中的奖励欺骗可诱发自然涌现的失对齐（Anthropic, arXiv:2511.18397）
注意力涣散 / 注意力稀释（Attention Dilution）	上下文退化（**Context Rot**）	长上下文实证研究刻画的核心现象：随无关上下文增长，模型有效推理能力显著衰减，典型表现为” 迷失在中间（Lost in the Middle）“的 U 型注意力曲线（Liu et al., TACL 2024）。有效上下文长度实测远低于标称值（Hsieh et al., 2024, RULER；Chroma, 2025, Context Rot 技术报告）
知识自噬中毒（Auto-Toxic Hallucination Pollution）/ 自噬性知识中毒 / 知识自噬（Auto-Toxic Degradation）	记忆投毒（**Memory Poisoning**）；宏观递归现象：模型坍缩（**Model Collapse**）	未经终审验证的自生经验经检索复用后对后续任务产生持续性污染，即记忆投毒——已被实证确认为智能体长期记忆的关键攻击面（MemoryGraft, arXiv:2512.16962；OEP, arXiv:2605.18930）。宏观层面的递归自我消费已由实证研究确认导致模型坍缩（Shumailov et al., *Nature* 631, 2024）；幻觉雪球效应（Hallucination Snowballing）刻画单次生成内的自我强化（Zhang et al., 2023）
反思自愈假设（Reflection Fallacy）	无外部验证的自我纠错不可行（描述性表述，删除品牌化英文名）	该假设已被系统性实证证伪：在无外部反馈时，大语言模型的自我纠错不仅无效，反而常导致性能退化（Huang et al., *Large Language Models Cannot Self-Correct Reasoning Yet*, ICLR 2024）
虚假通过（Tautological Illusion）	虚假通过（**Falsified Pass**）（描述性表述）	属于奖励欺骗在评测语境下的具体表现：通过自指验证回路（Self-Referential Verification Loop）制造通过假象，不设独立术语

A.3 公理体系术语（**T2**：保留命名，锚定既有文献）

公理	保留命名	对应的既有学术概念	锚点文献
公理 I	物理非信任公理（Axiom of Physical Non-Trustworthiness）	接地与验证鸿沟（Grounding & Verification Gap）；奖励欺骗（Reward Hacking）；谄媚性（Sycophancy）	Amodei et al., 2016；Sharma et al., 2023；Huang et al., ICLR 2024
公理 II	注意力稀释公理（Axiom of Attention Dilution）	上下文退化（Context Rot）；迷失在中间（Lost in the Middle）；有效上下文长度（Effective Context Length）	Liu et al., TACL 2024；Hsieh et al., 2024；Chroma, 2025
公理 III	变异因果律单调公理（Axiom of Monotonic Causal Mutation）	因果序（Happens-Before Ordering）；写前日志（Write-Ahead Logging, WAL）；幂等性（Idempotency）；租约（Lease）	Lamport, CACM 1978；Gray & Cheriton, SOSP 1989；Kleppmann, 2017
公理 IV	经验自免疫公理（Axiom of Crystallization Auto-Immunity）	记忆投毒（Memory Poisoning）；模型坍缩（Model Collapse）；隔离与验证晋升（Quarantine & Verified Promotion）	Shumailov et al., *Nature* 2024；MemoryGraft, 2025；OEP, 2026

A.4 模式与架构术语（**T3**：保留，给出最近对应概念）

本书术语	最近对应概念	说明
物理底座（Substrate）	执行环境（Execution Environment）/ 环境（Environment）	指智能体所作用的真实目标工程源码树、文件系统与构建运行时。保留” 底座” 以强调其物理约束属性（编译器、缓存、进程生命周期），区别于评测用沙箱环境
知识萃取（Crystallization）	经验固化（Memory Consolidation）；技能库（Skill Library）	对应记忆增强智能体文献中的经验沉淀机制（Voyager 的技能库, Wang et al., 2023；ExpeL, 2024）。本书的贡献在于为其附加隔离与终审晋升门禁
最小特权投影（PoLP Projection）	最小特权原则（Principle of Least Privilege, PoLP）	直接沿用 Saltzer & Schroeder (1975) 的经典安全原则，将其从权限域迁移至上下文域
分布式底座租约锁（Substrate Lease Lock）	租约（Lease）与看门狗（Watchdog）	沿用 Gray & Cheriton (SOSP 1989) 的租约机制
幂等变异日志与物理时钟补偿	写前日志（WAL）+ 幂等键（Idempotency Key）+ 单调时钟（Monotonic Clock）	标准分布式系统技术在增量编译缓存场景的迁移

本书术语	最近对应概念	说明
隐藏 Oracle 物理隔离沙箱 / 五重无旁路机械判据	验证门禁式评测（Verifier-Gated Evaluation）；数据去污染（Decontamination）；无旁路评测（Bypass-Free Evaluation）	对应评测方法论文献对” 智能体欺骗评测器” 问题的回应（Kapoor et al., *AI Agents That Matter*, 2024；SWE-bench Verified 的人工校验实践）
断言反自指核验（Tautology Check）	自指验证回路检测（Self-Referential Verification Detection）	属于奖励欺骗的实例级检测手段，保留为描述性技术名

A.5 参考文献（**References**）

1. Amodei, D., Olah, C., Steinhardt, J., Christiano, P., Schulman, J., & Mané, D. (2016). *Concrete Problems in AI Safety*. arXiv:1606.06565.
2. Krakovna, V., et al. (2020). *Specification gaming: the flip side of AI ingenuity*. DeepMind Research Blog.
3. Huang, J., Chen, X., Mishra, S., Zheng, H. S., Yu, A. W., Song, X., & Zhou, D. (2024). *Large Language Models Cannot Self-Correct Reasoning Yet*. ICLR 2024.
4. Sharma, M., et al. (2023). *Towards Understanding Sycophancy in Language Models*. arXiv:2310.13548.
5. Denison, C., et al. (2024). *Sycophancy to Subterfuge: Investigating Reward-Tampering in Language Models*. arXiv:2406.10162.
6. Anthropic Alignment Team (2025). *Natural emergent misalignment from reward hacking in production RL*. arXiv:2511.18397.
7. Liu, N. F., Lin, K., Hewitt, J., Paranjape, A., Bevilacqua, M., Petroni, F., & Liang, P. (2024). *Lost in the Middle: How Language Models Use Long Contexts*. Transactions of the Association for Computational Linguistics (TACL).
8. Hsieh, C.-P., et al. (2024). *RULER: What's the Real Context Size of Your Long-Context Language Models?* arXiv:2404.06654.
9. Chroma Research (2025). *Context Rot: How Increasing Input Tokens Impacts LLM Performance*. Technical Report.
10. Shumailov, I., Shumaylov, Z., Zhao, Y., Papernot, N., Anderson, R., & Gal, Y. (2024). *AI models collapse when trained on recursively generated data*. Nature, 631, 755–759.
11. Zhang, M., Press, O., Merrill, W., Liu, A., & Smith, N. A. (2024). *How Language Model Hallucinations Can Snowball*. ICML 2024.
12. *MemoryGraft: Persistent Compromise of LLM Agents via Poisoned Experience Retrieval*. arXiv:2512.16962.
13. *OEP: Poisoning Self-Evolving LLM Agents via Locally Correct but Non-Transferable Experiences*. arXiv:2605.18930.
14. Lamport, L. (1978). *Time, Clocks, and the Ordering of Events in a Distributed System*. Communications of the ACM, 21(7), 558–565.
15. Gray, J., & Cheriton, D. (1989). *Leases: An Efficient Fault-Tolerant Mechanism for Distributed File Cache Consistency*. SOSP 1989.
16. Saltzer, J. H., & Schroeder, M. D. (1975). *The Protection of Information in Computer Systems*. Proceedings of the IEEE, 63(9).
17. Kleppmann, M. (2017). *Designing Data-Intensive Applications*. O'Reilly Media.

18. Wang, G., Xie, Y., Jiang, Y., Mandlekar, A., Xiao, C., Zhu, Y., Fan, L., & Anandkumar, A. (2023). *Voyager: An Open-Ended Embodied Agent with Large Language Models*. arXiv:2305.16291.
19. Yang, J., et al. (2024). *SWE-agent: Agent-Computer Interfaces Enable Automated Software Engineering*. NeurIPS 2024.
20. Kapoor, S., et al. (2024). *AI Agents That Matter*. arXiv:2407.01502.
21. Xie, et al. (2026). *From Spark to Fire: Modeling and Mitigating Error Cascades in LLM-Based Multi-Agent Collaboration*. arXiv:2603.04474.
22. Zhu, K., et al. (2025). *Where LLM Agents Fail and How They Can Learn From Failures*. arXiv:2509.25370.
23. Chen, Y., et al. (2026). *OrchestraBench: Evaluating Multi-Agent Orchestration Failure Modes, Recovery, and Decomposition Quality*. arXiv:2608.05263.
24. Thaman, K., et al. (2026). *Reward Hacking Benchmark: Measuring Exploits in LLM Agents with Tool Use*. arXiv:2605.02964.
25. Roth, A., et al. (2026). *Hack-Verifiable Environments: Towards Evaluating Reward Hacking at Scale*. arXiv:2605.20744.
26. 王斌. 工业智能体控制论：自主软件工程的设计模式与形式化架构 [EB/OL]. (2026-10-25). https://github.com/dpsnet/industri
agentic-cybernetics. DOI: https://doi.org/10.5281/zenodo.23722977.

公理 **I–IV** 验证总结报告

工业智能体控制论（IAC）四条元公理的形式化与实证验证总账日期：2026-10-21　状态：四条公理全部闭环（形式化 + 实证 + 文档回写）形式化工程：`formal_proof/IACFormalization`（Lean 4 + mathlib4，**0 sorry**，全部定理经内核验证）正文：`docs/preface/03-axioms-and-invariance.md`；形式化附录：`docs/appendix-formal-proofs.md` 验证证据附录（元声明）：本报告是本书的证据账本——记录公理 I–IV 与定理 3.1 的预注册判读、实证数值与适用域边界，供审阅者核验。文体为证据记录而非范式正文：理论主张以正文公理声明为准，本报告不引入正文之外的理论承诺。

---

0. 总览

公理	核心主张	Lean 4 形式化	实证验证	判定
I 物理非信任	无外部接地的自检声称成功不可信	B.2：3 定理已证	文献锚点支撑（奖励欺骗实证）	【通过】闭环
II 注意力稀释	违约概率下界随无关上下文膨胀发散	B.3：稀释定理链 + 三增长分支 + 两相模型已证	E3/E3b（注意力通道）+ E4（W* 阈值）+ E8（负结果）	【通过】闭环
III 变异因果单调	可观测 ⇔ 物理时钟严格单调跳变；幂等可溯	B.4：2 定理已证	Cargo 28/28 组受控测量	【通过】闭环
IV 经验自免疫	双盲门禁压缩有效繁殖数，隔离 ⇒ 谱系灭绝	B.5：分支过程 + GW 相变定理链已证	DeepSeek 288 会话多代传播 + GW 仿真	【通过】闭环
定理 **3.1** 因果不变性	可观测 ∧ 局部 ∧ 解耦 ⇔ 确定性收敛	B.6：充分性 + 三反例已证	E-B6：12 组 Lyapunov 界 + 3×10^4 反例复现	【通过】闭环
随机 **Foster-Lyapunov**	$\mathbb{E}[\tau] \le V(x_0)/\delta$	B.7：截断停时 + 主定理已证	E-B7：27 组蒙特卡洛 + 截断一致界	【通过】闭环
租约锁（模式 **10**）	互斥 ∧ 看门狗活性 ∧ 心跳防护	B.8：5 定理已证	E-B8：5×10^4 离散时钟仿真	【通过】闭环

验证方法论统一遵循：预注册判读标准先于实验执行；结论一律条件定理化；与理论不符的观测如实记录为适用域边界，不修补理论。

---

1. 公理 **I**：物理非信任公理（**Axiom of Physical Non-Trustworthiness**）

主张：封闭推理链中（无外部物理传感器），智能体声称” 任务成功” 的物理真实率趋近于零。

形式化（**B.2**，全部已证）：- `self_verdict_zero_information`：条件独立封闭闭环中，自检通过的后验真值率等于先验——自检证据的贝叶斯似然比恒为 1；- `closed_loop_risk_factorizes`：闭环风险被先验乘积结构锁定，纯反思策略无法改变；- `posterior_independent_of_mechanism`：后验真值率与自检机制复杂度无关——排除”更强模型靠自省突破” 的幻想。

实证支撑：该公理是工程立场的形式化，其经验内容来自文献锚点——无接地模型自我报告不可信、可欺骗评价信号下受控实验普遍观测到奖励欺骗（Amodei et al. 2016；Huang et al., ICLR 2024；Anthropic arXiv:2511.18397）。物理 Exit 0 穿透（模式 01）是” 获得任何证据的唯一通道”。

---

2. 公理 II：注意力稀释与特权发散公理（**Axiom of Attention Dilution**）

主张：$P_{\text{violate}}(\rho) \geq 1 - e^{-\alpha\rho}$——无关上下文注入使违约概率下界发散，必须施加最小特权（PoLP）投影。

形式化（**B.3**，全部已证）：稀释严格性（`attention_dilution_strict`）、三增长分支衰减律（几何 `snr_geometric decay` / 多项式 `snr_polynomial_decay` / 幂律 `snr_power_decay`）、迭代几何界 `snr_decay_iterated`、违约下界 `violation_prob_lower_bound`、两相模型（稀释相 + 平台相不逆转）、口径定理（`snr_le_proxy`：填充口径系统性高估、`filler_growth_not_sufficient` 反例）。

实证验证：- **E3/E3b**（注意力通道，**Qwen2.5-1.5B/7B**，$\leq$ **131k**，**scnet DCU**）：幂律分支占优（AIC 33/36 cell，几何 0 票）；弱前提”a 非增” 方向性成立，强假设”a 恒定” 被证伪——衰减由分子收缩与分母膨胀共同贡献；残差（sink）通道为动态通道，总非目标质量全程非减，填充口径 SNR 系统性高估 35.8%–36.7%；近义对抗填充使 SNR 基线降至中性填充的 1/2.25（衰减参数由填充类型标定，并非常数）。- **E4**（**W*** 补偿阈值，**2026-10-20/21**）：SNR 衰减与任务正确率衰减之间存在补偿阈值 W^*——$\rho < W^*$ 时正确率 $\approx$ 100%，$\rho > W^*$ 时陡降。实测 $W^*_{1.5\text{B}} \approx$ 32k–64k $< W^*_{7\text{B}} >$ 131k $< W^*_{\text{Kimi}} \geq$ 1M（辅线难任务独立支撑：5-needle + 语义干扰下 512k 档 9/9 全对，prompt 725k tokens）。违约下界只在 $\rho > W^*$ 时传导为可观测任务失败；W^* 为经验参数，不写入形式化接口。- **E8**（负结果，关闭）：注意力熵、top-1% 集中度、key 有效秩三候选结构量跨 3 模型无一稳健复现——γ/β 保持自由参数；方向一致性（三模型同号）记录为弱信号。

---

3. 公理 III：变异因果律单调公理（**Axiom of Monotonic Causal Mutation**）

主张：物理生效 $\Leftrightarrow$ mtime 严格正向跳变，且变异动作具备幂等可溯的规范化签名。

形式化（**B.4**，全部已证）：`observability_iff_mtime_strict_mono`（可观测 $\Leftrightarrow$ 物理时钟严格单调跳变；回拨/停滞 $\Rightarrow$ 静默吞没）与 WAL 幂等回放定理。

实证验证（**Cargo 1.96 / Windows NTFS**，**28/28** 组全部支持预注册假设）：- mtime 停滞/回拨 $\Rightarrow$ 静默丢失（各 5/5，产物保持旧版本）；- mtime 严格跳变 $\Rightarrow$ 重建（5/5，纯时钟跳变即使内容不变也触发——重建触发纯由时钟通道决定，可观测性由内容差异决定，与定理前提划分一致）；- 幂等性在无变化重构建（5/5 跳过、sha 不变）与 git 回退-重试（语义输出恢复）中成立。

两个超出预注册的工程边界（如实回写）：(1) 参考时钟实测为" 上次构建完成时刻" R，静默丢失窗口 $(0, R]$ 宽于朴素模型——构建进行中并发写入天然不安全；(2) Windows PE 头含编译时间戳，同源码重编译字节级必异，幂等承诺在内容/语义层而非比特层。适用域：mtime-based 增量编译器（Cargo、Make）；内容哈希型构建系统（Bazel、Nix）不适用。

---

4. 公理 IV：经验自免疫公理（**Axiom of Crystallization Auto-Immunity**）

主张：未终审经验视为 `DRAFT_SUSPECT`，严禁横向传播；双盲过滤（$\text{Verdict}_{audit} \wedge \text{SubstratePass}$）后才准入全局知识库。

形式化（**B.5**，全部已证）：`expected_population_geometric`（$E(n) = m^n E(0)$）、`subcritical_extinction in_probability`（亚临界按概率灭绝）、`quarantine_compresses_offspring`（$m = \mu(1-\sigma)$）、`supercritical expectation_diverges`、`galton_watson_non_extinction` + `galton_watson_extinctProb_exact`（超临界以正概率永续，$q = \min\{s : \varphi(s) = s\}$）。

实证验证（**DeepSeek-V4-Pro-0813**，**4** 条件 × **12 replicate** × **6** 代 **= 288** 会话，预注册判读先于实验）：

判据	结果	判定
H1b 完全隔离（σ=1）	全部 replicate $Z_1 = 0$，无 de novo 再发现	【通过】通过
H2 几何律	池化 $R^2 = 0.958 \geq 0.8$，逐代比无趋势	【通过】通过
H3-数值	三亚临界变体 $q_{sim} = 1.0000 = q^*$ 无自由参数吻合，Markov 界成立	【通过】通过
H1a 标记门压缩	pro 档 $p = 0.15$ 不显著；SUPERCRITICAL C1-full 零压缩；H1AC Flash 大样本 $\bar{d} = 0.02$（$p = 0.69$）	【失败】标记门无效（三重独立确认，效应不存在非功效不足）
H1c 乘性压缩律	过滤层有效样本 $n = 1$，写出层涨落主导；H1AC Flash 大样本（64 链，双毒株）链均 $\hat{r}_{C2}/\hat{r}_{C0} = 0.466 \in [0.35, 0.65]$（乘性预测 0.5 吻合），bootstrap 95% CI $[0.333, 0.602]$ 下界微出界（per-parent 池化口径在 C2 幸存者偏倚下失效，改链均口径）	【待定】点估计支持、CI 判据未完全通过（下界出界 0.017）

总判定：工程核心承诺" 隔离 ⇒ 灭绝" 获最强形式验证；种群几何律成立（96 链大样本复验 R^2=0.923）；标记门显著性三重独立确认不存在（效应为零而非功效不足）；乘性律 LLM 层直接检验获大样本点估计支持（H1AC 64 链 $\hat{r}$=0.466 ≈ 0.5，CI 下界微出界 0.017，记录为适用域边界）；防御实现应依赖隔离而非仅依赖标记。

意外发现与超临界验证（适用域边界，**2026-10-22** 闭合）：无门禁下 $\hat{m} = 0.56 < 1$——选择性逐代转写协议本身将传播压入亚临界；超临界坍缩动力学对应无转写衰减的记忆架构（全量追加式记忆库、向量库直写）。SUPERCRITICAL

计划（全量追加架构，Flash 档）已确认：该架构传播为线性累积-容量竞争型（每代 $W \equiv 1$、$Z_{n+1} = Z_n + W$），C0-full $\hat{m} = 1.166$（CI $[1.156, 1.176]$）、W=32 线性 $Z \to 8$、W=8 灭绝（临界容量 $W_c \in (8, 16)$，低转写态读数）——机制层架构分叉成立；“超临界” 保留为工程语义（毒株池持续累积不灭绝），精确机制为累积-竞争。详见 `EXPERIMENT_PLAN_AXIOM4_SUPERCRITICAL.md` §8。

跨模型复核（**M2：Kimi `kimi-for-coding`，288 会话，2026-10-21**）：

判据	结果	判定
X-H1 隔离不变性	两模型合计 24/24 链 $Z_1 = 0$	【通过】通过
X-H4 跨模型幅度差异	$\hat{m}_{C0}$：DeepSeek 0.560 CI $[0.294, 0.735]$ vs Kimi 0.983 CI $[0.944, 1.000]$，差 CI 不含 0	【通过】显著成立
X-H3 标记门方向	两模型同号（Kimi $0.957 < 0.986$，$p = 0.323$）	【警告】方向成立/不显著
X-H2 几何律（M2）	池化 $R^2 = 0.744 < 0.8$，近临界区无动态范围	【警告】预注册未通过（判据无功效）
H3-数值（M2）	q_{sim} 与 $\varphi^{30}(0)$ 差 0.001，但与 q^* 差 0.65	【警告】字面未通过（时域截断）

结论修订：$\hat{m}$ 是模型特定参数而非普适常数，实测跨模型区间 $[0.56, 0.98]$ 且可含近临界核。Kimi 的繁殖核退化为 Bernoulli($p \approx 0.98$)，6 代存活率仍达 0.917，灭绝需 $\sim$ 50–100 代——工程上等于不退场。因此公理 IV 的适用域表述收紧为：“无门禁下的 $\hat{m}$ 由模型转写倾向决定；隔离（$\sigma = 1$）的灭绝保证与 $\hat{m}$ 取值无关。” 防御效果不得依赖模型自身的转写衰减，须依赖完全隔离。详见 `EXPERIMENT_PLAN_AXIOM4_CROSS_MODEL.md` §8。

漂移表征与容量调控（**2026-10-23~24** 闭合，**DeepSeek-V4.1-Flash-1017**，**Flash** 档，探针 + 控制实验；预注册判读先于实验）：

判据	结果	判定
漂移状态双峰	低转写态 ≈ 0.25 vs 高转写态 0.63–1.0；同日翻转间隔约 32 分钟（10-22 15:30 高态 0.917/代 vs 16:02 低态 0.25/代）	【通过】状态双峰成立
探针校准协议	15:00 窗口 8/8、night 窗口 8/8、第三窗口（08:47）5/5 均 p_{probe}=1.000；漂移模型 20 批 58 链 (α, β)=$(0.533, 0.159)$、$\hat{p}$=0.770	【通过】多时段高态延续
M_c 状态条件量	高态 W=8 存活 0.75、$M_c \in (4, 8)$；低态 W=8 灭绝、$M_c \in (8, 16)$（上节 SUPERCRITICAL 读数修正为低态标注）	【通过】探针门控重扫
C1 窗口收缩安全侧	毒丸存活 0.833→0.333（同批 12v12 Fisher 单侧 p=0.018；三窗口合并 13/32 vs 19/24，单侧 p=0.0040）	【通过】控制律高态分支实证
C2 效用判据	记忆效用保留 $0.328 \geq 0.275$（0.9×W4 基线 0.305）；跨窗口一致性检查	【通过】

判据	结果	判定
C3 同批对照	同窗口、同协议，静态 W=8 臂效用 0.541（同批离线判读）	【通过】
切换动力学	探针全程判高态、动态臂零切换——跨状态翻转未行使	【警告】待测（平行随动探针切片机制为此设计；跨翻转完整批因实验额度约束缩减）
部署成本-收益	探针增量（门控 +4%、随动 1:3 +42%、1:2 +54% 计算量）购买批内漂移可行使性而非直接安全；隔离零增量且毒丸存活 0、效用保留 0.88，绝对占优	边界声明（隔离可用性代价未量化）

结论修订（**2026-10-24**）：M_c 为状态条件量（高态 $(4, 8)$ vs 低态 $(8, 16)$），跨批绝对读数须按探针状态标注；容量调控的控制律高态分支获三窗口复现（p=0.0040），切换动力学维持待测；部署决策中隔离仍是成本-安全-效用上的绝对占优项，动态容量调控的合理性依赖隔离可用性代价这一未量化前提。判读详见论文 §7/§11.4。

---

5. 跨公理接口与体系完整性

`Axiom2_Axiom4_Bridge`（B.3 末尾）给出分层公理系统的纵向边：`InjectionCoupling` 将公理 IV 的记忆注入速率 μ 经无关量映射 $\rho(\mu)$ 接入公理 II 的稀释动力学——注入越快违约下界越紧（`injection_strengthens_lower bound`）。四条公理由此不是独立模型的集合，而是带严格无反馈规则的层间耦合体系：公理 I 划定证据合法性边界，公理 II 刻画上下文膨胀的必然代价，公理 III 保证状态变异的可观测与可溯，公理 IV 封顶经验传播的种群动力学。

6. 认识论声明

1. 全部形式化定理（B.2–B.5）为 Lean 4 内核验证的数学事实，不需要经验” 证真”；实验检验的是模型–现实映射的适用性。
2. 所有实测结论以条件定理形式呈现，适用域逐条声明（模型族、任务族、协议、平台）；
3. 与预注册判据不符的观测（H1a 功效不足、H1c 不可判定、E8 跨族崩溃、$\rho = 0$ 异常）一律如实记录为边界，理论未作任何事后修补。

数据与复现：`experiments/attention_growth/`（EXPERIMENT_PLAN.md、EXPERIMENT_PLAN_AXIOM3.md、EXPERIMENT_PLAN_AXIOM4.md 及各结果 JSON）；形式化复现见附录 B.12。

---

7. 局限与后续验证计划

四条公理的验证均条件化于实测的模型、任务族与协议。下表为针对每项边界的补足路径；其中跨模型、跨任务族、生产现场实验均已执行完毕，其余两份为预注册计划（未执行）。

局限	计划	性质	预注册核心判据
单一模型（仅 DeepSeek-V4-Pro-0813）	EXPERIMENT_PLAN AXIOM4_CROSS MODEL.md	【通过】已执行：Kimi 平行实验 288 会话	X-H1 通过（24/24）、X-H4 显著；X-H2/H3-数值受近临界区功效限制未通过
单一任务族（pytest 编写）	EXPERIMENT_PLAN AXIOM4_CROSS_TASK.md	【通过】已执行：四任务族 × 三条件（144 链，2026-10-22）	T-H1 通过（48/48）；T-H4 通过（$p = 0.026$）；T-H3 拒绝（邻接度序不成立）；T-H2 部分支持（近临界区判据失效）
超临界机制与适用域（原" 未出现"，2026-10-22 已闭合）	EXPERIMENT_PLAN AXIOM4 SUPERCRITICAL.md	【通过】已执行（**Flash** 档）：C0/C1/C3 各 12/12 + W8/W32 各 6/6 + selective 对照	S-H1 【通过】$\hat{m} = 1.166$（CI $[1.156, 1.176]$）；S-H2 【通过】存活率 1.0；S-H4 【通过】隔离跨机制截断；容量 $W_c \in (8, 16)$；S-H3 因累积型机制不适用（GW 框架不匹配）
H1a 标记门零压缩 / H1c 乘性压缩律	EXPERIMENT_PLAN AXIOM4_H1AC_BOOST.md	【通过】已执行（**2026-10-22**）：Flash 档 160 链（C0/C1 各 48 + C2 64）配对设计	B-H1a【失败】零压缩（$\bar{d} = 0.02$，$p = 0.69$）；B-H1c【待定】点估计支持（$\hat{r} = 0.466$，CI $[0.333, 0.602]$ 下界微出）；B-H2 【通过】$R^2 = 0.923$
模式 23/24 无形式化与实证	EXPERIMENT_PLAN PRODUCTION_FIELD TEST.md	【通过】已执行（**2026-10-22**）：Docker Compose 受控生产环境（F1–F4 各 10 reps + H2 篡改自测 20 + LLM 闭环 18 报告）	H1：F1/F2 检出率 1.00、F4 误报 0.00（F3 mem 3σ 判据形态边界）；H2 篡改否决率 1.00；H3 晋升比例 1.00、错误拦截 1.00；H5 环境泄漏 0；H4 mtime 判据有效（708 误拒系 exporter 序号复用装置缺陷，复核 456 快照单调 0 破坏）

功效缺口分析（**2026-10-22** 已补算）：H1a 标记门压缩（−38%，$p = 0.15$）的失效是功效不足而非效应缺失。用主实验 pro 档 per-parent 口径（C0=0.354，C1=0.188，配对差 $d = 0.167$，$sd = 0.432$，比值 0.53）做配对检验功效分析：当前 $n = 12$ 单侧 $\alpha = 0.05$ 下功效仅 0.38（置换核对 0.27）；达到功效 0.8 需约 48 配对样本量。`EXPERIMENT_PLAN_AXIOM4_H1AC_BOOST.md` 的 960 配对设计远超所需（$n = 96$ 功效 0.98），若效应真实且稳定，预期可给出显著结论。功效脚本/结果：`e_power_markgate.py`、`e_power_markgate.json`。

观测–学习回路的稳定性（**2026-10-21** 已闭合）：模式 23→24→23 的负反馈回路此前未给出 Lyapunov 函数。现已在 `Pattern23_24_ProductionLoop` 中闭合：以缺陷存量 $V(x) = x$ 为 Lyapunov 函数、$b = 1$、$\delta = 2q - 1$，证

明检出–修复率 $q > 1/2$ 时强漂移成立，命中" 存量 < 1"的期望时间满足 $\mathbb{E}[\tau] \le x_0/(2q-1)$；并给出临界负结果——$q \le 1/2$ 时 $V = \mathrm{id}$ 不构成 Lyapunov 函数。该结论为模型内结论（单缺陷类、单步注入/修复、i.i.d. 检出），不覆盖多缺陷类耦合与批量注入；q 的实测值已于 2026-10-22 由 `EXPERIMENT_PLAN_PRODUCTION_FIELD_TEST.md` 的 H1 执行：固定阈值类缺陷（pool/p99）$q = 1.00$ 满足门槛；mem 自适应 σ 判据因阈值漂移不满足（判据形态边界，见 `experiments/field_test/results/f3_boundary_evidence.md`）。理论侧的形式缺口至此清零，剩余缺口全部转为经验缺口。

跨任务族复核（**2026-10-22** 已闭合）：四任务族（pytest 同步 / httpx 异步 / CI workflow / CI workflow+P3 对照）× 三条件（C0/C1/C3）× 12 replicate × 6 代，共 144 链。T-H1 通过（48/48 条 C3 链 $Z_1 = 0$，零违例）；T-H4 通过（族内毒株对照 $p = 0.026$）；T-H3 拒绝（预注册邻接度序 $A \approx D > B > C$ 不成立，实测 $B > A > D > C$）；T-H2 部分支持（仅 D 族 $R^2 = 0.888$ 通过，近临界族判据失效）。关键修订：$\hat{m}$ 是任务族与毒株适用位点的联合参数，区间 $[0.29, 1.00]$，跨族不可迁移；隔离（$\sigma = 1$）的灭绝保证与 $\hat{m}$ 取值无关。模式 14 的门禁设计前提需重新标定为" 毒株在任务中具有可落地的适用位点 $\Rightarrow \mu > 0$"。详见 `EXPERIMENT_PLAN_AXIOM4_CROSS_TASK.md` §8。

---

8. 模式级闭环审计（**24** 模式可追溯矩阵）

> 矩阵本体（24 行口径表 + 统计）已前置至 §1.4.6——证据分布开卷即见。本节保留指标口径原则与三张处置清单，作为该矩阵的补充口径与审计台账。

指标口径原则（**2026-10-21** 增补）：凡涉及" 比 X 更快/更省" 的宣称，指标一律取相对量（配对差 Δ 或比值 ρ），绝对阈值只作描述性读数。理由：绝对量随 provider、模型、并发度、任务长度漂移，不可跨环境比较；相对量在同一配对条件下可比，且能直接写出零假设。模式 06（节省率 = 已付成本占比）与模式 22（首字时延差 $\Delta > 0$）已按此原则重述。

缺口分流（三张处置清单）：

1. 应补证明（已完成）：模式 11 已补 `Pattern11_PrimaryWriter`（单写者因果序 + 视图前缀单调，零 sorry）；模式 23/24 已补 `Pattern23_24_ProductionLoop`（$V = x$、$b = 1$、$\delta = 2q - 1$，含临界负结果）。二者均已挂入根模块并通过 `lake build`（6274 jobs）。除此之外，可定理化模式的核心结论均已入内核。
2. 数值宣称已逐条裁定：已完成补测 **2** 项——06（成本加权前缀核算，结论：节省率 = 已付成本占比而非任务计数占比；成本前置 $r \ge 1.2$ 时 $N = 32$ 期望 81.5%、断点 $k/N \ge 0.25$ 即可达 70%，与外部断点重试实测相符；等成本下期望约 50%）、22（宣称实质是相对量——同 provider 下原生网关首字时延短于 CLI 路径；应以配对差 $\Delta = T^{\text{cli}} - T^{\text{nat}}$ 的中位数与比值 ρ 为判据，`800ms/8~12` 秒仅为描述性读数。外部实测、本仓库不可复现；本次以 DeepSeek/scnet/Kimi 测得 0.98~2.65s 属域外数据，不构成检验）；待补测 **1** 项——20（配对 A/B 需配额，排在 CROSS_TASK 之后）；降级 4 项——05（口径未定）、07（"无效重试" 无定义）、08（行数为代理量，改测孤儿分支检出率）、13（依赖任务分布）；保留 1 项——21（已实测，需补口径）。各条已在对应模式文档 §9 显式标注。
3. 应显式降级为约定（已完成）：模式 03/16/17/19 已在正文 §9 标注为" 工程约定"，并声明不得作为其他模式的推理前提。

闭环判据：理论自洽的完整标准是——每个模式要么挂到一条已机检的定理上，要么挂到一组预注册实验的可证伪判据上，要么被显式标注为工程约定；三者都不满足的即为无效逻辑。按此判据，24 个模式已全部归类完毕：9 个有 Lean 锚点、10 个有实证或实测（与前者部分重叠）、4 个显式约定、3 个标注为未验证经验目标。剩余工作不再是" 逻辑缺口"，而是经验缺口：模式 20 的配对 A/B（排在配额之后）。生产现场实验（模式 23/24 的 q 实测）已于 2026-10-22 闭合：固定阈值类缺陷 $q = 1.00$（F1/F2），mem 自适应 σ 判据因阈值漂移不满足 $q > 1/2$ 门槛（判据形态边界，已留档）。