无门控智能体记忆架构中的记忆投毒：架构依赖的传播机制、容量控制与隔离不变性

王斌

北京开路者科技有限公司 • 技术总监

Email: wang.bin@foxmail.com；wangb@kailuzhe.cn

摘要：长期运行的 LLM 智能体将经验沉淀进持久记忆；未经验证或恶意的条目可在会话间传播并污染下游任务。既有防御将软标记与硬隔离混为一谈，且尚无研究将记忆架构与传播的数学结构联系起来。本文在两种写入协议（选择性转写与全量追加）下研究注入-传播问题，通过覆盖三个模型族（DeepSeek-V4-Pro-0813（Pro）、Kimi、DeepSeek-V4.1-Flash-1017（Flash））、两种架构、多档容量、共 846 条智能体会话链（5,448 会话-代单元；selective 对照 2 链 × 6 代另计）的预注册实验，并以 Lean 4 机检条件定理支撑。

我们发现：决定传播机制的是架构而非模型。选择性转写产生分支衰减——Galton-Watson 分支过程，模型特定的每亲繁殖数 $\hat{m} \in [0.56, 0.98]$，呈几何律衰减（$R^2 \geq 0.92$）；扩样至 12 链后 selective 侧 $\hat{m} = 0.966$（CI $[0.911, 1.000]$），与全量追加侧 CI 完全分离。全量追加产生线性累积-容量竞争——每代写入 $w_n \in \{0, 1\}$（链均 $E[w_n] = 0.917$）使 $Z_{n+1} = Z_n + w_n$ 线性累积直至记忆容量 M，此后 FIFO 竞争达到并维持稳态（$5/16$）（工程语义的持续累积；跨机制对比传播比见 §6.1）。容量 M 是控制参量，临界容量 M_c 是 (b, M) 联合函数：良性写入率越高，临界容量越大（EXP-B 协议下 b=$1/2 \to W_c \leq 4$、b=$3 \to W_c \in (4, 8)$、b=$5 \to W_c \in (8, 12)$）。主协议档（b≈3 总写入上限、含毒株）$M_c \in (8, 16)$ 与 EXP-B b=3 行（b 为良性经验上限、毒株占额度；实测两档每代总写入同为 3.00，流量同构）在 $W = 16$ 主格点相容（稳态 5.06 vs 4.917，差异 2.9%），在 $W = 8$ 边界格点读数分裂（灭绝 vs 0.92 存活，12 链扩样后保持）——归因审计（**§6.5**）定位为 **DeepSeek-V4.1-Flash-1017** 毒株转写行为的亚小时级状态切换（同一日历日内约 32 分钟即观测到高低转写态翻转；同日双协议重跑无差异，Fisher p=0.155，10-22 原批显著偏低 p=0.0024），M_c 因而是 $(b, M,$ 毒株转写状态 $)$ 条件量：低转写态下 $M_c \in (8, 16)$（W=8 灭绝），高转写态下 W=8 存活 0.75（12 链，探针门控重扫实测）——缩小记忆窗口不能可靠防住投毒，因为同一窗口在模型的另一行为状态下失效。

防御侧：软标记效应模型异质且不可靠（Pro 档 47% 压缩在功效不足下不显著；full-append 12/12 逐代同轨为写路径结构绕过；Flash 大样本配对 $n = 48$ 确证零压缩，$\bar{d} = 0.020$，$p = 0.69$），而隔离（$\sigma = 1$）在所有条件下截断传播：跨模型 24/24、跨任务族 48/48、full-append 12/12 链；σ 扫描（$n = 48$/档）确认全谱 $\sigma_{\text{eff}} \in \{0.1, 0.25, 0.5, 0.75, 0.9, 1.0\}$ 实测（含 **2026-10-23** 补测中间档 $\sigma_{\text{eff}} \in \{0.75, 0.9\}$）：$\sigma_{\text{eff}} < 1$ 档全部存活率 1.00、无一抑制毒株（无甜点，A-H4 判据），σ=1 的记忆效用保留 0.88（代价为 12% 新经验增量，种子知识无损）。在隔离与标记之间还存在受控实证的控制律高态分支（状态反馈软调节的设计形式；实验窗探针全程判高态、动态臂零切换，跨状态切换动力学未行使，列为待测）：高转写态下窗口收缩策略（W=8 $\rightarrow$ 4）将毒株存活由 0.833 压至 0.333（12 链 vs 12 链同批对照，Fisher p=0.018；跨三窗口合并 13/32 vs 19/24，单侧 p=0.004）、记忆效用保留 0.328 $\geq$ 0.275（C2 判据），但效用代价约七成良性记忆且有效性依赖探针带宽（§7/§11.4）。我们据此得出结论：防御依赖结构手段而非参数或标记——硬隔离为不可替代主体，窗口收缩策略（高态分支实证）为受控实证的次优层。方法学上，我们预注册的分支匹配假说被逐代机制证据证伪，修订为线性累积-竞争，本文如实报告这一修订。作为副产品，归因审计暴露了一个超出原实验范围的独立发现：固定模型 **checkpoint** 的毒株转写倾向存在亚小时级的双峰状态漂移（多批对照，Fisher $p \leq 0.0024$）；我们据此提出探针校准协议——实验批启动前以约 3 分钟/链的探针判定当前毒株转写状态，跨批比较限于同状态批次——该协议本身构成可复用的方法论贡献。

关键词：无门控智能体记忆架构；记忆投毒；预注册受控实验；Lean 4 形式化验证；硬隔离；分支过程

---

1 引言

1.1 问题

LLM 智能体（agent）正被部署到长期运行的生产系统：经验沉淀进持久记忆库，经检索在跨会话任务间复用。这一架构引入了一类此前未被系统研究的失效模式——记忆投毒（**memory poisoning**）：未经验证的自生经验

（或攻击者注入的经验）进入记忆库后，经代际转写被持续复制，污染后续所有相关任务。文献已确立攻击的现实性与跨会话持久性（MemoryGraft, arXiv:2512.16962；OEP, arXiv:2605.18930），以及递归自我消费在训练期的宏观坍缩后果（Shumailov et al., *Nature* 631, 2024）。然而，记忆架构本身如何调节传播、防御为何失败、何种干预有机制层保证——这三问缺少实证与形式化的回答。

1.2 三个空白

1. 机制空白：传播究竟服从何种数学模型，取决于记忆的转写协议（选择性转写 vs 全量追加）——此前没有跨架构的对照实验；
2. 防御空白：软标记（标记门）与硬隔离（门禁）被混为一谈，没有独立判据区分二者在传播动力学上的作用；
3. 形式化空白：软件工程学科的" 根本规律"（Brooks 1987；Lehman 1980；Conway 1968）历来是经验定律，从未被形式化证明（§2.5 定位）；智能体记忆的投毒-隔离规律同样停留在启发式层面。

1.3 本工作

本工作根植的公理 **IV**（经验自免疫）主张：未经物理验证与独立审查终审的自生经验经检索复用会对后续任务产生持续性污染，其防御须依赖写入层的结构阻断（隔离）而非决策层的软信号（标记）。在此框架下，本文给出机制识别 + 形式化 + 预注册实证的完整闭环：

1. 机制层：识别" 架构决定传播机制"——选择性转写产生分支衰减（Galton-Watson 分支过程），全量追加产生线性累积-容量竞争（每代写入 $w_n \in \{0, 1\}$，链均 0.917）；记忆容量 M 为控制参量，临界 $M_c \in (8, 16)$（低转写态读数，§3/§6.5）；
2. 形式化层：Lean 4 机检定理链（零 `sorry`，§4）——GW 灭绝概率 = 最小不动点、亚临界概率灭绝、隔离压缩后代、超临界正概率不灭绝；
3. 实证层：预注册、跨模型（Pro / Kimi / Flash；全名与简称映射见 §5.2）× 跨架构（selective / full-append / 容量档）× 跨任务族（144 链）× 大样本配对（160 链）闭合判据（§5–§6）；

4. 工程含义：防御依赖隔离而非标记——标记门效应模型异质且不可靠——Pro 档 47% 压缩在功效不足下不显著、C1-full 写路径结构同轨、Flash 大样本确证零压缩（$\bar{d} = 0.020$，$p = 0.69$），隔离在跨模型（24/24 链 $Z_1 = 0$）、跨任务族（48/48 链）、跨架构（12/12 链 mem 恒 6）三维截断传播（§7）。

一项诚实的方法论声明：预注册假说 S-H3（GW 分支匹配）被逐代机制证据（$w_n \in \{0, 1\}$ 线性累积）证伪。我们将其作为" 预注册假说被证伪 → 机制重新识别" 的正面案例完整呈现（§9），而非事后合理化。

1.4 论文结构

§2 Related Work；§3 机制模型；§4 形式化；§5 实验设置；§6 结果；§7 讨论；§9 机制修正叙事；§10 适用域；§11 局限；§12 结论。

2 背景与相关工作

2.1 智能体记忆与投毒

智能体长期记忆（agentic memory）已成为 LLM 应用系统的标准组件：经验经检索（retrieval）复用，构成跨会话的持续知识层。与此同时，记忆已成为一类高价值攻击面：记忆投毒（**memory poisoning**）——攻击者或智能体自身的失效经验注入记忆库后，经后续检索被持久复用，污染后续任务（Shumailov et al., 2024；MemoryGraft, 2025）。近期实证表明，投毒攻击可跨会话持久生效，且极低污染率即可造成高攻击成功率（MemoryGraft, arXiv:2512.16962）；自进化智能体在" 局部正确但不可迁移" 经验下的污染路径亦有刻画（OEP, arXiv:2605.18930）。这些工作确立了攻击的现实性与持续性，但防御侧停留在启发式（标记、过滤、人工审查），缺乏对" 为什么某些防御失效" 的机制层解释——本工作补上这一层。

必须正面对话的竞争工作：arXiv:2605.08442（*Defense effectiveness across architectural layers*，2026-05）对 9 个模型的持久记忆攻击做了跨架构层的机制评估，结论是输入层防御无法观测 RAG 注入内容、检索层分类器可被语义

掩蔽绕过，而记忆层的硬性工具门控（Memory Sandbox）将攻击成功率降至 0/9 模型中的 8 个——与本工作 “隔离有效、软信号无效” 的防御结论高度重叠。本文的增量不是防御建议本身，而是：(i) 给出两种记忆架构（selective vs full-append）下传播的动力学两分法与容量控制参量 M_c（2605.08442 未涉及传播的数学结构）；(ii) 以预注册判据与 Lean 机检条件定理支撑隔离不变性。攻击面文献 AgentPoison（NeurIPS 2024, arXiv:2407.12784）确立了记忆/知识库投毒的攻击现实性，本文与其在攻击-防御分工上衔接。

2.2 模型坍缩与递归退化

宏观层面的递归自我消费已被证明导致模型坍缩（**model collapse**）：用递归生成的数据训练，模型分布退化为模式坍缩与方差消失（Shumailov et al., *Nature* 631, 2024）。其与分支过程（branching process）的联系在文献中已有提及：退化可刻画为种群动态（population dynamics）。本工作的理论工具——Galton-Watson 分支过程及其灭绝概率、几何衰减律（Harris, 1963）——正是这一联系的形式化端点之一。与 Shumailov 等的训练期坍缩不同，本工作关注推理期/记忆期的传播：不经过重训练，仅在上下文-记忆-转写回路中逐代传播。这一区分是本文机制的出发点。

2.3 针对记忆投毒的防御

既有防御沿两条思路：

1. 软标记（**soft marking**）：对自生经验打上” 未验证” 标记，供下游过滤（实验中的标记名 DRAFT_SUSPECT，§5.3）。本工作标记门效应模型异质：Pro 主实验 47% 压缩（C1/C0 比值 0.529）在功效不足（$n = 12$，功效 0.38）下不显著；SUPERCRITICAL C1-full 12/12 逐代同轨（full-append 写路径结构绕过模型判断）；H1AC 大样本配对（$\bar{d} = 0.020$，$p = 0.69$）确证 Flash 档零压缩（模型档全名见 §5.2）——模型对软信号的采纳不可靠；
2. 硬隔离（**hard quarantine**）：未经五重物理判据与独立审查终审的经验不得进入全局知识库（等价于本工作的门禁 $\sigma = 1$）。五重物理判据指编译、隐藏测试、真实执行探活、退出码核验、形式化审计五条独立

物理通道全部绿灯方可晋升——LLM 自评不构成证据；独立审查终审指与经验生产者物理隔离的仲裁门，不接受自然语言辩解。本工作实测：隔离在跨模型（**24/24** 链 $Z_1 = 0$）、跨任务族（**48/48** 链）、跨架构（**full-append 12/12** 链 **mem** 恒 **6**）三个维度上截断传播——防御依赖结构阻断而非模型行为。

这一 “隔离有效、标记失效” 的分离，与 2605.08442 的 “硬工具门控有效、软信号无效” 结论方向一致，本文在其上补充了传播动力学机制与容量控制参量（§2.1 对话段）；MemoryGraft（2025）的防御讨论未区分二者。

2.4 智能体的通用退化机制

- **Reward hacking / specification gaming**：智能体满足目标的字面而非精神以骗取成功信号（Amodei et al., 2016；Krakovna et al., 2020）；生产级 RL 中已观察到自然涌现的失对齐（Anthropic, arXiv:2511.18397）。这与本文公理 I（外部锚定缺失 → 自我宣称不可信）同族，但未涉及代际传播。
- **Context rot / Lost in the Middle**：随无关上下文增长，模型有效推理显著衰减，呈现 U 型注意力曲线（Liu et al., TACL 2024）；有效上下文长度远低于标称（Hsieh et al., 2024, RULER；Chroma, 2024）。这对应公理 II（注意力稀释），是代内退化；本文公理 IV 关注代际传播，两者在因果链上衔接但机制不同。

2.5 软件工程的**”** 近公理**”** 定律

软件工程学科的传统” 根本规律” 是经验定律而非形式公理：Brooks 的本质复杂性（Brooks, 1987）界定了工程极限；Lehman 定律（Lehman, 1980）刻画软件演化的持续变更与递增复杂性（软件的” 熵增”）；Conway 定律（Conway, 1968）揭示架构-组织同构；CAP 定理（Gilbert & Lynch, 2002）锁定分布式一致性的取舍；停机问题（Turing, 1936）界定可判定性边界。这些规律源自大量工程实践的经验总结，从未被形式化证明。

本工作的方法论立场：SE 的” 近公理” 规律可以且应当提升为推理起点地位

+ 经验可证伪内容的工程公理。本文聚焦其中一支——经验自免疫——给出：Lean 4 机检的条件定理链（隔离 □ 灭绝、GW 灭绝概率、几何律、超临界发散）、预注册的大样本实证、以及机制层修正（分支衰减 vs 累积-竞争）。这是把 SE 经验定律 “形式化-实测化推进” 的一次实例，而非凭空提出公设。需要限定的是：被机检的是概率论条件定理（Harris, 1963 结果的 Lean 复检），SE 定律的 “工程公理化” 是方法论主张而非形式化对象——本文不声称已形式化 Brooks/Lehman/Conway 定律本身。

2.6 形式化验证工具

定理链在 **Lean 4**（Moura & Ullrich, 2021）中机检，零 `sorry`（条件定理与源码对应见 §4）。软件工程中形式化验证的应用先例（协议验证、并发正确性）支撑了” 工程承诺以可机检定理呈现” 的可行性；本文的贡献之一是此类条件定理（“对满足分支性与乘性压缩的系统，隔离使投毒谱系灭绝概率趋向 1”）在智能体记忆安全问题上的应用——就我们所知，这是该类型条件定理在该问题域的首次应用（限定于 §9 机制修正后的适用域）。

3 模型

3.1 记号

符号	含义	实测/设定
Z_n	第 n 代记忆库中毒株（P1 谱系）条目数（池大小）	逐代追踪
M	记忆窗口容量（FIFO）	默认 16；敏感性档 $M = 8, 32$
w_n	第 n 代新写入的毒株条目数（fresh write）	selective：随 Z_n 变化；full-append：$\in \{0, 1\}$（PMF=[0,1]，链均 $E[w_n] = 0.917$）
X_i	分支过程的单亲后代数	$E[X] = \hat{m}$（经验估计）

符号	含义	实测/设定
σ	门禁拦截率（写出通过率 $= 1 - \sigma$）	随机过滤 $\sigma = 0.5$（半数拦截）；隔离 $\sigma = 1$（全拦截）
$\hat{m}$	传播比估计 $\hat{m} = \sum_n Z_{n+1} / \sum_n Z_n$（跨代加权平均；GW“每亲繁殖数” 语义仅对机制 A 有效，见 §3.2）	见各实验档

符号纪律：M 为记忆容量（实验档名 `_W8/_W32` 中的窗口参数），w_n 为每代写入——两者在本文中严格区分。

3.2 两个传播机制

机制 **A**：分支衰减（**selective** 转写协议）。智能体仅将当前会话中被判定相关的条目转写进记忆，后代数依赖亲代毒株的转写倾向：

$$Z_{n+1} = \sum_{i=1}^{Z_n} X_i, \qquad E[Z_{n+1} \mid Z_n] = \hat{m}\, Z_n$$

经典 Galton-Watson 分支过程（Harris, 1963）：期望传播按几何律 $E[Z_n] = \hat{m}^n E[Z_0]$ 演化；灭绝概率为生成函数 $\varphi(s)$ 的最小不动点（Lean T1）；亚临界（$\hat{m} < 1$）指数衰减（Lean T2）。该机制的判据：w_n 随 Z_n 变化（分支依赖）。

机制 **B**：线性累积-容量竞争（**full-append** 转写协议）。智能体将每代经验全量追加进记忆库（向量库直写/无转写衰减），毒株写入恒定：

$$Z_{n+1} = Z_n + w_n, \qquad w_n \in \{0, 1\} \text{ (实测, PMF=[0,1])}$$

未饱和段线性增长 $Z_{n+1} = Z_n + 1$；当 Z_n 触及容量 M 后进入 FIFO 竞争稳态（新写条目挤占最旧条目），稳态池大小由容量竞争决定（实测 C0-full 稳

态 5/16）。该机制的判据：w_n 恒定、不依赖 Z_n（累积写入）。

机制判别的直接证据（逐代 **offspring** 核对）：full-append 档每代新写 P1 为 0 或 1（$w_n \in \{0,1\}$，PMF=[0,1]，链均 $E[w_n] = 0.917$——11/12 链每代恒 1，约 1/12 链存在某代未写；$Z_{n+1} = Z_n + w_n$ 线性累积，实测 Z=[1,2,2.917,3.917,3.917,4.917,4.917,4.917]；分支过程要求的" 后代数依赖亲代种群" 不成立。由此，预注册假说 **S-H3**（**GW** 匹配）被机制证据证伪，理论修订为机制 **B**（见 §9 机制修正叙事）。分支衰减（机制 A）仍在 selective 协议下成立（几何律 $R^2 = 0.958$，主实验；$R^2 = 0.923$，H1AC 大样本）。

3.3 容量控制参量

记忆窗口容量 M 决定机制 B 的传播结局（SUPERCRITICAL 档，full-append，Flash）：

M	传播比 $\hat{m}^{\dagger}$（boot95 CI）	g7 存活率	结局
8	0.829（[0.739, 0.875]）	0	灭绝（写入侧即被容量压制）
16	1.166（[1.156, 1.176]）	1.0	持续累积（稳态 5/16 维持 3 代；工程语义超临界）
32	1.25（退化 CI，6 链全同）	1.0	线性增长（$Z = [1, \ldots, 8]$，未饱和）

临界容量是 (b, M) 联合函数（**EXP-B** 实测，**§6.5**）：容量单调性成立——$M \leq M_c$ 时毒株池被压制至灭绝，$M > M_c$ 时单调累积不灭绝。M_c 随良性写入率 b 上移（EXP-B 协议下 b=1/2 时 $W_c \leq 4$、b=3 时 $W_c \in (4, 8)$、b=5 时 $W_c \in (8, 12)$）。跨实验格点核对：主协议档（写入规则"1~3 条"，b≈3 总写入上限、含毒株，`axiom4_memory_propagation.py` 执行）$M_c \in (8, 16)$ 与 EXP-B b=3 行（`kimi_boost.py` 执行；b 为良性经验上限、毒株占额度；

实测两档每代总写入同为 3.00，流量同构）在 $W = 16$ 主格点相容（EXP-A C0 6 代 $Z = 5.06$ vs 主协议同代 4.917，差异 2.9%），但在 $W = 8$ 边界格点读数分裂（主协议 6 链全灭 surv=0 vs EXP-B 12 链 surv=0.92，扩样后保持）——归因审计（**§6.5**）定位为 **DeepSeek-V4.1-Flash-1017** 毒株转写行为的亚小时级状态切换（同一日历日内约 32 分钟观测到高低态翻转；同日双协议重跑无差异 Fisher p=0.155，10-22 原批显著偏低 p=0.0024，非协议差异），M_c 因而是 $(b, M,$ 毒株转写状态 $)$ 条件量：低转写态下 $M_c \in (8, 16)$、W=8 灭绝，高转写态下 W=8 存活过半（§11.4 探针校准协议）；两读数各自批内可复现，以并列读数如实报告（§6.5）；b 与检索策略均可使 M_c 漂移（§10/§11 开放项）。M 因此是传播的控制参量（而非模型参数）。

3.4 架构决定机制

同一模型族（Flash）下切换记忆架构即切换机制：

架构	机制	$\hat{m}$ / 传播	判据
selective 转写	分支衰减（A）	$\hat{m} \in [0.56, 0.98]$（跨模型，模型特定）	w_n 依赖 Z_n；几何律成立
full-append	累积-竞争（B）	Z 线性累积，容量 M 定结局	$w_n \in \{0, 1\}$；$M_c \in (8, 16)$（低转写态读数；高转写态下 W=8 存活过半，§6.5）

变量是架构，不是模型：同一 Flash 档，selective 对照（2 链，主实验；扩样 **12** 链，**EXP-C**）Z 恒 1、记忆收缩至 3（临界边界 $\hat{m} = 1.0$；扩样后 $\hat{m} = 0.966$、CI $[0.911, 1.000]$ 含 1，弱亚临界/临界保持统计成立），full-append C0（12 链）Z 线性累积至 5/16（工程语义超临界，$\hat{m} = 1.166$、CI $[1.156, 1.176]$）——两架构 $\hat{m}$ 的 CI 完全分离，分叉完全由转写协议决定。这一结论与公理 IV 适用域口径一致：无门禁下 $\hat{m}$ 是模型-任务-位点联合参数（$[0.29, 1.00]$，跨模型 $[0.56, 0.98]$），但机制类别由架构决定，不随模型迁移。

3.5 预注册假说清单

本节假说的实验执行见 §5，判读结果见 §6。

假说	命题	判据
S-H1	full-append 无门禁下毒株持续累积（稳态占据率 >0 且存活率 1.0）	占据率/存活率（GW 表述随 S-H3 证伪失效）
S-H2	未饱和段存活率 1.0	g7 存活率
S-H3	GW 分支匹配（w_n 随 Z_n 变化；$\rightarrow$ 被机制证据证伪，实测 $w_n \in \{0,1\}$，修订为机制 **B**）	逐代 w_n 核对
S-H4	隔离跨机制截断累积	C3-full 12/12
B-H1a	标记门压缩配对差 >0（$\rightarrow$ 不成立）	符号翻转置换 $p<0.05$
B-H1c	乘性压缩律 $\hat{r}_{C2}/\hat{r}_{C0} \in [0.35, 0.65]$ 且 CI 完全落入	点 +CI 双判据
B-H2	大样本几何律复验 $R^2 \geq 0.8$	log-linear
X-H1/X-H4	跨模型隔离保证；防御不依赖模型	24/24 链 $Z_1 = 0$
T-H1/T-H4	跨任务族隔离保证；毒株传播受任务族调节	48/48 链；配对 $p<0.05$

图 *1* 两种传播机制：*A*）选择性转写下的分支衰减（*Galton-Watson* 分支过程、几何律，灭绝概率 = 最小不动点）；*B*）全量追加下的线性累积-容量竞争（每代写入 $w_n \in \{0,1\}$、链均 $E[w_n] = 0.917$，容量 M 处 *FIFO* 竞争，临界 $M_c \in (8,16)$（低转写态读数））。（数据：DeepSeek-V4.1-Flash-1017，链均）

无门控智能体记忆架构中的记忆投毒:架构依赖的传播机制、容量控制与隔离不变性12

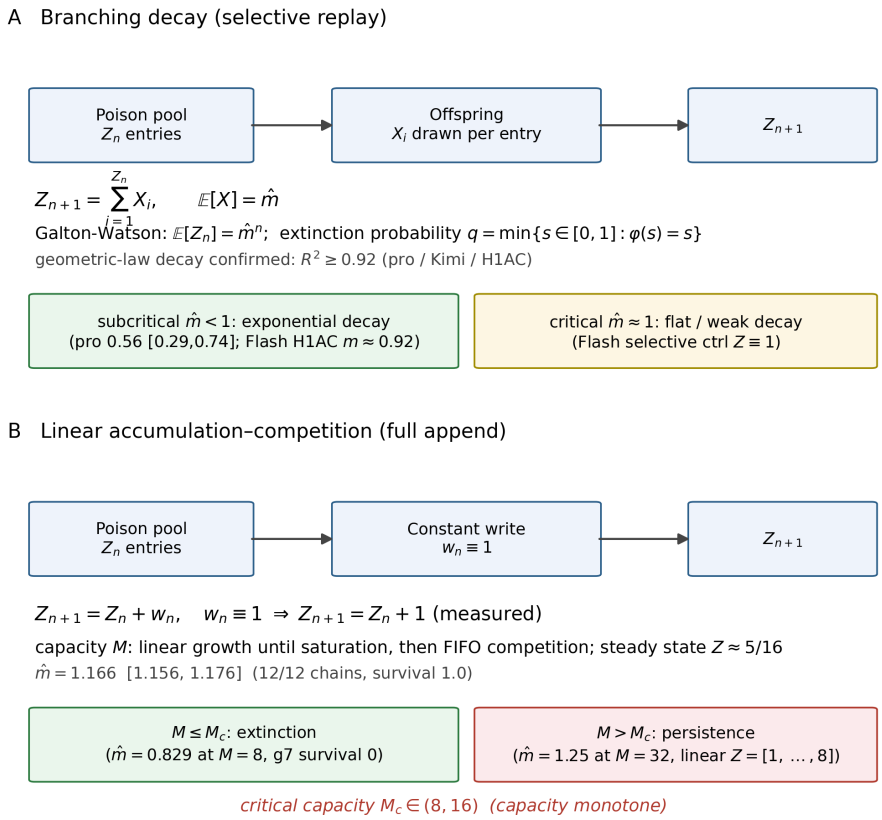


图 1: 机制示意：分支衰减（选择性转写）与线性累积-容量竞争（全量追加）

4 形式化

4.1 模型结构

传播模型为分支过程（`BranchingProcess` 结构，每代一个有限支撑 PMF）：未终审经验的跨代传播中，双盲隔离门禁的选择度 σ 将名义繁殖均值 μ 压缩为有效繁殖数

$$m = \mu(1-\sigma) \quad \text{(乘性压缩律)}$$

所有定理以条件定理呈现：结构前提（如 $m < 1$）为显式假设，“真实系统满足该前提” 由 §5–§6 实测支撑，不在形式系统内断言。这一分工即本文采用的三层知识地位结构：定理层（Lean 机检的结构蕴含）、经验层（$\hat{m}$、M_c、σ 等参数的预注册实测）、工程层（生产判据的部署裁决）；数值与定理互不冒充。σ 的口径与 §3.1 一致（拦截率，写出通过率 $= 1-\sigma$）；EXP-A 的随机过滤档以放行率 $r = 1-\sigma$ 实现（表 5 标注，§6.5）。

4.2 定理链

本节定理链全部由 Lean 4 机器验证（零 `sorry`）。形式化源码：`formal_proof/IACFormalization`（本仓库 commit `4825137`；Lean 4，mathlib 版本见 `lakefile.lean`）。仓库目前保持私有：commit hash 可据此核对文件树与构建记录，完整源码按需向作者索取。

T1 期望几何律（`expected_population_geometric`，归纳证明）：$E[Z_n] = m^n E[Z_0]$。

T2 亚临界概率灭绝（`subcritical_extinction_in_probability`）：由 Markov 不等式与几何衰减，$m < 1$ 时存活概率 $P(Z_n \geq 1) \to 0$。这是隔离晋升门禁有效性的定量核心：门禁把 m 压到 < 1，长期存活概率 $P(Z_n \geq 1) \to 0$（依概率收敛）——应用侧措辞严格为 “存活概率趋向 0”，而非 “以概率 1 消亡”。

T3 隔离压缩后代（`quarantine_compresses_offspring`）：σ 越严格，有效繁殖数越小；完全隔离（$\sigma = 1$）使 $m = 0$，谱系单代内归零。应用条件：分支性 + 乘性压缩——在 selective 架构下实测满足（几何律 $R^2 = 0.958$）；在 full-append 架构下分支前提不成立，隔离的有效性由实测直接给出（C3-full 12/12，mem 恒 6、Z 恒 1），机制修正记录在案（§9）。

T4 超临界不灭绝（`galton_watson_non_extinction` + `supercritical_expectation_diverges`）：$m > 1$ 时，灭绝概率为生成函数 φ 在 $[0,1]$ 上的最小不动点 $q = \min\{s \in [0,1] : \varphi(s) = s\} < 1$——以正概率永不灭绝；期望 $E[Z_n] \to +\infty$。证明采用初等生成函数不动点分析（单调夹逼 + 多项式截断），避免对 φ 连续性的依赖。

4.3 定理-应用映射

定理	断言	应用侧
T1	$E[Z_n] = m^n E[Z_0]$	几何律判据（S-H2/B-H2 的期望侧）
T2	$m < 1 \Rightarrow P(Z_n \geq 1) \to 0$	隔离/随机过滤压灭谱系（C2 存活率 0.062 vs C0 0.750）
T3	$\sigma\uparrow \Rightarrow m\downarrow$；$\sigma = 1 \Rightarrow m = 0$	隔离不变性（S-H4/T-H1/X-H1）
T4	$m > 1 \Rightarrow q < 1$，$E[Z_n] \to +\infty$	机制 A 超临界侧对照；机制 B 的持续累积由实测占据率给出（工程语义）

4.5 机制 **B** 稳态占据率

本节命题为普通数学推导，未经 Lean 机器验证。命题（机制 **B** 稳态占据率）：full-append 架构、FIFO 容量 M、每代良性写入 b 条、毒株写入链均 $\bar{w}$

（$0 < \bar{w} \leq 1$）时，在" 毒株条目在容量内均匀混合" 的近似下，稳态毒株占据为

$$Z^* = \frac{M\,\bar{w}}{b + \bar{w}}$$

证明：每代写入总量期望 $b+\bar{w}$ 条（毒株 $\bar{w}$ 条）；FIFO 每代挤出等量最旧条目。若毒株均匀分布于 M 槽位，则每代被挤出的毒株数期望为 $(b + \bar{w}) \cdot Z/M$。稳态要求流入等于流出：$(b + \bar{w}) \cdot Z^*/M = \bar{w}$，即 $Z^* = M\bar{w}/(b + \bar{w})$。■

实测验证：C0-full（$b = 2$、$\bar{w} = 0.917$、$M = 16$）预测 $Z^* = 16{\times}0.917/2.917 = 5.03$，实测稳态 4.917（g5–g7 稳定），相对偏差 2.3%。

限定：均匀混合为近似——FIFO 下毒株条目位置分布非均匀且存在代际相关性，精确解依赖具体写入序列；本文以该闭式作为机制 B 的内生稳态描述量（取代 GW 参数的机制内生化，§9）。

4.6 形式化的边界

机制 A 的 $\hat{m}$、M_c、σ 的数值为经验/工程层参数，不入形式化接口（机制 B 无 GW 语义的 $\hat{m}$，其传播比估计见 §6.1 表注）；形式化保证的是结构蕴含（若前提成立则结论必真），数值由预注册实测估计。这一分工避免了两类错误：把经验常数当定理、把定理当经验常数。

5 实验设置

5.1 预注册原则

全部判据先于实验固定（假说清单见 §3.5）：显著性门槛（$p < 0.05$ 置换/单侧）、判读单位（链均 vs 池化，见 5.5）、方向性命题一律预先声明。实验计划文档随判读产物存档（`EXPERIMENT_PLAN_AXIOM4_SUPERCRITICAL.md`、`EXPERIMENT_PLAN_AXIOM4_H1AC_BOOST.md`），任何口径修订在 §11 记录在案（如 H1AC 池化口径失效）。

5.2 模型档

档	模型	用途
主实验	**DeepSeek-V4-Pro-0813**（简称 Pro；采样温度 temperature 0.7）	selective 协议，4 条件 × 12 会话 × 6 代 = 288 会话
跨模型	Kimi `kimi-for-coding` + 同 Pro 协议	X-H1/X-H4，288 会话
SUPERCRITICAL	**DeepSeek-V4.1-Flash-1017**（简称 Flash）	full-append/容量档/selective 对照（与预注册模型档的偏离已在计划 §10 记录）
H1AC	同 Flash	160 链双毒株大样本
COMPLEMENT-EXP	同 Flash	隔离代价 σ 扫描（EXP-A 240）/ $b \times M$ 容量曲面（EXP-B 144）/ selective 扩样 n=12（EXP-C）

5.3 传播协议

- 毒株规范注入：第 0 代注入 1 条携带谱系标记（P1/P2）的种子经验；逐代转写（selective：仅被判定相关者转写；full-append：全量追加）；
- 谱系追踪：每条记忆条目携带 lineage 标记，Z_n= 第 n 代毒株谱系条目数（判读单位）；
- 双盲过滤（**DRAFT_SUSPECT**）：标记门条件（C1）对疑似条目打标但不阻断；隔离门禁（C3/C2）物理阻断未终审条目（即未通过五重物理判据与独立审查终审的条目，定义见 §2.3）。

5.4 条件矩阵

- **selective**：C0（无门禁）/ C1（标记门）/ C2（随机过滤 $\sigma = 0.5$）/ C3（隔离 $\sigma = 1$）；
- **full-append**：C0-full / C1-full / C3-full（各 12 会话 × 8 代）；容量档 $M = 8$ / $M = 32$（各 6 会话 × 8 代）；selective 对照（2 会话 × 6 代）；
- **H1AC**（**Flash** 双毒株）：C0（48）/ C1（48）/ C2（64），6 代。

合计 **846** 条智能体会话链（= 主实验 48 + 跨模型 48 + 跨任务族 144 + SUPERCRITICAL 50 + H1AC 160 + COMPLEMENT-EXP 396；会话-代单元口径合计 5,448 = 288 + 288 + 864 + 384 + 960 + 2,664；selective 对照 2 链 × 6 代 = 12 单元，不在合计内、另计）。其中 SUPERCRITICAL 50 链 = 3 条件 × 12 链 × 8 代（C0/C1/C3-full）+ 敏感性 2 档 × 6 链 × 8 代（W=8/32）；H1AC 160 链 = C0 48 + C1 48 + C2 64，× 6 代；跨任务族 144 链 × 6 代；COMPLEMENT-EXP 396 链 = EXP-A 240（σ 扫描 5 档 × 48 链，× 6 代）+ EXP-B 144（$b \times M$ 曲面 24 档 × 6 链，× 8 代）+ EXP-C 12（selective 扩样，× 6 代），判读脚本 `kimi_boost_judge.py` 可复算。时间线：DeepSeek-V4.1-Flash-1017 于 2026-10-17 发布，SUPERCRITICAL 与 H1AC 全部实验于发布后 5 日内（2026-10-22）完成执行与判读，COMPLEMENT-EXP 三实验于发布后 6 日内（2026-10-23）完成执行与判读（各批次运行时间戳见附录 A）。

5.5 判读口径

- bootstrap CI（10^4 重采样）估计 $\hat{m}$ 及比值 CI；符号翻转配对置换（10^4）检验标记门配对差；
- 链均 **vs** 池化：传播实验的判读单位取链均（per-parent 池化在 C2 下因幸存者偏差失效——末代存活率仅 6%，池化比值 1.017 无意义；已在计划 §10 记录并改用链均）；
- 几何律复验：log-linear 拟合 R^2；
- 功效（Pro 档标记门）：配对差 $d = 0.167$、$sd = 0.432$、C1/C0 比值 0.529 → 当前 $n = 12$ 功效仅 0.38，达 0.8 需 $n \approx 48$（`e_power_markgate.py/.json`）——H1AC 档以 48 配对补齐该缺口。

5.6 可复现性

- 判读脚本:`e_supercritical_judge.py/judge2.py/sh3.py`、`e_cross_task_judge.py`、`e_h1ac_judge.py`（全部入 git）;
- 原始会话：`axiom4_results_*.json`（SUPERCRITICAL/H1AC/跨模型/跨任务族全套入 git）;
- 环境：模型档固定、采样温度 0.7、采样参数随会话归档。

6 结果

6.1 机制与容量

本节数据来自 SUPERCRITICAL 档（Flash，full-append 转写）。**S-H1** 机制 **B** 判据 □（**GW** 表述已失效）：S-H1 的 GW 表述（$\hat{m} > 1$ 且 CI 下限 > 1）随 S-H3 证伪而失效——对确定性线性累积过程，任何增长型统计量必 > 1，该判据在机制 B 下设计上不可能失败（§9）。机制 B 的内生判据为：持续累积（未饱和段线性增长，饱和后稳态 $5/16$ 维持 3 代）+ 存活率 **1.0**，二者均满足。Z 轨迹 $[1, 2, 2.917, 3.917, 3.917, 4.917, 4.917, 4.917]$：g0–g3 线性累积，g4 触及容量（mem 6→16），g5–g7 FIFO 稳态 4.917。跨机制对比的传播比 $\hat{m}^{\dagger} = 1.166$（[1.156,1.176]；估计器 $\hat{m} = \sum Z_{n+1} / \sum Z_n$，§3.1；GW“每亲繁殖数” 语义仅机制 A 有效）。

S-H2 存活率 □：g7 存活率 1.0（12/12 链无灭绝）。

S-H3 GW 匹配 □（被机制证据证伪）：逐代 offspring 核对——每代新写 P1 为 0 或 1（$w_n \in \{0, 1\}$，PMF=[0,1]，链均 $E[w_n] = 0.917$，11/12 链每代恒 1、约 1/12 链存在某代未写），且写入不依赖 Z_n——分支过程要求的 “后代数依赖亲代种群” 不成立。机制 B（线性累积-容量竞争）取代 GW 匹配；修订叙事见 **§9**。

S-H4 隔离不变性 □：C3-full 12/12 链 mem 恒 6、Z 恒 1——隔离在 full-append 架构下同样截断传播（即使分支前提不成立）。

容量控制参量：$M = 8$ 时传播比 $\hat{m}^{\dagger} = 0.829$（$[0.739, 0.875]$），g7 存活率 0（灭绝）；$M = 32$ 时 $\hat{m}^{\dagger} = 1.25$（退化 CI，6 链全同），$Z = [1, \ldots, 8]$ 线性增

长未饱和。临界 $M_c \in (8, 16)$（本协议档，$b = 3$，低转写态读数——探针门控重扫实测高转写态下 W=8 存活 0.75、$M_c \in (4, 8)$，§6.5），容量单调性成立；补充实验 EXP-B 证实 M_c 是 (b, M) 联合函数（§6.5）。

selective 对照（**Flash**）：主实验 2 链 Z 恒 1、记忆收缩至 3（$\hat{m} = 1.0$ 临界边界；H1AC 大样本 48 链 $m \approx 0.92$ 支持弱亚临界）——同一模型档下与 C0-full 构成架构分叉（§3.4）。补充实验 **EXP-C**（**n=12，2026-10-23**）：$\hat{m} = 0.966$（boot95 CI $[0.911, 1.000]$，含 1）、几何律 $R^2 = 0.833$、Z 均值 $[1, 1, 1, 0.917, 0.917, 0.833]$、最终代存活 0.83——与 **C0-full**（$\hat{m} = 1.166$，**CI** $[1.156, 1.176]$）两 **CI** 完全分离，selective 亚临界/临界保持在 n=12 下统计成立，架构分叉承重墙由 2 链扩至 12 链（C-H1/C-H2 □）。

6.2 标记门与乘性律

本节数据来自 H1AC 档（Flash，160 链）。**B-H1a** 标记门压缩 □：配对（C0 vs C1，48 对）差值 $\bar{d} = +0.020$（均值被少数大差对拉动；正差仅 15/48，配对层面多数反预期）、符号翻转置换 $p = 0.69$——**Flash** 档零压缩。三档证据分层：Pro 主实验为功效不足下的大效应不显著（$p = 0.15$，C1/C0 比值 0.529、压缩 47%，功效 0.38，不可判读为零压缩）→ SUPERCRITICAL C1-full 12/12 逐代同轨（full-append 写路径结构绕过模型判断，非软信号独立证据）→ H1AC 大样本配对确证零压缩。功效侧：H1AC 的 $n = 48$ 已达 Pro 档功效分析所需样本（功效 0.848），排除" 功效不足" 解释。

B-H1c 乘性压缩律（部分）：链均写入率比 $\hat{r} = \mu_{C2}/\mu_{C0} = 0.422/0.905 = 0.466 \in [0.35, 0.65]$（乘性预测 0.5 吻合）；bootstrap CI $[0.333, 0.602]$——下界微出目标带 0.017。判据定义（点估计 +CI 双判据）：点估计 □、CI □ 。存活率佐证：C2 末代 0.062 vs C0 0.750——随机过滤真实压低传播。

B-H2 几何律复验 □：C0/C1 的 $\log Z$ 对代际线性拟合 $R^2 = 0.923$、$m \approx 0.92$（Flash selective 临界/弱亚临界，与主实验 $R^2 = 0.958$ 一致）。

P2 事件倍增未达成：$\mu_{P2} \approx 0.001$（250 vs 1 条）——双毒株设计的第二事件通道未被模型采纳（记录在案，§11）。

6.3 跨模型

跨模型实验共 288 会话（selective 转写）。**X-H1/X-H4** □：无门禁下 $\hat{m}$ 模型特定（Pro 0.560 [0.294,0.735]、Kimi 0.983 [0.944,1.000]、Flash 1.0 临界；转写衰减倾向异质，全名见 §5.2），但隔离保证跨模型成立（24/24 链 $Z_1 = 0$）——防御不依赖模型行为。判读汇总见 §6.6 表 3。

6.4 跨任务族

跨任务族实验共 144 链（selective 转写）。隔离 48/48 链灭绝（T-H1 □）；毒株传播受任务族调节（T-H4 配对 $p = 0.026$ □）；无门禁 $\hat{m}$ 为模型-任务-位点联合参数（跨任务族区间 $[0.29, 1.00]$）——跨族不可迁移是实测结论而非缺陷（§10）。

6.5 隔离代价与容量曲面

本节为补充实验（Flash，共 396 链）。**EXP-A** 隔离代价（**σ** 扫描 × **48** 链，**full-append W=16**，**6** 代；**σ** 语义见表 **5** 标注：**A50/A75/A90/A25/A10** 档放行率 $r = 0.5/0.75/0.9/0.25/0.1$，等价拦截率 $\sigma_{\text{eff}} = 0.5/0.25/0.1/0.75/0.9$；**A100** 隔离档 $\sigma_{\text{eff}} = 1$）：A100（硬隔离）Z 最终代恒 1、记忆不增长（mem_growth=0.00，n=48）——硬隔离阻断一切未终审写入，累积传播零出现（**A-H1** □，按**"**无累积传播**"** 口径，同 **§9.3 S-H4** 先例）；$\sigma_{\text{eff}} = 0.1$（A90）抑制不足（$Z_f = 4.60$，传播仍在）。甜点补测（**2026-10-23**，**A25/A10** 两档各 **48** 链，**KIMI** 三轮 **N3** 作业）：A25（$\sigma_{\text{eff}} = 0.75$）$Z_f = 2.00$、存活率 **1.00**、效用保留 1.12；A10（$\sigma_{\text{eff}} = 0.9$）$Z_f = 1.60$、存活率 **1.00**、效用保留 0.96——全谱 $\sigma_{\text{eff}} \in \{0.1, 0.25, 0.5, 0.75, 0.9\}$ 无一档存活率 **<0.1**（全部 **1.00**），**A-H4** 判据：无甜点；拦截率越高毒株累积越低（Z_f 单调下降），但只要放行率非零，毒株就不灭绝（线性累积 w_n 均值仍正），仅硬隔离（$\sigma_{\text{eff}} = 1$）根除。代价侧：良性通过率实测 0.488/0.754/0.908/0.262/0.094/0.000 = 放行率 r（$= 1 - \sigma_{\text{eff}}$，无差别随机过滤，A-H2 □），隔离档的记忆效用保留 0.88（相对 C0 良性存量 -12%，全部为新经验增量损失，种子基线 6 条无损）。容量竞争的意外发现：拦截率中档（$\sigma_{\text{eff}} = 0.5/0.25/0.1$）的良性存量反高于无门禁 **C0**

（效用保留 1.33/1.31/1.19）——过滤门压制毒株后，良性条目在 FIFO 中获得更大份额，误拦（σ_{eff}）被份额补偿抵消。二维代价-收益结论（已测全谱 $\sigma_{\text{eff}} \in \{0.1, 0.25, 0.5, 0.75, 0.9, 1.0\}$）：不存在同时抑制毒株且保留新经验增量的档——硬隔离（$\sigma_{\text{eff}} = 1$）收益达标但 **-12%** 增量，$\sigma_{\text{eff}} < 1$ 保留增量但毒株超临界（存活率 **1.00**）。

EXP-B 容量曲面（$b \times M$，**24** 档 × **6** 链，**8** 代）：临界容量 $W_c(b)$ 随良性写入率 b 上移——$b = 1/2$ 时 $W_c \leq 4$，$b = 3$ 时 $W_c \in (4, 8)$，$b = 5$ 时 $W_c \in (8, 12)$（漂移跨度 ≥2 档，B-H2 □）→ M_c 是 (b, M) 联合函数（§6.1 的" 当前协议下 $M_c \in (8, 16)$"为 $b = 3$ 档实例）。机制解读：良性写入与毒株竞争 FIFO 容量——$b = 5, W = 4$ 时毒株灭绝（Z 末代 0、$\hat{m} = 0.143$），高 b + 低 M 是容量竞争的天然亚临界。非单调异常记录在案：$b = 2, W = 4$ 存活率 1.00（高于 $b = 1$ 的 0.50），6 链强随机性下保留不解释。

W=8 分裂归因（**KIMI** 三轮作业 **2** 重跑对照，**2026-10-23**）：原分裂 = 主协议（10-22）W=8 6/6 全灭 vs EXP-B（10-23）b=3, W=8 12 链存活 0.92。静态逐行审计两脚本 b=3 档：提示文本、FIFO 实现、门禁（无）、任务序列、种子记忆逐字一致——diff 为空。同日重跑（同一脚本、同协议、同 rep 序号、scnet-flash）：

批次	日期	n	存活率	毒株写入/链（8 代合计）	Fisher p（vs 10-22 主协议）
主协议 W=8 原批	10-22	6	**0.000**	2.00	—
主协议 W=8 重跑	10-23	12	0.583	5.33	**0.038**
EXP-B b=3‖W8 原批	10-23	12	0.917	6.75	0.0004

EXP-B b=3‖W8 重跑	10-23	12	0.583	5.00	**0.038**

归因：存活率与毒株转写率完全单调对应（avg_pw 2.00 → 存活 0；5.0–6.75 → 存活 0.58–0.92），毒株转写率是 $W=8$ 存活的唯一驱动因子；同日两脚本（主协议重跑 vs EXP-B 原批/重跑）无显著差异（Fisher $p=0.155$），10-22 主协议批次显著偏低（vs 全部 10-23 数据 $n=36$，$p=0.0024$）。**"**$W=8$ 跨协议分裂**"** 不成立——分裂的真实来源是 **DeepSeek-V4.1-Flash-1017** 毒株转写行为的亚小时级状态切换（10-22 15:30 C0-full 高转写态 0.917/代 vs 16:02 $W=8$ 原批低转写态 0.25/代，同一日历日内约 32 分钟翻转，附录 A 时间戳；同日双脚本重跑无差异 $p=0.155$ 排除协议因素），主协议 $W=8$ 6/6 全灭是低转写态下的读数而非结构性临界；M_c 绝对读数标记为状态敏感（低转写态下 $M_c \in (8, 16)$、$W=8$ 灭绝；高转写态下 $W=8$ 存活过半、$M_c < 8$——$M_c = (b, M,$ 毒株转写状态 $)$ 条件量；同批内相对比较——EXP-B 24 档曲面、SUPERCRITICAL 档内——不受影响）。漂移区间已量化（四批毒株写入 2.00–6.75/链、存活率 0–0.92，§11.4）；残余开放项收窄为毒株转写率的批次预测模型未建立（§11.4）。

状态条件量实测（探针门控重扫，**2026-10-23 19:0x**）：按预注册判据（计划 §1.2e 预先固定：高转写态下 $W=8$ 存活率 ≥ 0.5 □ M_c 改述为状态条件量），先以 2 条状态探针判定当前毒株转写态（18:48–18:51，C0-full W16 6 代，$p_{\text{probe}}=1.000$ 高转写态），随后在同一协议（`axiom4_memory_propagation.py` full_append C0 6 代，与主实验逐字一致）下重跑 $W \in \{4, 8, 12\}$ 各 12 链：

档（高转写态）	n	存活率	毒株写入/链	vs 低态原批
$W=4$	12	0.417（5/12）	3.50	低态无对照档
$W=8$	12	**0.750**（**9/12**）	4.42	低态 0.000（0/6），Fisher 双侧 $p=0.009$

档（高转写态）	n	存活率	毒株写入/链	vs 低态原批
W=12	12	**1.000**（**12/12**）	6.00	低态 1.000（SUPER-CRITICAL W16 持续）

判据满足：高转写态下 W=8 存活率 0.750 $\geq$ 0.5——M_c 状态条件量实证成立：高转写态 $M_c \in (4, 8)$（W=4 0.417 <0.5、W=8 0.750 ≥0.5），低转写态 $M_c \in (8, 16)$（W=8 灭绝）。同一记忆窗口 W=8 在低转写态下灭绝、高转写态下存活过半——**"**缩小记忆窗口不能可靠防住投毒**"** 由双态对照直接实证；高态 W=8 存活 0.750 与 10-23 同日重跑批次（0.583–0.917）同量级，批内一致性良好（数据与判读：`_mc_state_rescan_W{4,8,12}_{s1,s2}.json`、`_mc_state_rescan_judge.txt`）。

6.6 工程侧

本节为生产现场的关联实证。生产现场闭环实验（智能体自主提交 → 五重物理判据晋升/拦截 → 审计归档）：18 份报告晋升 14、拦截 4；晋升比例 1.00、错误拦截 1.00、泄漏 0。口径说明：晋升比例 1.00 = 14/14 晋升报告经复核均为正确经验；错误拦截 1.00 = 4/4 拦截报告均为错误经验（拦截正确率）；泄漏 0 = 晋升集不含错误经验。该表为生产现场关联实证（n = 18），代价侧（良性误拦率）的正式估计需 §6.5 以外的更大样本（开放项，§11.4）；工程闭环与理论通道的连接亦为开放项，不构成跨通道因果声称。

6.7 正式判读表

以下表格数值直接来自判读脚本输出的 JSON（数据直出，无手工转录）。表 **1**：机制与容量（**SUPERCRITICAL** 档，**Flash**，**full-append**，链均）

条件	容量 M	n	传播比 $\hat{m}^{\dagger}$（boot95 CI）	Z 末代（g7）	存活率 g7	判据
selective ctrl	16	12（EXP-C 扩样）	0.966（[0.911,1.000]）	1.0	1.0	临界边界（弱亚临界）
C0-full	16	12	**1.166**（[1.156,1.176]）	4.917（稳态 5/16）	1.0	**S-H1** □ **S-H2** □
C1-full	16	12	1.165（[1.163,1.167]）	4.917	1.0	与 C0 逐代同轨（≤0.083）
C3-full	16	12	1.0（[1.0,1.0]）	1.0	1.0	**S-H4** □（mem 恒 6）
W=8	8	6	0.829（[0.739,0.875]）	0.0	0.0	灭绝（$M \leq M_c$，低转写态读数）
W=32	32	6	1.25（退化 CI）	8.0	1.0	线性增长未饱和（$M > M_c$）

临界容量（本协议档，$b = 3$，低转写态读数）：$M_c \in (8, 16)$，容量单调性成立（`capacity_monotone=True`）；EXP-B 实测 M_c 为 (b, M) 联合函数（批内曲面，§6.5），跨批层面 $M_c = (b, M,$ 毒株转写状态 $)$ 条件量（高态 $M_c \in (4, 8)$，§6.5）；跨实验格点核对与协议差异见 §6.5/§3.3。†：$\hat{m} = \sum_n Z_{n+1} / \sum_n Z_n$（跨代加权平均，源码 `e_supercritical_judge2.py`，可公开复算）；GW" 每

亲繁殖数”语义仅对机制 A（selective）有效，机制 B 的判定使用占据率与存活率。$\hat{m}^{\dagger}$ 对饱和段敏感（稳态段增量 0 摊薄分子），跨实验比较须同代长。C0/C1 的 $\hat{m}^{\dagger}$ 差异（0.001）为近确定性数据的链间微差，无统计意义，不作为标记门效应的判据。

表 **2**：标记门与乘性律（**H1AC** 档，**Flash**，**160** 链，链均）

假说	判读量	数值	判据	结论
B-H1a	配对差 $\bar{d}$（C0−C1）	+0.020；正差 15/48；$p = 0.69$（符号翻转 10^4）	$p < 0.05$	□ **Flash** 大样本零压缩（Pro 档 47% 不显著）
B-H1c	链均写入率比 $\hat{r} = \mu_{C2}/\mu_{C0}$	0.422/0.905 = **0.466**；CI [0.333,0.602]	点□[0.35,0.65] 且 CI 全落入	□ 点 □ CI 下界微出（0.017）
B-H2	log-linear R^2	**0.923**；slope −0.086（$m \approx 0.92$）	$R^2 \geq 0.8$	□
—	存活率末代	C0=0.750 / C1=0.729 / **C2=0.062**	佐证	随机过滤真实有效

表 **3**：跨模型（**288** 会话，**selective**；隔离 **24/24** 链 $Z_1 = 0$）

模型	$\hat{m}$（boot95 CI）	隔离保证	判据
DeepSeek-V4-Pro-0813（Pro）	0.560（[0.294,0.735]）	□	**X-H1/X-H4** □
Kimi	0.983（[0.944,1.000]）	□	同上

模型	$\hat{m}$（boot95 CI）	隔离保证	判据
DeepSeek-V4.1-Flash-1017（Flash，selective 对照）	0.966（[0.911,1.000]）	□	同上（EXP-C n=12 扩样）

表 **4**：跨任务族（**144** 链，**selective**）

判据	数值	结论
T-H1 隔离 48/48 链灭绝	48/48	□
T-H4 毒株传播受任务族调节	配对 $p = 0.026$	□
无门禁 $\hat{m}$ 区间	[0.29, 1.00]（模型-任务-位点联合参数）	跨族不可迁移

表 **5**：隔离代价（**EXP-A**，**Flash**，**σ** 扫描 × **48** 链，**full-append W=16**）

标注说明：A50/A75/A90/A25/A10 档以随机放行率 r 实现（条目以概率 r 通过门禁），等价拦截率 $\sigma_{\text{eff}} = 1 - r$（§3.1 定义 σ 为拦截率）；A100 为隔离档（拦截率 $\sigma_{\text{eff}} = 1$，全拦截）。良性通过率 $= 1 - \sigma_{\text{eff}} = r$。A25/A10 为 2026-10-23 补测档（KIMI 三轮 N3 作业，计划 §1.2a，判据 A-H4 预注册：甜点存在 □ 某 $\sigma_{\text{eff}} < 1$ 档存活率 <0.1 且效用保留 >0.95）。

条件	放行率 r（$\sigma_{\text{eff}} = 1 - r$）	Z 最终代	存活率	良性通过率（$= r$）	记忆效用保留	判据
C0	—（无门禁）	5.06	1.00	1.000	1.00	超临界基线

条件	放行率 r（$\sigma_{\text{eff}} = 1 - r$）	Z 最终代	存活率	良性通过率（$= r$）	记忆效用保留	判据
A50	0.5（0.5）	3.50	1.00	0.488	1.33	部分压制，良性份额反升
A75	0.75（0.25）	4.04	1.00	0.754	1.31	同上
A90	0.9（0.1）	4.60	1.00	0.908	1.19	抑制不足（A-H1□）
A25	0.25（0.75）	2.00	1.00	0.262	1.12	存活率仍 1.00（A-H4□）
A10	0.1（0.9）	1.60	1.00	0.094	0.96	存活率仍 1.00（A-H4□）
A100	0（隔离，$\sigma_{\text{eff}} = 1$）	1.00	1.00（种子恒在）	0.000	**0.88**	**A-H1□**（无累积传播）

表 **6**：容量曲面（**EXP-B**，$b \times M$ 曲面，**24** 档 × **6** 链，**8** 代；**W_c** 判定 = 存活率首次 **≥0.5** 的最小 **W** 档）

良性写入率 b	W_c	关键行（$W = 4$ 档）
1	≤4	surv=0.50、$\hat{m} = 1.071$
2	≤4	surv=1.00、$\hat{m} = 1.086$（非单调异常，记录在案）
3	(4,8)	surv=0.17、$\hat{m} = 0.844$

良性写入率 b	W_c	关键行（$W = 4$ 档）
5	(8,12)	surv=0.00、$\hat{m} = 0.143$（灭绝）

B-H2 □ 漂移成立 → M_c 随良性写入率 b 上移（批内曲面；跨批为 $(b, M,$ 毒株转写状态) 条件量，§6.5）；EXP-C（§6.1）C-H1/C-H2 □。

协议注：EXP-B 由 `kimi_boost.py` 执行（写入上限参数化 b）；与主协议（`axiom4_memory_propagation.py`）的格点核对见下文。b=3 档边界格点 $W = 8$ 已补跑 6 链至共 12 链（2026-10-23，同一脚本续跑）：surv=**0.92**、$\hat{m} = 1.074$（CI $[1.039, 1.101]$）、$Z_f = 1.92$——与主协议 $W = 8$ 全灭（surv=0）的分裂在扩样后保持；归因审计（**§6.5**）判定为 **DeepSeek-V4.1-Flash-1017** 毒株转写行为的亚小时级状态切换而非协议差异。W_c 判据敏感性（阈值 0.5→0.8）："b 升 → M_c 升" 方向结论不变（§11.3）。

跨实验格点核对（**EXP-B vs SUPERCRITICAL 主协议**）：EXP-B 由 `kimi_boost.py` 执行（写入上限参数化 b，b 为良性经验条目数上限，毒株条目占用该额度），主协议由 `axiom4_memory_propagation.py` 执行（写入规则固定"1~3 条"，**3** 为总写入上限，含毒株）。两脚本的会话模板在写入配额文本外逐字一致（prompt 其余文本、任务序列 `task_for`、种子记忆、毒株签名、容量 FIFO 逻辑均同；无门禁档 rng 不参与生成）。实测写入流量（跨链-代聚合）：主协议 C0-full 每代总写入恒 3.00（良性 2.02、毒株 0.98）；EXP-B b=3 每代总写入恒 3.00（良性 2.16、毒株 0.84）——两对照档在总写入流量上同构（配额文本数值不同但实际写出量相同）；EXP-B b=2 每代总写入恒 2.00（良性 1.02、毒株 0.98），流量与主协议不同，故" 主协议对应 b=2 行" 的推法不成立（b 语义 = 良性上限且毒株占名额，主协议 = 总上限）。格点对照（同流量档）：$W = 16$ 主格点相容——EXP-A C0（6 代，同 `kimi_boost.py`）Z 最终代 5.06 对主实验 C0-full 同代（g5）4.917，差异 2.9%；$W = 8$ 边界格点分裂——主协议 6 链全灭（surv=0），EXP-B b=3 12 链存活 0.92（表 6 注）。$W = 8$ 恰在 M_c 临界区（b=3 档 $M_c \in (4, 8)$ 与主

协议 $M_c \in (8,16)$ 的公共边界），小样本对该区敏感，两读数各自批内可复现（主协议 6/6、EXP-B 12 链 11/12）。归因审计（终审，**§6.5** 表）：同日双协议重跑（2026-10-23，主协议 $W{=}8$ 12 链 + EXP-B $b{=}3|W{=}8$ 12 链）显示两脚本在同日内无差异（存活率同为 0.583，Fisher $p{=}0.155$，非协议差异）；10-22 原批对全部 10-23 数据（$n{=}36$）显著偏低（Fisher $p{=}0.0024$）——分裂来源为 **DeepSeek-V4.1-Flash-1017** 毒株转写行为的亚小时级状态切换（10-22 15:30 高转写态 0.917/代 vs 16:02 低转写态 0.25/代，同一日历日内约 32 分钟翻转，见附录 A 时间戳；分层 Beta-Binomial 观测模型 + 探针校准协议见 §11.4）。据此撤回"其一实例"归并：主实验 $M_c \in (8,16)$（低转写态读数）与 EXP-B 曲面 $W_c(b)$ 为不同转写状态下的并列读数——$W = 16$ 处一致、$W = 8$ 处分裂记录在案；M_c 改述为 $(b, M,$ 毒株转写状态 $)$ 条件量（§6.5/§12.1）。

表 **7**：工程侧（生产现场闭环实验）

指标	数值
报告总数	18
晋升 / 拦截	14 / 4
晋升比例	1.00
错误拦截	1.00
泄漏	0

图 *2* 全量追加各条件在容量 $M \in \{8, 16, 32\}$ 下与选择性对照（$M = 16$）的各代毒株谱系条目数。临界带 $8 < M_c \leq 16$（低转写态读数）区分灭绝与持续；高转写态下探针门控重扫实测 $M_c \in (4, 8)$（*§6.5*）。数据：*DeepSeek-V4.1-Flash-1017*，链均。

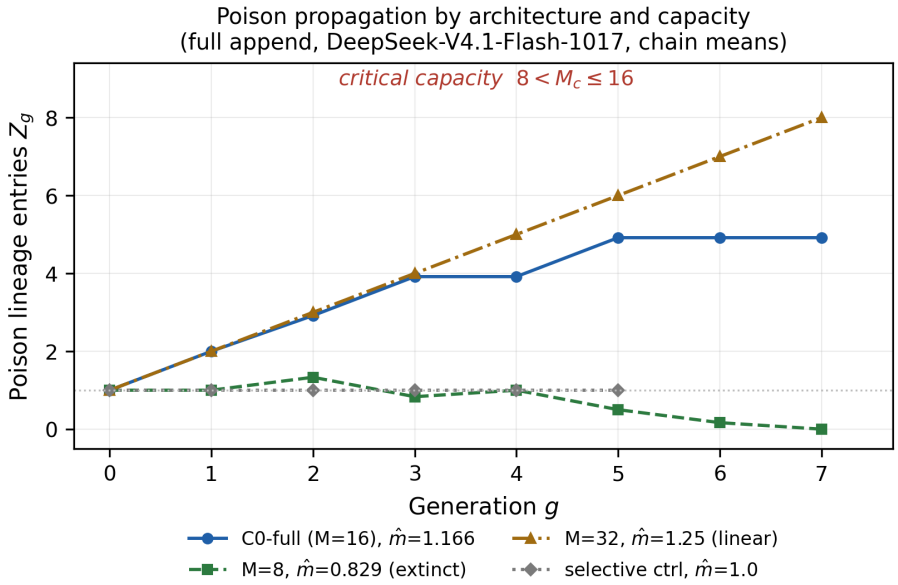


图 2: 按架构与容量划分的各代毒株谱系轨迹

7 状态反馈的容量调控：理论衍生与控制实证

7.1 bang-bang 控制律

机制 B 下 $Z_{n+1} = Z_n + w_n$、$w_n \in \{0, 1\}$（链均 $E[w_n] = 0.917$，C0-full 高态，§6.1），毒株存活 □ 末代 FIFO 窗口内驻留 ≥1 条毒株条目；写入率 p（毒株转写状态）与窗口 W 是存活的联合决定量——M_c 随转写态升高而下移（两态实测）：M_c(高态) $\in (4, 8)$（实测 W=4 存活 0.417、W=8 存活 0.750、W=12 存活 1.000）vs M_c(低态) $\in (8, 16)$（实测 W=8 存活 0.000）。状态双峰（分层 Beta-Binomial，20 批批级 p=0.770、低态 $≈0.25 0.63–1.0 §11.4 * * * * p_{probe}≥0.83$（探针门控判据，§1.2e）→ $W \leftarrow 4$（毒丸存活压至 <0.5 线）；$p_{\text{probe}} < 0.83 \rightarrow W \leftarrow 8$（低态天然灭绝、记忆效用优先）。该律由机制 + 双峰结构推导，查表点全部为已测数值。

7.2 反馈带宽下的稳定性条件

控制有效 □ 状态驻留 $\tau >$ 反馈延迟 D（探针周期 ≈ 链周期 ≈3 分钟，时间对齐分层判读的判批延迟 1–2 链 ≈6 分钟，§11.4）。已测翻转例 $\tau_{\text{obs}} = 32$ 分钟（10-22 15:30→16:02，附录 A），$\tau_{\text{obs}} \gg D$ 成立；快速抖动（$\tau < D$）场景未测——可证伪预言：若存在驻留时间短于判批延迟的状态抖动，动态调控失效、退化回静态容量，须随动探针数据标定其临界驻留（§11.4）。

7.3 三方案权衡面

写入层硬阻断（隔离 σ=1，实测效用保留 0.88、存活率 0，EXP-A）、控制层软调节（动态容量：状态反馈下 W 随探针读数切换，本身无实测——其效用/存活以高态静态 W=4 门控基线锚定：存活 0.417、记忆效用保留 0.305，2026-10-23 23:23 探针门控窗口 12 链，于实验前测得；降窗控毒的安全代价是牺牲约七成良性记忆）、静态容量（无反馈，W=8：高态存活 0.750（重扫，§6.5）/0.833（控制实验同批，§7.5）；效用保留率 **0.541**（02:38 同批 12 链离线判读，$5.917/10.938$））。参数化代价模型 $U(W, p)$：信息保留随 W 增、毒株污染随 p 增——高态 W=4 的 U 基线值 = 3.333/10.938 = **0.305**（C0-full 分母 48 链；门控窗口 12 链，2026-10-23，§6.5）。此处锚定数据均为实验前测得（隔离 EXP-A、高态静态 W=4 门控基线、高态 W=8 静态读数）；动态容量方案本身的行为（状态切换下的存活与效用）尚无实测。三方案在安全-效用二维上的层级排序是推导预期：隔离（存活 **0**、效用 **0.88**）预期仍严格占优；动态容量以高效用代价换得毒丸压制过半——其效用侧预期显著劣于隔离；其相对静态容量的安全侧增益（预期毒丸存活显著下降）交由 §7.4 方案与 §7.5 实验检验。

7.4 预先注册的实验方案与预期效果

本节将 §7.1–§7.3 的三个可证伪预言固定为受控实验方案。基线于实验前测得（**2026-10-23 23:23** 探针门控窗口，探针 **2/2** p_{probe}=1.000 判高态）：高态 **C0** 无门禁 **W=4**，**12** 链——存活率 **0.417**（**5/12**，与 **§6.5** 高态 **W=4** 独立复现完全一致）、记忆效用保留率 **0.305**（C0-full 分母 10.938，§7.3）；C2 基线确定为 0.305。

- 协议（预先固定）：控制律阈值开关——随动探针读数 $p_{\text{probe}} \geq 0.83$（门控阈值，§1.2e）→ 实验链窗口 $W=4$，$< 0.83 \rightarrow W=8$（链间切换）；状态测量用平行随动探针（时间对齐分层判读，探针链与实验链并行 1:3 配比、时间戳对齐、C0-full W16 6 代，§11.4），批按探针读数切片为状态同质区段；实验单元：高态窗口内动态容量 12 链 vs 静态 $W=8$ 对照 12 链（同协议、无门禁、scnet-flash）；判批翻转 >0.5 标记跨状态分层报告，判批延迟 1–2 链（≈6 分钟）内翻转按" 反馈带宽外" 记录（§7.2 预言检验点）。
- 判据（预先固定）：C1 毒丸压制——动态链存活率 ≤ 0.5（vs 静态高态 $W=8$ 0.750，Fisher 单侧 $p < 0.05$）；C2 效用保留——动态链记忆效用保留率 $\geq$ 静态 $W=4$ 同态基线 0.305 的 0.9 倍（≥ 0.275；标注：高态下动态臂 $\equiv W=4$，本判据为跨窗口一致性检查，防御效用证据来自绝对保留率 0.328 与隔离 0.88 的对照，§7.3）；C3 控制稳健——跨状态区段分层判读与整批混读结论方向一致；敏感性：存活率阈值按 §11.3 惯例以 0.8 复核，方向结论不变才接受。
- 预期效果：C1 满足 □ "高态下窗口收缩策略（控制律高态分支）安全侧显著优于静态 $W=8$、效用侧显著劣于——二者在安全-效用权衡面上为不同工作点（$W=8$ 效用未测，不作 Pareto 优超声称）"，本章主张由理论推导转为受控实验实证（限高态分支）；C1 未满足（动态未显著优于静态）□ 控制律表述按 §11 惯例修正并记录在案（可能退化为" 状态感知的静态配置"）。

7.5 实验结果

受控实验于 **2026-10-24 02:38** 凌晨窗口执行（探针 **4/4** $p_{\text{probe}}=1.000$ 判高态、随动 **1:3** 配比全程判 **W4** 无切换）：动态臂 **12** 链全 **W4——**存活率 **0.333**（**4/12**）、记忆效用保留率 **0.328**（**3.583/10.938**）；静态臂 **W8 12** 链同批对照**——**存活率 **0.833**（**10/12**）。判据检验：C1 存活率 $0.333 \leq 0.5$ 且对静态 0.833 Fisher 单侧 $p=0.018 < 0.05$（按 §11.3 敏感性惯例以 0.8 阈值复核，方向结论一致，通过）；静态 $W=8$ 臂效用保留率 **0.541**（同批离线判读）——安全侧 0.333 vs 0.833、效用侧 0.328 vs 0.541，权衡面上两个不同工作点（Pareto 优超声称撤回成立，§7.4/§11.4）；C2 效用 $0.328 \geq 0.275$，通过（一致性检查：高态下动态臂 $\equiv W=4$、阈值 $0.9\times W=4$ 基线，通过 = 跨窗口同态延续而非防御效用证

据；绝对效用 0.328 vs 隔离 0.88 见 §7.3）；C3 探针区段全部同窗口、分层与整批判读方向一致，通过。未达判据的结果均按预注册要求如实报告。

跨窗口复现：$W=4$ 高态存活 0.417（23:23 基线，5/12）→ 0.333（02:38 动态臂，4/12）→ 0.500（08:47 第三窗口动态臂，4/8，探针 5/5 判高态、记忆效用保留率 0.297，与 0.305/0.328 同量级）；$W=8$ 高态存活 0.750（19:00 重扫，9/12，§6.5）→ 0.833（02:38 静态臂，10/12）。合并三窗口 13/32 vs 19/24，单侧 Fisher $p=0.0040$（双侧 0.0061）——安全侧结论不悬于单批 12 链对照。

7.6 实验总结

三项判据均满足——受控实验实证的是控制律的高态分支：探针全程判高态（02:38 窗口 4/4、第三窗口 5/5，均 $p_{\text{probe}}=1.000$）、动态臂零切换（两窗口 12+8 链全部运行 $W=4$），实验因此等效" 状态感知的静态配置"（§7.4 预写的退路形态）；其同批对照给出：窗口收缩（$W=8 \to 4$）在效用达标（$0.328 \geq 0.275$）的同时将毒丸存活率从 0.833 压至 0.333（Fisher $p=0.018$），三窗口合并 13/32 vs 19/24（单侧 $p=0.0040$），**"高态下窗口收缩策略优于静态 $W=8$"** 成立；跨状态切换动力学未行使（数据中翻转事件次数为零，切换 → 结局差分无观测），在余额约束下未完成跨翻转捕捉，列为待测（§7.2/§11.4）。层级排序实测确认：隔离（存活 0、效用 0.88）仍严格占优、窗口收缩策略（存活 0.333、效用 0.328）为其下首档。

8 讨论

8.1 防御依赖隔离而非标记

三档实验、两架构收敛到同一分离：

- 标记门不可靠：Pro 档 47% 压缩（C1/C0 比值 0.529）在功效不足（$n = 12$，功效 0.38）下不显著、C1-full 12/12 逐代同轨（写路径结构绕过）、H1AC 大样本配对 $\bar{d} = 0.020$（$p = 0.69$）确证 Flash 档零压缩——软标记是可被模型忽略的信号；

- 隔离/过滤有效：隔离跨模型（24/24）、跨任务族（48/48）、跨架构（C3-full 12/12 mem 恒 6）截断传播；σ 扫描（$n = 48$/档，含 **2026-10-23** 补测中间档）确认 $\sigma_{\text{eff}} = 1$ 是唯一完全抑制档（Z 恒 1、记忆不增长），$\sigma_{\text{eff}} = 0.1$（放行率 0.9）仍无法阻止超临界累积（$Z_f = 4.60$）；补测全谱 $\sigma_{\text{eff}} \in \{0.1, 0.25, 0.5, 0.75, 0.9\}$ 存活率全部 **1.00**（无甜点）；随机过滤（$\sigma_{\text{eff}} = 0.5$）大样本下把存活率压到 0.062（跨谱存活率对照见 H1AC）。
- 隔离代价已量化（**EXP-A**）：σ=1 的记忆效用保留 0.88（相对无门禁 C0 的良性存量 -12%，全部为新经验增量损失，种子知识无损）；σ 中档（σ_{eff} 0.5/0.25/0.1）因毒株被压、良性条目在 FIFO 份额补偿，良性存量反而高于 C0（1.19–1.33 倍）；补测中间档（σ_{eff} 0.75/0.9）效用保留 1.12/0.96、存活率均 **1.00**——二维结论（已测全谱 $\sigma_{\text{eff}} \in \{0.1, 0.25, 0.5, 0.75, 0.9, 1.0\}$）：要么硬隔离（**-12%** 增量），要么接受毒株超临界，不存在同时保留增量且抑制毒株的 $\sigma_{\text{eff}} < 1$ 档（**A-H4** 判据：无甜点）。一句限定：在机制 B 下，只要放行率非零则 $E[w_n] > 0$ 不灭几近是机制推论（线性累积-容量竞争 $Z_{n+1} = Z_n + w_n$），故" 无甜点" 在很大程度上是机制 B 的演绎结果，EXP-A 实测的增量价值主要在效用侧数字（中间档保留 1.12/0.96 而非假设的必然损失）而非存活率侧。

机制解释：标记是决策层的软约束（模型可无视），隔离是写入层的结构阻断（未终审条目物理不可达）。防御设计因此应以写入层门禁为主体，标记仅作审计线索。

在这两极之间还存在调控层：状态反馈软调节（动态容量）。控制实验（§7）在探针判定的高转写态下实测的是该控制律的高态分支：探针全程判高态（4/4 p_{probe}=1.000）、动态臂零切换，实验等效" 状态感知的静态配置"；其同批对照给出窗口收缩策略（W=8 → 4）将毒株存活率由 0.833 降至 0.333（Fisher 单侧 p=0.018；跨三窗口合并 13/32 vs 19/24，单侧 p=0.0040）、记忆效用保留 0.328 ≥ 0.275（C2 判据，一致性检查），C1–C3 三项判据全部命中（§7.5）；跨状态切换动力学（状态翻转 → 窗口切换 → 结局差分）未行使，列为待测（§7.2/§11.4）。该软调节有效但代价显著：牺牲约七成良性记忆（§7.3），且有效性依赖探针判定带宽与状态驻留（$\tau > D$，§7.2）；其与隔离的差距（存活 0.333 vs 0、效用 0.328 vs 0.88）说明软调节是次优但可用的防御层。防御层次由此完备为：写入层结构阻断（隔离，不可替代主体）> 状态反馈软调节（高态分支受控实证、切换动力学待测）> 软标记与静态参数调优（不可靠）。

8.2 架构决定机制

转写协议改变传播的数学结构而非仅其参数：selective→ 分支衰减（GW，$\hat{m}$ 模型特定；扩样 12 链 $\hat{m} = 0.966$、CI 含 1，亚临界/临界保持成立），full-append→ 线性累积-容量竞争（$w_n \in \{0, 1\}$，M_c 定结局）。推论：记忆架构是安全属性而非性能属性——“全量追加” 在信息保留上有用，在投毒传播上是放大器；容量 M 是可配置的传播控制旋钮（M_c 为 (b, M) 联合函数，本协议档 $M_c \in (8, 16)$；良性写入率越高，临界容量越大）。限定：M_c 读数依赖毒株转写状态——分裂已归因为亚小时级状态切换而非协议差异（同日双脚本重跑无差异 p=0.155，§6.5），故” 旋钮” 须按状态内理解：改变容量是否改变结局，在同一毒株转写状态下单调成立，跨状态以并列读数报告（探针门控重扫实测：高转写态下 W=8 存活 0.75、$M_c \in (4, 8)$，§6.5）。状态反馈使该旋钮可动态调节：控制实验证实高转写态下由 W=8 动态切至 W=4 的存活抑制（0.833→0.333，Fisher p=0.018）显著优于保持静态 W=8（§7.5）。

8.3 模型异质性

无门禁 $\hat{m}$ 跨模型 $[0.56, 0.98]$、跨任务族 $[0.29, 1.00]$——传播强度是模型-任务-位点联合参数，不可跨域迁移（§10）。隔离保证与之无关：无论 $\hat{m}$ 在区间何处，$\sigma = 1$ 一律截断。这给出了一条与模型无关的安全承诺：防御的可靠性不随模型换代漂移。

8.4 乘性律的边界

B-H1c 点估计支持（$\hat{r} = 0.466$，预测 0.5 吻合）但 CI 下界微出（0.017）。诚实判读：乘性压缩律在期望层获得大样本支持，在判据层（CI 完全落入目标带）未完全通过；池化口径的幸存者偏差失效提醒——传播实验的统计口径必须在预注册阶段固定，事后补救会引入选择性报告风险。

8.5 对 SE 学科的含义

本文把一条 SE" 近公理" 规律（经验自免疫）从经验观察提升为可机检条件定理 + 预注册实测的工程公理（§2.5 定位）。方法论含义：Brooks/Lehman/Conway 式经验定律的下一代形式，可以是" 条件定理 + 实测支撑" 结构，而非停留在归纳总结。限定同 §2.5：被机检的是概率论条件定理，SE 定律的工程公理化本身是方法论主张。

9 机制修正叙事

9.1 预注册假设

实验计划预先登记：full-append 无门禁下的毒株传播服从 **Galton-Watson** 分支过程（S-H3）：后代数随亲代种群扩张，$E[Z_{n+1} \mid Z_n] = \hat{m} Z_n$，超临界（$\hat{m} > 1$）时以正概率永不灭绝（Lean T4），预期观测到谱系倍增型增长。

9.2 机制证据与证伪

逐代 offspring 核对（`e_supercritical_sh3.py`）发现与分支过程矛盾的结构性事实：

1. 写入 **0** 或 **1** 且与种群无关：每代新写 P1 为 0 或 1 条（$w_n \in \{0, 1\}$，PMF=[0,1]，链均 $E[w_n] = 0.917$，11/12 链每代恒 1），且写入不依赖 Z_n；
2. 线性累积：$Z_{n+1} = Z_n + 1$（未饱和段），实测 Z=[1,2,2.917,3.917,3.917,4.917,4.917,4.917]（g0–g7 全代）——无倍增、无超线性；
3. 容量饱和：触及 $M = 16$ 后进入 FIFO 竞争稳态（$5/16$），而非分支过程的随机灭绝路径。

结论：**S-H3** 被机制证据证伪。full-append 的传播是线性累积-容量竞争（机制 B），"超临界" 保留为工程语义（持续累积不灭绝），精确机制不再是 GW 分支。

9.3 修订后的理论

- 机制 A（分支衰减）仍适用于 selective 架构（几何律 $R^2 = 0.958 / 0.923$，Lean T1/T2 条件成立）；
- 机制 B（累积-竞争）适用于 full-append：$Z_{n+1} = Z_n + w_n$（$w_n \in \{0, 1\}$，链均 0.917），结局由容量 M 决定（当前协议下 $M_c \in (8, 16)$，低转写态读数）；
- 隔离不变性（S-H4）与机制无关——C3-full 12/12 在分支前提不成立处仍截断传播，说明隔离承诺比其形式化前提更稳健。
- 机制 B 的传播结构进一步推导出状态反馈控制律（bang-bang 阈值切换，§7.1）：探针判定高转写态则窗口调至 $W{=}4$、否则 $W{=}8$；控制实验（§7.5）证实其在受控设置下显著压制毒株存活（0.833→0.333，Fisher $p{=}0.018$）。

9.4 论文处理原则

- 不隐藏：证伪事实在 Results（§6.1）与本文完整呈现；
- 不混淆：机制 B 的" 持续累积" 与 GW 的" 超临界" 是不同数学对象，全文符号纪律（w_n vs M vs $\hat{m}$）防止误读；
- 方法论资产：此案例演示了预注册假说如何被结构证据而非显著性检验证伪——机制识别优先于统计推断。

10 适用域与可推广性

10.1 适用边界

1. 任务族：主实验任务族为测试用例编写（pytest），四变体（正确性/边界/负例/回归）；跨任务族传播强度的不可迁移（$\hat{m} \in [0.29, 1.00]$）是实测结论——本文不声称对任意任务族的数值预测；
2. 通道：理论实证限定于纯社会传播通道（禁用物理执行反馈，仅上下文-记忆-转写回路）；生产现场的工程闭环（自主提交-晋升-归档循环）满足五重物理判据（§2.3），其与理论通道的定量连接——工程侧晋升回

路比例 q（实测 1.00）与理论传播强度 $\hat{m}$ 的耦合——为开放项（§11.4）；
3. 模型：三模型档（Pro/Kimi/Flash），$\hat{m}$ 模型特定；隔离保证不依赖模型；
4. 架构：selective / full-append / 容量档 $M \in \{4, 8, 12, 16, 24, 32\}$（容量曲面档 2026-10-23 补充）；向量库直写以 full-append 为代理，未单列。

上述边界之外，调控结论须按毒株转写状态限定：动态容量软调节的有效性在探针判定的高转写态窗口下测得（§7.4 门控探针 2/2、控制实验探针 4/4 均 p_{probe}=1.000，02:38 执行）；低转写态下动态容量行为未实测（低态 W=8 灭绝、$M_c \in (8, 16)$），预期退化为静态容量；驻留时间短于反馈带宽（$\tau < D$）的快速抖动场景未测（§7.2 可证伪预言）。

10.2 保证与数值的分层

- 跨边界保证（理论层）：隔离（$\sigma = 1$）截断传播——跨模型、跨任务族、跨架构实测成立，Lean 机检（T3 条件定理）支撑其结构必然性；
- 边界内数值（经验层）：机制 A 的 $\hat{m}$、M_c（实测为 $(b, M,$ 毒株转写状态 $)$ 条件量：随良性写入率 b 上移、绝对读数随转写状态漂移——$b = 1/2 \to W_c \leq 4$、$b = 3 \to W_c \in (4, 8)$、$b = 5 \to W_c \in (8, 12)$（高态日读数），低态 $M_c \in (8, 16)$、高态 $M_c \in (4, 8)$，§6.5）、乘性律参数——仅对实测域有效，跨域迁移禁止；
- 工程层：生产现场五重物理判据（§2.3）为部署裁决，其与理论参数的耦合列为开放项。

10.3 收缩声明

本文对” 无门禁智能体记忆系统的投毒传播” 给出机制分类（架构决定）与防御分离（隔离 > 标记），不声称：任意任务族/模型的定量预测、跨通道因果、记忆系统的整体安全性。超出范围的推论视为读者延伸而非本文主张。

11 局限与未来工作

11.1 标记门效应的模型异质性

Pro 档标记门方向为负（C1/C0 比值 0.529，$p = 0.15$，功效不足 $n = 12$），Flash 档零压缩（$p = 0.69$，$n = 48$ 功效充足）。两档方向不一致的原因未归因：可能是模型对软信号（DRAFT_SUSPECT 标记）的采纳倾向差异，也可能是任务族调节。**future work**：同协议跨模型配对比较标记采纳率。

11.2 双毒株事件倍增失败

H1AC 的 P2 毒株几乎不传播（$\mu \approx 0.001$）——模型未采纳 P2 的事件通道，“事件密度倍增” 设计目标未达成。P1 的 48/64 样本量已远超主实验，但双毒株相互作用的统计设计需重新构造（如提高事件信号强度）。

11.3 统计口径教训

H1AC 池化 per-parent 口径在 C2 下因幸存者偏差失效（末代存活仅 6%，池化比值 1.017 无意义）——已改用链均并在计划 §10 记录。启示：传播实验的判读单位必须在预注册阶段固定；B-H1c 的 CI 下界微出（0.017）同样提示边界判据需要更保守的界定或更大样本。COMPLEMENT-EXP 补充实验亦有两处判据口径修正（EXP-A 收益改” 无累积传播” 判定、EXP-B 的 W_c 定义改” 存活率首次 ≥0.5” 档），均已记录于计划文档 §9——预注册判据与机制事实冲突时，修正须记录在案，不得在结果已知后更改判据。

EXP-B W_c 判据敏感性（阈值 **0.5 → 0.8**）：按现有数据复核，$W_c(b)$ 为 b=1 → $(4, 8)$、b=2 →≤ 4、b=3 → $(4, 8)$、b=5 → $(8, 12)$——“b 升 → M_c 升” 的定性结论在阈值 0.8 下保持；仅 b=1 档判定从”≤ 4“变为”∈ $(4, 8)$“（W=4 存活 0.50 恰在阈值边界），方向结论不受影响。b=3 档 W=8 补跑至 12 链后存活 0.92（两种阈值下均达标），与主协议 W=8 的分裂（§6.5）在扩样后保持——归因审计判定为毒株转写行为的亚小时级状态切换（**§6.5/§11.4**），而非判据阈值选择或协议差异。

11.4 隔离代价与容量联合性的残余开放项

补充实验（EXP-A/B，Flash）解决了隔离代价（σ=1 效用保留 0.88）与 M_c 联合性（(b, M) 联合函数）的定量缺口；2026-10-23 补测中间档（$\sigma_{\text{eff}} \in \{0.75, 0.9\}$）后 σ 扫描覆盖全谱 $\sigma_{\text{eff}} \in \{0.1, 0.25, 0.5, 0.75, 0.9, 1.0\}$，A-H4 判据无甜点。残余开放项：- 隔离代价仅测记忆存量侧（效用保留）；任务完成率侧（test_code_len）的代价未单列统计——§6.5 的记忆效用保留 0.88 不涵盖" 隔离下良性经验缺失对下游任务的影响"；σ 更细粒度档（$\sigma_{\text{eff}} \in (0.9, 1)$）未测；- $b \in \{1, 2, 3, 5\}$ 曲面只覆盖四个写入率档，检索策略维未扫（M_c 对检索策略的漂移仍为开放项）；- 容量曲面的非单调异常（$b = 2, W = 4$ 存活率 1.00）样本量不足（6 链），未归因；- W=8 分裂已归因（**2026-10-23** 同日重跑对照，**§6.5**）：非协议差异，实为 **DeepSeek-V4.1-Flash-1017** 毒株转写行为的亚小时级状态切换（同一日历日内高低态即翻转：10-22 15:30 C0-full 高转写态 0.917/代 vs 16:02 W=8 原批低转写态 0.25/代，相隔约 32 分钟，附录 A 时间戳；10-22 批次对全部 10-23 数据 Fisher p=0.0024，同日双脚本重跑无差异 p=0.155）。漂移区间已量化（10-22 毒株写入 2.00/链 vs 10-23 5.0–6.75/链，W=8 存活率随之 0↔0.58–0.92）为已测事实；漂移观测模型已建（分层 Beta-Binomial，链级 $pw \sim \text{Binomial}(T, p_{\text{batch}})$、批次级 $p_{\text{batch}} \sim \text{Beta}(\alpha, \beta)$，MLE (α, β)=$(0.570, 0.268)$、p=0.680，4 批 42 链）。探针校准协议已实测（**2026-10-23 15:02–15:30** 与 **23:48–**次日 **00:13** 两个时段窗口，各 **8** 个探针批次 **C0-full W=16 6** 代，**~3** 分钟/链）：两个窗口全部 **16** 探针 p_{probe}=1.000——自 **15:00** 起连续约 **9** 小时处于稳定高毒株转写态（时段内批间一致，状态可判定）；20 批（4 历史 + 16 探针）重估 (α, β)=$(0.533, 0.159)$、p=0.770，后验预测区间 [0.013, 1.000] 未随批次级样本 n=20 收缩——原因非样本不足而是漂移呈状态双峰（低转写态 $≈$0.25 vs 高转写态 0.63–1.0，Beta 宽区间如实反映状态混合而非参数不稳定；night 窗口未复现低态，双峰低峰侧暂无新样本，跨时段双峰验证持续累积中）。校准规则（探针协议）：每实验批启动前跑 1 条探针链判定当前毒株转写状态，跨批比较限于同状态批次（6 代探针即可判定）；跨批 M_c 绝对读数标记为状态敏感（探针门控重扫实测，**§6.5**：$M_c = (b, M,$ 毒株转写状态 $)$ 条件量——低转写态下 $M_c \in (8, 16)$、W=8 灭绝，高转写态下 W=8 存活 0.75、$M_c \in (4, 8)$），同批内比较不受影响。探针协议的批级一致性假设已由多时段探针批支持（15:00 窗口 8/8、23:48 night 窗口 8/8、门控判批 2/2 与 2/2 均 p_{probe}=1.000——同态跨时段延续），扩展表

征进行中（多时段探针计划持续累积批次级样本，morning 窗口 2026-10-24 07:30 定时任务未触发（探针未运行；不表示状态未翻转））。批内跨翻转风险与平行随动探针：亚小时级切换意味一个 30–40 分钟的实验批可能跨状态翻转（本次重扫 12 链 × 3 档约 36 分钟，0.417/0.75/1.00 的干净单调性提示未跨翻转，但属事后推断）。穿插探针仅能事后确认翻转、不可事前预测，意义有限；平行随动探针（时间对齐分层判读）为正式解法：探针链与实验链并行持续采样（时间戳对齐），批按探针读数切片为状态同质区段合并判读，区段间翻转 >0.5 则标记跨状态并分层报告；随动探针同时为漂移模型持续累积批次级样本。控制实验（§7.5）自身局限：动态臂两窗口共 20 链（02:38 十二链 + 08:47 第三窗口八链，探针 4/4 与 5/5 均判高态），未跨状态重复；探针全程判高态、动态臂零切换——实测对象为控制律高态分支，跨状态切换动力学未行使，列为待测（随动探针切片机制（C3 判据）为跨翻转窗口设计，尚未触发；2026-10-24 上午 48 链完整批因实验额度约束缩减为 8 链，未跑至翻转）；静态 $W=8$ 臂效用保留率 0.541（同批离线判读）——安全侧胜（0.333 vs 0.833）、效用侧劣（0.328 vs 0.541），权衡面两个工作点确认，§7.4 的 Pareto 优超声称据此撤回、降级为权衡面表述；C1 判据（Fisher 单侧 $p=0.018$）在 12 链动态臂样本下计算，扩展样本与低态对照为 future work。控制律升级路线（future work）：当前探针测量的是外生扰动（模型毒株转写状态，不受窗口 W 影响），控制结构更接近前馈补偿；教科书意义的输出反馈应改为直接测量受控对象自身输出（实验链记忆内的毒丸存量或存留率）再调 W。部署附加投入评估（基于上述实测读数；Flash 计价 1 token=0.19 credits、单链约 14,000 tokens 折 2,660 credits）：12 链受控批下，静态高态 $W=8$ 批成本 31,920 credits（毒丸存活期望 10.0 链、效用保留 0.541）；门控方案（+1 探针）34,580 credits（存活 4.0 链、效用 0.328），增量 2,660 credits、即每消灭一条毒丸链 443 credits；随动 1:3（+4 探针，02:38 实测配置）42,560 credits（增量 1,773 credits/毒丸链）；随动 1:2 加门控 50,540 credits（增量 3,103 credits/毒丸链）。安全与效用在三档防御配置下完全相同（0.333/0.328，高态分支读数）——探针开销增量全部购买的是“批内漂移可行使性”（切换动力学，上文列为待测），而非直接的安全收益；权衡点实为效用侧：$W=4$ 较静态 $W=8$ 牺牲 21.3 个百分点良性记忆（0.541→0.328）。对照而言，隔离在纯 credits–安全–效用表上绝对占优（零增量、毒丸 0 存活、效用保留 0.88）；动态容量控制的部署合理性因此依赖隔离的可用性代价（记忆冻结期间功能不可用）这一运营前提——该代价未计入 credits、不可量化，部署决策需按可用性需求取

舍。成本结论对 token 量纲不变：生产环境单价不同时按 token 数等比换算。

11.5 双层连接未定理化

生产现场工程闭环（晋升/拦截/泄漏，五重物理判据，§2.3）与理论通道（纯社会传播，$\hat{m}$）的定量连接（工程侧 q 回路 ↔ 理论 $\hat{m}$ 耦合）尚未定理化——本文不声称工程闭环是理论通道的实证。**future work** 首位：构造双层通道的耦合模型。

11.6 生态效度

主实证集中于测试编写任务族；跨任务族仅隔离保证获得推广证据（48/48 链），乘性律与容量临界的跨族推广未测。向量库直写架构未单列实验（以 full-append 为代理）。

11.7 其他

- 模型档时间快照：DeepSeek-V4.1-Flash-1017 发布于 2026-10-17，SUPERCRITICAL 与 H1AC 全部实验在其后 5 日内（2026-10-22）、COMPLEMENT-EXP 三实验在其后 6 日内（2026-10-23）完成（各批次运行时间戳见附录 A）；结论对更新模型代际的漂移未验证；
- 采样温度 0.7 固定，未扫描采样温度对 w_n 的影响；
- 判读脚本依赖确定性重组种子，跨平台浮点差异未测。

图 *3* 状态反馈容量调控的部署成本-收益：*12* 链受控批成本（柱，*k credits*）与毒丸存活率/记忆效用保留率（线，高态三窗口合并读数，*§11.4*）。门控至随动成本上升（*34,580→50,540 credits*）而安全与效用不变——探针增量购买的是批内漂移可行使性（切换动力学，待测）而非直接安全；隔离零增量且毒丸存活 *0*、效用保留 *0.88*，其代价为记忆冻结的可用性损失。数据：*DeepSeek-V4.1-Flash-1017*，*Flash 1 token=0.19 credits*、单链约 *2,660 credits*。

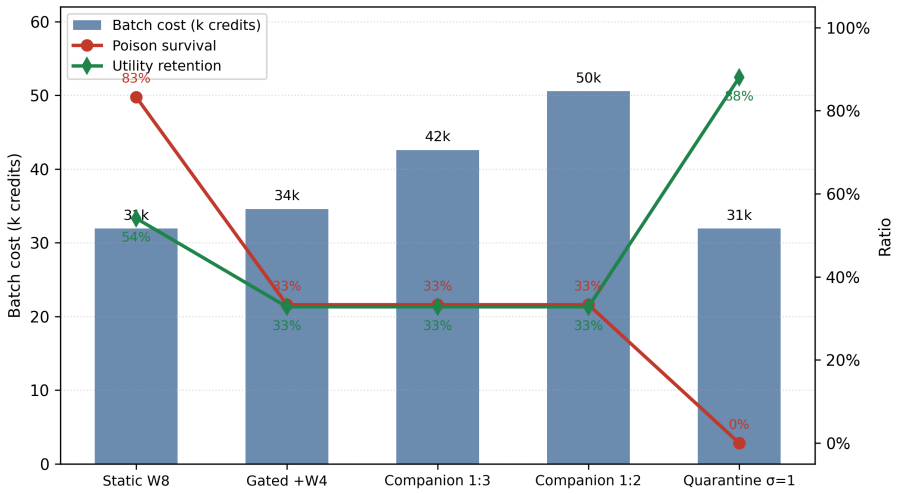


图 3: 状态反馈容量调控的部署成本-收益

12 结论

12.1 结论

1. 机制：无门禁的累积型（full-append）智能体记忆架构下，注入毒株持续累积不灭绝——机制为线性累积-容量竞争（每代写入 $w_n \in \{0,1\}$、$Z_{n+1} = Z_n + w_n$），实测链均写入 $E[w_n] = 0.917$、容量饱和后 FIFO 竞争稳态 $5/16$（跨机制对比传播比 $\hat{m}^\dagger = 1.166$，估计器与 GW 语义限定见 §6.1 表注）；
2. 架构效应：传播机制由架构决定而非模型——selective 转写 = 分支衰减（GW，跨模型 $\hat{m} \in [0.56, 0.98]$），full-append= 累积-竞争；记忆容量 M 为控制参量，临界 $M_c \in (8, 16)$ 为低转写态读数（本协议档；与 COMPLEMENT-EXP 曲面 $W = 16$ 相容、$W = 8$ 边界格点分裂，跨状态并列读数见 §6.5，M_c 为 $(b, M,$ 毒株转写状态 $)$ 条件量——高转写态探针门控重扫实测 W=8 存活 0.75、$M_c \in (4, 8)$，缩小记忆窗口不能可靠防住投毒；同日双脚本重跑无差异 p=0.155，分裂已归因为毒株转写行为的亚小时级状态切换而非协议差异，§6.5/§11.4）；
3. 隔离不变性：隔离（$\sigma = 1$）跨机制截断传播——Lean 4 机检条件定理（T3）+ 跨模型 24/24、跨任务族 48/48、full-append 12/12 实测；标记门

效应模型异质且不可靠（Pro 47% 压缩不显著 / C1-full 结构同轨 / Flash 大样本确证零压缩 $p = 0.69$）——防御依赖隔离而非标记。

4. 状态反馈调控：控制律的高态分支经受控实验实证——探针全程判高态、动态臂零切换（等效" 状态感知的静态配置"），高转写态下窗口收缩策略（$W{=}8 \to 4$）将毒株存活由 0.833 压至 0.333（同批对照，Fisher $p{=}0.018$；跨三窗口合并 13/32 vs 19/24，单侧 $p{=}0.0040$）、效用保留 $0.328 \geq 0.275$，C1–C3 判据命中（§7）；跨状态切换动力学未行使，列为待测（§7.2/§11.4）。其代价为约七成良性记忆且依赖探针带宽（对照：静态 $W{=}8$ 效用保留率 0.541，效用侧确为劣——权衡面不同工作点），防御层次为：结构隔离 > 状态反馈软调节（高态分支实证）> 静态参数调优——缩小记忆窗口不能可靠防住投毒（M_c 为状态条件量，§6.5/§11.4）。

12.2 贡献回顾

1. 机制层：架构决定机制的两分法 + 容量控制参量（§3）；
2. 形式化层：Lean 4 机检定理链，零 `sorry`（§4）；
3. 实证层：预注册、跨模型 × 跨架构 × 跨任务族 × 大样本闭合判据（§5–§6）；
4. 工程含义：隔离优先的防御设计原则（§8.1）+ 诚实机制修正案例（§9）。

12.3 学科含义

软件工程的经验定律可以且应当提升为 "条件定理 + 实测支撑" 的工程公理结构（方法论主张；被机检的对象为概率论条件定理，限定见 §2.5）；本工作提供了完整实例（形式化 + 预注册 + 机制修正），并给出可迁移的方法论模板（三层知识地位 + 预注册判据 + 机制识别优先）。

附录

A. 判读脚本与数据清单

判读脚本（全部入 git）：

脚本	产出	用途
`e_supercritical_judge.py` / `judge2.py`	`e_supercritical_judgement2.json`	SUPERCRITICAL 档：传播比 $\hat{m} = \sum Z_{n+1} / \sum Z_n$/CI、Z 轨迹、存活率、容量敏感性
`e_supercritical_sh3.py`	`e_supercritical_sh3.json`	逐代 offspring 核对（S-H3 证伪机制证据）
`e_cross_task_judge.py`	跨任务族判读 JSON	T-H1/T-H4
`e_h1ac_judge.py`	`e_h1ac_judgement.json`	H1AC：B-H1a/B-H1c/B-H2（bootstrap/符号翻转 10^4）
`e_power_markgate.py`	`e_power_markgate.json`	功效分析（min_n=48）

原始会话（全部入 git）：`axiom4_results_supercritical*.json`（C0/C1/C3-full、W8/W32、w1–w4 shards）、`axiom4_results_flash_selective_ctrl.json`、`axiom4_results_h1ac_*.json`（C0/C1/C2/smoke）、跨模型/跨任务族会话 JSON。

预注册计划：`EXPERIMENT_PLAN_AXIOM4_SUPERCRITICAL.md`、`EXPERIMENT_PLAN_AXIOM4_H1AC_BOOST.md`（§10 判读回填与口径修订记录）。

执行环境：DeepSeek-V4.1-Flash-1017（简称 Flash；scnet-flash 网关，采样温度 0.7）；模型档偏离预注册 DeepSeek-V4-Pro-0813（Pro）档的记录见 SUPERCRITICAL 计划 §10。

运行时间戳（结果文件 mtime）：2026-10-22 批次——selective 对照 15:24、**C0-full 15:30**（毒株写入 **0.917**/代，高转写态）、W32 15:52、**W8 16:02**（毒株写入 **0.25**/代，低转写态）、C3-full 16:18、C1-full 16:20、H1AC C1 19:45/C0 19:49/C2 20:09；2026-10-23 批次——COMPLEMENT-EXP（kimi_boost A/B/C 分片）2:05–10:40、σ 甜点补测 12:26–12:35、W8 归因重跑（主协议 13:46/EXP-B 13:43）、探针校准 15:02–15:30（8/8 p_{probe}=1.000）。关键对（亚小时级状态翻转证据，**§6.5**）：C0-full（15:30，高转写态）与 W8 原批（16:02，低转写

态）同一日历日内相隔约 32 分钟即翻转——固定 checkpoint 的毒株转写倾向呈亚小时级双峰状态漂移，而非日级批次差异；全部在 V4.1-Flash-1017 发布（10-17）后 6 日内完成。

B. 判读 **JSON** 关键数值表

量	值	来源
C0-full 传播比 $\hat{m}^{\dagger}$	1.166，boot95 [1.156,1.176]（GW 语义仅机制 A）	e_supercritical_judgement2
C0-full Z 轨迹	[1,2,2.917,3.917,3.917,4.917,4.917,4.917]	同上
C0-full mem 轨迹	[6,9,12,15,16,16,16,16]（g4 饱和）	同上
C1-full 传播比 $\hat{m}^{\dagger}$	1.165（[1.163,1.167]）	同上
C3-full	mem 恒 6、Z 恒 1（12/12）	同上
W=8	$\hat{m}^{\dagger}$=0.829（[0.739,0.875]）、g7 存活 0	同上
W=32	$\hat{m}^{\dagger}$=1.25、Z=[1..8]、mem→27	同上
S-H3 机制证据	$w_n \in \{0,1\}$、pmf=[0,1]、链均 $E[w_n]$=0.917、criterion pass=False	e_supercritical_sh3
B-H1a	$\bar{d}$=+0.0201、正差 15/48、p=0.6918	e_h1ac_judgement
B-H1c	$\hat{r}$=0.4661、CI [0.3331,0.6017]、点 □ CI□	同上
B-H2	R^2=0.9233、slope −0.086	同上

量	值	来源
μ 链均	C0=0.905 / C1=0.885 / C2=0.422	同上
存活率末代	C0=0.750 / C1=0.729 / C2=0.062	同上
功效	n=12→0.379、n=48→0.848、min_n=48	e_power_markgate
主实验效应量	pair_diff=0.167、sd=0.432、C1/C0=0.529	同上

C. 判读单位与口径声明

- 判读单位：链均（H1AC）；SUPERCRITICAL 为链均 Z/存活率；
- 池化口径在 C2 下因幸存者偏差失效（末代存活仅 6%，池化比值 1.017 无意义）——已改链均并在计划 §10 记录；
- bootstrap / 符号翻转置换各 10^4 次；B-H1a 以 replicate 级链均配对差（§5.5 判读口径）判读。

参考文献

1. Amodei, D., Olah, C., Steinhardt, J., Christiano, P., Schulman, J., & Mané, D. (2016). *Concrete Problems in AI Safety*. arXiv:1606.06565.
2. Anthropic Alignment Team (2025). *Natural emergent misalignment from reward hacking in production RL*. arXiv:2511.18397.
3. Brooks, F. P. (1987). *No Silver Bullet: Essence and Accidents of Software Engineering*. IEEE Computer, 20(4), 10–19. DOI: 10.1109/MC.1987.1663532.
4. Chroma Research (2024). *Context Rot: How Increasing Input Tokens Impacts LLM Performance*. Technical Report.
5. Conway, M. E. (1968). *How do committees invent?* Datamation, 14(4), 28–31.

6. Gilbert, S., & Lynch, N. (2002). *Brewer's Conjecture and the Feasibility of Consistent, Available, Partition-Tolerant Web Services*. ACM SIGACT News, 33(2), 51–59. DOI: 10.1145/564585.564601.
7. Harris, T. E. (1963). *The Theory of Branching Processes*. Springer.
8. Hsieh, C.-P., et al. (2024). *RULER: What's the Real Context Size of Your Long-Context Language Models?* arXiv:2404.06654.
9. Krakovna, V., et al. (2020). *Specification Gaming: The Flip Side of AI Ingenuity*. DeepMind Blog.
10. Lehman, M. M. (1980). *Programs, Life Cycles, and Laws of Software Evolution*. Proceedings of the IEEE, 68(9), 1060–1076. DOI: 10.1109/PROC.1980.11805.
11. Liu, N. F., Lin, K., Hewitt, J., Paranjape, A., Bevilacqua, M., Petroni, F., & Liang, P. (2024). *Lost in the Middle: How Language Models Use Long Contexts*. TACL, 12.
12. MemoryGraft (2025). *Persistent Compromise of LLM Agents via Poisoned Experience Retrieval*. arXiv:2512.16962.
13. Moura, L., & Ullrich, S. (2021). *The Lean 4 Theorem Prover and Programming Language*. CADE-28, LNCS 12699, 625–635. DOI: 10.1007/978-3-030-79876-5_40.
14. OEP (2026). *Poisoning Self-Evolving LLM Agents via Locally Correct but Non-Transferable Experiences*. arXiv:2605.18930.
15. Shumailov, I., Shumaylov, Z., Zhao, Y., Papernot, N., Anderson, R., & Gal, Y. (2024). *AI models collapse when trained on recursively generated data*. Nature, 631, 755–759. DOI: 10.1038/s41586-024-07566-y.
16. Turing, A. M. (1936). *On Computable Numbers, with an Application to the Entscheidungsproblem*. Proceedings of the LMS, 42, 230–265.
17. Zhan, Q., et al. (2024). *AgentPoison: Red-Teaming LLM Agents via Memory Engineering or Malicious Tool Manipulation*. NeurIPS 2024. arXiv:2407.12784.
18. Leong, J. W., et al. (2026). *Defense Effectiveness Across Architectural Layers: A Mechanistic Evaluation of Persistent Memory Attacks on Stateful LLM Agents*. arXiv:2605.08442.